國　立　中　央　大　學

資　訊　管　理　學　系

碩　士　論　文

非穩態類別不平衡資料之模型集成與特徵選取研究

研　究　生：　鍾柏安

指導教授：　蔡志豐

中華民國一一六年六月

國　立　中　央　大　學

資　訊　管　理　學　系

碩　士　論　文

非穩態類別不平衡資料之模型集成與特徵選取研究

研　究　生：　鍾柏安

指導教授：　蔡志豐

中華民國一一六年六月

非穩態類別不平衡資料之模型集成與特徵選取研究

摘　要

時間變化與類別不平衡常同時出現在分類問題中：歷史資料樣本較多，卻未必符合近期情況；近期資料較接近預測時點，少數類樣本卻較少。本研究以具有時間資訊的不平衡分類為對象，比較以歷史（Old）與近期（New）資料建立之模型的運用方式，並評估模型集成與特徵選取的影響。

實證使用 1999–2018 年美國企業的公開年度財務資料，以破產公司的最後觀測年度重建下一年度破產事件標籤，正類僅占全部紀錄的 0.77%。實驗一在相同年份配置下比較四種分類器的 Old、New 與合併重訓（Retrain），再以 XGBoost 建立 Old ／ New 六模型池，比較靜態集成、動態分類器選擇與動態集成選擇；實驗二在採樣前加入四種特徵選取方法與兩種保留數。所有成員選擇與分類門檻均由驗證資料決定。

結果顯示，近期資料的優勢依分類器而異。在固定模型池中，只整合近期模型的 New3 平均 AUC 最高（0.8601），依驗證資料選出兩個成員的靜態集成 F1-score 最高（0.1795）；等權整合全部六模型與動態選擇則未帶來改善。特徵選取沒有在多數方法與指標上一致改善。調參後的單一分類器與集成表現相當，因此本研究的證據支持審慎選擇集成成員，而非主張集成必然優於單一模型。改用公司最終狀態標籤時，方法的排序隨之改變，顯示標籤定義會影響結論。

關鍵字：類別不平衡、時間資料、模型集成、動態選擇、特徵選取、破產預測

Ensemble Learning and Feature Selection for Non-Stationary Class-Imbalanced Data

ABSTRACT

Temporal change and class imbalance often occur together in classification. Historical data provide more samples but may no longer reflect recent conditions, whereas recent data are closer to the prediction period but contain fewer minority-class cases. This study examines how models built from historical (Old) and recent (New) data can be used for time-stamped imbalanced classification, and evaluates the effects of ensemble learning and feature selection.

The empirical case uses public annual financial data of U.S. companies from 1999 to 2018. A next-year bankruptcy event label is reconstructed from the last observed year of each failed company, so that positive cases account for only 0.77% of all records. Experiment 1 compares Old, New, and combined retraining (Retrain) for four classifiers under the same year configuration, and then builds a six-model Old/New XGBoost pool to compare static ensembles, dynamic classifier selection, and dynamic ensemble selection. Experiment 2 adds four feature selection methods with two retention levels before sampling. Ensemble members and decision thresholds are selected on validation data only.

The advantage of recent data depends on the classifier. Within the fixed pool, the New-only ensemble (New3) achieves the highest mean AUC (0.8601), and the validation-selected static ensemble, which keeps two members, achieves the highest F1-score (0.1795). Equal weighting of all six models and dynamic selection do not improve performance. Feature selection does not yield consistent gains across methods and metrics. Tuned single classifiers perform comparably to the ensembles, so the evidence supports careful selection of ensemble members rather than a general superiority of ensembles. When the companies' final status is used as the label instead, the ranking of methods changes, indicating that the label definition affects the conclusions.

Keywords: class imbalance, temporal data, ensemble learning, dynamic selection, feature selection, bankruptcy prediction

誌謝

此頁為選填的誌謝示例。若不需要誌謝，請於 main.tex 註解相應的 \input 指令。

目錄

中文摘要 . . . . . **i**

英文摘要 . . . . . **ii**

誌謝 . . . . . **iii**

目錄 . . . . . **iv**

圖目錄 . . . . . **vii**

表目錄 . . . . . **viii**

一、 緒論 **1**

1-1 研究背景 1

1-2 研究動機 2

1-3 研究目的與研究問題 2

1-4 研究範圍與貢獻 3

1-5 論文章節安排 3

二、 文獻探討 **4**

2-1 時間資訊與分類資料的變化 4

2-1-1 歷史資料與近期資料的取捨 4

2-1-2 固定時間切分與滑動視窗 4

2-2 類別不平衡與採樣方法 5

2-2-1 不平衡問題的觀察方式 5

2-2-2 低採樣與 Tomek links 5

2-2-3 過採樣：SMOTE 與 ADASYN 5

2-2-4 混合採樣與 SMOTEENN 6

2-3 表格資料分類器 6

2-3-1 線性模型與樹模型 6

2-3-2 表格深度學習與情境學習 7

2-4 靜態集成與動態選擇 7
2-4-1 靜態成員與機率整合 7
2-4-2 動態分類器選擇 7
2-4-3 動態集成選擇 8
2-5 特徵選取與可解釋方法 8
2-5-1 Filter、Wrapper 與 Embedded 8
2-5-2 SHAP 的角色與特徵排序 9
2-5-3 特徵選取的驗證界線 9
2-6 分類評估與統計比較 10
2-6-1 排序能力與指定門檻的結果 10
2-6-2 重複紀錄、不確定性與多重比較 10
2-7 相關研究整理與本研究定位 10

三、 研究方法 12
3-1 研究架構 12
3-2 實驗資料與配置 14
3-2-1 資料來源與標籤定義 14
3-2-2 欄位與資料品質 14
3-2-3 資料用途與驗證分區 16
3-2-4 時間視窗與資料配置 17
3-3 實驗一：Baseline 與集成分類器比較 18
3-3-1 Baseline 分類器比較 18
3-3-2 Old ／ New 集成分類器比較 21
3-4 實驗二：特徵選取集成分類器比較 27
3-4-1 特徵選取方法 27
3-4-2 實驗二之特徵選取參數 29
3-4-3 特徵選取與模型訓練流程 30
3-4-4 特徵選取後的集成比較 30
3-5 實驗驗證準則 31
3-5-1 訓練、驗證與測試程序 31
3-5-2 分類效能評估指標 31
3-5-3 結果彙整與模型比較 32
3-5-4 以公司為單位的統計比較 33

四、 實驗結果與討論 **35**
4-1 結果範圍與閱讀方式 35
4-2 實驗一：Baseline 比較 35
4-3 實驗一：Old ／ New 集成比較 37
4-3-1 六個基礎模型與靜態成員數 37
4-3-2 集成方法比較 38
4-3-3 與 Baseline 的公平比較 40
4-3-4 不同測試年度的表現 41
4-4 實驗二：FS 集成比較 42
4-5 標籤定義對結果的影響 45
4-6 研究問題的綜合討論 47
4-6-1 訓練資料期間與單一分類器 47
4-6-2 集成規則與模型成員 47
4-6-3 特徵精簡與少數類辨識 47
4-7 推論範圍與限制 47

五、 結論與未來研究 **48**
5-1 研究結論 48
5-2 研究限制 48
5-3 未來研究方向 49

參考文獻 **50**

附錄一 實驗補充設定與統計檢定 **54**
一-1 兩項實驗之資料與紀錄規格 54
一-2 Baseline 超參數與訓練控制 54
一-3 軟體環境與隨機性控制 54
一-4 實驗完成範圍與比較限制 55
一-5 Baseline 各採樣設定之完整結果 57
一-6 最終狀態標籤之公司群聚配對檢定 58
一-7 年度資料分布與特徵選取明細 65

圖目錄

圖 3-1　本研究兩項實驗之整體架構 13
圖 3-2　通用滑動視窗概念與本研究固定年份配置 17
圖 3-3　實驗一之 Baseline 分類器比較架構 20
圖 3-4　實驗一之 Old ／ New 集成分類器架構 22
圖 3-5　實驗二之特徵選取集成分類器架構 27

圖 4-1　事件標籤下各分類器之訓練策略比較 36
圖 4-2　事件標籤下未進行 FS 之集成方法比較 39
圖 4-3　事件標籤下各 FS 條件相對同方法 no-FS 之 AUC 差值 44

表目錄

表 2-1　本研究採樣設定與方法作用 6
表 2-2　相關研究主題與本研究的銜接 11

表 3-1　兩項實驗之研究架構與比較目的 12
表 3-2　本研究使用之財務特徵 16
表 3-3　兩項實驗資料與驗證設定摘要 16
表 3-4　Baseline 傳統分類器之超參數候選集合 19
表 3-5　固定年份資料分區與兩種標籤之正類紀錄數 23
表 3-6　Old ／ New 六模型池組成 23
表 3-7　集成模型之主要方法與參數 24
表 3-8　不同模型數量的 Old ／ New 混合靜態組合 25
表 3-9　特徵選取方法與操作方式 28
表 3-10　實驗二特徵選取之主要參數與執行規則 29

表 4-1　事件標籤下各分類器三種訓練策略之結果 35
表 4-2　六個模型池位置之分類器驗證結果 37
表 4-3　事件標籤下六個基礎模型之測試結果 37
表 4-4　事件標籤下不同靜態成員數之候選平均結果 38
表 4-5　事件標籤下未進行 FS 之集成方法結果 39
表 4-6　集成池預設 XGBoost 與 Baseline 調參 XGBoost 之對照 40
表 4-7　事件標籤下固定年份集成之逐年測試結果 41
表 4-8　事件標籤下實驗二各特徵條件之 AUC 42
表 4-9　事件標籤下實驗二各特徵條件之 F1-score 43
表 4-10　事件標籤下實驗二各特徵條件之 Recall 44
表 4-11　兩種標籤定義下未進行 FS 之集成結果 46

表 A-1　本研究本機設備與固定年份執行設定 55
表 A-2　事件標籤 Baseline 各採樣設定之結果 57
表 A-3　實驗一完整配對檢定：各方法減 Equal6 59
表 A-4　實驗二完整 AUC 配對檢定：FS 減同方法 no-FS 60

表 A-5　實驗二完整 F1 配對檢定：FS 減同方法 no-FS 61
表 A-6　實驗二完整 Recall 配對檢定：FS 減同方法 no-FS 63
表 A-7　各年度公司財務紀錄與破產標籤分布 65
表 A-8　實驗二特徵入選種子數（X1–X9）. 66
表 A-9　實驗二特徵入選種子數（X10–X18） 66

一、 緒論

1-1 研究背景

分類模型常以過去累積的資料訓練，再用來判斷較晚時間出現的樣本。這個做法有一項前提：過去學到的關係，在後續資料中仍具有參考價值。然而，資料來源、觀測對象及外在環境都可能改變，舊模型的表現也可能隨之變動。概念漂移（concept drift）研究便關心輸入與目標之間的關係如何隨時間改變，以及模型應如何因應這些變化〔1〕。對具有時間資訊的分類問題而言，訓練資料要保留多久、近期資料要如何使用，因而成為模型建立時需要處理的問題。

另一項挑戰是類別不平衡。當研究關注的正類只占少數，多數類所提供的訊息可能主導模型的學習。即使整體正確率較高，也未必表示模型能辨認研究關心的樣本。例如，正類占比很低時，將大部分樣本判為負類便可能取得看似不錯的正確率。Saito 與 Rehmsmeier〔2〕指出，不平衡分類的評估需要留意正類預測的可靠程度，不能只從 ROC 圖的外觀判斷模型是否適合使用。

時間與不平衡問題也可能同時出現。較長的歷史期間通常提供較多訓練紀錄，卻不一定與近期資料具有相同特性；近期資料較接近測試期間，但少數類樣本可能不足。若直接合併全部資料，較多的歷史樣本可能影響模型的學習方向；若完全捨棄歷史資料，又可能失去仍有參考價值的分類資訊。本研究因此從歷史與近期資料的運用方式出發，比較分別建模、合併重訓及模型集成的表現。

本研究以公開的美國企業年度財務資料作為實證案例。企業財務資訊具有明確年度，且資料中的破產類別相對較少，適合用來觀察不同訓練期間與不平衡處理方式的差異。資料的研究背景來自 Lombardo 等人〔3〕，實際使用作者公開更新的版本〔4〕。本地資料共含 1999–2018 年的 78,682 筆公司年度紀錄、8,971 個匿名公司識別碼與 18 個財務特徵。資料版本、欄位及標籤的核對結果於第三章說明。

需要先界定的是，公開資料的公司狀態在同一公司所有年度保持一致，只記錄公司最終是否破產。若直接使用這個最終狀態，破產公司較早年度的紀錄也會被標為正類，模型可能學到「哪些公司終將破產」，而不是「下一年是否發生破產」。因此，本研究以破產公司的最後觀測年度重建事件標籤，作為主要分析目標；正類只占全部紀錄的 0.77%，類別不平衡更為明顯。原最終狀態標籤保留為對照，用來檢查結論是否受標

籤定義影響。由於事件年度是由最後觀測年度推定，並非逐筆核對的破產申請日，實證結果仍以回溯性的研究比較解讀。

1-2 研究動機

改善少數類辨識能力，可以從資料採樣、模型組成及特徵空間等方向著手。採樣改變模型接觸到的訓練資料；集成結合不同模型的判斷；特徵選取則調整模型能使用的資訊。這些方法處理的問題不同，搭配使用時的效果也需要透過對照實驗確認，不能只因某一方法在其他研究有效，就預期相同結論會出現在本資料中。

本研究首先關心資料期間的取捨。若近期模型的分數較高，可能與資料較接近測試期間有關，也可能同時受到樣本數、採樣與驗證設定的影響。因而，除了比較歷史資料模型 Old、近期資料模型 New 與合併資料重訓模型 Retrain，也有必要記錄各種分類器與採樣設定，避免將單一分數差異簡化為時間因素造成的效果。

其次，歷史與近期模型是否值得一起保留，不能只看各自的分數。若模型在不同樣本上各有所長，集成可能提供互補資訊；若模型的錯誤相近，加入更多模型也不一定有幫助。靜態集成在推論前固定成員，動態選擇則依待判斷樣本的鄰近資料估計模型能力。兩種做法都具有合理出發點，實際表現仍須在相同模型池與驗證規則下比較。本研究以固定分類器建立 Old ／ New 六模型池，使比較能集中於模型組成與選擇方式。

最後，刪減特徵可能移除重複或干擾資訊，也可能刪掉少數類辨識所需的線索。動態方法另外依賴特徵空間中的鄰近關係，因此特徵選取除了影響基礎分類器，也可能改變其局部能力估計。本研究將特徵選取安排為另一項實驗，沿用既有集成條件，分別比較不同方法及保留數，而不預設保留較少特徵必然較好。

1-3 研究目的與研究問題

本研究的目的，是建立具有時間資訊之不平衡分類比較流程，說明資料期間、集成方式及特徵選取如何影響分類結果。流程以通用的樣本、時間、正類及特徵表示；企業資料提供本次實證案例。具體研究問題如下。

1. **研究問題一：不同訓練期間與採樣方式下，單一分類器呈現哪些差異？**在與集成相同的資料列、標籤與年份下，比較四種分類器的 Old、New 與 Retrain，並以 2014 年驗證資料調參，整理 AUC、F1-score 與 Recall。

2. **研究問題二：固定 Old ／ New 模型池後，靜態與動態集成的表現是否不同？**使用

相同分類器、六個基礎模型及固定驗證資料，比較單一期間集成、六模型等權集成、驗證選出的靜態集成，以及動態分類器與動態集成選擇。

3. **研究問題三：在相同集成流程中加入特徵選取，是否改變區辨能力與少數類辨識表現？**比較四種特徵選取方法及兩種保留數，並與同方法、同種子、同測試樣本的未選取特徵結果配對，檢視效能與特徵精簡程度的關係。

上述問題安排為兩項實驗。實驗一包含 Baseline 與固定年份集成比較，實驗二則為特徵選取後的集成比較。AUC 用來觀察整體分數排序，F1-score 與 Recall 用來補充正類分類結果；靜態成員與分類門檻均由驗證資料決定，測試資料不參與選擇。第四章依此順序呈現結果，並以最終狀態標籤的結果作為對照。

1-4 研究範圍與貢獻

本研究的貢獻在於整理可追溯的比較流程與實證證據，並非提出新的分類演算法。首先，將資料期間與採樣來源納入 Old ／ New 模型池的組成，使不同集成方法可以使用相同成員進行比較。其次，在固定年份設定中分開模型擬合、動態選擇參考及候選選擇用途，並讓 Baseline 使用相同資料列與年份，以對照參數設定對集成比較的影響。再者，特徵選取在採樣前使用允許的擬合資料執行，並以完整特徵結果作為配對對照。最後，比較事件標籤與最終狀態標籤，說明標籤定義如何改變結論。

結果同時列出合併四年、各年度與十個種子的分數。事件標籤的公司群聚配對檢定尚未完成，主要結果以描述性比較呈現；最終狀態標籤已完成以公司為重抽單位的配對檢定與多重比較校正，作為對照。

本研究探討非穩態資料下，如何運用歷史與近期模型；但所有實驗都採固定年份切分，測試期間不更新模型，因此不驗證持續學習或線上適應的能力。第三章的滑動視窗圖只用來說明一般時間配置。本次實證限於一份公開資料，同一公司也可能跨訓練與測試年度出現，評估不屬於完全未見公司的驗證。

1-5 論文章節安排

本文共五章。第一章交代背景、研究問題與範圍；第二章整理相關文獻；第三章說明通用架構、資料、兩項實驗與驗證程序；第四章呈現結果與討論；第五章整理結論與後續方向。補充設定、完整結果與檢定細節置於附錄。

二、 文獻探討

本章依研究問題整理相關方法。先說明具有時間資訊的分類與類別不平衡，再介紹本研究使用的分類器、集成方式及特徵選取，最後討論評估與統計比較。文獻用來交代方法的出發點與適用條件；本研究實際採用的資料分區、參數與操作順序另於第三章列明。

2-1 時間資訊與分類資料的變化

2-1-1 歷史資料與近期資料的取捨

Gama 等人〔1〕將概念漂移的討論放在資料持續到達、輸入與目標關係可能隨時間改變的情境。這項觀點提醒研究者，增加歷史資料雖可能增加樣本量，卻不能直接保證模型更適合目前的資料。對本研究而言，Old 與 New 的區分提供一種觀察方式：分別建立模型，再比較保留歷史規則、使用近期規則或整合兩者的結果。

不過，年份不同不等於已證實概念漂移。某年度分數下降，可能與正類比例、樣本組成、門檻或可用紀錄數改變有關。若沒有額外的分布或漂移檢測，就無法由分數變化判定是哪一種原因。本研究因此使用「不同期間資料」描述實驗條件，將年度結果視為補充分析，不把所有差異歸因於景氣、制度或特定漂移機制。

2-1-2 固定時間切分與滑動視窗

具有時間資訊的實驗，至少需要說清楚訓練、驗證與測試資料各自來自何時。固定時間切分在選定期間建立模型，再評估保留的較晚資料；滑動視窗則會隨評估時間向前移動可使用的資料區間。兩者對應不同問題：前者觀察固定模型在後續期間的表現，後者還包含更新時間與視窗長度的影響。若使用同一組測試年份，兩者仍不能視為相同實驗。

本研究的 Baseline、集成與 FS 都固定一組年份配置，測試期間內沒有線上更新。第三章另以概念圖區分滑動配置與目前固定配置，目的在於讓讀者看清楚時間角色，而非將未執行的更新機制寫成成果。

在資料定義上，也要區分觀測年度與事件時間。Lombardo 等人〔3〕提供美國企業破產研究的公開資料與基準。本研究沿用其公開資料作為案例，但是否能回答提前預

測問題，仍須依實際版本的標籤與可用日期判斷。本研究的公開資料只記錄公司最終狀態，第三章因此依最後觀測年度重建事件標籤，並保留最終狀態標籤作為對照。

2-2 類別不平衡與採樣方法

2-2-1 不平衡問題的觀察方式

不平衡資料的困難不只取決於正負類數量。Batista 等人〔5〕比較多種平衡方法，指出少數類樣本不足與類別重疊等因素也會影響學習。因此，調整類別比例並不是唯一目的；採樣可能同時改變類別邊界附近的資料與模型接觸到的樣本資訊。

本研究依此將不採樣、低採樣、過採樣與混合採樣列為不同比較條件。不採樣保留原始分布，讓其他設定具有共同基準。採樣只作用於允許的訓練資料，驗證與測試仍保留原有比例，才能觀察模型在未經人為平衡的資料上有何表現。

2-2-2 低採樣與 Tomek links

低採樣藉由移除部分樣本改變訓練資料，但不同方法的移除規則並不相同。Tomek links 關注彼此接近、卻屬於不同類別的樣本配對，依設定移除其中指定類別的樣本。相較於隨機刪除大量多數類，這類方法具有清理類別邊界的用意。官方實作也明確指出，移除 Tomek links 後不保證各類樣本數相同〔6〕。

因此，本研究表中的 Under 代表具體演算法 TomekLinks，不能解讀為每次都將正負類調成一比一。此點也影響 Old ／ New 模型池的理解：三種採樣來源提供的是不同資料處理方式，不只是三種固定類別比例。

2-2-3 過採樣：SMOTE 與 ADASYN

Chawla 等人〔7〕提出 SMOTE，利用少數類樣本與其鄰近樣本之間的資訊建立合成樣本，擴充少數類的訓練表示。它與單純複製既有樣本不同，但合成資料仍由原訓練樣本推得，不能當成額外蒐集的獨立觀測。

He 等人〔8〕提出 ADASYN，依少數類樣本周邊的學習困難程度分配合成數量，使較難處理的區域獲得較多合成樣本。本研究的 Over 使用 ADASYN。這項設計使過採樣不只增加正類數量，也會依原資料的鄰近關係改變合成樣本的分布。

由於這些方法依賴距離或鄰近樣本，特徵尺度與選取結果都可能影響採樣。若先在全部資料上採樣再切分，合成程序便可能間接使用評估資料的資訊。前處理與採樣皆限制於允許的擬合分區；FS 實驗則先選定特徵，再合成樣本。

2-2-4 混合採樣與 SMOTEENN

混合採樣將增加樣本與清理樣本結合。Batista 等人〔5〕討論 SMOTE 搭配 Tomek links 或 Edited Nearest Neighbours（ENN）的做法，嘗試在擴充少數類之後整理重疊區域。本研究使用 SMOTEENN 作為 Hybrid：先由 SMOTE 合成樣本，再依 ENN 規則清理。

表 2-1 整理本研究採樣設定的作用差異。三種方法的目的不同，本文不預設某一方法普遍最佳，而是讓它們分別形成基礎模型，進一步比較模型整合後的結果。

表 2-1 本研究採樣設定與方法作用

設定	代表方法	主要作用與解讀注意事項
None	不採樣	保留訓練分布，作為採樣比較的基準。
Under	TomekLinks	清理跨類別鄰近配對；不保證類別數相等。
Over	ADASYN	依少數類周邊的困難程度分配合成樣本。
Hybrid	SMOTEENN	結合少數類合成與鄰近規則清理。

(資料來源：本研究依 SMOTE、ADASYN、混合採樣文獻與 TomekLinks 文件整理〔7, 8, 5, 6〕)

2-3 表格資料分類器

2-3-1 線性模型與樹模型

本研究的 Baseline 包含不同模型家族。Logistic Regression 以線性分數連結二元類別機率，適合提供結構較簡單的比較基準；Random Forest 及梯度提升樹則可以透過樹的分割表示較複雜的關係。比較這些模型，有助於觀察資料期間與採樣的差異是否只出現在某一種架構。

Breiman〔9〕提出的 Random Forest 結合多棵樹，並在建立樹時引入隨機性；其表現與個別樹的能力及樹之間的相關程度有關。XGBoost 則是梯度提升樹的系統實作，Chen 與 Guestrin〔10〕將正則化目標與可擴充的樹學習設計結合。Ke 等人〔11〕提出 LightGBM，著重提升梯度提升樹處理資料的效率。這些方法雖都包含多棵樹，其訓練方式與超參數作用並不相同。

本研究在用語上區分兩個層次：Random Forest、XGBoost 或 LightGBM 本身可由多棵樹構成；第三章的 Old ／ New 集成則整合多個分別訓練的分類器。後者的成員差異來自資料期間與採樣方式，不能直接與模型內部的樹數混為一談。固定年份實驗使

用 XGBoost 作為共同基底，是為了讓後續比較集中於整合規則，並非宣稱其他分類器不適用。

2-3-2 表格深度學習與情境學習

在表格深度學習方面，Gorishniy 等人〔12〕提出 TabM，藉由共享大部分參數，在單一模型內產生多個預測，結合多層感知器與有效率的集成設計。本研究將 TabM 納入調參後的 Baseline 比較；其模型內部集成與後續 Old ／ New 模型池的整合屬於不同層次。

Qu 等人〔13〕提出 TabICL，採用情境學習（in-context learning），以提供的資料作為預測情境，而非必須針對每份目標資料更新全部模型參數。該文介紹的是原方法的架構與基準結果，不能直接替本研究歷史執行紀錄背書。

本研究各分類器的調參預算並非完全相同，因此結果只作本資料下的描述性比較。TabICL 的既有探索紀錄未保存與其他分類器相同的驗證選參資訊，故不列入第四章的調參結果表；其補充設定及執行紀錄限制集中於附錄說明。

2-4 靜態集成與動態選擇

2-4-1 靜態成員與機率整合

靜態集成在推論前固定參與的分類器與整合規則。若各成員輸出正類機率，可以用等權平均形成集成分數。此作法容易說明，但並不保證加入越多模型越好：若某些成員在相同樣本上給出不合適的分數，平均也可能降低區辨能力。

本研究從相同六模型池比較數種靜態安排。Old3 與 New3 各整合同一期間的模型，Equal6 使用全部成員；V-static 則由驗證資料選擇同時含 Old 與 New 的混合子集。這些控制組對應不同問題：是否需要跨期間、是否應納入全部成員，以及驗證選擇子集是否有幫助。選模資料與測試資料必須分開，否則將測試分數最高的子集當成可使用的方法，會高估實際選擇程序的能力。

2-4-2 動態分類器選擇

動態分類器選擇（Dynamic Classifier Selection, DCS）依待預測樣本的局部區域選擇分類器。Woods 等人〔14〕以局部分類正確程度研究模型組合，使選擇與樣本周邊的表現連結。本研究比較 Overall Local Accuracy（OLA）與 Local Class Accuracy（LCA）。

OLA 使用鄰近區域的整體正確程度；LCA 則依分類器對查詢樣本所預測的類別，查看相應鄰近樣本的表現〔15, 16〕。

局部能力並不是在測試標籤上計算，而是由另行保留的 Dynamic Selection Dataset（DSEL）估計。DSEL 因而是動態選擇規則的參考資料，不是可再併回基礎模型訓練的閒置資料。若這個區域不足以代表待預測樣本，選出的模型也未必適合，因此 DCS 的效果仍須透過保留測試資料確認。

2-4-3 動態集成選擇

動態集成選擇（Dynamic Ensemble Selection, DES）將選擇對象由單一分類器擴大為一組分類器。Ko 等人〔17〕討論由動態分類器選擇延伸至動態集成選擇的方式。本研究比較 KNORA-E 與 KNORA-U：前者找出能正確處理局部鄰近樣本的成員，必要時縮小區域；後者利用能正確處理部分鄰近樣本的成員及其局部表現進行整合〔18, 19〕。

DESlib 提供靜態、DCS 與 DES 的實作與共同介面〔20〕。本研究依固定版本設定使用該套件，讓動態方法共用相同模型池、DSEL 與近鄰數，並在第三章交代機率整合方式。此處只保留理解選擇機制所需的原理；具體選擇、權重與例外處理由實際使用的演算法決定。

局部區域依特徵距離建立，因此不同尺度或特徵子集可能改變鄰居，即使分類器種類不變，動態選擇結果也可能不同。這是本研究將 FS 與集成共同評估的理由之一。若 FS 後分數改變，應考慮基礎模型與局部區域同時改變，而非只用「移除雜訊」解釋所有結果。

2-5 特徵選取與可解釋方法

2-5-1 Filter、Wrapper 與 Embedded

Guyon 與 Elisseeff〔21〕整理特徵選取的多種問題，包括預測能力、計算成本及資料理解。依特徵評估與模型訓練的關係，常區分為過濾式（Filter）、包裝式（Wrapper）及嵌入式（Embedded）方法。這項分類說明方法如何產生特徵子集，並不直接表示哪一類在所有資料上較佳。

本研究以互資訊（Mutual Information, MI）作為 Filter 代表，依個別特徵與標籤的關聯排序；以遞迴特徵刪除（Recursive Feature Elimination, RFE）作為 Wrapper 代表，反覆依估計器的特徵重要性移除特徵；另以決策樹（CART）訓練後的重要性作為

Embedded 代表。各方法在特徵間關係、模型依賴與搜尋成本上有所不同，實際操作可由所用套件的特徵選取介面確認〔22〕。

三類方法在本研究是平行條件，並未串接成先 Filter、再 Wrapper、最後 Embedded 的程序。各方法分別產生固定特徵集合，再重新建立模型池。保留 50% 與 80% 是事先設定的兩種精簡程度，用來比較刪減較多與保留較多資訊的差別，不稱為文獻認定或本資料搜尋得到的最佳比例。

2-5-2 SHAP 的角色與特徵排序

可解釋人工智慧（Explainable Artificial Intelligence, XAI）關心如何說明模型的判斷；特徵選取則決定模型之後使用哪些輸入，兩者目的不同。Lundberg 與 Lee〔23〕提出 SHAP，以特徵貢獻值說明個別預測。將多筆樣本的貢獻取絕對值後平均，可以形成整體重要性排序，再依保留數篩選特徵。

Hancock 等人〔24〕研究利用 SHAP 進行特徵選取與分析，提供將解釋資訊用於篩選的例子。本研究將 SHAP 視為另一種特徵排序方式，與 MI、CART 及 RFE 比較，並未將它稱為最新 FS，也未直接重現該文的完整選取程序。實作使用 LightGBM 的樹模型貢獻輸出，排除偏置項後計算平均絕對貢獻；模型、樣本及保留數均在第三章說明。

SHAP 值說明的是特定模型如何使用特徵，並不證明特徵對公司狀態具有因果影響。若兩個財務欄位高度相關，重要性也可能分配在不同欄位，不能只依一次排序認定其中之一沒有資訊。Goldwasser 與 Hooker〔25〕進一步研究特徵重要性排名的統計顯著性，提醒排名亦有不確定性。本研究附錄只整理十個種子中的入選次數，屬於描述性紀錄，沒有執行該文的排名檢定。

2-5-3 特徵選取的驗證界線

只要選取程序使用了標籤或資料分布，它就屬於模型建立的一部分。如果先用測試資料選出特徵，再評估模型，分數便包含了測試資訊。本研究讓各 FS 只在 Old 擬合資料上執行，將同一組欄位及順序套用至 New、DSEL、Calibration 與 Test。如此可比較固定歷史選取規則在後續資料的表現，也同時限制了模型無法使用近期資料重新挑選特徵。

另外，FS 在採樣之前執行，讓選取依據維持原擬合資料的比例。這是一項固定流程的設計選擇，而非宣稱所有資料都應依此順序處理。不同順序可能得到不同子集，本研究並未另做先採樣再選取的對照，因此結論限於目前程序。

2-6 分類評估與統計比較

2-6-1 排序能力與指定門檻的結果

AUC 衡量模型將正類分數排在負類之前的能力，不依賴單一分類門檻。F1-score 與 Recall 則需要先把分數轉成類別。兩者回答的問題不同：分數排序改善時，固定門檻下仍可能漏掉部分正類；提高 Recall 也可能伴隨更多誤報。因此，本研究以 AUC 為主要報告指標，並同時列出 F1-score 與 Recall。

Precision–Recall 關係較直接呈現正類預測的精確程度〔2〕。本研究另以 Average Precision（AP）比較驗證資料中的靜態候選。AP 依召回增量加權精確率，與以梯形積分計算的 PR 曲線面積不應直接視為相同數值〔26〕。本文選成員使用 Calibration AP，選分類門檻使用 Calibration F1-score，最終 Test 的三項指標各自保留，不用測試結果回頭調整上述規則。

2-6-2 重複紀錄、不確定性與多重比較

Efron 與 Tibshirani〔27〕說明以重抽樣估計統計量變異的基本原理；但重抽樣單位必須符合資料結構。Obuchowski〔28〕討論群聚 ROC 資料的相關性問題。對本研究而言，同一公司可能有數年紀錄，若逐列當成獨立樣本重抽，便忽略公司內部的關聯。因此，第四章補充分析以公司為單位，讓同公司年度紀錄一起被抽入，兩方法也使用相同抽樣公司，形成配對差值。

隨機種子的標準差與公司重抽樣信賴區間也有不同用途。前者表示既定資料下執行隨機程序的分數變化；後者表示已保存模型在重抽測試公司下的差值變化。兩者都不能完整代表重新取得訓練資料、變更年份或換到另一市場時的不確定性。

當同時比較多種方法與指標，單獨對每項使用 0.05 門檻會累積誤判機會。Holm〔29〕提出逐步多重檢定校正。本研究將最終狀態標籤事後補充的 165 項比較放在同一校正範圍，完整保留增加、下降及未顯著的結果；逐項信賴區間與校正後的顯著判斷分別呈現，不把未顯著解釋為兩方法已證實相同。

2-7 相關研究整理與本研究定位

表 2-2 依方法角色整理代表性研究。本表比較的是研究內容與本研究使用方式，不是把不同資料集、切分與指標下的分數放在一起排名。

表 2-2 相關研究主題與本研究的銜接

研究	討論重點	本研究的使用方式與界線
Chawla 等人（2002）〔7〕	少數類合成樣本	作為混合採樣中 SMOTE 的原理依據；合成資料不是獨立新觀測。
He 等人（2008）〔8〕	依困難程度分配合成數量	Over 採 ADASYN；實際影響依本資料比較，不沿用原文成效。
Gama 等人（2014）〔1〕	時間變化與適應問題	說明歷史／近期資料取捨；本研究未執行線上漂移偵測。
Woods 等人（1997）與 Ko 等人（2008）〔14, 17〕	局部能力與動態模型選擇	比較 DCS ／ DES，使用獨立 DSEL；不假設一定優於靜態方法。
Lombardo 等人（2022）〔3〕	企業資料與分類基準	提供資料研究背景；依實際公開版另核對標籤與識別碼數。
Hancock 等人（2025）〔24〕	SHAP 用於特徵選取與分析	將 SHAP 排序列為 FS 對照，未重現其全部程序。
Goldwasser 與 Hooker（2025）〔25〕	特徵重要性排名的不確定性	入選次數僅作描述，不冒稱已完成排名顯著性檢定。

(資料來源：本研究依表列原始文獻整理)

上述文獻分別提供採樣、時間變化、動態選擇與 FS 的依據。本研究將這些既有方法放入兩項實驗，著重回答：在本資料與固定流程下，哪些分數差異能被觀察到，又有哪些差異仍缺乏足夠證據。實驗一以相同年份的 Baseline 作為單一分類器基準，另用固定六模型池比較集成；實驗二沿用同一設定加入 FS，檢查效能與特徵數的變化。研究定位是有控制條件的實證比較，不是宣稱已提出新的採樣、集成或解釋演算法。

三、 研究方法

3-1 研究架構

本研究以具有時間資訊的不平衡分類資料為對象，比較歷史與近期資料的使用方式，並評估模型集成與特徵選取的影響。本節先說明通用架構，實際資料與年份配置列於第 3-2 節。

每筆輸入包含特徵、分類標籤與觀測時間，可表示為 $\{(x_i, y_i, t_i)\}_{i=1}^{n}$。其中，$n$ 是樣本數，x_i 是特徵向量，$y_i \in \{0, 1\}$ 是分類標籤，t_i 是觀測時間。同一個體若有多筆紀錄，另保留識別碼供配對。Old ／ New 的期間長度、驗證方式與分類器可依應用設定。

實驗安排如圖 3-1 與表 3-1。實驗一包含單一分類器 Baseline 與 Old ／ New 集成比較；實驗二沿用集成條件，加入特徵選取，並以完整特徵結果為對照。流程中的正類代表應用所關注的類別，各模型依所屬資料分區重新訓練。

表 3-1 兩項實驗之研究架構與比較目的

實驗	主要變動因素	比較目的	實驗間之銜接
實驗一：Baseline 與集成比較	分類器、訓練期間、採樣方式及模型組成	建立單模型基準，分析 Old ／ New 模型的集成方式	提供實驗二未進行 FS 的集成對照
實驗二：FS 集成比較	特徵選取方法及保留數	比較加入 FS 後的集成分類效能	沿用實驗一集成設定，進行同條件配對比較

(資料來源：本研究整理)

模型建立後，先完成驗證決策，再評估保留的測試資料。指標與比較規則統一於第 3-5 節說明。



圖 3-1 本研究兩項實驗之整體架構

(資料來源：本研究)

3-2 實驗資料與配置

本研究使用第一章介紹的美國企業年度財務資料進行實證。以下說明資料版本、分類標籤、欄位與時間切分，作為後續兩項實驗的共同依據。

3-2-1 資料來源與標籤定義

資料研究背景參照 Lombardo 等人〔3〕，實際採作者於 2024 年 4 月 10 日更新的公開版本〔4〕。資料涵蓋 1999–2018 年，共有 78,682 筆紀錄、8,971 個匿名公司識別碼及 18 個財務特徵。公開說明記載 8,262 家公司，與檔內識別碼數不同，本文依實際資料計數；版本核對詳見附錄 一-7。

原始欄位 `status_label` 記錄公司的最終狀態：609 個識別碼為 `failed`，其所有年度共 5,220 筆紀錄都標為破產，占 6.63%。這種最終狀態標籤無法看出公司在哪一年破產，較早年度的紀錄也帶有日後才知道的結果。

因此，本研究的主要標籤改為重建的事件標籤：破產公司只有最後一個觀測年度記為正類 1，表示下一年度發生破產；該公司較早年度與所有存續公司的紀錄均為 0。全資料共有 609 筆事件，占 0.77%。年度 t 的標籤要到 $t+1$ 年才能確定，因此各分區只使用在測試期間開始前即可取得的標籤。公開檔沒有可逐筆核對的破產申請日期，事件年度是由最後觀測年度推定，並非官方記錄的申請日。

最終狀態標籤保留為對照。兩種標籤使用相同資料列、分區、模型池與選擇規則，只改變目標欄位；對照結果於第 4-5 節呈現。

3-2-2 欄位與資料品質

本研究以公司年度紀錄為觀測單位。公司識別碼、年度及標籤只供分區、配對與檢核，不作預測輸入。同一公司可能跨擬合與測試年份出現，因此本研究評估較晚年度的狀態分類，不將結果解釋為對未見公司的驗證。

載入資料時檢查公司與年度組合是否重複，並確認 18 個財務欄位的有效值。目前資料未出現重複公司年度紀錄、遺失值或無限值，因此沒有因這些問題刪除紀錄。流程仍保留平均數補值器，以維持各設定相同的前處理順序。補值與標準化的參數均依各實驗允許的擬合分區估計。

模型只使用 X1–X18，欄位意義見表 3-2。2024 年公開版的欄位順序及數值與 2022 年版不同，本文依公開研究附件的欄位名稱及跨版本數值對照整理，未直接沿用 2022 年文獻表中的 X 編號〔30〕。本研究保留實際使用版本的數值及欄位順序，未另依舊版

倍率換算。公司識別碼、年度、標籤及產業分類均不作預測特徵，也未新增財務比率、股價或落後期特徵。

表 3-2 本研究使用之財務特徵

欄位	財務項目
X1	流動資產
X2	資產總額
X3	銷貨成本
X4	長期負債總額
X5	折舊與攤銷
X6	稅息前盈餘（EBIT）
X7	稅息折舊攤銷前盈餘（EBITDA）
X8	毛利
X9	存貨
X10	流動負債總額
X11	淨利
X12	保留盈餘
X13	應收款項總額
X14	營收總額
X15	市值
X16	負債總額
X17	銷貨淨額
X18	營業費用總額

(資料來源：本研究依作者公開研究附件之欄位名稱與跨版本資料對照整理〔30〕)

本表使用本研究實際版本的順序；X14 與 X17 在目前公開檔中的數值相同，名稱依發布附件保留。

3-2-3 資料用途與驗證分區

各年度的紀錄數與標籤比例列於附錄 一-7，兩項實驗的分區與驗證用途整理於表 3-3。

表 3-3 兩項實驗資料與驗證設定摘要

比較部分	**實際擬合資料**	**驗證用途**	**測試資料**
實驗一：Baseline	Old：1999–2011；New：2012–2013；Retrain：兩者合併	2014 年全部資料，供超參數與門檻決定	2015–2018 年
實驗一：集成	Old-fit：1999–2011；New-fit：2012–2013	2014 年等分為 DSEL 與 Calibration	2015–2018 年
實驗二：FS 集成	同實驗一之集成比較；前處理及特徵選取僅擬合 Old-fit	同實驗一之集成比較，固定資料列分配	2015–2018 年

(資料來源：本研究整理)

3-2-4　時間視窗與資料配置

滑動視窗可用來描述框架在時間向前推進時的資料配置：對每一個預測時點，以較早期間建立 Old ／ New 模型，以獨立的驗證資料決定模型組合與門檻，再評估更晚的 Test；時點前移後，相同規則套用於下一個視窗。各視窗均須重新遵守資料可用時間與擬合邊界，不能把未來標籤提前用於模型建立。

圖 3-2 上半部示範視窗等距前移，下半部列本研究實際採用的固定配置。這張圖用於說明時間安排，不代表兩項實驗已執行逐年更新模型的滑動視窗評估。本研究的集成與 FS 模型固定使用 Old-fit 1999–2011 年、New-fit 2012–2013 年及 2014 年驗證，測試 2015–2018 年；測試年度之間沒有重新訓練。Baseline 使用相同的年份配置，只把 2014 年整年作為驗證資料。

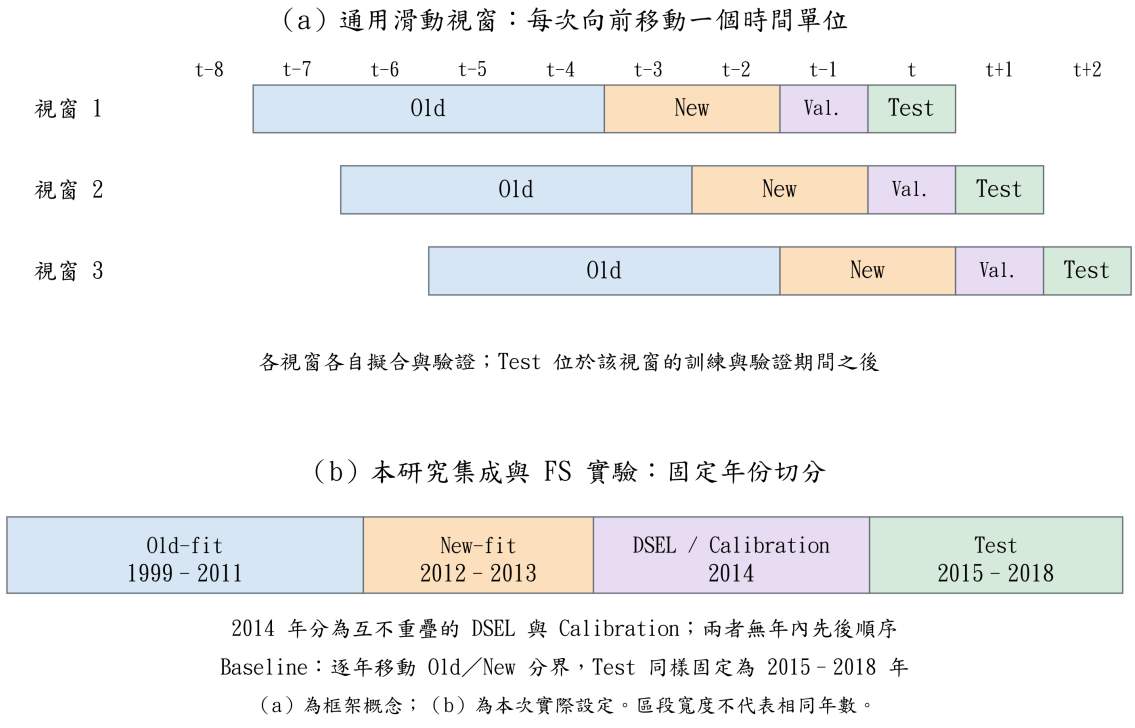


圖 3-2 通用滑動視窗概念與本研究固定年份配置

(資料來源：本研究)

上半部為時間配置示意，Val. 表示驗證資料；區段寬度不表示本研究的年份數。下半部之 DSEL 與 Calibration 均來自 2014 年，兩者沒有年內先後順序。

3-3 實驗一：Baseline 與集成分類器比較

實驗一先觀察單一分類器使用哪些年度資料、搭配何種採樣方式時有較好的表現，再比較六模型池的整合方式。兩部分使用相同的資料列、標籤、擬合年份與 Test；差別在於 Baseline 以 2014 年整年調參，集成則把 2014 年分成 DSEL 與 Calibration，且池內模型使用預設參數。

3-3-1 Baseline 分類器比較

Baseline 的流程如圖 3-3。各分類器分別使用 Old、New 或合併資料訓練，並搭配四種採樣設定，作為單一模型的比較基準。

1. 分類器與超參數設定

Baseline 比較 XGBoost、LightGBM、Random Forest 與 Logistic Regression 四種分類器。每個「分類器 × 訓練策略 × 採樣」組合各評估 24 組候選參數：候選 0 為集成池使用的預設參數，其餘 23 組依固定亂數從表 3-4 的候選集合抽出，不窮舉全部排列。各候選以種子 42 擬合，依 2014 年驗證資料的 ROC-AUC 選參；選定後以十個種子重新訓練，並以同一驗證資料的 F1-score 決定門檻。測試資料不參與上述決策。TabM 的候選集合已定義，但事件標籤版本尚未執行，因此不列入比較。

表 3-4 Baseline 傳統分類器之超參數候選集合

分類器	參數項目	超參數候選值
XGBoost	n_estimators	100、300、500、800、1000
	learning_rate	0.01、0.03、0.05、0.1、0.2
	max_depth	3、5、7、10
	min_child_weight	1、3、5、20、50
	subsample	0.7、0.85、1.0
	colsample_bytree	0.7、0.85、1.0
	gamma	0.0、0.1、0.2
	reg_alpha	0.0、0.1、1.0
	reg_lambda	0.5、1.0、3.0、10.0
LightGBM	num_leaves	31、50、100、150
	max_depth	5、7、10、15、-1
	learning_rate	0.01、0.03、0.05、0.1、0.2
	n_estimators	100、200、500、800、1000
	min_child_samples	20、50、100
	subsample	0.7、0.85、1.0
	colsample_bytree	0.7、0.85、1.0
	reg_alpha	0.0、0.1、1.0
	reg_lambda	0.0、0.1、1.0、3.0
Random Forest	n_estimators	200、400、600、800
	max_depth	None、8、12、16、20、24、32
	min_samples_leaf	1、2、4、8、16
	min_samples_split	2、4、8、16、32
	max_features	sqrt、log2、0.2、0.35、0.5、0.65
Logistic Regression	C	0.01、0.1、1.0、10.0、100.0
	solver	lbfgs、saga
	max_iter	500、1000、2000

(資料來源：本研究整理)

表中 None 表示 Random Forest 不限制樹深度，LightGBM 的深度值 -1 表示不設定深度上限；Random Forest 的小數型 `max_features` 表示每次分裂考量的特徵比例。各組合實際選中的候選編號保存於執行紀錄。

2. 訓練流程與時間切分

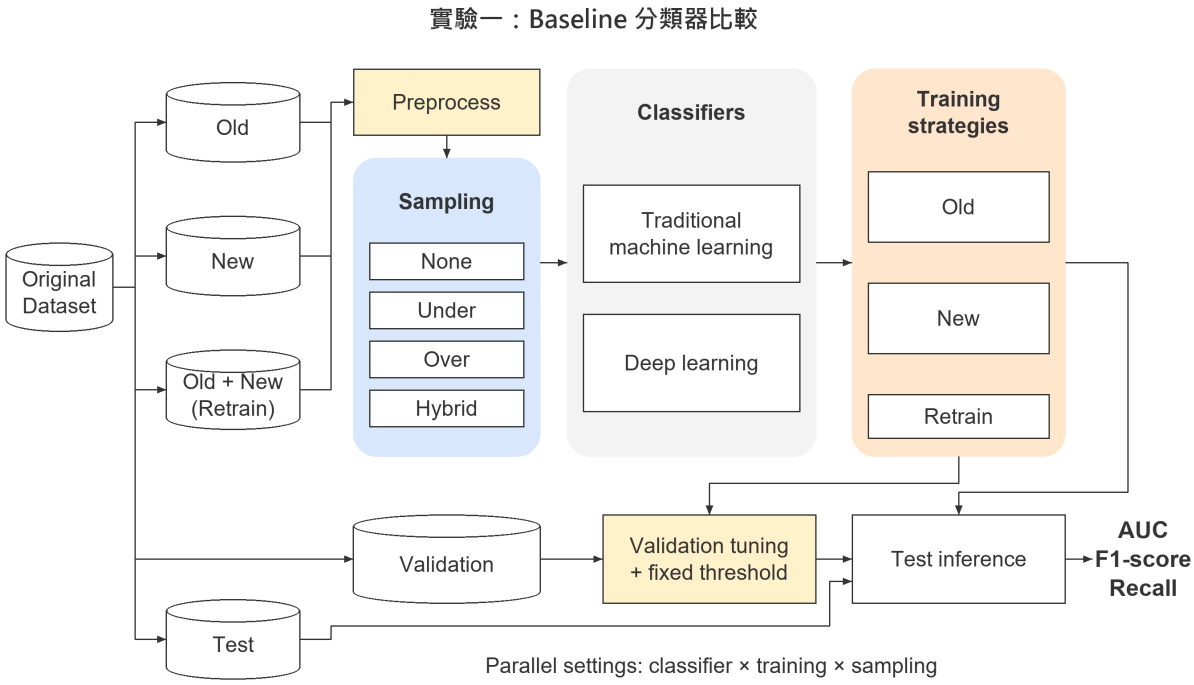


圖 3-3 實驗一之 Baseline 分類器比較架構

(資料來源：本研究)

Baseline 與集成使用相同的固定年份：Old 為 1999–2011 年的 Old-fit，New 為 2012–2013 年的 New-fit，Retrain 合併兩者重新訓練單一模型。2014 年全部 3,504 筆紀錄（33 筆事件）作為驗證資料，用於選參與決定門檻；2015–2018 年為 Test。前處理參數只由 Old-fit 估計，與集成實驗相同。

由於驗證事件只有 33 筆，候選間的驗證 AUC 差距可能受少數樣本影響。圖 3-3 中的深度學習分支對應 TabM，本次事件標籤版本尚未執行。

3. 分類器與訓練策略

本部分比較三種訓練策略。Old 僅使用歷史期間的擬合資料，評估歷史資訊對較晚年度樣本的適用程度；New 使用近期期間的擬合資料，評估近期資訊所建立的分類能力；Retrain 合併 Old 與 New 的擬合資料，從頭訓練單一模型，作為使用完整可用訓練期間的比較基準。

本章以 New 表示使用近期資料重新訓練的模型，沒有延續舊模型的權重。

4. 資料前處理與採樣策略

資料前處理包含平均數補值與標準化，參數只由 Old-fit 估計，再將相同轉換套用於其他分區。

採樣設定包含不採樣（None）、低採樣（Under-sampling）、過採樣（Over-sampling）與混合採樣（Hybrid Sampling）。不採樣保留原始類別分布；其餘設定分別透過樣本刪減、少數類別樣本生成，或兩者結合，改變模型實際使用的訓練資料。採樣僅作用於擬合資料，驗證與測試資料均保留原始類別分布。

本研究採用的代表方法為 TomekLinks、ADASYN 與 SMOTEENN。TomekLinks 依近鄰關係移除類別邊界附近的指定樣本，其作用偏向邊界清理，不能視為固定將兩類樣本調整至相同比例。各方法的參數列於實驗設定，補充版本說明見附錄。

5. 驗證結果彙整與集成基底定位

本部分的比較單位為「分類器 × 訓練策略 × 採樣方式」，共 $4 \times 3 \times 4 = 48$ 個組合，每個組合以十個種子重做。超參數與門檻固定後，再於 2015–2018 年計算 AUC、F1-score 與 Recall。為了說明集成基底的選擇，第四章另以驗證資料彙整四種分類器在集成池六個位置（Old ／ New × Under、Over、Hybrid）的表現，不使用 Test 分數。

集成與 FS 實驗以 XGBoost 為固定基底。XGBoost 為樹提升方法〔10〕，其二元機率輸出可直接供靜態平均及動態選擇使用；固定基底也使六模型池只因訓練期間、採樣方式與特徵條件而改變，較容易判讀集成規則與 FS 的影響。此基底在 Baseline 完成前即已決定，並未依 Test 表現回選；本研究也不宣稱 XGBoost 是最佳分類器。

3-3-2　Old ／ New 集成分類器比較

實驗一的集成部分固定基礎分類器種類，分析不同資料期間與採樣方式所形成模型的整合表現。本部分使用 XGBoost 建立 Old ／ New 模型池，比較靜態集成、DCS 與 DES，架構如圖 3-4 所示。

1. 實驗資料切分

本部分以 1999 年至 2011 年為 Old 訓練期間，2012 年至 2014 年為名義上的 New 營運期間，並固定 2015 年至 2018 年為測試期間。其中，2014 年完整保留供驗證使用，因此 New 模型實際以 2012 年至 2013 年資料進行擬合。

這組界線以原資料研究所使用的 1999–2011、2012–2014 與 2015–2018 年區間為參

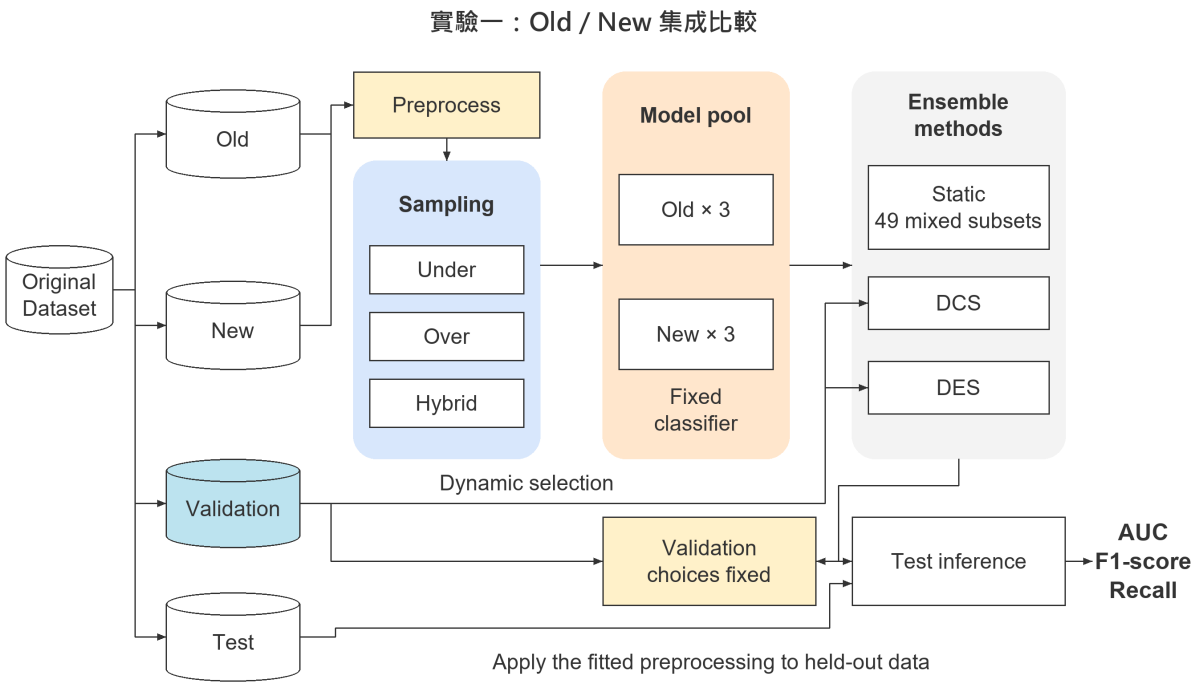


圖 3-4 實驗一之 Old ／ New 集成分類器架構

(資料來源：本研究)

圖中 Validation 為驗證用途的概括表示；實際分為互不重疊的 DSEL 與 Calibration。前者估計局部分類能力，後者選擇靜態候選及分類門檻。

考〔3〕，讓各方法都在同一個較晚期間接受測試。本研究將其中 2012–2013 年改供 New 模型學習近期資訊，再保留測試前最近的 2014 年建立 DSEL 與 Calibration。因此，本研究與原文具有相近的年份邊界，但模型可用的訓練資料不同，不直接比較兩者分數。2011 年切點是固定的歷史／近期比較條件，不是由 Test 搜尋得到的最佳年份。

2014 年資料以固定隨機種子 42，依事件標籤分層切分為等量且互不重疊的動態選擇資料集（Dynamic Selection Dataset, DSEL）與校準資料集（Calibration）。DSEL 提供動態方法估計局部分類能力；Calibration 用於靜態候選選擇與分類門檻決定，兩者均不加入基礎分類器的擬合資料。

表 3-5 固定年份資料分區與兩種標籤之正類紀錄數

分區	年份	紀錄數	事件標籤正類	最終狀態正類	主要用途
Old-fit	1999–2011	55,927	403（0.72%）	4,442	Old 模型訓練；前處理與特徵選取擬合
New-fit	2012–2013	6,969	54（0.77%）	349	New 模型訓練
DSEL	2014	1,752	17（0.97%）	71	動態選擇的局部能力估計
Calibration	2014	1,752	16（0.91%）	71	靜態候選選擇與分類門檻
Test	2015–2018	12,282	119（0.97%）	287	設定固定後的最終評估

(資料來源：本研究實驗資料分區彙整)

數值為公司年度紀錄數，不是獨立公司數。事件標籤只把破產公司最後一個觀測年度記為正類；最終狀態標籤把破產公司所有年度記為正類。兩種標籤使用相同資料列與分區。

事件標籤下，DSEL 與 Calibration 各只有 17 與 16 筆事件，靜態成員與門檻的選擇因此較易受少數樣本影響。

Calibration 在本文指用來選擇靜態成員與分類門檻的資料，沒有額外執行機率校準。DSEL 與 Calibration 均取自 2014 年；資料未提供更細的公開時間，兩者只有用途上的區分，沒有年內先後順序。

2. 基礎模型池建立

本部分先於 Old-fit 估計各輸入特徵的平均數，以進行遺失值補值，再以補值後的 Old-fit 擬合標準化參數。相同轉換一致套用於 New-fit、DSEL、Calibration 與 Test，使六個基礎模型及動態方法使用共同的特徵表示。

完成前處理後，Old-fit 與 New-fit 各自執行 TomekLinks、ADASYN 及 SMOTEENN，並分別重新訓練分類器，形成表 3-6 所示的六模型池。實驗一之集成比較使用完整 18 個輸入特徵；分類器本身不另加入類別權重，以採樣方式作為本部分的類別不平衡處理因素。

表 3-6 Old ／ New 六模型池組成

模型名稱	**擬合資料**	**採樣方法**
Old_under	Old-fit	TomekLinks
Old_over	Old-fit	ADASYN
Old_hybrid	Old-fit	SMOTEENN

續下頁

表 3-6（續）

模型名稱	擬合資料	採樣方法
New_under	New-fit	TomekLinks
New_over	New-fit	ADASYN
New_hybrid	New-fit	SMOTEENN

(資料來源：本研究整理)

六個模型都使用 XGBoost，差別在於訓練年度與採樣後的資料。集成比較據此檢查：這些模型的差異是否能補足彼此的預測錯誤。

3. 集成模型之固定設定

實驗一的集成部分與實驗二使用相同的 XGBoost 和採樣設定，見表 3-7；FS 選取器另列於表 3-10。未另指定的參數沿用固定套件版本預設值。池內 XGBoost 使用預設參數，即 Baseline 搜尋中的候選 0，沒有讀取 Baseline 選定的超參數；兩者的對照列於第 4-3 節。

表 3-7 集成模型之主要方法與參數

項目	固定設定
補值	Old-fit 平均數補值；保留全空欄位的輸入維度
縮放	StandardScaler，僅擬合 Old-fit
基礎分類器	XGBoost；objective=binary:logistic、eval_metric=auc、tree_method=hist；預設參數（Baseline 候選 0）；不另加入類別權重，未重新搜尋超參數，亦未啟用早停
低採樣	TomekLinks；sampling_strategy=auto
過採樣	ADASYN；sampling_strategy=auto、n_neighbors=5
混合採樣	SMOTEENN；SMOTE 的 k_neighbors=5；ENN 的 n_neighbors=3、kind_sel=all
靜態候選選擇	49 種混合子集，以 Calibration AP 排序；平手依固定方法名稱排序
分類門檻	Calibration F1-score；0.01–0.99、間隔 0.01；平手取最小門檻
DCS ／ DES	OLA、LCA、KNORA-E、KNORA-U；k=7、DFP=False、with_IH=False；DCS 使用 best，DES 使用 soft

(資料來源：本研究整理)

2014 年分區種子固定為 42，所有模型種子與特徵條件均使用相同分區。模型、採樣與具有隨機性的特徵選取程序，使用 42、123、456、789、2024、7、21、84、168、999 共十個種子；可接收種子的元件依各次設定傳遞。Baseline 之超參數候選見表 3-4。

軟體環境、補充訓練控制與實驗紀錄規格詳見附錄 附錄一。

4. 靜態集成方法

靜態集成於推論前固定成員組合，並以成員對正類的預測機率進行等權平均。令模型池中的三個 Old 模型集合為 $\mathcal{O}$，三個 New 模型集合為 $\mathcal{N}$，則混合候選子集須滿足：

$$S \subseteq \mathcal{O} \cup \mathcal{N}, \qquad S \cap \mathcal{O} \neq \varnothing, \qquad S \cap \mathcal{N} \neq \varnothing. \tag{1}$$

Old 與 New 各有 $2^3 - 1$ 個非空子集，因此混合組合數為：

$$(2^3 - 1)(2^3 - 1) = 49. \tag{2}$$

表 3-8 不同模型數量的 Old ／ New 混合靜態組合

集成模型數量	混合組合數
2	9
3	18
4	15
5	6
6	1
合計	49

(資料來源：本研究整理)

對任一候選子集 S，集成機率定義為：

$$\hat{p}_S(x) = \frac{1}{|S|} \sum_{i \in S} \hat{p}_i(x), \tag{3}$$

其中，$\hat{p}_i(x)$ 為第 i 個分類器對樣本 x 預測為正類的機率，$|S|$ 為該子集的模型數。

除混合候選外，另保留六個單模型，以及三個 Old 模型的等權集成 Old3、三個 New 模型的等權集成 New3，作為比較基準。完整六模型的等權集成稱為 Equal6，其成員組合已包含在 49 種混合候選之中，不額外增加混合組合數。Old3 與 New3 為單一期間控制組，均不納入 49 種跨期間混合候選的選擇範圍。

5. 動態分類器與集成選擇

動態選擇依待預測樣本的鄰近區域評估基礎模型的分類能力。本研究以完整六模型池為候選來源，使用獨立 DSEL 建立局部能力估計，並比較動態分類器選擇（Dynamic Classifier Selection, DCS）與動態集成選擇（Dynamic Ensemble Selection, DES）。

DCS 比較 Overall Local Accuracy（OLA）與 Local Class Accuracy（LCA）。OLA 以分類器在樣本鄰近區域的整體正確率估計其能力；LCA 則依各分類器對待預測樣本所判定的類別，估計相應的局部分類能力。兩者原則上選擇局部能力最高的單一分類器，平手時依固定模型順序選擇。

DES 比較 k-Nearest Oracles Eliminate（KNORA-E）與 k-Nearest Oracles Union（KNORA-U）。KNORA-E 尋找能正確分類鄰近區域所有樣本的分類器，必要時縮小鄰域；KNORA-U 則選取至少能正確分類一個鄰近樣本的分類器，並依其局部正確分類次數形成貢獻權重。兩者依所選分類器產生最終集成輸出。

本研究使用 DESlib 0.3.7 的標準實作，鄰居數固定為 $k = 7$；DES 採機率軟投票，DCS 使用 best 選擇規則，並關閉額外的動態剪枝與樣本難度分流。當所有基礎分類器對某樣本的類別判斷一致時，沿用套件直接平均機率的處理。因此，DCS 的單分類器選擇描述適用於需要進行局部選擇的情況，不能推定每個樣本的輸出皆來自單一模型。

上述方法的標準定義分別參見 DESlib 的 OLA〔15〕、LCA〔16〕、KNORA-E〔18〕與 KNORA-U〔19〕文件；本研究的實際版本與開關設定以正式執行紀錄為準。

6. 集成候選選擇與分類門檻

靜態候選與分類門檻均由 Calibration 決定。首先，對 49 種混合靜態候選計算 Calibration AP，選出 AP 最高者，記為 ValidationSelectedStatic。若 AP 相同，依固定的方法名稱字典序決定，以維持選擇結果的可重現性。保留所有候選的測試表現可供組成分析，但不再依 Test 排名回選候選。

其次，各單模型、控制組、靜態候選與動態方法，均在 Calibration 上搜尋 F1-score 最高的分類門檻。門檻候選集合為：

$$\mathcal{T} = \{0.01, 0.02, \ldots, 0.99\}, \qquad \tau_m^* = \arg\max_{\tau \in \mathcal{T}} F1_{\text{Calibration}}(m, \tau). \tag{4}$$

若多個門檻得到相同的最高 F1-score，採用其中最小者。分類時以 $\hat{p}_m(x) \geq \tau_m^*$ 判定為正類；ValidationSelectedStatic 沿用其所選候選的門檻。

候選與門檻固定後，於 Test 計算整體及各年度的 AUC、F1-score 與 Recall。各方法在四個測試年度均沿用相同的 Calibration 門檻，不利用年度測試標籤重新調整。

Retrain 為 Old-fit 與 New-fit 合併訓練的單一模型，不納入六模型池；其結果列於 Baseline，與集成使用相同的資料列與 Test。

3-4 實驗二：特徵選取集成分類器比較

實驗二檢查全部 18 個輸入特徵是否都有保留的必要。資料分區、XGBoost 設定、採樣方式與集成方法沿用實驗一，只在採樣之前加入特徵選取，再重新建立模型池。流程如圖 3-5 所示。

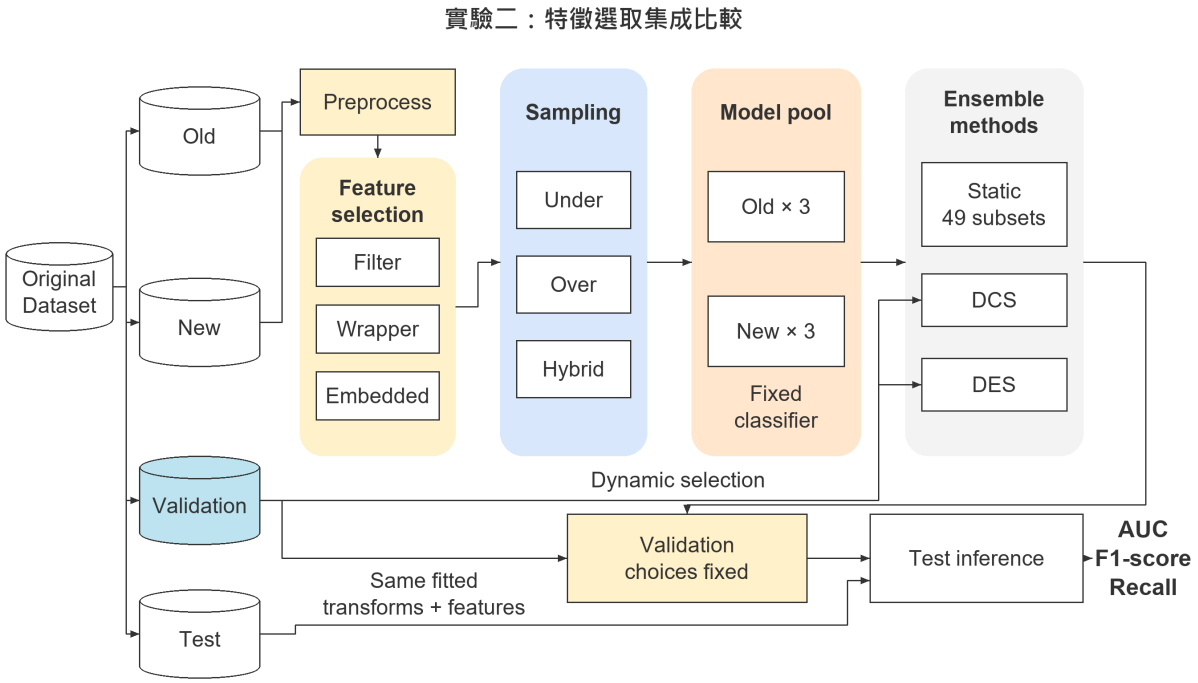


圖 3-5 實驗二之特徵選取集成分類器架構

(資料來源：本研究)

各 FS 方法平行執行；SHAP 為模型解釋後的特徵排序，其定位另於正文說明。DSEL 與 Calibration 維持實驗一集成部分的分配。

3-4-1 特徵選取方法

本研究比較 MI、CART、RFE 與 SHAP 排序，操作依據見表 3-9；各方法獨立執行，以 k_{FS} 表示保留的特徵數。相關原理與 XAI 的定位已於第二章說明，本節著重實際選取程序。

表 3-9 特徵選取方法與操作方式

方法	方法定位	特徵選取依據
MI	Filter	計算各特徵與分類標籤的互資訊，依分數選取前 k_{FS} 個特徵
CART	模型重要性篩選，對應 Embedded 類	以決策樹學得的特徵重要性排序，選取前 k_{FS} 個特徵
RFE	Wrapper	以決策樹反覆擬合並移除特徵，直至保留指定數量
SHAP 排序	模型解釋後的特徵篩選	以 LightGBM 計算訓練樣本的樹模型貢獻值，依平均絕對值排序選取特徵

(資料來源：本研究整理)

MI 與 RFE 由 scikit-learn 實作〔22〕。SHAP 排序則使用 LightGBM 的樹模型貢獻值：先排除基準值欄位，再以各特徵的平均絕對貢獻值排序〔31〕。它是模型解釋後的篩選程序，與直接依樹模型重要性選取的 CART 分開比較。

各特徵在十個種子中的入選次數列於附錄，用來描述選取結果的一致性，不另作排名顯著性檢定。

各方法分別設定保留比例 $r = 0.5$ 與 $r = 0.8$，特徵數依下式決定：

$$k_{\mathrm{FS}} = \max\{1, \lfloor d \times r \rfloor\}, \tag{5}$$

其中，$d = 18$ 為原始輸入特徵數。因此，兩種設定分別保留 9 與 14 個特徵；80% 為名義比例，實際保留數依向下取整規則計算。四種方法各有兩種保留設定，共形成八種特徵選取條件，另以完整 18 特徵作為對照。

50% 用來觀察刪去約半數特徵的結果，80% 則代表保留大部分特徵、僅作較小幅度刪減的條件。四種方法共用兩種保留數，可以在相近的特徵數量下比較不同選取規則；no-FS 則提供不刪減特徵的基準。這兩個比例是固定的實驗設計值，沒有依 Calibration 或 Test 最佳化，也不代表所有可能比例中的最適解。

3-4-2 實驗二之特徵選取參數

表 3-10 列出四種選取器的固定參數及執行規則；未另指定者沿用同版本套件預設值，不使用 Calibration 或 Test 搜尋 FS 參數。

表 3-10 實驗二特徵選取之主要參數與執行規則

方法	參數或項目	實際設定
共同設定	擬合資料	前處理後的 Old-fit；於採樣前執行
	保留數與隨機種子	9、14 個；random_state 隨十個模型種子設定
MI	函式與連續特徵	mutual_info_classif；discrete_features=auto，本研究密集數值矩陣按連續特徵處理
	鄰居數	n_neighbors=3（套件預設）
	選取規則	互資訊分數由高至低；平手保留原欄位先後順序
CART	估計器	DecisionTreeClassifier；class_weight=balanced
	分裂規則	criterion=gini、splitter=best（預設）
	樹的大小	max_depth=None、min_samples_split=2、min_samples_leaf=1（預設）
	剪枝與特徵抽樣	ccp_alpha=0、max_features=None（預設）
	選取規則	依特徵重要性排序；平手保留原欄位先後順序
RFE	估計器	與 CART 相同的平衡類別權重決策樹
	移除步長及停止條件	step=1；n_features_to_select 分別為 9、14
	輸出順序	依選取遮罩保留原欄位順序
SHAP 排序	估計器	LGBMClassifier；n_estimators=100、class_weight=balanced
	樹與學習率	boosting_type=gbdt、num_leaves=31、max_depth=-1、learning_rate=0.1（預設）
	葉節點與抽樣	min_child_samples=20、colsample_bytree=1.0、subsample=1.0（預設）
	正則化與執行緒	reg_alpha=0、reg_lambda=0（預設）；n_jobs=4
	重要性計算	在 Old-fit 使用 pred_contrib=True；排除基準值欄位，再計算平均絕對貢獻值
	選取規則	依貢獻值排序；平手保留原欄位先後順序

(資料來源：本研究特徵選取程式與固定版本套件設定整理)

scikit-learn 1.8.0；LightGBM 4.6.0。未列項目沿用相同版本預設值。

CART、RFE 與 SHAP 排序中的平衡類別權重只用於特徵選取器；後續六個 XGBoost 模型仍依集成實驗的設定訓練。同一種子與 FS 條件選出的特徵會共同套用於六模型及 DSEL。各特徵在十個種子中的入選次數列於附錄 一-7，供檢視選取結果是否一致。

3-4-3 特徵選取與模型訓練流程

本部分的處理順序固定為「資料分區 → 前處理 → 特徵選取 → 採樣 → 模型訓練」。補值與標準化參數先以 Old-fit 擬合，再於轉換後的 Old-fit 執行各特徵選取方法。所選特徵及欄位順序固定後，一致套用於 New-fit、DSEL、Calibration 與 Test。

先選特徵再採樣，使選取器看到的是 Old-fit 原始樣本。CART、RFE 的決策樹及 SHAP 排序使用的 LightGBM 仍採平衡類別權重，降低少數類別在特徵評分時被忽略的可能；MI 則直接估計特徵與標籤的互資訊。選取器與後續 XGBoost 基礎模型的參數分開設定，詳見第 3-4-2 節。

完成特徵選取後，Old-fit 與 New-fit 分別執行三種採樣，再訓練三個 Old 與三個 New 分類器。各特徵條件均重新建立六模型池，以確保模型於對應的輸入空間中學習。

同一特徵條件下，六模型、DSEL 與其他評估分區都使用相同特徵；換用另一組特徵時，重新建立動態選擇器。刪除部分特徵也可能改變哪些樣本被視為彼此接近，因此 FS 除了影響分類器本身，也可能改變動態方法參考的鄰近樣本。

3-4-4 特徵選取後的集成比較

各特徵條件均沿用實驗一之集成比較的 49 種混合靜態子集、Old3、New3、Equal6 與四種動態方法。DSEL 的資料列分配維持一致；Calibration 分別用於該條件的靜態候選選擇與門檻決定，Test 則使用相同樣本計算最終指標。

FS 與 no-FS 使用相同種子及測試樣本配對。固定方法的比較保持集成規則與模型成員一致；驗證選定靜態集成則在各 FS 條件下重新依 Calibration 選擇成員。後者的差值同時包含特徵選取與靜態成員改變的影響。

對任一固定方法 m 與指標 M，配對差值定義為：

$$\Delta M_{s,m,f} = M_{s,m,f} - M_{s,m,\text{no_fs}}, \tag{6}$$

其中，s 表示相同隨機種子，f 表示特徵選取條件。正值表示該指標高於未進行特徵選取的對照。即使模型成員固定，各條件的分類門檻仍依各自的 Calibration 決定，因此 F1-score 與 Recall 差異反映特徵選取、重新訓練及門檻選擇後的整體結果。除效能外，亦記錄所選特徵名稱、順序與數量，以保留結果追溯依據。

3-5 實驗驗證準則

3-5-1 訓練、驗證與測試程序

各部分均先固定資料用途，再執行資料前處理與模型建立。基礎模型的學習、特徵選取及採樣僅使用允許的擬合資料；DSEL 用於動態局部能力估計；Calibration 用於靜態候選及分類門檻決定。測試標籤不參與上述決策。

Calibration 用來比較候選與決定門檻，模型設定已參考過這些資料，因此不能用它的最高分代表最終預測表現。本研究以設定固定後的 Test 結果作正式評估，並保留所有方法與特徵條件，讓讀者可以比較完整結果。

3-5-2 分類效能評估指標

令關注類別為正類。TP 與 TN 分別為正確分類的正類與負類紀錄數；FN 為正類被判為負類的紀錄數；FP 為負類被判為正類的紀錄數。實證案例的正類對應第 3-2 節定義的標籤。

一、AUC

ROC 曲線以真陽性率（True Positive Rate, TPR）為縱軸，假陽性率（False Positive Rate, FPR）為橫軸，定義為：

$$\text{TPR} = \frac{TP}{TP + FN}, \qquad \text{FPR} = \frac{FP}{FP + TN}. \tag{7}$$

AUC 為 ROC 曲線下的面積，用於衡量正負類樣本的排序區辨能力，數值越高表示整體區辨表現越佳。AUC 由預測機率計算，不依賴本研究所選的單一分類門檻；惟其無法單獨反映實際門檻下的正類樣本辨識情形，故另以 F1-score 與 Recall 補充。

二、F1-score

Precision 表示預測為正類的紀錄中，實際正類者所占比例；Recall 表示實際正類紀錄中被正確辨識的比例。兩者與 F1-score 定義如下：

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}, \tag{8}$$

$$F1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}. \tag{9}$$

F1-score 同時反映正類預測的精確程度與涵蓋程度。本研究以各方法在 Calibration

決定的門檻計算測試 F1-score；計算遇到未定義的零分母情形時，依統一的評估規則記為零。

三、Recall

Recall 與 TPR 相同，表示實際正類紀錄中被正確辨識的比例。較低的 Recall 代表較多正類紀錄被漏判；惟較高 Recall 亦可能伴隨較多誤報，因此須與 F1-score 及 AUC 共同解讀，不僅依 Recall 判定方法優劣。

四、Average Precision

AP 用於實驗一之集成比較與實驗二的靜態候選選擇，依不同門檻的 Precision 與 Recall 計算：

$$\mathrm{AP} = \sum_{n} (R_n - R_{n-1}) P_n, \tag{10}$$

其中，P_n 與 R_n 分別為第 n 個操作點的 Precision 與 Recall。本研究以 Recall 增量加權 Precision；此計算不同於對 PR 曲線直接進行梯形積分，定義見 scikit-learn AP 文件〔26〕。AP 用於驗證選模，最終主文仍以 AUC、F1-score 與 Recall 為主要報告指標。

五、特徵精簡率

除預測指標外，實驗二也記錄刪除了多少特徵。令原始特徵數為 d、保留數為 k_{FS}，特徵精簡率定義為：

$$R_{\mathrm{FS}} = \left(1 - \frac{k_{\mathrm{FS}}}{d}\right) \times 100\%. \tag{11}$$

原始特徵數為 18，保留 9 個時精簡率為 50.00%，保留 14 個時為 22.22%；no-FS 的精簡率為 0%。名義保留比例為 80% 的設定，實際保留 14 個，即 77.78%，因此本文分別報告名義設定與實際數量。本研究未進行獨立的樣本選取實驗，不另套用樣本精簡率解釋過採樣或混合採樣的結果。

3-5-3 結果彙整與模型比較

實驗一的集成比較與實驗二同時呈現整體及逐年結果。整體結果將 2015–2018 年的測試標籤與預測合併，再計算一次指標，以下稱為「合併四年結果（pooled）」。這與先算各年度分數再取平均不同。逐年結果則分開計算每一年的表現，所有年度均沿用驗證時固定的模型與門檻。

相同設定使用十個隨機種子重做，結果以平均值及標準差呈現。標準差越小，表示這十次執行的分數越接近。不過，十次使用的是同一份測試資料，不能當作十份獨立資料來做推論。方法間的統計比較另依第 3-5-4 節處理。

實驗一分別比較 Baseline 與固定年份集成；實驗二則在相同種子、方法及測試樣本下，比較有無 FS 的結果。對 V-static 而言，FS 後還會重新選擇模型成員，須與保持成員不變的方法分開解讀。資料切分或訓練規則不同時，分數差可能有多個來源，因此不全部歸因於集成或 FS。本文結論也限於實際使用的資料與年份。

3-5-4 以公司為單位的統計比較

兩個方法的分數不同，可能來自方法本身，也可能與剛好測到哪些公司有關。為了解差異是否穩定，本研究反覆重新抽取測試公司，再比較同一批公司上兩個方法的分數。抽到一家公司時，會一起保留它的各年度紀錄，避免把同一公司的多筆資料當成彼此無關的樣本。

為評估方法間差異的不確定性，本研究針對最終狀態標籤的固定年份集成結果，補作以公司為重抽單位的配對群聚 bootstrap；事件標籤結果的相同分析尚未完成，第四章僅作描述性比較。此分析在既有實驗完成後制定，屬事後探索性分析；所有分類器、特徵設定、靜態選模規則與分類門檻均使用已保存的驗證決策，不因檢定結果調整模型。Bootstrap 的一般原理見 Efron 與 Tibshirani〔27〕；群聚 ROC 資料須考量同一群聚內相關性的原因，見 Obuchowski〔28〕。本研究依公司年度資料結構設計下列配對重抽程序。

1. 比較對象與估計量

實驗一以完整六模型等權集成 Equal6 為共同基準，分別比較 Old3、New3、驗證選定靜態集成（以下簡稱 V-static）、DCS-OLA、DCS-LCA、KNORA-E 及 KNORA-U，共七組比較。V-static 在各種子內依 Calibration AP 選擇混合成員，不使用 Test 排序結果選擇靜態方案。Baseline 與集成的參數及驗證資料不同，不納入此檢定範圍。

實驗二將 MI、CART、SHAP 與 RFE 的兩種保留比例，各自與相同方法的 no-FS 結果配對。比較方法為 Equal6、V-static、DCS-OLA、DCS-LCA、KNORA-E 與 KNORA-U，因此共有 $8 \times 6 = 48$ 組比較。V-static 允許 FS 後依原有 Calibration 規則重新選擇成員，故該比較評估完整選模程序的變化；其他方法保持方法名稱與規則一致，但仍重新訓練模型並以 Calibration 固定各自門檻。

每組比較均計算 AUC、F1-score 及 Recall，合計 $(7 + 48) \times 3 = 165$ 項檢定。若 M 為任一指標，$S = 10$ 為種子數，方法 A 相對方法 B 的差值定義為：

$$\widehat{\Delta}_M = \frac{1}{S} \sum_{s=1}^{S} \left[M(y, p_{A,s}; \tau_{A,s}) - M(y, p_{B,s}; \tau_{B,s}) \right]. \tag{12}$$

其中，p 為模型預測機率，τ 為驗證程序固定的門檻；AUC 不使用門檻。此估計量先計算各種子的 pooled 指標，再平均其差值，不將十個種子的機率平均後另建一個預測模型。

2. 重抽、信賴區間與多重比較

每次 bootstrap 從 Test 所含的 C 家公司中等機率、有放回抽取 C 次。公司被抽中後，保留該公司在 2015–2018 年的全部測試紀錄，並將同一組公司抽取次數同時套用於所有種子、方法及 FS 設定。如此可保留同公司跨年的相依性及方法間的配對關係；各次重抽均重新計算指標，但不重新訓練或調整門檻。

本研究使用 49,999 次重抽。為使統計分析可重現，bootstrap 重抽樣的隨機種子設為 20261027。由差值重抽分布的第 2.5 與第 97.5 百分位數建立逐項 95% 信賴區間。以 $\Delta_M^{*(b)}$ 表示第 b 次重抽差值，針對虛無假設 $H_0 : \Delta_M = 0$，以置中重抽誤差分布計算雙尾近似 p 值：

$$p_M = \frac{1 + \sum_{b=1}^{B} \mathbf{1}\left\{\left|\Delta_M^{*(b)} - \widehat{\Delta}_M\right| \geq \left|\widehat{\Delta}_M\right|\right\}}{B+1}, \qquad B = 49{,}999. \tag{13}$$

式中以有限次隨機重抽估計 p 值，因此結果仍可能有少量抽樣波動；這種計算也稱為 Monte Carlo 估計。分子與分母各加一，可避免報告零機率，最小可報值為 0.00002。

同時比較很多方法時，較容易把偶然出現的分數差誤認為有效差異。因此，兩項實驗共 165 個 p 值一併使用 Holm 法〔29〕校正，以降低這類誤判。校正後數值記為 p_H，小於 0.05 時判為達到統計顯著。表中的 95% 信賴區間各自計算，沒有作同樣的多重比較校正，所以顯著性仍以 p_H 為準。未達顯著只表示本次證據不足，不能據此認定兩方法相同。

上述分析固定原有模型、資料切分與驗證決策，只改變抽到的測試公司。因此，它回答的是「換一批測試公司時，兩方法的分數差是否仍相近」，沒有評估換一批訓練資料後的變化。此外，不同公司也可能受到相同產業或景氣影響，這些關聯未另行估計。結果應限於本次資料與設定解讀，檢定結果於第 efsec:results-label 節摘要，完整比較列於附錄。

四、 實驗結果與討論

4-1 結果範圍與閱讀方式

本章主要結果使用第 3-2-1 節定義的事件標籤。Baseline、集成與 FS 三部分共用相同資料列、擬合年份與 Test：2015–2018 年共 12,282 筆紀錄、3,700 家公司，其中 119 筆為事件，各屬一家破產公司。表中分數為合併四年結果（pooled）的十種子平均，並附種子標準差；粗體只標示表定範圍內較高的數值。

事件標籤下的公司群聚配對檢定尚未完成，因此第 4-2 至第 4-4 節僅呈現描述性結果，不作顯著性判斷。第 4-5 節再以最終狀態標籤對照，說明主要結論是否受標籤定義影響；該標籤已完成的 165 項檢定列於附錄 一-6。

4-2 實驗一：Baseline 比較

表 4-1 列出四種分類器在三種訓練策略下的結果。每一列平均四種採樣與十個種子；超參數與門檻都由 2014 年驗證資料決定，各採樣的完整結果見附錄 一-5。

表 4-1 事件標籤下各分類器三種訓練策略之結果

分類器	策略	驗證 AUC	AUC	F1-score	Recall
XGBoost	Old	0.8407	0.8125	0.1159	0.2313
	New	0.8427	**0.8272**	**0.1580**	**0.3393**
	Retrain	**0.8485**	0.8245	0.1326	0.2284
LightGBM	Old	0.8318	0.8123	0.1068	**0.3143**
	New	0.8446	**0.8646**	**0.1393**	0.2324
	Retrain	**0.8531**	0.8299	0.1128	0.3046
Random Forest	Old	0.8703	0.8437	0.1482	0.4506
	New	0.8462	0.8389	**0.1893**	0.3685
	Retrain	**0.8709**	**0.8543**	0.1478	**0.4782**
Logistic Regression	Old	0.8512	**0.7694**	**0.1304**	0.1746
	New	0.8062	0.7684	0.1161	**0.2433**
	Retrain	**0.8522**	0.7685	0.1257	0.1540

(資料來源：本研究事件標籤 Baseline 實驗結果)

驗證 AUC 為 2014 年驗證資料，其餘為 2015–2018 年 Test 之合併四年結果；各值為四種採樣與十個種子的平均。粗體表示同一分類器三種策略中該欄最高值，不代表統計顯著。

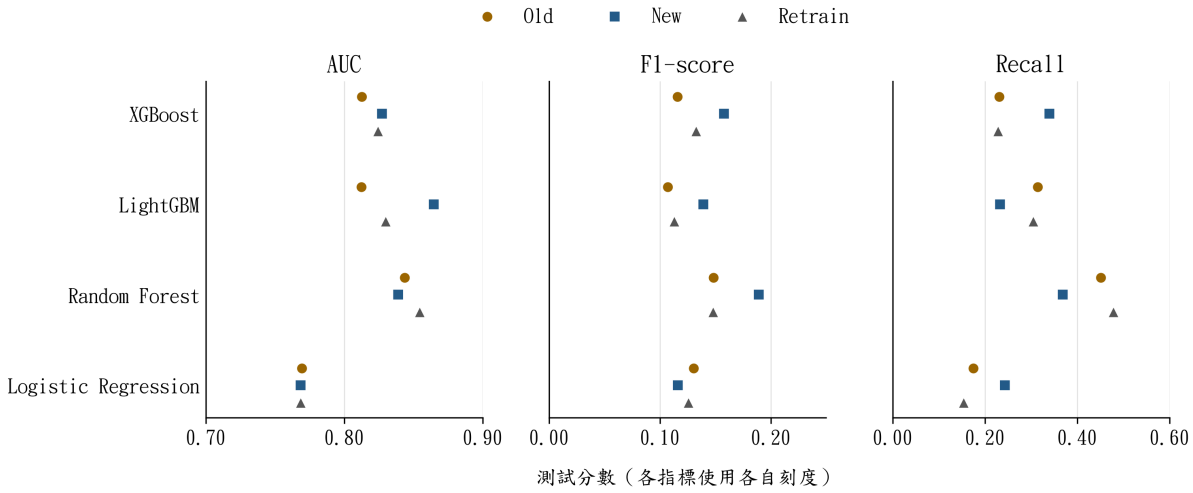


圖 4-1 事件標籤下各分類器之訓練策略比較

(資料來源：本研究依表 4-1 之完整精度結果繪製)

各點為四種採樣與十個種子之平均。各指標刻度不同；點位不含信賴區間，分類器依固定順序排列。

近期資料的優勢並非在所有分類器都出現。XGBoost 與 LightGBM 的 New AUC 分別為 0.8272 與 0.8646，高於 Old 的 0.8125 與 0.8123；Random Forest 則以 Retrain 的 0.8543 最高，Old 的 0.8437 也高於 New 的 0.8389。Logistic Regression 三種策略的 AUC 都約為 0.769。F1-score 方面，XGBoost、LightGBM 與 Random Forest 都以 New 最高，Logistic Regression 則以 Old 最高。因此，資料期間的影響須與分類器一起判讀，不能概括為「近期資料一定較好」。

表 4-2 只使用驗證資料，比較四種分類器在集成池六個位置上的表現。Random Forest 的驗證 AUC 為 0.8538，其次為 Logistic Regression 0.8330、XGBoost 0.8314 與 LightGBM 0.8260。Logistic Regression 的驗證排名較前，但 Test AUC 最低，可見只有 33 筆事件的驗證資料不足以穩定區分分類器。本研究不據此改換集成基底，也不宣稱 XGBoost 為最佳分類器。

表 4-2 六個模型池位置之分類器驗證結果

驗證排名	分類器	驗證 AUC	驗證 PR-AUC
1	Random Forest	0.8538	0.0627
2	Logistic Regression	0.8330	0.0677
3	XGBoost	0.8314	0.0511
4	LightGBM	0.8260	0.0451

(資料來源：本研究事件標籤 Baseline 實驗結果)

各值為 Old ／ New 與 Under、Over、Hybrid 共六個模型池位置、十個種子的 2014 年驗證平均，依驗證 AUC 排序；本表不使用 Test 分數。2014 年驗證資料只有 33 筆正類，排名差距須審慎解讀。

4-3 實驗一：Old ／ New 集成比較

4-3-1 六個基礎模型與靜態成員數

表 4-3 為池內六個 XGBoost 模型的結果。三個 New 模型的 AUC 都約為 0.83；Old_over 與 Old_hybrid 只有 0.6844 與 0.6874，F1-score 也僅 0.0227 與 0.0260。Old_under 的 AUC 為 0.7812，是三個 Old 模型中最高者。成員品質差異明顯，後續的集成結果應連同成員本身解讀。

表 4-3 事件標籤下六個基礎模型之測試結果

基礎模型	AUC	F1-score	Recall
Old_under	0.7812	0.0948	0.3277
Old_over	0.6844	0.0227	0.0202
Old_hybrid	0.6874	0.0260	0.0244
New_under	0.8311	**0.2004**	**0.3950**
New_over	0.8285	0.1137	0.3580
New_hybrid	**0.8314**	0.1279	0.2672

(資料來源：本研究事件標籤集成實驗結果)

完整 18 特徵、十個種子平均；under、over、hybrid 分別為 TomekLinks、ADASYN、SMOTEENN。粗體為六模型中該指標最高值，不表示差異達統計顯著；門檻由 Calibration 決定。

表 4-4 事件標籤下不同靜態成員數之候選平均結果

模型數	候選數	AUC	F1-score	Recall
2	9	0.7846	**0.1071**	0.1898
3	18	0.7850	0.0973	**0.2265**
4	15	0.7859	0.0964	0.2222
5	6	0.7866	0.1053	0.1763
6	1	**0.7881**	0.1041	0.1941

(資料來源：本研究事件標籤集成實驗結果)

每個種子先平均同一成員數全部候選的 Test 分數，再取十個種子平均。粗體僅供比較，不依此選成員數，也不表示顯著差異。

表 4-4 依成員數平均 49 個混合候選。兩模型到六模型候選的平均 AUC 介於 0.7846 與 0.7881，差距很小；這些平均涵蓋不同組合，不能解釋為只改變成員數的效果。V-static 仍由 Calibration AP 選擇，不依本表決定成員數。

4-3-2 集成方法比較

表 4-5 與圖 4-2 比較八種集成方法。Old3 與 New3 各整合同一期間的三個模型，Equal6 平均全部六模型，V-static 依各種子的 Calibration AP 從 49 個混合子集選定成員；四種動態方法使用相同模型池與 DSEL。

表 4-5 事件標籤下未進行 FS 之集成方法結果

方法	AUC	PR-AUC	F1-score	Recall
Old3	0.7198 (±0.0062)	0.0245 (±0.0009)	0.0199 (±0.0146)	0.0168 (±0.0137)
New3	**0.8601** (±0.0043)	0.0905 (±0.0055)	0.1289 (±0.0142)	0.4319 (±0.0605)
Equal6	0.7881 (±0.0037)	0.0533 (±0.0027)	0.1041 (±0.0073)	0.1941 (±0.0535)
V-static	0.8472 (±0.0000)	**0.1252** (±0.0000)	**0.1795** (±0.0000)	0.2353 (±0.0000)
DCS-OLA	0.7450 (±0.0079)	0.0288 (±0.0025)	0.0411 (±0.0167)	0.3857 (±0.2526)
DCS-LCA	0.7450 (±0.0082)	0.0298 (±0.0032)	0.0404 (±0.0185)	0.3849 (±0.2540)
KNORA-E	0.7859 (±0.0052)	0.0581 (±0.0049)	0.1017 (±0.0297)	0.2739 (±0.2164)
KNORA-U	0.7771 (±0.0045)	0.0513 (±0.0039)	0.0686 (±0.0268)	**0.4824** (±0.2116)

(資料來源：本研究事件標籤集成實驗結果)

各格上列為十個種子之合併四年 Test 平均，下列為種子標準差；Test 共 12,282 筆紀錄、119 筆事件。粗體為八種方法中該指標最高值，不表示差異達統計顯著。

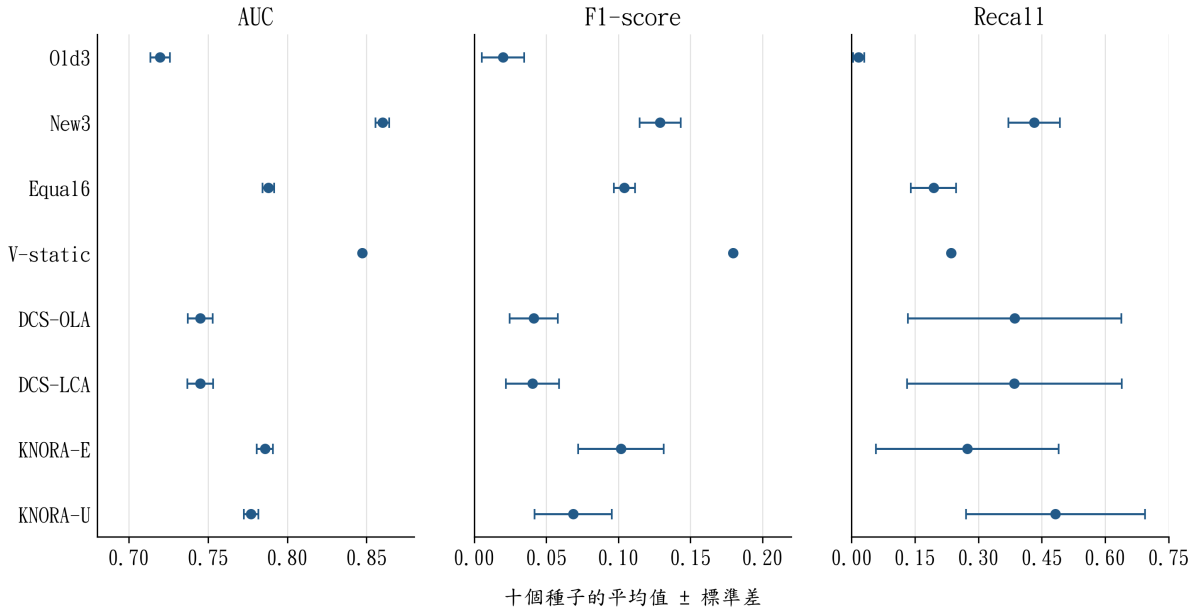


圖 4-2 事件標籤下未進行 FS 之集成方法比較

(資料來源：本研究事件標籤集成實驗結果)

點為合併四年測試指標的十種子平均，線段為種子標準差，並非公司重抽樣的信賴區間。各指標刻度不同，方法順序不依測試分數排列。

New3 的平均 AUC 最高，為 0.8601；V-static 為 0.8472，但 PR-AUC 與 F1-score 最高，分別為 0.1252 與 0.1795。十個種子的 V-static 都選中 Old_under 與 New_under 兩個模型，等於只保留各期間表現最好的一個成員。相對地，Equal6 的 AUC 為 0.7881，低於 New3，顯示把兩個較弱的 Old 模型一起等權平均，會拉低整體排序能力。Old3 的

F1-score 與 Recall 僅 0.0199 與 0.0168，幾乎無法辨識事件。

動態方法沒有超過 New3 或 V-static。DCS-OLA 與 DCS-LCA 的 AUC 都是 0.7450；KNORA-E 為 0.7859，與 Equal6 相近。KNORA-U 與兩種 DCS 的平均 Recall 雖高於 0.38，但種子標準差超過 0.21，F1-score 也偏低，代表判為事件的紀錄中誤報很多，且結果隨種子變動大。

綜合而言，在固定的六模型池中，「選擇哪些成員」比「是否整合全部成員」更影響結果：只用近期模型的 New3 與只選兩個成員的 V-static 表現較佳，全部等權平均與動態選擇則未帶來改善。這些差異尚未經事件標籤的配對檢定，屬描述性觀察。

4-3-3 與 Baseline 的公平比較

集成池的六個 XGBoost 使用預設參數，即 Baseline 搜尋中的候選 0；Baseline 則從 24 組候選中選參。表 4-6 以相同資料列、標籤、擬合期間與採樣對照兩者。

表 4-6 集成池預設 XGBoost 與 Baseline 調參 XGBoost 之對照

模型池位置	XGBoost 參數	AUC	F1-score	Recall
Old_under	預設（集成池）	0.7812	0.0948	0.3277
	調參（候選 5）	0.8710	0.1590	0.2748
Old_over	預設（集成池）	0.6844	0.0227	0.0202
	調參（候選 4）	0.7532	0.0755	0.1630
Old_hybrid	預設（集成池）	0.6874	0.0260	0.0244
	調參（候選 4）	0.7544	0.0746	0.1731
New_under	預設（集成池）	0.8311	0.2004	0.3950
	調參（候選 20）	0.7965	0.1595	0.3109
New_over	預設（集成池）	0.8285	0.1137	0.3580
	調參（候選 13）	0.8577	0.1463	0.3689
New_hybrid	預設（集成池）	0.8314	0.1279	0.2672
	調參（候選 13）	0.8577	0.1598	0.3496

(資料來源：本研究事件標籤集成與 Baseline 實驗結果)

兩者使用相同資料列、標籤、擬合期間與採樣；預設列的門檻由 Calibration（2014 年半數）決定，調參列的參數與門檻由完整 2014 年驗證資料決定。各值為十個種子的合併四年 Test 平均，僅供說明參數條件的差異。

調參在五個位置提高 AUC，例如 Old_under 由 0.7812 提高到 0.8710，Old_hybrid 由 0.6874 提高到 0.7544；New_under 則由 0.8311 降為 0.7965，表示依 33 筆事件選出的參數未必在 Test 較好。調參後的單一模型也與集成相當，例如 LightGBM New 的平均 AUC 為 0.8646，Random Forest Retrain 為 0.8543，均不低於 V-static 的 0.8472。

因此，Baseline 與集成之間的分數差同時包含參數、驗證資料（完整 2014 年或其

中一半）與分類器的差異，不能全部歸因於集成本身。本研究可以比較的是同一模型池內的整合方式；集成能否優於調參後的單一分類器，需要以調參後的成員重建模型池才能回答。

4-3-4 不同測試年度的表現

表 4-7 事件標籤下固定年份集成之逐年測試結果

方法	年度	AUC	F1-score	Recall
Old3	2015	0.6958	0.0292	0.0242
	2016	0.6817	0.0080	0.0069
	2017	0.7861	0.0000	0.0000
	2018	0.7345	0.0381	0.0278
New3	2015	**0.8721**	0.1423	0.4818
	2016	**0.8479**	0.1328	**0.4517**
	2017	0.8792	0.0963	0.4238
	2018	0.8465	0.1412	0.3750
Equal6	2015	0.7696	**0.1575**	0.2909
	2016	0.7450	0.0858	0.1793
	2017	0.8464	0.0513	0.1286
	2018	0.8072	0.1061	0.1556
V-static	2015	0.8291	0.1463	0.1818
	2016	0.8117	**0.1772**	0.2414
	2017	**0.8917**	**0.2388**	0.3810
	2018	**0.8651**	**0.1667**	0.1944
DCS-OLA	2015	0.6833	0.0355	0.3182
	2016	0.7069	0.0418	0.3759
	2017	0.8184	0.0361	0.4810
	2018	0.7897	0.0529	0.4000
DCS-LCA	2015	0.6817	0.0311	0.3152
	2016	0.7074	0.0426	0.3759
	2017	0.8192	0.0365	0.4810
	2018	0.7902	0.0532	0.4000
KNORA-E	2015	0.7709	0.1574	0.3455
	2016	0.7454	0.0891	0.2483
	2017	0.8416	0.0480	0.2429
	2018	0.7996	0.0996	0.2472
KNORA-U	2015	0.7612	0.0870	**0.5121**
	2016	0.7351	0.0628	0.4483
	2017	0.8164	0.0452	**0.5000**
	2018	0.8038	0.0748	**0.4722**

(資料來源：本研究事件標籤集成實驗結果)

各值為十個種子的年度指標平均；粗體表示同一年度八種方法中該指標最高值。2015–2018 年事件數依序為 33、29、21、36；各年沿用 Calibration 固定的門檻。

表 4-7 分開列出四個測試年度。New3 在 2015 與 2016 年的 AUC 最高，V-static 則在 2017 與 2018 年最高，分別為 0.8917 與 0.8651。各年只有 21 至 36 筆事件，年度間的排名變動可能受少數樣本影響；本表不把四年當成四次獨立實驗，也不據此推論特定景氣因素。

4-4 實驗二：FS 集成比較

八種 FS 條件分別與相同種子、測試樣本及集成方法的 no-FS 結果配對。50% 與 80% 分別保留 9 與 14 個特徵，精簡率為 50.00% 與 22.22%；各條件都重新訓練模型，並依相同 Calibration 規則決定成員與門檻。表 4-8、表 4-9 與表 4-10 列出完整結果。

表 4-8 事件標籤下實驗二各特徵條件之 AUC

FS	Equal6	V-static	OLA	LCA	KNORA-E	KNORA-U
no-FS（18）	0.7881 (±0.0037)	0.8472 (±0.0000)	**0.7450** (±0.0079)	**0.7450** (±0.0082)	0.7859 (±0.0052)	0.7771 (±0.0045)
MI 50%	0.7827 (±0.0075)	0.8440 (±0.0311)	0.7180 (±0.0161)	0.7148 (±0.0133)	0.7674 (±0.0071)	0.7622 (±0.0068)
MI 80%	0.7902 (±0.0043)	0.8573 (±0.0036)	0.7329 (±0.0122)	0.7329 (±0.0119)	0.7795 (±0.0065)	0.7776 (±0.0068)
CART 50%	0.7748 (±0.0045)	0.8523 (±0.0000)	0.7139 (±0.0076)	0.7143 (±0.0078)	0.7559 (±0.0073)	0.7603 (±0.0066)
CART 80%	0.7736 (±0.0049)	0.8492 (±0.0023)	0.7368 (±0.0084)	0.7373 (±0.0082)	0.7673 (±0.0052)	0.7640 (±0.0072)
SHAP 50%	0.7565 (±0.0059)	0.7885 (±0.0498)	0.6995 (±0.0083)	0.6980 (±0.0082)	0.7520 (±0.0040)	0.7496 (±0.0076)
SHAP 80%	**0.7906** (±0.0065)	0.8512 (±0.0000)	0.7396 (±0.0092)	0.7390 (±0.0088)	**0.7920** (±0.0073)	**0.7878** (±0.0072)
RFE 50%	0.7759 (±0.0045)	0.8523 (±0.0000)	0.7159 (±0.0096)	0.7161 (±0.0093)	0.7583 (±0.0066)	0.7633 (±0.0063)
RFE 80%	0.7844 (±0.0049)	**0.8579** (±0.0000)	0.7339 (±0.0069)	0.7310 (±0.0075)	0.7741 (±0.0036)	0.7702 (±0.0057)

(資料來源：本研究事件標籤 FS 集成實驗結果)

各格上列為十個種子的合併四年 Test 平均，下列為種子標準差。粗體表示同一方法（同一欄）九種特徵條件中最高的平均分數，不代表已選定最佳設定或差異達統計顯著。50%、80% 分別保留 9、14 個特徵；V-static 依各條件的 Calibration 重新選成員。

表 4-9 事件標籤下實驗二各特徵條件之 F1-score

FS	Equal6	V-static	OLA	LCA	KNORA-E	KNORA-U
no-FS（18）	0.1041 (±0.0073)	**0.1795** (±0.0000)	0.0411 (±0.0167)	0.0404 (±0.0185)	0.1017 (±0.0297)	0.0686 (±0.0268)
MI 50%	0.0886 (±0.0200)	0.1421 (±0.0384)	0.0478 (±0.0081)	0.0448 (±0.0095)	0.0934 (±0.0260)	0.0736 (±0.0270)
MI 80%	0.1028 (±0.0228)	0.1715 (±0.0410)	0.0502 (±0.0204)	0.0504 (±0.0211)	0.1035 (±0.0290)	0.0728 (±0.0302)
CART 50%	0.0867 (±0.0127)	0.1444 (±0.0000)	0.0341 (±0.0212)	0.0356 (±0.0204)	0.0972 (±0.0220)	0.0819 (±0.0169)
CART 80%	0.0976 (±0.0158)	0.1736 (±0.0077)	**0.0676** (±0.0119)	**0.0664** (±0.0114)	**0.1112** (±0.0244)	**0.0955** (±0.0311)
SHAP 50%	**0.1325** (±0.0237)	0.1396 (±0.0268)	0.0441 (±0.0182)	0.0367 (±0.0144)	0.0743 (±0.0269)	0.0938 (±0.0269)
SHAP 80%	0.0755 (±0.0395)	0.1566 (±0.0000)	0.0515 (±0.0084)	0.0500 (±0.0061)	0.0910 (±0.0434)	0.0777 (±0.0226)
RFE 50%	0.0890 (±0.0178)	0.1444 (±0.0000)	0.0369 (±0.0238)	0.0402 (±0.0200)	0.1074 (±0.0138)	0.0880 (±0.0249)
RFE 80%	0.0913 (±0.0141)	0.1748 (±0.0000)	0.0608 (±0.0095)	0.0495 (±0.0178)	0.0963 (±0.0202)	0.0946 (±0.0195)

(資料來源：本研究事件標籤 FS 集成實驗結果)

各格上列為十個種子的合併四年 Test 平均，下列為種子標準差。粗體表示同一方法（同一欄）九種特徵條件中最高的平均分數，不代表已選定最佳設定或差異達統計顯著。50%、80% 分別保留 9、14 個特徵；V-static 依各條件的 Calibration 重新選成員。

表 4-10 事件標籤下實驗二各特徵條件之 Recall

FS	Equal6	V-static	OLA	LCA	KNORA-E	KNORA-U
no-FS（18）	0.1941 (±0.0535)	0.2353 (±0.0000)	**0.3857** (±0.2526)	**0.3849** (±0.2540)	0.2739 (±0.2164)	**0.4824** (±0.2116)
MI 50%	0.3790 (±0.1278)	0.1571 (±0.0457)	0.1689 (±0.1181)	0.1538 (±0.1211)	0.3101 (±0.0931)	0.2748 (±0.1645)
MI 80%	0.3336 (±0.1473)	0.2277 (±0.1376)	0.1261 (±0.1771)	0.1252 (±0.1776)	0.3261 (±0.1594)	0.4017 (±0.1917)
CART 50%	0.3143 (±0.1097)	0.1092 (±0.0000)	0.0353 (±0.0301)	0.0353 (±0.0293)	0.1815 (±0.1095)	0.2563 (±0.1148)
CART 80%	0.3218 (±0.0952)	0.2798 (±0.0080)	0.1261 (±0.1075)	0.1227 (±0.1096)	0.2874 (±0.1092)	0.2513 (±0.1195)
SHAP 50%	0.2798 (±0.0506)	0.1689 (±0.0897)	0.0958 (±0.0182)	0.0790 (±0.0182)	0.4092 (±0.1019)	0.3193 (±0.0920)
SHAP 80%	**0.5185** (±0.1460)	0.3361 (±0.0000)	0.2798 (±0.1375)	0.2748 (±0.1406)	**0.4504** (±0.1299)	0.4370 (±0.1643)
RFE 50%	0.3109 (±0.1184)	0.1092 (±0.0000)	0.0378 (±0.0300)	0.0328 (±0.0208)	0.1756 (±0.0748)	0.2311 (±0.0932)
RFE 80%	0.3756 (±0.0984)	**0.3445** (±0.0000)	0.1210 (±0.0617)	0.0899 (±0.0675)	0.3336 (±0.0747)	0.2798 (±0.1310)

(資料來源：本研究事件標籤 FS 集成實驗結果)

各格上列為十個種子的合併四年 Test 平均，下列為種子標準差。粗體表示同一方法（同一欄）九種特徵條件中最高的平均分數，不代表已選定最佳設定或差異達統計顯著。50%、80% 分別保留 9、14 個特徵；V-static 依各條件的 Calibration 重新選成員。



圖 4-3 事件標籤下各 FS 條件相對同方法 no-FS 之 AUC 差值

(資料來源：本研究事件標籤 FS 集成實驗結果)

每格為十種子平均的 FS 減 no-FS，正值表示增加、負值表示下降。色彩只表示差值方向與大小，不表示統計顯著；50% ／ 80% 分別實際保留 9 ／ 14 個特徵。

圖 4-3 顯示，多數 FS 條件降低 Equal6 與四種動態方法的 AUC，其中 SHAP 50% 在六種方法都下降，降幅介於 0.0275 與 0.0587。V-static 在六個條件下 AUC 略增，最大為 RFE 80% 的 0.0107；Equal6 與 KNORA-U 在 MI 80% 與 SHAP 80%、KNORA-E 在 SHAP 80% 也有小幅增加。整體而言，保留 14 個特徵的條件較接近 no-FS，刪去一半特徵時下降較多。

F1-score 與 Recall 的方向依方法而異。V-static 在八個 FS 條件下的 F1-score 都低於 no-FS，降幅介於 0.0046 與 0.0399。Equal6 的 Recall 在八個條件都提高，增幅介於 0.0857 與 0.3244；兩種 DCS 則全部下降，但其 no-FS Recall 的種子標準差已超過 0.25，差值不宜單獨解讀。V-static 在 FS 後會重新選擇成員，例如 MI 50% 只有五個種子仍選 Old_under 與 New_under，SHAP 50% 只有四個種子，因此其變化包含整個選模流程，而非只反映特徵減少。

本實驗未出現在多數方法與指標上一致改善的 FS 條件。FS 能把輸入由 18 個減為 9 或 14 個，但需要接受 AUC 或 F1-score 的變動；是否可接受取決於應用對精簡程度與漏判、誤報的權衡。各特徵在十個種子中的入選次數列於附錄 一-7。

4-5 標籤定義對結果的影響

為了解結論是否依賴標籤定義，表 4-11 對照相同資料列、模型池與選擇規則下，最終狀態標籤與事件標籤的 no-FS 結果。兩者正類比例不同，原始分數只比較方向，不比較高低。

表 4-11 兩種標籤定義下未進行 FS 之集成結果

方法	標籤	AUC	F1-score	Recall
Old3	最終狀態	0.7134	0.1168	0.2383
	事件	0.7198	0.0199	0.0168
New3	最終狀態	0.7959	0.2007	0.2268
	事件	0.8601	0.1289	0.4319
Equal6	最終狀態	0.7815	0.1815	0.2690
	事件	0.7881	0.1041	0.1941
V-static	最終狀態	0.8152	0.2355	0.2481
	事件	0.8472	0.1795	0.2353
DCS-OLA	最終狀態	0.7386	0.1542	0.2909
	事件	0.7450	0.0411	0.3857
DCS-LCA	最終狀態	0.7369	0.1631	0.3195
	事件	0.7450	0.0404	0.3849
KNORA-E	最終狀態	0.7613	0.1837	0.2714
	事件	0.7859	0.1017	0.2739
KNORA-U	最終狀態	0.7481	0.1817	0.2620
	事件	0.7771	0.0686	0.4824

(資料來源：本研究固定年份集成實驗結果)

兩種標籤使用相同資料列、分區、模型池、十個種子與選擇規則；Test 正類分別為 287 筆（最終狀態）與 119 筆（事件）。正類比例不同，原始分數只比較方向，不比較高低。

兩種標籤下，V-static 的 F1-score 都高於 Equal6，Old3 的 AUC 都最低，動態方法的 AUC 與 F1-score 也都未超過 V-static。差別在於最佳 AUC：最終狀態標籤下 V-static 為 0.8152，高於 New3 的 0.7959；事件標籤下則是 New3 的 0.8601 高於 V-static 的 0.8472。Old3 的 F1-score 也由 0.1168 降為 0.0199。最終狀態標籤把破產公司的每個年度都記為正類，歷史模型可以學到「哪些公司最終會破產」的特徵；改為只標記事件前一年後，歷史模型對近期事件的辨識能力明顯較弱。

最終狀態標籤已完成以公司為單位的配對 bootstrap 與 165 項 Holm 校正。該分析中，V-static 相對 Equal6 的 AUC 與 F1-score 增加均達校正後顯著（p_H 為 0.00632 與 0.02416），FS 則沒有校正後顯著的 AUC 增加；完整結果見附錄 一-6。這些檢定只適用於最終狀態標籤，不直接延伸至事件標籤。

4-6 研究問題的綜合討論

4-6-1 訓練資料期間與單一分類器

研究問題一的答案是：資料期間的效果依分類器而異。XGBoost 與 LightGBM 以 New 的 AUC 較高，Random Forest 以 Retrain 最高，Logistic Regression 三者相近。由於各策略的訓練筆數同時不同，本研究不把差異完全歸因於資料新近程度。

4-6-2 集成規則與模型成員

研究問題二的答案是：在固定的預設參數模型池中，成員選擇比整合方式更重要。New3 與 V-static 優於 Equal6 及四種動態方法；兩者分別以 AUC 和 F1-score 較高。歷史模型在事件標籤下表現較弱，V-static 只保留最好的 Old 模型，Equal6 全部納入則降低排序能力。此結果支持保留簡單的單一期間與等權控制組，再以驗證資料決定是否加入歷史模型。

不過，調參後的單一分類器與集成表現相當，集成池成員又未經調參。因此本研究只能說明同一池內整合方式的差異，尚不能主張集成優於調參後的單一模型。

4-6-3 特徵精簡與少數類辨識

研究問題三的答案是：FS 沒有帶來一致的改善。保留 14 個特徵時大多接近 no-FS，保留 9 個特徵時 AUC 多半下降；Recall 與 F1-score 的方向則隨集成方法而變。本研究記錄了特徵數，但未比較訓練與推論時間，因此不能將輸入維度減少換算為已證實的成本節省。

4-7 推論範圍與限制

事件標籤以破產公司的最後觀測年度推定事件時間，並非逐筆核對的破產申請日；Calibration 與 DSEL 各只有 16 與 17 筆事件，選模與門檻決策的不確定性較大。事件標籤結果尚未完成配對檢定，本章差異均為描述性。同一公司可能同時出現在擬合與測試期間，主要實驗也採固定年份、測試期間不更新模型，因此結果不代表對未見公司或持續學習情境的驗證。實證只使用一份公開資料，結論限於本資料與既定時間分區。

五、 結論與未來研究

5-1 研究結論

本研究以具有時間資訊的不平衡分類為對象，在美國企業年度財務資料上比較歷史與近期模型的運用方式。主要分析採用重建的下一年度破產事件標籤，並以公司最終狀態標籤作為對照。依三項研究問題，結論整理如下。

第一，近期資料的優勢依分類器而異。在相同年份配置與驗證規則下，XGBoost 與 LightGBM 以近期資料模型的 AUC 較高，Random Forest 以合併重訓最高，Logistic Regression 三種策略相近。因此，訓練資料期間應與分類器一起決定，不宜預設捨棄歷史資料或只用近期資料。

第二，在固定的 Old ／ New 模型池中，成員選擇比整合方式更重要。只整合近期模型的 New3 AUC 最高，依驗證資料選出兩個成員的靜態集成 F1-score 最高；等權平均全部六模型反而因納入較弱的歷史模型而降低 AUC，四種動態選擇方法也未超過上述兩者。實務上，保留單一期間與等權集成作為控制組，再以驗證資料決定是否加入歷史模型，比直接採用較複雜的動態方法更穩妥。

第三，特徵選取沒有帶來一致改善。保留 14 個特徵時大多接近完整特徵，保留 9 個特徵時 AUC 多半下降；Recall 與 F1-score 的方向則依集成方法而變。特徵選取的價值須連同精簡程度與漏判、誤報的權衡一起判斷。

此外，調參後的單一分類器與集成表現相當，而集成池成員使用預設參數。因此，本研究的證據支持「在固定模型池中審慎選擇成員」，尚不足以主張集成優於調參後的單一分類器。標籤定義也會改變結論：改用公司最終狀態標籤時，驗證選定的靜態集成 AUC 高於 New3，與事件標籤的結果相反。研究使用具時間資訊的資料時，應先確認標籤所代表的時間意義。

5-2 研究限制

本研究的限制如下。第一，事件標籤以破產公司的最後觀測年度推定，並非逐筆核對的破產申請日；驗證資料中的事件也只有 33 筆，選模與門檻決策的不確定性較大。第二，事件標籤結果尚未完成公司群聚配對檢定，主要差異屬描述性觀察。第三，

集成池成員未經調參，Baseline 與集成之間的分數差同時受參數與驗證資料影響。第四，所有實驗採固定年份切分，測試期間不更新模型，因此不驗證持續學習或線上適應的能力。第五，實證只使用一份公開資料，同一公司也可能同時出現在訓練與測試期間，結論不延伸至未見公司或其他市場。

5-3 未來研究方向

後續研究可依上述限制延伸。首先，對事件標籤結果補作以公司為單位的配對檢定與多重比較校正，確認主要差異是否穩定。其次，以 Baseline 調參後的成員重建模型池，在相同驗證資料下比較集成與單一分類器，回答集成本身是否帶來增益。第三，採用滑動視窗或逐期更新的設計，檢驗歷史與近期模型在持續更新情境下的運用方式。第四，取得可核對的破產日期，或使用其他具有明確事件時間的資料，檢查結論能否推廣；並區分訓練期間出現過與未出現過的公司，評估對新個體的預測能力。最後，若要主張特徵選取可降低成本，應以相同程序量測訓練與推論時間。

參考文獻

〔1〕 J. Gama et al., “A Survey on Concept Drift Adaptation”. *ACM Computing Surveys*, 46(4). 2014. Article 44. DOI: 10.1145/2523813.

〔2〕 T. Saito and M. Rehmsmeier, “The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets”. *PLOS ONE*, 10(3). 2015. Article e0118432. DOI: 10.1371/journal.pone.0118432.

〔3〕 G. Lombardo et al., “Machine Learning for Bankruptcy Prediction in the American Stock Market: Dataset and Benchmarks”. *Future Internet*, 14(8). 2022. Article 244. DOI: 10.3390/fi14080244.

〔4〕 sowide research group, “Bankruptcy prediction dataset for American companies in the stock market”. URL: https://github.com/sowide/bankruptcy_dataset 檢索日期：10/27/2026.

〔5〕 G. E. A. P. A. Batista et al., “A Study of the Behavior of Several Methods for Balancing Machine Learning Training Data”. *ACM SIGKDD Explorations Newsletter*, 6(1). 2004. Pp. 20–29. DOI: 10.1145/1007730.1007735.

〔6〕 imbalanced-learn, “TomekLinks”. URL: https://imbalanced-learn.org/stable/references/generated/imblearn.under_sampling.TomekLinks.html 檢索日期：10/27/2026.

〔7〕 N. V. Chawla et al., “SMOTE: Synthetic Minority Over-sampling Technique”. *Journal of Artificial Intelligence Research*, 16. 2002. Pp. 321–357. DOI: 10.1613/jair.953.

〔8〕 H. He et al., “ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning”. *2008 IEEE International Joint Conference on Neural Networks*. 2008. Pp. 1322–1328. DOI: 10.1109/IJCNN.2008.4633969.

〔9〕 L. Breiman, “Random Forests”. *Machine Learning*, 45(1). 2001. Pp. 5–32. DOI: 10.1023/A:1010933404324.

〔10〕 T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System”. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016. DOI: 10.1145/2939672.2939785.

〔11〕 G. Ke et al., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree”. *Advances in Neural Information Processing Systems*. Vol. 30. 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html.

〔12〕 Y. Gorishniy et al., “TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling”. *The Thirteenth International Conference on Learning Representations*. 2025. URL: https://openreview.net/forum?id=Sd4wYYOhmY.

〔13〕 J. Qu et al., “TabICL: A Tabular Foundation Model for In-Context Learning on Large Data”. *Proceedings of the 42nd International Conference on Machine Learning*. Vol. 267. PMLR. 2025. Pp. 50817–50847. URL: https://proceedings.mlr.press/v267/qu25d.html.

〔14〕 K. Woods et al., “Combination of Multiple Classifiers Using Local Accuracy Estimates”. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 19(4). 1997. Pp. 405–410. DOI: 10.1109/34.588027.

〔15〕 DESlib, “Overall Local Accuracy (OLA)”. URL: https://deslib.readthedocs.io/en/latest/modules/dcs/ola.html 檢索日期：10/27/2026.

〔16〕 DESlib, “Local Class Accuracy (LCA)”. URL: https://deslib.readthedocs.io/en/latest/modules/dcs/lca.html 檢索日期：10/27/2026.

〔17〕 A. H. R. Ko et al., “From Dynamic Classifier Selection to Dynamic Ensemble Selection”. *Pattern Recognition*, 41(5). 2008. Pp. 1718–1731. DOI: 10.1016/j.patcog.2007.10.015.

〔18〕 DESlib, “k-Nearest Oracle-Eliminate (KNORA-E)”. URL: https://deslib.readthedocs.io/en/latest/modules/des/knora_e.html 檢索日期：10/27/2026.

〔19〕 DESlib, “k-Nearest Oracle Union (KNORA-U)”. URL: https://deslib.readthedocs.io/en/latest/modules/des/knora_u.html 檢索日期：10/27/2026.

〔20〕 R. M. O. Cruz et al., “DESlib: A Dynamic Ensemble Selection Library in Python”. *Journal of Machine Learning Research*, 21(8). 2020. Pp. 1–5. URL: https://jmlr.org/papers/v21/18-144.html.

〔21〕 I. Guyon and A. Elisseeff, “An Introduction to Variable and Feature Selection”. *Journal of Machine Learning Research*, 3. 2003. Pp. 1157–1182. URL: https://www.jmlr.org/papers/v3/guyon03a.html.

〔22〕 scikit-learn, “Feature selection”. URL: https://scikit-learn.org/stable/modules/feature_selection.html 檢索日期：10/27/2026.

〔23〕 S. M. Lundberg and S.-I. Lee, “A Unified Approach to Interpreting Model Predictions”. *Advances in Neural Information Processing Systems*. Vol. 30. 2017.

〔24〕 J. T. Hancock et al., “A problem-agnostic approach to feature selection and analysis using SHAP”. *Journal of Big Data*, 12. 2025. Article 12. DOI: 10.1186/s40537-024-01041-1.

〔25〕 J. Goldwasser and G. Hooker, “Statistical Significance of Feature Importance Rankings”. *Proceedings of the Forty-first Conference on Uncertainty in Artificial Intelligence*. Vol. 286. PMLR. 2025. Pp. 1476–1496. URL: https://proceedings.mlr.press/v286/goldwasser25a.html.

〔26〕 scikit-learn, “average_precision_score”. URL: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html 檢索日期：10/27/2026.

〔27〕 B. Efron and R. Tibshirani, “Bootstrap Methods for Standard Errors, Confidence Intervals, and Other Measures of Statistical Accuracy”. *Statistical Science*, 1(1). 1986. Pp. 54–75. DOI: 10.1214/ss/1177013815.

〔28〕 N. A. Obuchowski, “Nonparametric Analysis of Clustered ROC Curve Data”. *Biometrics*, 53(2). 1997. Pp. 567–578. DOI: 10.2307/2533958.

〔29〕 S. Holm, “A Simple Sequentially Rejective Multiple Test Procedure”. *Scandinavian Journal of Statistics*, 6(2). 1979. Pp. 65–70. URL: https://www.jstor.org/stable/4615733.

〔30〕 sowide research group, “Public financial research supplement for the bankruptcy dataset”. URL: https://github.com/sowide/bankruptcy_dataset/blob/main/dataset_paper.zip 檢索日期：10/27/2026.

〔31〕 LightGBM, “lightgbm.Booster”. Version 4.6.0. URL: https://lightgbm.readthedocs.io/en/v4.6.0/pythonapi/lightgbm.Booster.html 檢索日期：10/27/2026.

附錄一　實驗補充設定與統計檢定

一-1　兩項實驗之資料與紀錄規格

實驗一包含 Baseline 與 Old ／ New 集成比較；實驗二在集成架構中加入特徵選取。三部分使用相同的資料列、事件標籤、擬合年份與 Test。Baseline 以 2014 年整年調參與決定門檻；集成與 FS 則把 2014 年分為互斥的 DSEL 與 Calibration，池內 XGBoost 使用預設參數。

實驗紀錄包含資料分區與樣本識別、標籤定義、擬合期間、隨機種子、採樣前後筆數、前處理參數、所選特徵及排列順序、分類器設定、驗證候選排序、固定門檻，以及整體與逐年預測結果。紀錄另保留資料與方法版本的識別資訊，供研究重現與來源核對，不將內部儲存名稱當作方法定義。

一-2　Baseline 超參數與訓練控制

Baseline 對四種分類器的每個「訓練策略 × 採樣」組合各評估 24 組候選：候選 0 為集成池使用的預設參數，其餘 23 組依分類器固定的亂數種子，從表 3-4 的候選集合抽出。Logistic Regression 的候選集合共 30 組，也只抽出 23 組，並未全部遍歷。LightGBM 的抽樣比例小於 1 時，另設定 `bagging_freq=1`，使該參數實際生效。

調參時以種子 42 擬合各候選，依 2014 年驗證 AUC 選出一組參數，再以十個種子重新訓練；門檻依同一驗證資料的 F1-score 決定。各組合選中的候選編號保存在執行紀錄，不同組合可能選出不同參數，因此不以單一組參數代表全部設定。TabM 的候選集合已定義，但事件標籤版本尚未執行；先前以最終狀態標籤執行的 TabM 與 TabICL 探索紀錄，因標籤與驗證方式不同，不納入本文比較。

一-3　軟體環境與隨機性控制

依本研究採用的本機設備，CPU、記憶體、作業系統及顯示卡規格列於表 A-1。硬體於 2026 年 10 月 27 日由系統查核；作業系統與驅動版本列為本次查核值，不推定每次歷史執行都使用相同的更新版本。

表 A-1 本研究本機設備與固定年份執行設定

項目	規格／設定
CPU	Intel Core i7-10870H，2.20 GHz；8 核心、16 邏輯處理器
記憶體	32 GB（安裝容量）
作業系統	Windows 11 家用版，64 位元；版本 10.0.26200
獨立顯示卡	NVIDIA GeForce GTX 1650 Ti；4096 MiB 顯示記憶體
內建顯示晶片	Intel UHD Graphics
本機 NVIDIA 驅動	592.82（本次查核值）
固定年份 XGBoost	CPU；hist 樹建構，未設定 CUDA device
FS 執行	scikit-learn 決策樹／ MI 與 LightGBM CPU 設定；最多四執行緒
查核日期	2026 年 10 月 27 日

(資料來源：依使用者指定，採本機系統查核與實驗程式設定整理)

設備具有 GPU 不代表所有方法都使用 GPU；本次查得的作業系統及驅動版本不回推為每次歷史執行的原始版本。

固定年份集成實驗所保存的環境為 Python 3.14.0、NumPy 2.4.2、pandas 3.0.1、scikit-learn 1.8.0、XGBoost 3.2.0、imbalanced-learn 0.14.1、LightGBM 4.6.0 及 DESlib 0.3.7。各設定使用四個執行緒，整體最多三個工作程序平行執行。這些資訊描述產生該批結果時的環境，不以後續工作環境版本取代。

2014 年驗證分區的種子固定為 42。模型、採樣與具隨機性的特徵選取程序，使用 42、123、456、789、2024、7、21、84、168、999 共十個種子。相同種子與方法的 FS ／ no-FS 比較使用相同測試樣本；種子標準差描述程序隨機變異，不等於獨立資料抽樣的信賴區間。固定年份 XGBoost 使用 hist 樹建構且未指定 CUDA，FS 的決策樹、MI 與 LightGBM 亦使用 CPU 設定；不能由本機配有 GPU 推定上述方法採 GPU 加速。其他深度模型是否使用 GPU，依其個別執行紀錄判讀。

一-4　實驗完成範圍與比較限制

事件標籤的集成實驗已完成十個種子與九種特徵條件，Baseline 已完成四種分類器、三種訓練策略與四種採樣。事件標籤的公司群聚配對檢定尚未完成；已保存的一份檢定輸出缺少部分檔案，因此本文不引用其數值。最終狀態標籤的相同實驗與 165 項檢定已完成，列於附錄 一-6 作為對照。

集成池的 XGBoost 使用預設參數，未讀入 Baseline 選定的參數。第四章已對照兩者，但若要判斷集成能否優於調參後的單一分類器，仍須以調參後的成員重建模型池，並在相同驗證資料下比較。

事件標籤以破產公司的最後觀測年度推定事件年份；公開檔沒有可逐筆核對的破產申請日與財報公開時間。同一公司可能跨訓練與測試年度出現，因此結果不延伸為對未見公司的驗證。

一-5 Baseline 各採樣設定之完整結果

本節分列正文四種分類器在 Old ／ New ／ Retrain 與四種採樣下的事件標籤結果。各格為十個種子的描述性指標。

表 A-2 事件標籤 Baseline 各採樣設定之結果

分類器	策略	採樣	驗證 AUC	AUC	F1-score	Recall
XGBoost	Old	None	0.8993	**0.8716**	0.1546	**0.3143**
		Under	**0.8994**	0.8710	**0.1590**	0.2748
		Over	0.7824	0.7532	0.0755	0.1630
		Hybrid	0.7818	0.7544	0.0746	0.1731
	New	None	**0.8461**	0.7970	**0.1663**	0.3277
		Under	0.8457	0.7965	0.1595	0.3109
		Over	0.8393	**0.8577**	0.1463	**0.3689**
		Hybrid	0.8397	**0.8577**	0.1598	0.3496
	Retrain	None	0.9004	0.8799	**0.1943**	0.2849
		Under	**0.9009**	**0.8862**	0.1830	**0.3252**
		Over	0.7955	0.7644	0.0771	0.1714
		Hybrid	0.7973	0.7673	0.0759	0.1319
LightGBM	Old	None	0.9042	**0.8691**	**0.1429**	**0.4782**
		Under	**0.9046**	0.8689	0.1405	**0.4782**
		Over	0.7794	0.7564	0.0810	0.1412
		Hybrid	0.7389	0.7548	0.0629	0.1597
	New	None	0.8453	**0.8677**	**0.1534**	0.0975
		Under	0.8428	0.8643	0.1356	0.0891
		Over	**0.8457**	0.8645	0.1343	0.3639
		Hybrid	0.8445	0.8619	0.1340	**0.3790**
	Retrain	None	**0.9060**	**0.8793**	**0.1721**	**0.4445**
		Under	0.9003	0.8739	0.1362	0.1345
		Over	0.7946	0.7779	0.0753	0.2689
		Hybrid	0.8117	0.7886	0.0674	0.3706

續下頁

表 A-2（續）

分類器	策略	採樣	驗證 AUC	AUC	F1-score	Recall
Random Forest	Old	None	0.9060	**0.8847**	0.2188	0.4277
		Under	**0.9105**	0.8709	**0.2423**	0.3008
		Over	0.8276	0.8075	0.0650	**0.5504**
		Hybrid	0.8369	0.8118	0.0667	0.5235
	New	None	0.8370	0.8333	0.2956	0.3412
		Under	0.8455	**0.8433**	**0.3025**	0.3286
		Over	**0.8513**	0.8401	0.0832	**0.4748**
		Hybrid	0.8512	0.8387	0.0758	0.3294
	Retrain	None	**0.9106**	0.8747	**0.2499**	0.3134
		Under	0.9070	**0.8880**	0.2028	0.4882
		Over	0.8340	0.8291	0.0688	**0.5731**
		Hybrid	0.8320	0.8256	0.0698	0.5378
Logistic Regression	Old	None	0.8332	0.7523	0.1190	**0.1765**
		Under	0.8320	0.7449	0.1203	**0.1765**
		Over	**0.8734**	**0.7901**	0.1409	0.1697
		Hybrid	0.8662	**0.7901**	**0.1415**	0.1756
	New	None	0.7982	0.7642	0.0990	0.2941
		Under	0.7981	0.7642	0.1004	**0.3025**
		Over	**0.8164**	**0.7734**	0.1288	0.1849
		Hybrid	0.8120	0.7720	**0.1361**	0.1916
	Retrain	None	0.8422	0.7457	0.1114	**0.1681**
		Under	0.8431	0.7445	0.1102	**0.1681**
		Over	0.8606	**0.7932**	0.1370	0.1353
		Hybrid	**0.8627**	0.7905	**0.1441**	0.1445

(資料來源：本研究事件標籤 Baseline 實驗結果)

各值為十個種子平均；超參數依 2014 年驗證 AUC 由 24 組候選選出，候選 0 為集成池使用的預設參數。粗體比較同一分類器與策略下的四種採樣。Under、Over、Hybrid 分別為 TomekLinks、ADASYN、SMOTEENN。

一-6　最終狀態標籤之公司群聚配對檢定

本節列出最終狀態標籤下，實驗一的 21 項檢定與實驗二的 144 項檢定；事件標籤的檢定尚未完成，不在此列。比較規則與雙尾近似檢定依第 3-5-4 節；所有表格共用 49,999 組公司重抽樣本，且 165 個 p 值共同採 Holm 校正。差值均為候選方法減對應基準，不依測試分數或顯著性排序。

信賴區間為逐項 95% 百分位區間，未作同時區間校正。p 為置中 bootstrap 的未校正值，p_H 為 Holm 校正值；附錄的 p 值顯示五位小數，指標差值與區間顯示四位小數，

計算與校正使用原精度。最小可報 p 為 0.00002，並非零。有限重抽亦具有 Monte Carlo 誤差，接近顯著門檻的結論應審慎解讀；未達顯著不等同方法等效。

以 CART 50% 的 KNORA-E AUC 為例，49,999 次重抽中有 12 次置中誤差達到或超過觀察差值，因此 $p = 13/50{,}000 = 0.00026$，$p_H = 0.03900$。未校正 p 的 Monte Carlo 標準誤約為 0.000072；多重比較校正會放大此數值誤差的影響。若要將其作為關鍵顯著性結論，應增加重抽次數或以其他適切方法驗證。

實驗一：各方法與 Equal6 比較

表 A-3 實驗一完整配對檢定：各方法減 Equal6

方法	指標	差值	95% 信賴區間	p	p_H
Old3	AUC	-0.0681	[-0.0890, -0.0488]	0.00002	0.00330
	F1	-0.0647	[-0.0937, -0.0355]	0.00002	0.00330
	Recall	-0.0307	[-0.0766, +0.0144]	0.18742	1.00000
New3	AUC	+0.0144	[-0.0019, +0.0313]	0.09184	1.00000
	F1	+0.0192	[-0.0048, +0.0427]	0.11316	1.00000
	Recall	-0.0422	[-0.0710, -0.0140]	0.00416	0.58240
V-static	AUC	+0.0337	[+0.0198, +0.0480]	0.00004	0.00632
	F1	+0.0540	[+0.0266, +0.0811]	0.00016	0.02416
	Recall	-0.0209	[-0.0518, +0.0086]	0.17084	1.00000
DCS-OLA	AUC	-0.0430	[-0.0634, -0.0233]	0.00012	0.01860
	F1	-0.0273	[-0.0572, +0.0026]	0.07438	1.00000
	Recall	+0.0220	[-0.0255, +0.0692]	0.36144	1.00000
DCS-LCA	AUC	-0.0446	[-0.0663, -0.0242]	0.00012	0.01860
	F1	-0.0184	[-0.0503, +0.0139]	0.26582	1.00000
	Recall	+0.0505	[-0.0021, +0.1030]	0.05944	1.00000
KNORA-E	AUC	-0.0202	[-0.0387, -0.0029]	0.02702	1.00000
	F1	+0.0023	[-0.0198, +0.0236]	0.83454	1.00000
	Recall	+0.0024	[-0.0315, +0.0350]	0.88668	1.00000
KNORA-U	AUC	-0.0334	[-0.0517, -0.0161]	0.00042	0.06258
	F1	+0.0002	[-0.0072, +0.0071]	0.95856	1.00000
	Recall	-0.0070	[-0.0182, +0.0035]	0.21108	1.00000

(資料來源：本研究實驗結果整理)

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

實驗二：FS 與相同方法 no-FS 比較

表 A-4 實驗二完整 AUC 配對檢定：FS 減同方法 no-FS

FS	方法	差值	95% 信賴區間	p	p_H
MI 50%	Equal6	-0.0171	[-0.0471, +0.0116]	0.25188	1.00000
	V-static	-0.0327	[-0.0584, -0.0087]	0.01050	1.00000
	DCS-OLA	-0.0257	[-0.0564, +0.0052]	0.10044	1.00000
	DCS-LCA	-0.0431	[-0.0728, -0.0128]	0.00466	0.64308
	KNORA-E	-0.0274	[-0.0571, +0.0018]	0.06818	1.00000
	KNORA-U	-0.0220	[-0.0487, +0.0046]	0.10514	1.00000
MI 80%	Equal6	+0.0007	[-0.0137, +0.0151]	0.92404	1.00000
	V-static	-0.0007	[-0.0142, +0.0125]	0.91738	1.00000
	DCS-OLA	-0.0066	[-0.0250, +0.0117]	0.48028	1.00000
	DCS-LCA	-0.0184	[-0.0391, +0.0022]	0.08194	1.00000
	KNORA-E	-0.0100	[-0.0278, +0.0081]	0.27618	1.00000
	KNORA-U	+0.0076	[-0.0094, +0.0250]	0.38194	1.00000
CART 50%	Equal6	-0.0304	[-0.0500, -0.0116]	0.00224	0.32256
	V-static	-0.0221	[-0.0378, -0.0064]	0.00594	0.80784
	DCS-OLA	-0.0299	[-0.0564, -0.0037]	0.02730	1.00000
	DCS-LCA	-0.0295	[-0.0570, -0.0013]	0.03868	1.00000
	KNORA-E	-0.0435	[-0.0666, -0.0212]	0.00026	0.03900
	KNORA-U	-0.0229	[-0.0426, -0.0036]	0.02194	1.00000
CART 80%	Equal6	-0.0003	[-0.0117, +0.0111]	0.95828	1.00000
	V-static	-0.0013	[-0.0130, +0.0104]	0.83052	1.00000
	DCS-OLA	+0.0026	[-0.0188, +0.0238]	0.80822	1.00000
	DCS-LCA	+0.0003	[-0.0203, +0.0205]	0.97564	1.00000
	KNORA-E	-0.0056	[-0.0224, +0.0113]	0.51062	1.00000
	KNORA-U	+0.0013	[-0.0107, +0.0134]	0.83722	1.00000
SHAP 50%	Equal6	-0.0220	[-0.0456, +0.0009]	0.06396	1.00000
	V-static	-0.0182	[-0.0375, +0.0012]	0.06578	1.00000
	DCS-OLA	-0.0033	[-0.0326, +0.0260]	0.82518	1.00000
	DCS-LCA	-0.0109	[-0.0406, +0.0191]	0.47292	1.00000
	KNORA-E	-0.0216	[-0.0487, +0.0047]	0.11142	1.00000
	KNORA-U	-0.0141	[-0.0372, +0.0088]	0.22560	1.00000
SHAP 80%	Equal6	-0.0000	[-0.0106, +0.0106]	0.99394	1.00000
	V-static	-0.0036	[-0.0173, +0.0106]	0.61462	1.00000
	DCS-OLA	-0.0041	[-0.0268, +0.0187]	0.71830	1.00000
	DCS-LCA	-0.0090	[-0.0342, +0.0163]	0.48298	1.00000
	KNORA-E	-0.0129	[-0.0307, +0.0050]	0.15408	1.00000
	KNORA-U	-0.0013	[-0.0139, +0.0112]	0.83592	1.00000

續下頁

表 A-4（續）

FS	方法	差值	95% 信賴區間	p	p_H
RFE 50%	Equal6	-0.0198	[-0.0415, +0.0016]	0.07106	1.00000
	V-static	-0.0141	[-0.0319, +0.0030]	0.11212	1.00000
	DCS-OLA	-0.0278	[-0.0560, -0.0002]	0.05066	1.00000
	DCS-LCA	-0.0286	[-0.0552, -0.0017]	0.03634	1.00000
	KNORA-E	-0.0378	[-0.0616, -0.0143]	0.00224	0.32256
	KNORA-U	-0.0125	[-0.0346, +0.0100]	0.26526	1.00000
RFE 80%	Equal6	+0.0022	[-0.0061, +0.0106]	0.59906	1.00000
	V-static	-0.0002	[-0.0091, +0.0087]	0.95992	1.00000
	DCS-OLA	+0.0115	[-0.0054, +0.0288]	0.18800	1.00000
	DCS-LCA	-0.0013	[-0.0188, +0.0167]	0.88422	1.00000
	KNORA-E	-0.0014	[-0.0150, +0.0128]	0.84648	1.00000
	KNORA-U	+0.0087	[-0.0028, +0.0202]	0.13506	1.00000

(資料來源：本研究實驗結果整理)

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

表 A-5 實驗二完整 F1 配對檢定：FS 減同方法 no-FS

FS	方法	差值	95% 信賴區間	p	p_H
MI 50%	Equal6	-0.0168	[-0.0461, +0.0125]	0.26002	1.00000
	V-static	-0.0395	[-0.0782, -0.0012]	0.04484	1.00000
	DCS-OLA	-0.0020	[-0.0289, +0.0247]	0.87992	1.00000
	DCS-LCA	-0.0277	[-0.0558, -0.0002]	0.05094	1.00000
	KNORA-E	-0.0244	[-0.0550, +0.0047]	0.10716	1.00000
	KNORA-U	+0.0004	[-0.0322, +0.0326]	0.97808	1.00000
MI 80%	Equal6	+0.0003	[-0.0195, +0.0204]	0.97596	1.00000
	V-static	-0.0092	[-0.0387, +0.0205]	0.54284	1.00000
	DCS-OLA	-0.0001	[-0.0228, +0.0229]	0.99524	1.00000
	DCS-LCA	-0.0182	[-0.0446, +0.0083]	0.17378	1.00000
	KNORA-E	-0.0057	[-0.0306, +0.0190]	0.65140	1.00000
	KNORA-U	+0.0105	[-0.0094, +0.0307]	0.29838	1.00000
CART 50%	Equal6	-0.0273	[-0.0523, -0.0026]	0.03006	1.00000
	V-static	-0.0413	[-0.0714, -0.0110]	0.00734	0.99090
	DCS-OLA	-0.0284	[-0.0531, -0.0033]	0.02524	1.00000
	DCS-LCA	-0.0331	[-0.0657, -0.0005]	0.04598	1.00000
	KNORA-E	-0.0396	[-0.0648, -0.0152]	0.00160	0.23360
	KNORA-U	-0.0196	[-0.0446, +0.0056]	0.12514	1.00000

續下頁

表 A-5（續）

FS	方法	差值	95% 信賴區間	p	p_H
CART 80%	Equal6	-0.0050	[-0.0234, +0.0134]	0.59386	1.00000
	V-static	-0.0034	[-0.0230, +0.0172]	0.73982	1.00000
	DCS-OLA	-0.0077	[-0.0311, +0.0160]	0.51782	1.00000
	DCS-LCA	-0.0076	[-0.0300, +0.0144]	0.49750	1.00000
	KNORA-E	+0.0019	[-0.0187, +0.0227]	0.85098	1.00000
	KNORA-U	+0.0092	[-0.0078, +0.0266]	0.29086	1.00000
SHAP 50%	Equal6	-0.0177	[-0.0453, +0.0091]	0.20082	1.00000
	V-static	-0.0488	[-0.0837, -0.0139]	0.00560	0.76720
	DCS-OLA	-0.0042	[-0.0380, +0.0294]	0.80980	1.00000
	DCS-LCA	-0.0270	[-0.0597, +0.0053]	0.10304	1.00000
	KNORA-E	-0.0190	[-0.0511, +0.0125]	0.24466	1.00000
	KNORA-U	-0.0109	[-0.0385, +0.0163]	0.43100	1.00000
SHAP 80%	Equal6	+0.0034	[-0.0173, +0.0243]	0.74344	1.00000
	V-static	-0.0152	[-0.0396, +0.0099]	0.22892	1.00000
	DCS-OLA	-0.0175	[-0.0401, +0.0047]	0.12432	1.00000
	DCS-LCA	-0.0357	[-0.0658, -0.0052]	0.01968	1.00000
	KNORA-E	-0.0119	[-0.0333, +0.0094]	0.27586	1.00000
	KNORA-U	+0.0103	[-0.0087, +0.0296]	0.28914	1.00000
RFE 50%	Equal6	-0.0238	[-0.0501, +0.0020]	0.07316	1.00000
	V-static	-0.0236	[-0.0579, +0.0112]	0.17734	1.00000
	DCS-OLA	-0.0170	[-0.0414, +0.0068]	0.16816	1.00000
	DCS-LCA	-0.0239	[-0.0461, -0.0020]	0.03312	1.00000
	KNORA-E	-0.0335	[-0.0599, -0.0076]	0.01218	1.00000
	KNORA-U	-0.0120	[-0.0391, +0.0146]	0.38550	1.00000
RFE 80%	Equal6	+0.0058	[-0.0083, +0.0197]	0.41802	1.00000
	V-static	-0.0058	[-0.0254, +0.0139]	0.56196	1.00000
	DCS-OLA	+0.0062	[-0.0123, +0.0246]	0.51236	1.00000
	DCS-LCA	-0.0076	[-0.0260, +0.0107]	0.41442	1.00000
	KNORA-E	-0.0057	[-0.0247, +0.0125]	0.55236	1.00000
	KNORA-U	+0.0128	[-0.0012, +0.0270]	0.07450	1.00000

(資料來源：本研究實驗結果整理)

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

表 A-6 實驗二完整 Recall 配對檢定：FS 減同方法 no-FS

FS	方法	差值	95% 信賴區間	p	p_H
MI 50%	Equal6	+0.0840	[+0.0358, +0.1326]	0.00098	0.14406
	V-static	+0.0282	[-0.0175, +0.0733]	0.22176	1.00000
	DCS-OLA	-0.0007	[-0.0528, +0.0498]	0.98046	1.00000
	DCS-LCA	-0.0819	[-0.1343, -0.0312]	0.00218	0.31610
	KNORA-E	+0.0181	[-0.0319, +0.0655]	0.46496	1.00000
	KNORA-U	+0.0192	[-0.0311, +0.0682]	0.44442	1.00000
MI 80%	Equal6	-0.0181	[-0.0479, +0.0115]	0.23144	1.00000
	V-static	+0.0819	[+0.0480, +0.1169]	0.00002	0.00330
	DCS-OLA	-0.0376	[-0.0774, +0.0021]	0.06376	1.00000
	DCS-LCA	-0.1098	[-0.1553, -0.0644]	0.00002	0.00330
	KNORA-E	-0.0080	[-0.0467, +0.0305]	0.68614	1.00000
	KNORA-U	+0.0059	[-0.0239, +0.0365]	0.69992	1.00000
CART 50%	Equal6	-0.0265	[-0.0640, +0.0103]	0.16214	1.00000
	V-static	+0.0397	[+0.0059, +0.0740]	0.02324	1.00000
	DCS-OLA	-0.0296	[-0.0742, +0.0155]	0.19342	1.00000
	DCS-LCA	-0.1847	[-0.2327, -0.1369]	0.00002	0.00330
	KNORA-E	-0.0244	[-0.0634, +0.0135]	0.21380	1.00000
	KNORA-U	-0.0519	[-0.0865, -0.0178]	0.00312	0.44304
CART 80%	Equal6	-0.0449	[-0.0714, -0.0190]	0.00062	0.09176
	V-static	+0.0338	[+0.0120, +0.0572]	0.00388	0.54708
	DCS-OLA	-0.0794	[-0.1179, -0.0405]	0.00006	0.00936
	DCS-LCA	-0.0767	[-0.1149, -0.0387]	0.00012	0.01860
	KNORA-E	-0.0077	[-0.0390, +0.0242]	0.63158	1.00000
	KNORA-U	-0.0042	[-0.0288, +0.0208]	0.74322	1.00000
SHAP 50%	Equal6	-0.0066	[-0.0486, +0.0348]	0.75364	1.00000
	V-static	+0.1021	[+0.0630, +0.1416]	0.00004	0.00632
	DCS-OLA	-0.0732	[-0.1280, -0.0187]	0.00824	1.00000
	DCS-LCA	-0.0777	[-0.1308, -0.0243]	0.00420	0.58380
	KNORA-E	-0.0314	[-0.0806, +0.0164]	0.20392	1.00000
	KNORA-U	+0.0111	[-0.0316, +0.0538]	0.60232	1.00000
SHAP 80%	Equal6	-0.0017	[-0.0320, +0.0294]	0.91182	1.00000
	V-static	+0.0690	[+0.0412, +0.0988]	0.00002	0.00330
	DCS-OLA	+0.0631	[+0.0155, +0.1105]	0.00968	1.00000
	DCS-LCA	-0.0916	[-0.1371, -0.0466]	0.00012	0.01860
	KNORA-E	-0.0181	[-0.0509, +0.0146]	0.27960	1.00000
	KNORA-U	+0.0136	[-0.0143, +0.0424]	0.34650	1.00000

續下頁

表 A-6（續）

FS	方法	差值	95% 信賴區間	p	p_H
RFE 50%	Equal6	+0.0042	[-0.0363, +0.0445]	0.84192	1.00000
	V-static	+0.0324	[-0.0097, +0.0755]	0.13518	1.00000
	DCS-OLA	-0.0516	[-0.0954, -0.0092]	0.02018	1.00000
	DCS-LCA	-0.0268	[-0.0724, +0.0185]	0.24660	1.00000
	KNORA-E	-0.0084	[-0.0500, +0.0323]	0.68754	1.00000
	KNORA-U	-0.0432	[-0.0808, -0.0068]	0.02212	1.00000
RFE 80%	Equal6	-0.0265	[-0.0473, -0.0060]	0.01218	1.00000
	V-static	+0.0516	[+0.0312, +0.0729]	0.00002	0.00330
	DCS-OLA	-0.0254	[-0.0577, +0.0067]	0.12222	1.00000
	DCS-LCA	-0.0366	[-0.0727, +0.0000]	0.04858	1.00000
	KNORA-E	-0.0118	[-0.0419, +0.0167]	0.42766	1.00000
	KNORA-U	-0.0056	[-0.0256, +0.0148]	0.58660	1.00000

(資料來源：本研究實驗結果整理)

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

一-7　年度資料分布與特徵選取明細

表 A-7 依實際公開檔計算各年度紀錄數與正類比例。核對作者 2022 年與 2024 年兩次公開資料，均為 78,682 筆、8,971 個識別碼；本地檔與目前公開檔的位元組也相同。原文的 8,262 公司數無法由兩次公開檔重建，本文因此報告公開識別碼數，保留說明文字與公開內容不一致的限制。status_label 在同一公司的所有年度保持相同，表中「破產標籤紀錄數」為最終狀態標籤的計數，不是該年度新增破產事件數；事件標籤的分區計數見表 3-5。

2022 年與更新版的公司、年度及狀態相同，但財務欄位的排列與數值不同。本文使用更新版的欄位順序，依作者公開研究附件的欄位名稱整理表 3-2，不將舊版的 X 編號直接套用到新資料，也未以固定倍率把兩版財務值強制轉成相同。既有模型均使用相同的本地更新版資料，本次只修正欄位說明，沒有變更模型輸入或重算測試分數。

表 A-7 各年度公司財務紀錄與破產標籤分布

年度	紀錄數	破產標籤紀錄數	破產標籤比例
1999	5,308	380	7.16%
2000	5,226	404	7.73%
2001	4,897	414	8.45%
2002	4,651	414	8.90%
2003	4,417	415	9.40%
2004	4,348	404	9.29%
2005	4,205	379	9.01%
2006	4,128	366	8.87%
2007	4,009	336	8.38%
2008	3,857	284	7.36%
2009	3,743	234	6.25%
2010	3,625	218	6.01%
2011	3,513	194	5.52%
2012	3,485	182	5.22%
2013	3,484	167	4.79%
2014	3,504	142	4.05%
2015	3,354	111	3.31%
2016	3,191	83	2.60%
2017	3,014	57	1.89%
2018	2,723	36	1.32%

(資料來源：本研究依實際使用資料整理)

比例以公司年度紀錄計算，並非該年度新增破產事件率。

表 A-8 與表 A-9 統計事件標籤下，每個財務特徵在十個種子中被選取的次數。每

個 FS 條件的特徵數固定為 9 或 14 個，但特徵名稱可能隨種子而異。此處只描述已完成的選取結果，不把跨種子出現頻率另組成新的特徵子集。

表 A-8 實驗二特徵入選種子數（X1–X9）

FS 設定	X1	X2	X3	X4	X5	X6	X7	X8	X9
MI 50%	10	0	0	9	0	10	10	0	1
MI 80%	10	0	0	10	0	10	10	6	9
CART 50%	10	10	0	10	10	0	0	0	0
CART 80%	10	10	0	10	10	10	10	0	10
SHAP 50%	10	0	0	0	10	10	0	0	10
SHAP 80%	10	0	10	0	10	10	0	10	10
RFE 50%	10	10	0	10	10	0	0	0	0
RFE 80%	10	10	10	10	10	0	10	0	10

(資料來源：本研究事件標籤各種子特徵選取結果)

數值為十個種子中入選的次數；此表僅描述已選特徵，不據此重新挑選 Test 最佳子集。

表 A-9 實驗二特徵入選種子數（X10–X18）

FS 設定	X10	X11	X12	X13	X14	X15	X16	X17	X18
MI 50%	3	10	10	0	0	10	10	0	7
MI 80%	10	10	10	5	10	10	10	10	10
CART 50%	10	10	10	0	0	10	10	0	0
CART 80%	10	10	10	10	0	10	10	0	10
SHAP 50%	10	10	10	0	0	10	10	0	0
SHAP 80%	10	10	10	10	10	10	10	0	10
RFE 50%	10	10	10	0	0	10	10	0	0
RFE 80%	10	10	10	10	0	10	10	0	10

(資料來源：本研究事件標籤各種子特徵選取結果)

數值為十個種子中入選的次數；此表僅描述已選特徵，不據此重新挑選 Test 最佳子集。