國　立　中　央　大　學

資　訊　管　理　學　系

碩　士　論　文

企業破產預測模型之比較研究（示範題目）

研　究　生：　研究生姓名

指導教授：　指導教授姓名

中華民國一一六年六月

國　立　中　央　大　學

資　訊　管　理　學　系

碩　士　論　文

企業破產預測模型之比較研究（示範題目）

研　究　生：　研究生姓名

指導教授：　指導教授姓名

中華民國一一六年六月

企業破產預測模型之比較研究（示範題目）

摘　要

本論文中文摘要示範文字。正式稿應依中央大學要求，說明研究目的、資料來源、研究方法與研究結果，約三百至五百字。本文僅展示格式，並不代表已完成研究或獲得實驗結論。

關鍵字：企業破產預測、機器學習、分類器比較、資料不平衡

A Comparative Study of Bankruptcy Prediction Models (Example)

ABSTRACT

This is placeholder text for the English abstract. Replace it with an approximately 300–500-word abstract describing the research objectives, data sources, methods, and empirical findings. Do not treat this sample as a completed abstract.

Keywords: bankruptcy prediction, machine learning, classification, class imbalance

誌謝

此頁為選填的誌謝示例。若不需要誌謝，請於 main.tex 註解相應的 \input 指令。

目錄

中文摘要 . . . . . **i**

英文摘要 . . . . . **ii**

誌謝 . . . . . **iii**

目錄 . . . . . **iv**

圖目錄 . . . . . **vi**

表目錄 . . . . . **vii**

符號說明 . . . . . **viii**

一、 緒論 **1**

1-1 研究背景與動機 1

1-2 研究目的 1

1-3 研究架構 1

二、 文獻探討 **2**

2-1 資料不平衡的處理方法 2

2-2 可解釋人工智慧 2

三、 研究方法 **3**

3-1 研究架構 3

3-2 實驗一：Baseline 與集成分類器比較 5

3-2-1 Baseline 分類器比較 5

3-2-2 Old ／ New 集成分類器比較 8

3-3 實驗二：特徵選取集成分類器比較 13

3-3-1 特徵選取方法 13

3-3-2 特徵選取與模型訓練流程 14

3-3-3 特徵選取後的集成比較 15

3-4 實驗設定與參數 15
3-4-1 資料來源與驗證設定 15
3-4-2 Baseline 分類器之超參數設定 18
3-4-3 實驗二之特徵選取參數 21
3-4-4 集成模型之固定設定 22
3-5 實驗驗證準則 22
3-5-1 訓練、驗證與測試程序 22
3-5-2 分類效能評估指標 23
3-5-3 結果彙整與模型比較 24
3-5-4 公司群聚配對統計檢定 25

四、 實驗設計與結果 27
4-1 統計分析資料與比較範圍 27
4-2 實驗一：固定年份集成比較 27
4-3 實驗二：FS 集成比較 29
4-4 統計推論範圍與限制 30

五、 結論與未來研究 31
5-1 研究結論 31
5-2 研究限制與未來方向 31

參考文獻 32

附錄一 實驗補充設定與統計檢定 34
一-1 兩項實驗之資料與紀錄規格 34
一-2 Baseline 超參數與訓練控制 34
一-3 軟體環境與隨機性控制 36
一-4 實驗完成範圍與比較限制 37
一-5 公司群聚配對檢定完整結果 38
一-6 年度資料分布與特徵選取明細 44

圖目錄

圖 1　本研究兩項實驗之整體架構 4
圖 2　實驗一之 Baseline 分類器比較架構 5
圖 3　實驗一之 Old ／ New 集成分類器架構 8
圖 4　實驗二之特徵選取集成分類器架構 13

表目錄

表 1　兩項實驗之研究架構與比較目的 3
表 2　集成比較之固定年份資料分區 9
表 3　Old ／ New 六模型池組成 9
表 4　不同模型數量的 Old ／ New 混合靜態組合 10
表 5　特徵選取方法與操作方式 14
表 6　本研究使用之財務特徵 17
表 7　兩項實驗資料與驗證設定摘要 17
表 8　Baseline 傳統分類器之超參數候選集合 19
表 9　Baseline TabM 之超參數候選集合 20
表 10　實驗二特徵選取之主要參數與執行規則 21
表 11　集成模型之主要方法與參數 22

表 12　實驗一固定年份集成之 pooled 結果 27
表 13　實驗一各集成方法相對 Equal6 之 AUC 配對檢定 28
表 14　實驗二各 FS 設定相對同方法 no-FS 之 AUC 差值 29

表 15　Baseline 已保存之驗證 AUC 紀錄彙整 35
表 16　TabM 補充搜尋預算與訓練控制 35
表 17　TabICL 補充固定參數預設值 36
表 18　本研究本機設備與固定年份執行設定 36
表 19　實驗一完整配對檢定：各方法減 Equal6 38
表 20　實驗二完整 AUC 配對檢定：FS 減同方法 no-FS 39
表 21　實驗二完整 F1 配對檢定：FS 減同方法 no-FS 40
表 22　實驗二完整 Recall 配對檢定：FS 減同方法 no-FS 42
表 23　各年度公司財務紀錄與破產標籤分布 44
表 24　實驗二特徵入選種子數（X1–X9） 45
表 25　實驗二特徵入選種子數（X10–X18） 45

符號說明

x	公司年度財務特徵向量。
$y, \hat{y}$	實際標籤與預測標籤；破產類別為正類。
$p_i(x)$	第 i 個基礎分類器對正類的預測機率。
$S, \lvert S \rvert$	靜態集成的成員集合及其模型數量；統計比較式中的 S 另表示種子數。
$p_S(x)$	子集 S 的等權集成機率。
τ	分類門檻。
TP, TN	真陽性與真陰性樣本數。
FP, FN	假陽性與假陰性樣本數。
TPR, FPR	真陽性率與假陽性率。
AUC	ROC 曲線下面積。
AP	平均精確率。
Precision	正類預測的精確率。
Recall	正類召回率。
F1	Precision 與 Recall 的調和平均數。
B	統計推論的 bootstrap 重抽次數。
Δ	兩種模型在指定指標上的差值。

一、 緒論

1-1 研究背景與動機

本文件是中央大學資訊管理學系碩士論文的排版示範；所有研究內容均為示例，請自行取代。透過 LaTeX 可以自動維護目錄、表格、圖形、公式與參考文獻。

1-2 研究目的

研究目標請依自己的論文主題改寫，不應沿用樣板內容。

1-3 研究架構

本研究章節依序包括文獻探討、研究方法、實驗設計與結果，以及結論。

二、 文獻探討

2-1 資料不平衡的處理方法

Chawla 等人提出 SMOTE 方法〔1〕；引用請由 Zotero 匯出 `references.bib` 並核對原文。

2-2 可解釋人工智慧

SHAP 的經典研究由 Lundberg 與 Lee 提出〔2〕。這裡只作為 BibLaTeX 引用示例。

三、 研究方法

3-1 研究架構

企業的財務狀況與營運環境會隨時間改變，較早年度資料所建立的分類規則，未必適用於較晚年度。近期資料較接近測試期間，但可用樣本也較少。本研究關心的是：在破產樣本相對有限的情況下，歷史與近期資料應如何搭配，才能辨識較晚年度的破產類別。

實驗安排如圖 1 所示。實驗一包含單一分類器的 Baseline 比較，以及固定使用 XGBoost 的 Old ／ New 集成比較。Baseline 用來觀察訓練期間與採樣方式的影響；集成部分則控制基礎演算法，將比較重點放在模型成員與整合規則。實驗二沿用相同的 XGBoost 設定，加入特徵選取後重新訓練，觀察保留不同財務特徵時，預測結果如何改變。

表 1 列出兩項實驗的比較內容。Baseline 與集成是實驗一的兩個部分；實驗二則以未進行特徵選取的集成結果為對照。模型均依各部分的資料分區重新訓練。

表 1 兩項實驗之研究架構與比較目的

實驗	主要變動因素	比較目的	實驗間之銜接
實驗一：Baseline 與集成比較	分類器、訓練期間、採樣方式及模型組成	建立單模型基準，分析 Old ／ New 模型的集成方式	提供實驗二未進行 FS 的集成對照
實驗二：FS 集成比較	特徵選取方法及保留數	比較加入 FS 後的集成分類效能	沿用實驗一集成設定，進行同條件配對比較

資料來源：本研究整理。

本研究以公司年度財務紀錄為觀測單位，直接使用公開資料中的公司層級存續或破產狀態，並將破產設為正類。實際檔案中，同一家公司的狀態在所有觀測年度都相同；此標籤不是每個年度分別判定的次年破產事件。模型輸入只包含財務特徵，公司識別碼、年度及標籤不納入預測。由於同一公司可能跨訓練與測試年度出現，結果解釋為既有資料中較晚年度的公司狀態分類，未涵蓋未見公司的測試，也不據此宣稱提前一年預測能力。資料版本與標籤核對詳見第 3-4-1 節。



圖 1 本研究兩項實驗之整體架構

資料來源：本研究。

最終測試以 ROC 曲線下面積（Area Under the ROC Curve, AUC）為主要報告指標，並以 F1-score 與 Recall 補充破產類別的辨識表現。實驗一之集成比較與實驗二另以平均精確率（Average Precision, AP）選擇靜態集成候選，並依驗證資料的 F1-score 決定分類門檻。候選選擇、門檻決定與測試報告分別具有不同用途，其規則於後續各節說明。

3-2　實驗一：Baseline 與集成分類器比較

實驗一先觀察單一分類器使用哪些年度資料、搭配何種採樣方式時有較好的表現，再比較六模型池的整合方式。Baseline 採年內驗證，集成比較則完整保留 2014 年作驗證，兩部分的分數須連同各自的資料條件解讀。

3-2-1　Baseline 分類器比較

Baseline 的流程如圖 2。各分類器分別使用 Old、New 或合併資料訓練，並搭配四種採樣設定，作為單一模型的比較基準。

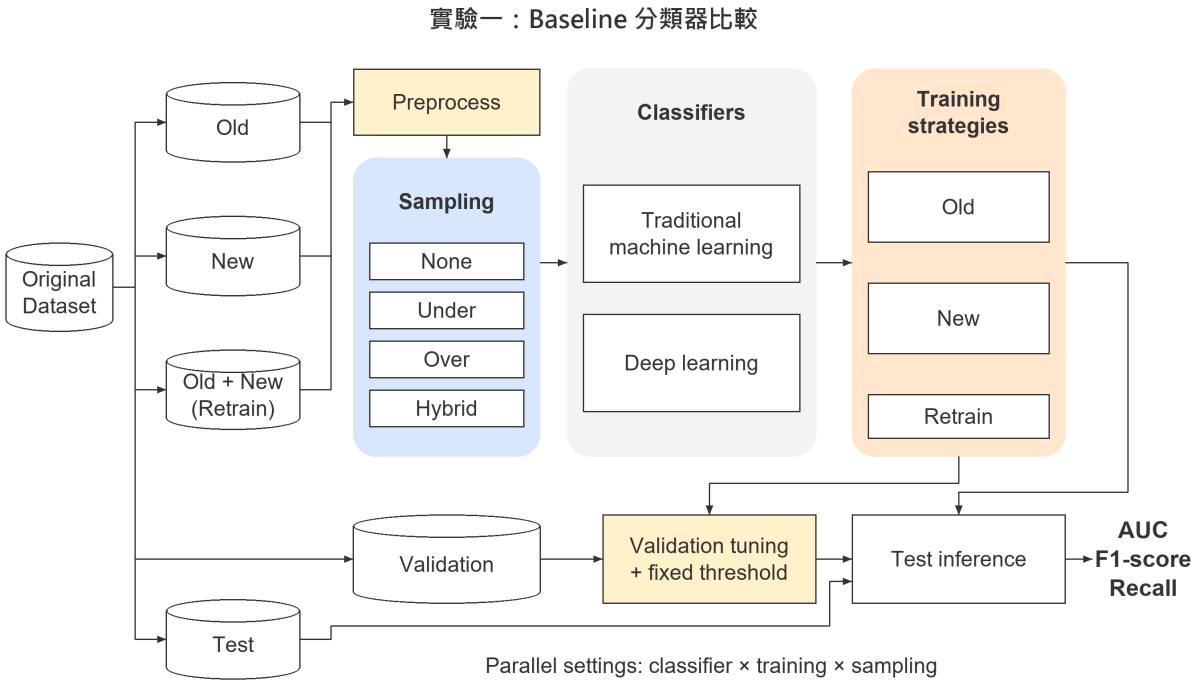


圖 2 實驗一之 Baseline 分類器比較架構

資料來源：本研究。

1. 實驗資料與年份切分

本研究使用 1999 年至 2018 年之公司年度財務資料，將 1999 年至 2014 年設定為模型建立期間，2015 年至 2018 年固定作為測試期間。為分析歷史與近期資料範圍對分類結果的影響，本部分逐年移動 Old ／ New 分界，形成 15 組年份設定。

令 b 為 Old 期間的最後一年，則各組資料期間定義為：

$$\begin{aligned} \text{Old}(b) &= \{1999, \ldots, b\}, \\ \text{New}(b) &= \{b+1, \ldots, 2014\}, \\ b &\in \{1999, \ldots, 2013\}. \end{aligned} \tag{1}$$

因此，最早一組為 Old 使用 1999 年、New 使用 2000 年至 2014 年；最晚一組為 Old 使用 1999 年至 2013 年、New 使用 2014 年。各組皆保留至少一年的 Old 與 New 資料。

在內層驗證方面，既有 Baseline 比較流程從對應訓練期間的各年份資料中抽取約 20% 樣本作為驗證資料，其餘作為實際擬合資料。Old 與 New 分別依其期間建立擬合與驗證分區；Retrain 則合併兩側的擬合資料及驗證資料。前處理與採樣於切分後執行，驗證資料用於相關設定與門檻的決定。

此年內抽樣方式使擬合與驗證資料可能涵蓋相同年份，與實驗一之集成比較與實驗二完整保留 2014 年作為驗證期間的方式不同。因此，15 組設定主要用於觀察訓練期間敏感度；跨比較設定分數的比較另須考量驗證制度與資料可用範圍的差異。

2. 分類器與訓練策略

候選分類器涵蓋傳統機器學習與以神經網路為基礎的表格模型，包括 Logistic Regression、Random Forest、XGBoost、LightGBM、TabM 與 TabICL。主要超參數設定列於本章，補充訓練控制與後端版本說明見附錄 附錄一。

本部分比較三種訓練策略。Old 僅使用歷史期間的擬合資料，評估歷史資訊對較晚年度樣本的適用程度；New 使用近期期間的擬合資料，評估近期資訊所建立的分類能力；Retrain 合併 Old 與 New 的擬合資料，從頭訓練單一模型，作為使用完整可用訓練期間的比較基準。

本章以 New 表示使用近期資料建立的模型分支。模型是否延續舊模型權重屬於不同的訓練程序，相關名稱與版本的區分見附錄 附錄一。

3. 資料前處理與採樣策略

資料前處理包含依各分類器流程執行的遺失值處理與數值縮放。需由資料估計的參數僅使用對應的擬合資料計算，再將固定轉換套用於驗證與測試資料。不同前處理設定之比較界線見附錄 附錄一。

採樣設定包含不採樣（None）、低採樣（Under-sampling）、過採樣（Over-sampling）與混合採樣（Hybrid Sampling）。不採樣保留原始類別分布；其餘設定分別透過樣本刪

減、少數類別樣本生成，或兩者結合，改變模型實際使用的訓練資料。採樣僅作用於擬合資料，驗證與測試資料均保留原始類別分布。

本研究採用的代表方法為 TomekLinks、ADASYN 與 SMOTEENN。TomekLinks 依近鄰關係移除類別邊界附近的指定樣本，其作用偏向邊界清理，不能視為固定將兩類樣本調整至相同比例。各方法的參數列於實驗設定，補充版本說明見附錄。

4. 驗證結果彙整與集成基底定位

本部分的比較單位為「分類器 × 年份邊界 × 訓練策略 × 採樣方式」。各候選的超參數與分類門檻由訓練及驗證資料決定，固定後再於 2015 年至 2018 年資料計算 AUC、F1-score 與 Recall；後續集成的演算法種類另採固定 XGBoost 設計。

XGBoost、LightGBM、Random Forest、Logistic Regression 與 TabM 以驗證 AUC 選擇各設定的超參數，候選值列於第 3-4-2 節。彙整時，Old 與 New 分開計算：先在同一年份邊界內等權平均四種採樣的驗證 AUC，再等權平均 15 組邊界。Retrain 使用相同的完整訓練期間，每種採樣只有一筆設定，因此只平均四種採樣，不將其重複計為 15 次。已保存的驗證結果整理於附錄表 15；缺少驗證紀錄者保留缺值。

後續集成與 FS 實驗將 XGBoost 定位為固定研究基底，不以本次歷史驗證彙整宣稱其為最佳分類器。不同 Baseline 版本的搜尋預算與資料處理未完全一致，不能由這些平均值建立公平的演算法排名。固定 XGBoost 可使六模型池只因訓練期間、採樣方式與特徵條件而改變，較容易判讀集成規則與 FS 的影響。XGBoost 為樹提升方法〔3〕，本研究的二元機率輸出也能直接供靜態平均及動態選擇使用。這批集成模型的演算法種類與參數在重播測試及統計分析時均維持既定值，未依 Test 表現回選基底。

由於 15 組設定共用測試期間，且訓練資料高度重疊，各組分數具有相依性。分析時以期間敏感度與描述性差異為主，不將其視為 15 次彼此獨立的驗證。分類器選擇與固定設定的比較限制見附錄 附錄一。

3-2-2　Old ／ New 集成分類器比較

實驗一的集成部分固定基礎分類器種類，分析不同資料期間與採樣方式所形成模型的整合表現。本部分使用 XGBoost 建立 Old ／ New 模型池，比較靜態集成、DCS 與 DES，架構如圖 3 所示。

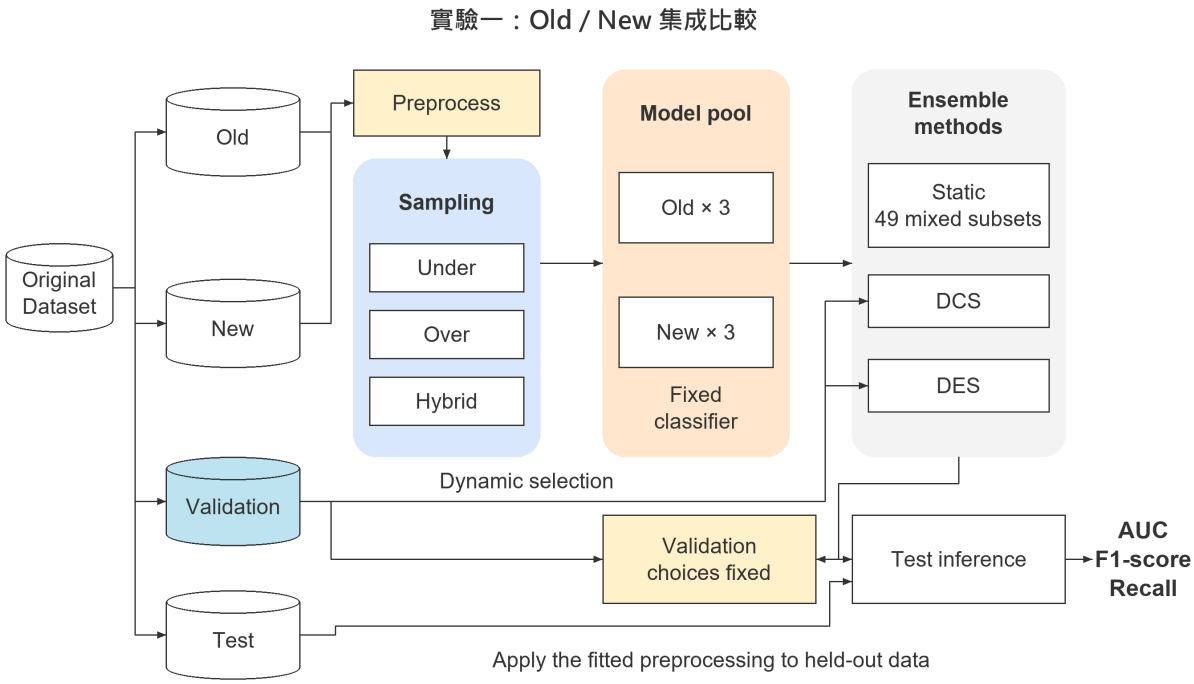


圖 3 實驗一之 Old ／ New 集成分類器架構

資料來源：本研究。

圖中 Validation 為驗證用途的概括表示；實際分為互不重疊的 DSEL 與 Calibration。前者估計局部分類能力，後者選擇靜態候選及分類門檻。

1. 實驗資料切分

本部分以 1999 年至 2011 年為 Old 訓練期間，2012 年至 2014 年為名義上的 New 營運期間，並固定 2015 年至 2018 年為測試期間。其中，2014 年完整保留供驗證使用，因此 New 模型實際以 2012 年至 2013 年資料進行擬合。

這組界線以原資料研究所使用的 1999–2011、2012–2014 與 2015–2018 年區間為參考〔4〕，讓各方法都在同一個較晚期間接受測試。本研究將其中 2012–2013 年改供 New 模型學習近期資訊，再保留測試前最近的 2014 年建立 DSEL 與 Calibration。因此，本研究與原文具有相近的年份邊界，但模型可用的訓練資料不同，不直接比較兩者分數。2011 年切點是固定的歷史／近期比較條件，不是由 Test 搜尋得到的最佳年份。

2014 年資料以固定隨機種子 42，依類別標籤分層切分為等量且互不重疊的動態選

擇資料集（Dynamic Selection Dataset, DSEL）與校準資料集（Calibration）。DSEL 提供動態方法估計局部分類能力；Calibration 用於靜態候選選擇與分類門檻決定，兩者均不加入基礎分類器的擬合資料。

表 2 集成比較之固定年份資料分區

分區	年份	公司年度紀錄數	正類紀錄數	主要用途
Old-fit	1999–2011	55,927	4,442	Old 模型訓練；前處理與特徵選取擬合
New-fit	2012–2013	6,969	349	New 模型訓練
DSEL	2014	1,752	71	動態選擇的局部分類能力估計
Calibration	2014	1,752	71	靜態候選選擇與分類門檻決定
Test	2015–2018	12,282	287	設定固定後的最終評估
合計	1999–2018	78,682	5,220	五個分區在資料列上互斥

資料來源：本研究實驗資料分區彙整。表中數值為公司年度紀錄數，並非各分區獨立公司數。

Calibration 在本文指用來選擇靜態成員與分類門檻的資料，沒有額外執行機率校準。DSEL 與 Calibration 均取自 2014 年；資料未提供更細的公開時間，兩者只有用途上的區分，沒有年內先後順序。

2. 基礎模型池建立

本部分先於 Old-fit 估計各財務特徵的平均數，以進行遺失值補值，再以補值後的 Old-fit 擬合標準化參數。相同轉換一致套用於 New-fit、DSEL、Calibration 與 Test，使六個基礎模型及動態方法使用共同的特徵表示。

完成前處理後，Old-fit 與 New-fit 各自執行 TomekLinks、ADASYN 及 SMOTEENN，並分別重新訓練分類器，形成表 3 所示的六模型池。實驗一之集成比較使用完整 18 個財務特徵；分類器本身不另加入類別權重，以採樣方式作為本部分的類別不平衡處理因素。

表 3 Old ／ New 六模型池組成

模型名稱	擬合資料	採樣方法
Old_under	Old-fit	TomekLinks
Old_over	Old-fit	ADASYN

續下頁

表 3（續）

模型名稱	擬合資料	採樣方法
Old_hybrid	Old-fit	SMOTEENN
New_under	New-fit	TomekLinks
New_over	New-fit	ADASYN
New_hybrid	New-fit	SMOTEENN

資料來源：本研究整理。

六個模型都使用 XGBoost，差別在於訓練年度與採樣後的資料。集成比較據此檢查：這些模型的差異是否能補足彼此的預測錯誤。

3. 靜態集成方法

靜態集成於推論前固定成員組合，並以成員對破產正類的預測機率進行等權平均。令模型池中的三個 Old 模型集合為 $\mathcal{O}$，三個 New 模型集合為 $\mathcal{N}$，則混合候選子集須滿足：

$$S \subseteq \mathcal{O} \cup \mathcal{N}, \qquad S \cap \mathcal{O} \neq \varnothing, \qquad S \cap \mathcal{N} \neq \varnothing. \tag{2}$$

Old 與 New 各有 $2^3 - 1$ 個非空子集，因此混合組合數為：

$$(2^3 - 1)(2^3 - 1) = 49. \tag{3}$$

表 4 不同模型數量的 Old ／ New 混合靜態組合

集成模型數量	混合組合數
2	9
3	18
4	15
5	6
6	1
合計	49

資料來源：本研究整理。

對任一候選子集 S，集成機率定義為：

$$\hat{p}_S(x) = \frac{1}{|S|} \sum_{i \in S} \hat{p}_i(x), \tag{4}$$

其中，$\hat{p}_i(x)$ 為第 i 個分類器對樣本 x 預測為破產的機率，$|S|$ 為該子集的模型數。

除混合候選外，另保留六個單模型，以及三個 Old 模型的等權集成 Old3、三個 New 模型的等權集成 New3，作為比較基準。完整六模型的等權集成稱為 Equal6，其成員組合已包含在 49 種混合候選之中，不額外增加混合組合數。Old3 與 New3 為單一期間控制組，均不納入 49 種跨期間混合候選的選擇範圍。

4. 動態分類器與集成選擇

動態選擇依待預測樣本的鄰近區域評估基礎模型的分類能力。本研究以完整六模型池為候選來源，使用獨立 DSEL 建立局部能力估計，並比較動態分類器選擇（Dynamic Classifier Selection, DCS）與動態集成選擇（Dynamic Ensemble Selection, DES）。

DCS 比較 Overall Local Accuracy（OLA）與 Local Class Accuracy（LCA）。OLA 以分類器在樣本鄰近區域的整體正確率估計其能力；LCA 則依各分類器對待預測樣本所判定的類別，估計相應的局部分類能力。兩者原則上選擇局部能力最高的單一分類器，平手時依固定模型順序選擇。

DES 比較 k-Nearest Oracles Eliminate（KNORA-E）與 k-Nearest Oracles Union（KNORA-U）。KNORA-E 尋找能正確分類鄰近區域所有樣本的分類器，必要時縮小鄰域；KNORA-U 則選取至少能正確分類一個鄰近樣本的分類器，並依其局部正確分類次數形成貢獻權重。兩者依所選分類器產生最終集成輸出。

本研究使用 DESlib 0.3.7 的標準實作，鄰居數固定為 $k = 7$；DES 採機率軟投票，DCS 使用 best 選擇規則，並關閉額外的動態剪枝與樣本難度分流。當所有基礎分類器對某樣本的類別判斷一致時，沿用套件直接平均機率的處理。因此，DCS 的單分類器選擇描述適用於需要進行局部選擇的情況，不能推定每個樣本的輸出皆來自單一模型。

上述方法的標準定義分別參見 DESlib 的 OLA〔5〕、LCA〔6〕、KNORA-E〔7〕與 KNORA-U〔8〕文件；本研究的實際版本與開關設定以正式執行紀錄為準。

5. 集成候選選擇與分類門檻

靜態候選與分類門檻均由 Calibration 決定。首先，對 49 種混合靜態候選計算 Calibration AP，選出 AP 最高者，記為 ValidationSelectedStatic。若 AP 相同，依固定的方法名稱字典序決定，以維持選擇結果的可重現性。保留所有候選的測試表現可供組成分析，但不再依 Test 排名回選候選。

其次，各單模型、控制組、靜態候選與動態方法，均在 Calibration 上搜尋 F1-score 最高的分類門檻。門檻候選集合為：

$$\mathcal{T} = \{0.01, 0.02, \ldots, 0.99\}, \qquad \tau_m^* = \arg\max_{\tau \in \mathcal{T}} F1_{\text{Calibration}}(m, \tau). \tag{5}$$

若多個門檻得到相同的最高 F1-score，採用其中最小者。分類時以 $\hat{p}_m(x) \geq \tau_m^*$ 判定為正類；ValidationSelectedStatic 沿用其所選候選的門檻。

候選與門檻固定後，於 Test 計算整體及各年度的 AUC、F1-score 與 Recall。各方法在四個測試年度均沿用相同的 Calibration 門檻，不利用年度測試標籤重新調整。

Retrain 在研究架構中定位為 Old-fit 與 New-fit 合併訓練的獨立基準，不納入六模型池。其比較須另以相同資料可用範圍、採樣及驗證規則建立；其完成範圍與同協定比較限制詳見附錄 附錄一。

3-3 實驗二：特徵選取集成分類器比較

實驗二檢查全部 18 個財務特徵是否都有保留的必要。資料分區、XGBoost 設定、採樣方式與集成方法沿用實驗一，只在採樣之前加入特徵選取，再重新建立模型池。流程如圖 4 所示。

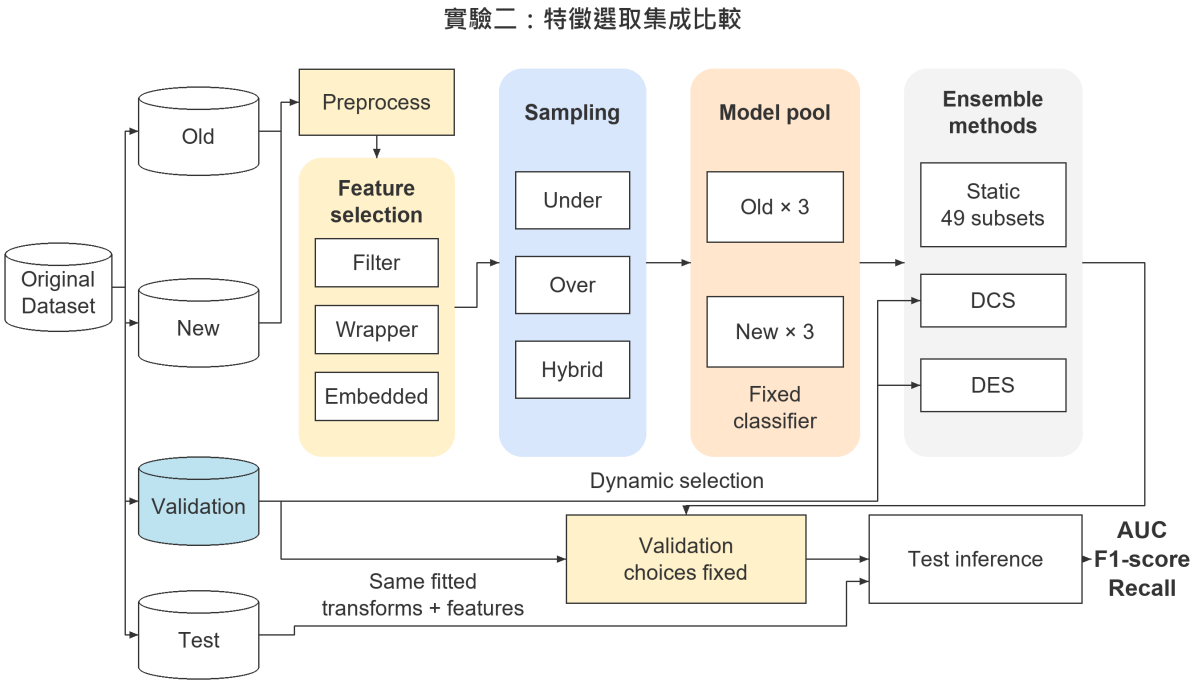


圖 4 實驗二之特徵選取集成分類器架構

資料來源：本研究。

各 FS 方法平行執行；SHAP 為模型解釋後的特徵排序，其定位另於正文說明。DSEL 與 Calibration 維持實驗一集成部分的分配。

3-3-1 特徵選取方法

特徵選取可依機制概分為過濾式（Filter）、包裝式（Wrapper）及嵌入式（Embedded）。本研究的具體設定為互資訊（Mutual Information, MI）、分類與迴歸樹（Classification and Regression Tree, CART）、遞迴特徵消除（Recursive Feature Elimination, RFE），以及以 SHAP 貢獻值排序的特徵選取。各方法獨立執行，不依序串接。

表 5 特徵選取方法與操作方式

方法	方法定位	特徵選取依據
MI	Filter	計算各特徵與分類標籤的互資訊，依分數選取前 k_{FS} 個特徵
CART	模型重要性篩選，對應 Embedded 類	以決策樹學得的特徵重要性排序，選取前 k_{FS} 個特徵
RFE	Wrapper	以決策樹反覆擬合並移除特徵，直至保留指定數量
SHAP 排序	模型解釋後的特徵篩選	以 LightGBM 計算訓練樣本的樹模型貢獻值，依平均絕對值排序選取特徵

資料來源：本研究整理。

MI 與 RFE 由 scikit-learn 實作〔9〕。SHAP 排序則使用 LightGBM 的樹模型貢獻值：先排除基準值欄位，再以各特徵的平均絕對貢獻值排序〔10〕。它是模型解釋後的篩選程序，與直接依樹模型重要性選取的 CART 分開比較。

各方法分別設定保留比例 $r = 0.5$ 與 $r = 0.8$，特徵數依下式決定：

$$k_{\mathrm{FS}} = \max\{1, \lfloor d \times r \rfloor\}, \tag{6}$$

其中，$d = 18$ 為原始財務特徵數。因此，兩種設定分別保留 9 與 14 個特徵；80% 為名義比例，實際保留數依向下取整規則計算。四種方法各有兩種保留設定，共形成八種特徵選取條件，另以完整 18 特徵作為對照。

50% 用來觀察刪去約半數特徵的結果，80% 則代表保留大部分特徵、僅作較小幅度刪減的條件。四種方法共用兩種保留數，可以在相近的特徵數量下比較不同選取規則；no-FS 則提供不刪減特徵的基準。這兩個比例是固定的實驗設計值，沒有依 Calibration 或 Test 最佳化，也不代表所有可能比例中的最適解。

3-3-2 特徵選取與模型訓練流程

本部分的處理順序固定為「資料分區 → 前處理 → 特徵選取 → 採樣 → 模型訓練」。補值與標準化參數先以 Old-fit 擬合，再於轉換後的 Old-fit 執行各特徵選取方法。所選特徵及欄位順序固定後，一致套用於 New-fit、DSEL、Calibration 與 Test。

先選特徵再採樣，使選取器看到的是 Old-fit 原始樣本。CART、RFE 的決策樹及 SHAP 排序使用的 LightGBM 仍採平衡類別權重，降低少數類別在特徵評分時被忽略的

可能；MI 則直接估計特徵與標籤的互資訊。選取器與後續 XGBoost 基礎模型的參數分開設定，詳見第 3-4-3 節。

完成特徵選取後，Old-fit 與 New-fit 分別執行三種採樣，再訓練三個 Old 與三個 New 分類器。各特徵條件均重新建立六模型池，以確保模型於對應的輸入空間中學習。

同一特徵條件下，六模型、DSEL 與其他評估分區使用共同特徵集合；不同特徵條件則各自重新建立動態選擇器。由於特徵選取也會改變 DSEL 的距離計算空間，其影響可能同時來自基礎分類器與局部鄰域的改變。

3-3-3 特徵選取後的集成比較

各特徵條件均沿用實驗一之集成比較的 49 種混合靜態子集、Old3、New3、Equal6 與四種動態方法。DSEL 的資料列分配維持一致；Calibration 分別用於該條件的靜態候選選擇與門檻決定，Test 則使用相同樣本計算最終指標。

FS 與 no-FS 使用相同種子及測試樣本配對。固定方法的比較保持集成規則與模型成員一致；驗證選定靜態集成則在各 FS 條件下重新依 Calibration 選擇成員。後者的差值同時包含特徵選取與靜態成員改變的影響。

對任一固定方法 m 與指標 M，配對差值定義為：

$$\Delta M_{s,m,f} = M_{s,m,f} - M_{s,m,\text{no_fs}}, \tag{7}$$

其中，s 表示相同隨機種子，f 表示特徵選取條件。正值表示該指標高於未進行特徵選取的對照。即使模型成員固定，各條件的分類門檻仍依各自的 Calibration 決定，因此 F1-score 與 Recall 差異反映特徵選取、重新訓練及門檻選擇後的整體結果。除效能外，亦記錄所選特徵名稱、順序與數量，以保留結果追溯依據。

3-4 實驗設定與參數

3-4-1 資料來源與驗證設定

本研究使用原作者公開的美國企業破產資料，研究背景參照 Lombardo 等人〔4〕，實際資料採作者於 2024 年 4 月 10 日更新的公開版本〔11〕。本次以固定版本下載核對，本地檔與作者公開檔的 SHA-256 完全相同，因此下述筆數與標籤不是本地合併或改寫所產生。資料涵蓋 1999–2018 年；`status_label` 的 `failed` 設為正類 1，`alive` 設為負類 0。

實際使用的資料共有 78,682 筆紀錄與 8,971 個匿名公司識別碼，其中 5,220 筆為正

類，占 6.63%。多數類與少數類紀錄數的比值為 14.07。原始文獻與資料介紹寫 8,262 家公司，但 2022 年首次公開檔與 2024 年更新檔均可數得 8,971 個識別碼，兩版的公司、年度與狀態欄也一致。因此，這是原始說明與公開資料內容不一致，並非 2024 年增加公司或本研究處理資料造成。作者未提供可將 8,971 個匿名識別碼對應至 8,262 家真實公司的名單，本文以可重建的公開識別碼數作為統計口徑。

5,220 筆正類紀錄來自 609 個公司識別碼；同一識別碼在所有年度都維持相同狀態。原文描述的次年事件標籤，與本研究實際取得的年度重複狀態並不相同。公開檔未提供可逐筆核對的破產申請日期，故本研究不重建事件日或改寫標籤，而以原公開狀態進行回溯性分類。上述正類比例不是每年新增破產事件率。

載入資料時檢查公司與年度組合是否重複，並確認 18 個財務欄位的有效值。目前資料未出現重複公司年度紀錄、遺失值或無限值，因此沒有因這些問題刪除紀錄。流程仍保留平均數補值器，以維持各設定相同的前處理順序。補值與標準化的參數均依各實驗允許的擬合分區估計。

模型只使用 X1–X18，欄位意義見表 6。2024 年公開版的欄位順序及數值與 2022 年版不同，本文依公開研究附件的欄位名稱及跨版本數值對照整理，未直接沿用 2022 年文獻表中的 X 編號〔12〕。本研究保留實際使用版本的數值及欄位順序，未另依舊版倍率換算。公司識別碼、年度、標籤及產業分類均不作預測特徵，也未新增財務比率、股價或落後期特徵。

表 6 本研究使用之財務特徵

欄位	財務項目
X1	流動資產
X2	資產總額
X3	銷貨成本
X4	長期負債總額
X5	折舊與攤銷
X6	稅息前盈餘（EBIT）
X7	稅息折舊攤銷前盈餘（EBITDA）
X8	毛利
X9	存貨
X10	流動負債總額
X11	淨利
X12	保留盈餘
X13	應收款項總額
X14	營收總額
X15	市值
X16	負債總額
X17	銷貨淨額
X18	營業費用總額

資料來源：本研究依作者公開研究附件之欄位名稱與跨版本資料對照整理〔12〕。本表使用本研究實際版本的順序；X14 與 X17 在目前公開檔中的數值相同，名稱依發布附件保留。

各年度的紀錄數與標籤比例列於附錄 一-6，兩項實驗的分區與驗證用途整理於表 7。

表 7 兩項實驗資料與驗證設定摘要

比較部分	**實際擬合資料**	**驗證用途**	**測試資料**
實驗一：Baseline	1999–2014 年內依 15 組邊界與策略設定，扣除年內驗證樣本	各訓練年份抽取約 20%，供設定比較與門檻決定	2015–2018 年
實驗一：集成	Old-fit：1999–2011；New-fit：2012–2013	2014 年等分為 DSEL 與 Calibration	2015–2018 年
實驗二：FS 集成	同實驗一之集成比較；前處理及特徵選取僅擬合 Old-fit	同實驗一之集成比較，固定資料列分配	2015–2018 年

資料來源：本研究整理。

3-4-2 Baseline 分類器之超參數設定

Baseline 分類器比較同時包含預設參數與超參數調整設定。XGBoost、LightGBM、Random Forest、Logistic Regression 與 TabM 先以擬合資料訓練候選，再依未採樣驗證資料的 ROC-AUC 選參，測試資料不參與決策。相關實驗紀錄、版本與比較界線見附錄 附錄一。

表 8 與表 9 採「分類器、參數項目、候選值」列出本研究目前採用的候選設定。候選集合與單次搜尋預算分別定義；從集合中抽取有限組合，不代表窮舉全部排列。四種傳統分類器的搜尋預算預設為 48 組，可由執行參數覆寫。Logistic Regression 的候選集合共有 30 組，當預算達到或超過此數量時，改為遍歷全部組合。不同執行版本的預算差異見附錄 附錄一。

表 8 Baseline 傳統分類器之超參數候選集合

分類器	參數項目	超參數候選值
XGBoost	n_estimators	100、300、500、800、1000
XGBoost	learning_rate	0.01、0.03、0.05、0.1、0.2
XGBoost	max_depth	3、5、7、10
XGBoost	min_child_weight	1、3、5、20、50
XGBoost	subsample	0.7、0.85、1.0
XGBoost	colsample_bytree	0.7、0.85、1.0
XGBoost	gamma	0.0、0.1、0.2
XGBoost	reg_alpha	0.0、0.1、1.0
XGBoost	reg_lambda	0.5、1.0、3.0、10.0
LightGBM	num_leaves	31、50、100、150
LightGBM	max_depth	5、7、10、15、-1
LightGBM	learning_rate	0.01、0.03、0.05、0.1、0.2
LightGBM	n_estimators	100、200、500、800、1000
LightGBM	min_child_samples	20、50、100
LightGBM	subsample	0.7、0.85、1.0
LightGBM	colsample_bytree	0.7、0.85、1.0
LightGBM	reg_alpha	0.0、0.1、1.0
LightGBM	reg_lambda	0.0、0.1、1.0、3.0
Random Forest	n_estimators	200、400、600、800
Random Forest	max_depth	None、8、12、16、20、24、32
Random Forest	min_samples_leaf	1、2、4、8、16
Random Forest	min_samples_split	2、4、8、16、32
Random Forest	max_features	sqrt、log2、0.2、0.35、0.5、0.65
Logistic Regression	C	0.01、0.1、1.0、10.0、100.0
Logistic Regression	solver	lbfgs、saga
Logistic Regression	max_iter	500、1000、2000

資料來源：本研究整理。

表中 None 表示 Random Forest 不限制樹深度，LightGBM 的深度值 -1 表示不設定深度上限；Random Forest 的小數型 max_features 表示每次分裂考量的特徵比例。候選集合與實際執行版本之對應說明見附錄 附錄一。

表 9 Baseline TabM 之超參數候選集合

分類器	參數項目	超參數候選值
TabM	k	16、24、32
TabM	n_blocks	2、3、4
TabM	d_block	128、256、384、512
TabM	dropout	0.0、0.1、0.2、0.3
TabM	lr	0.0005、0.001、0.002、0.003
TabM	weight_decay	1e-05、0.0001、0.0003、0.001
TabM	use_num_embeddings	False、True
TabM	d_embedding	8、16

資料來源：本研究整理。

TabM 分別搜尋集成成員數、區塊數、區塊寬度、dropout、學習率、權重衰減與數值嵌入設定。未使用數值嵌入時，嵌入維度不參與該候選的有效設定。補充搜尋預算、訓練輪次上限、早停控制及 TabICL 固定參數，整理於附錄 附錄一。

3-4-3 實驗二之特徵選取參數

實驗二使用四種選取方法，每種各保留 50% 與 80% 的名義特徵數；依向下取整規則，實際分別保留 9 與 14 個。表 10 列出程式明示設定及所用套件版本的主要預設值。這些是固定的選取器設定，沒有再用 Calibration 或 Test 搜尋 FS 超參數。

表 10 實驗二特徵選取之主要參數與執行規則

方法	參數或項目	實際設定
共同設定	擬合資料	前處理後的 Old-fit；於採樣前執行
共同設定	保留數與隨機種子	9、14 個；random_state 隨十個模型種子設定
MI	函式與連續特徵	mutual_info_classif；discrete_features=auto，本研究密集數值矩陣按連續特徵處理
MI	鄰居數	n_neighbors=3（套件預設）
MI	選取規則	互資訊分數由高至低；平手保留原欄位先後順序
CART	估計器	DecisionTreeClassifier；class_weight=balanced
CART	分裂規則	criterion=gini、splitter=best（預設）
CART	樹的大小	max_depth=None、min_samples_split=2、min_samples_leaf=1（預設）
CART	剪枝與特徵抽樣	ccp_alpha=0、max_features=None（預設）
CART	選取規則	依特徵重要性排序；平手保留原欄位先後順序
RFE	估計器	與 CART 相同的平衡類別權重決策樹
RFE	移除步長及停止條件	step=1；n_features_to_select 分別為 9、14
RFE	輸出順序	依選取遮罩保留原欄位順序
SHAP 排序	估計器	LGBMClassifier；n_estimators=100、class_weight=balanced
SHAP 排序	樹與學習率	boosting_type=gbdt、num_leaves=31、max_depth=−1、learning_rate=0.1（預設）
SHAP 排序	葉節點與抽樣	min_child_samples=20、colsample_bytree=1.0、subsample=1.0（預設）
SHAP 排序	正則化與執行緒	reg_alpha=0、reg_lambda=0（預設）；n_jobs=4
SHAP 排序	重要性計算	在 Old-fit 使用 pred_contrib=True；排除基準值欄位，再計算平均絕對貢獻值
SHAP 排序	選取規則	依貢獻值排序；平手保留原欄位先後順序

資料來源：本研究特徵選取程式與固定版本套件設定整理。scikit-learn 1.8.0；LightGBM 4.6.0。未列項目沿用相同版本預設值。

CART、RFE 與 SHAP 排序中的平衡類別權重只用於特徵選取器；後續六個 XGBoost 模型仍依集成實驗的設定訓練。同一種子與 FS 條件選出的特徵會共同套用於六模型及 DSEL。各特徵在十個種子中的入選次數列於附錄 一-6，供檢視選取結果是否一致。

3-4-4 集成模型之固定設定

實驗一的集成部分與實驗二使用相同的 XGBoost 和採樣設定，見表 11；FS 選取器另列於表 10。未另指定的參數沿用固定套件版本預設值。這批集成模型沒有讀取 Baseline 各組選定的超參數，相關比較限制見附錄 附錄一。

表 11 集成模型之主要方法與參數

項目	固定設定
補值	Old-fit 平均數補值；保留全空欄位的輸入維度
縮放	StandardScaler，僅擬合 Old-fit
基礎分類器	XGBoost；objective=binary:logistic、eval_metric=auc、tree_method=hist；不另加入類別權重；本部分未重新搜尋超參數，亦未啟用早停
低採樣	TomekLinks；sampling_strategy=auto
過採樣	ADASYN；sampling_strategy=auto、n_neighbors=5
混合採樣	SMOTEENN；SMOTE 的 k_neighbors=5；ENN 的 n_neighbors=3、kind_sel=all
靜態候選選擇	49 種混合子集，以 Calibration AP 排序；平手依固定方法名稱排序
分類門檻	Calibration F1-score；0.01–0.99、間隔 0.01；平手取最小門檻
DCS ／ DES	OLA、LCA、KNORA-E、KNORA-U；k=7、DFP=False、with_IH=False；DCS 使用 best，DES 使用 soft

資料來源：本研究整理。

2014 年分區種子固定為 42，所有模型種子與特徵條件均使用相同分區。模型、採樣與具有隨機性的特徵選取程序，使用 42、123、456、789、2024、7、21、84、168、999 共十個種子；可接收種子的元件依各次設定傳遞。Baseline 之超參數候選見第 3-4-2 節；補充訓練控制與版本說明見附錄 附錄一。

軟體環境、補充訓練控制與實驗紀錄規格詳見附錄 附錄一。

3-5 實驗驗證準則

3-5-1 訓練、驗證與測試程序

各部分均先固定資料用途，再執行資料前處理與模型建立。基礎模型的學習、特徵選取及採樣僅使用允許的擬合資料；DSEL 用於動態局部能力估計；Calibration 用於靜態候選及分類門檻決定。測試標籤不參與上述決策。

使用同一 Calibration 比較候選並決定門檻，屬於本研究的模型選擇程序，因此

Calibration 上的最佳分數不作為最終泛化效能。正式報告以決策固定後的 Test 表現為準，並保留各方法與各特徵條件的結果，不只呈現測試期表現最高者。

3-5-2 分類效能評估指標

本研究將 failed 定義為正類。TP 為實際破產且預測為破產的紀錄數；FN 為實際破產但預測為存續的紀錄數；FP 為實際存續但預測為破產的紀錄數；TN 為實際存續且預測為存續的紀錄數。

一、AUC

ROC 曲線以真陽性率（True Positive Rate, TPR）為縱軸，假陽性率（False Positive Rate, FPR）為橫軸，定義為：

$$\text{TPR} = \frac{TP}{TP + FN}, \qquad \text{FPR} = \frac{FP}{FP + TN}. \tag{8}$$

AUC 為 ROC 曲線下的面積，用於衡量正負類樣本的排序區辨能力，數值越高表示整體區辨表現越佳。AUC 由預測機率計算，不依賴本研究所選的單一分類門檻；惟其無法單獨反映實際門檻下的破產樣本辨識情形，故另以 F1-score 與 Recall 補充。

二、F1-score

Precision 表示預測為破產的紀錄中，實際破產者所占比例；Recall 表示實際破產紀錄中被正確辨識的比例。兩者與 F1-score 定義如下：

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}, \tag{9}$$

$$F1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}. \tag{10}$$

F1-score 同時反映正類預測的精確程度與涵蓋程度。本研究以各方法在 Calibration 決定的門檻計算測試 F1-score；計算遇到未定義的零分母情形時，依統一的評估規則記為零。

三、Recall

Recall 與 TPR 相同，表示實際破產紀錄中被正確辨識的比例。較低的 Recall 代表較多破產紀錄被漏判；惟較高 Recall 亦可能伴隨較多誤報，因此須與 F1-score 及 AUC 共同解讀，不僅依 Recall 判定方法優劣。

四、Average Precision

AP 用於實驗一之集成比較與實驗二的靜態候選選擇，依不同門檻的 Precision 與 Recall 計算：

$$\mathrm{AP} = \sum_{n} (R_n - R_{n-1}) P_n, \tag{11}$$

其中，P_n 與 R_n 分別為第 n 個操作點的 Precision 與 Recall。本研究以 Recall 增量加權 Precision；此計算不同於對 PR 曲線直接進行梯形積分，定義見 scikit-learn AP 文件〔13〕。AP 用於驗證選模，最終主文仍以 AUC、F1-score 與 Recall 為主要報告指標。

五、特徵精簡率

除預測指標外，實驗二也記錄刪除了多少特徵。令原始特徵數為 d、保留數為 k_{FS}，特徵精簡率定義為：

$$R_{\mathrm{FS}} = \left(1 - \frac{k_{\mathrm{FS}}}{d}\right) \times 100\%. \tag{12}$$

原始特徵數為 18，保留 9 個時精簡率為 50.00%，保留 14 個時為 22.22%；no-FS 的精簡率為 0%。名義保留比例為 80% 的設定，實際保留 14 個，即 77.78%，因此本文分別報告名義設定與實際數量。本研究未進行獨立的樣本選取實驗，不另套用樣本精簡率解釋過採樣或混合採樣的結果。

3-5-3 結果彙整與模型比較

實驗一之集成比較與實驗二分別計算 2015 年至 2018 年的 pooled 與逐年指標。Pooled 指將四個測試年度的標籤與預測合併後計算一次指標，與先計算四個年度指標再取平均不同；本研究不混用兩種口徑。逐年結果用於觀察不同年度的分類表現，所有年度沿用驗證程序固定的模型與門檻。

跨種子結果以平均值與種子標準差呈現。十個種子使用相同資料來源、驗證分區與測試樣本，標準差主要描述本次設定下的程序隨機變異，不能視為十份獨立資料的抽樣不確定性，亦不直接作為統計顯著性證據。公司層級的配對檢定另依第 3-5-4 節執行。

實驗一分別呈現 Baseline 的分類器與訓練期間比較，以及固定年份的模型池與集成方法比較；實驗二依相同種子、方法與測試樣本，對照未進行 FS 的集成結果。固定方法的配對比較與重新選擇靜態成員的政策比較分別呈現。研究結論依此比較範圍解釋，不將跨協定分數差直接歸因於集成或特徵選取，亦不由單一資料集的結果推論跨市場或未來事件預測能力。

3-5-4　公司群聚配對統計檢定

為評估方法間差異的不確定性，本研究針對固定年份集成結果，補作以公司為重抽單位的配對群聚 bootstrap。此分析在既有實驗完成後制定，屬事後探索性分析；所有分類器、特徵設定、靜態選模規則與分類門檻均使用已保存的驗證決策，不因檢定結果調整模型。Bootstrap 的一般原理見 Efron 與 Tibshirani〔14〕；群聚 ROC 資料須考量同一群聚內相關性的原因，見 Obuchowski〔15〕。本研究依公司年度資料結構設計下列配對重抽程序。

1. 比較對象與估計量

實驗一以完整六模型等權集成 Equal6 為共同基準，分別比較 Old3、New3、驗證選定靜態集成（以下簡稱 V-static）、DCS-OLA、DCS-LCA、KNORA-E 及 KNORA-U，共七組比較。V-static 在各種子內依 Calibration AP 選擇混合成員，不使用 Test 排序結果選擇靜態方案。Baseline 的 15 組年份邊界共享訓練與測試資料，且與固定年份集成的驗證制度不同，因此不將它們當成獨立重複進行顯著性檢定，也不與集成結果直接作跨協定檢定。

實驗二將 MI、CART、SHAP 與 RFE 的兩種保留比例，各自與相同方法的 no-FS 結果配對。比較方法為 Equal6、V-static、DCS-OLA、DCS-LCA、KNORA-E 與 KNORA-U，因此共有 $8 \times 6 = 48$ 組比較。V-static 允許 FS 後依原有 Calibration 規則重新選擇成員，故該比較評估完整選模程序的變化；其他方法保持方法名稱與規則一致，但仍重新訓練模型並以 Calibration 固定各自門檻。

每組比較均計算 AUC、F1-score 及 Recall，合計 $(7 + 48) \times 3 = 165$ 項檢定。若 M 為任一指標，$S = 10$ 為種子數，方法 A 相對方法 B 的差值定義為：

$$\widehat{\Delta}_M = \frac{1}{S} \sum_{s=1}^{S} \left[M(y, p_{A,s}; \tau_{A,s}) - M(y, p_{B,s}; \tau_{B,s}) \right]. \tag{13}$$

其中，p 為模型預測機率，τ 為驗證程序固定的門檻；AUC 不使用門檻。此估計量先計算各種子的 pooled 指標，再平均其差值，不將十個種子的機率平均後另建一個預測模型。

2. 重抽、信賴區間與多重比較

每次 bootstrap 從 Test 所含的 C 家公司中等機率、有放回抽取 C 次。公司被抽中後，保留該公司在 2015–2018 年的全部測試紀錄，並將同一組公司抽取次數同時套用

於所有種子、方法及 FS 設定。如此可保留同公司跨年的相依性及方法間的配對關係；各次重抽均重新計算指標，但不重新訓練或調整門檻。

本研究使用 49,999 次重抽，重抽種子固定為 20261027。由差值重抽分布的第 2.5 與第 97.5 百分位數建立逐項 95% 信賴區間。以 $\Delta_M^{*(b)}$ 表示第 b 次重抽差值，針對虛無假設 $H_0 : \Delta_M = 0$，以置中重抽誤差分布計算雙尾近似 p 值：

$$p_M = \frac{1 + \sum_{b=1}^{B} \mathbf{1}\left\{\left|\Delta_M^{*(b)} - \widehat{\Delta}_M\right| \geq \left|\widehat{\Delta}_M\right|\right\}}{B+1}, \qquad B = 49{,}999. \tag{14}$$

此為有限次 Monte Carlo 計算的 bootstrap 近似檢定，並非精確置換檢定；加一修正使報告值不為零，最小可報值為 0.00002。

為避免只呈現有利的比較，兩項實驗、所有方法與三項指標的 165 個 p 值共同採 Holm 法〔16〕校正，整體顯著水準設為 0.05，校正後數值記為 p_H。區間為未作多重比較校正的逐項區間，因此即使區間不包含零，仍可能未通過 Holm 校正；顯著性判斷以 p_H 為準。未拒絕虛無假設不表示兩方法等效。

此推論以既定的訓練模型、資料切分、驗證決策與十個種子為條件，描述測試公司組成改變時的差異，不涵蓋重新抽取訓練公司的不確定性。方法亦假設不同公司可作為重抽單位，未另外建模公司間產業關聯或共同年度衝擊，故不能據此推論其他景氣期間、未見公司或未來事件預測的普遍優越性。檢定結果於第四章呈現，完整比較列於附錄。

四、 實驗設計與結果

4-1 統計分析資料與比較範圍

本章針對實驗一的固定年份集成比較，以及實驗二的 FS 集成比較，呈現既有預測結果與公司群聚配對檢定。兩項比較使用同一份資料切分：Old 擬合期間為 1999–2011 年，New 擬合期間為 2012–2013 年，2014 年分為 DSEL 與 Calibration，2015–2018 年為 Test。Test 含 12,282 筆公司年度紀錄，其中 287 筆屬破產正類，來自 3,700 家公司，其中 119 家為破產公司。

兩項實驗共使用十個種子與九種特徵設定，合計 90 組設定。進行統計分析前，先核對各組測試紀錄與標籤，再以保存的機率及門檻重算 AUC、F1-score 與 Recall；所比較的 560 個輸出均與原紀錄一致。統計分析沿用原有模型、門檻與靜態選模結果。

表中 pooled 指標先於每個種子內合併四個測試年度計算，再跨十個種子彙整；種子標準差描述程序隨機變異。差值的信賴區間與近似檢定則使用第 3-5-4 節的公司群聚 bootstrap，將同公司跨年的紀錄一併重抽。兩項實驗共 165 項比較共同採 Holm 校正，與只將十個種子視為獨立樣本的檢定具有不同推論單位。

實驗一的歷史 Baseline 使用年份邊界與年內驗證，並未與本章固定年份集成完成同協定的重新調參比較。故本章統計檢定限於下列固定年份方法，不將其與歷史 Baseline 的分數差作為集成效益之檢定證據。

4-2 實驗一：固定年份集成比較

先比較使用完整 18 個特徵的集成結果。Old3 與 New3 各整合同一期間的三種採樣模型，Equal6 使用全部六模型；V-static 則依各種子的 Calibration AP，從 49 個混合子集中選定成員。動態方法使用相同六模型池與 DSEL，結果見表 12。

表 12 實驗一固定年份集成之 pooled 結果

方法	AUC	F1-score	Recall
Old3	0.7134±0.0046	0.1168±0.0046	0.2383±0.0759
New3	0.7959±0.0027	0.2007±0.0090	0.2268±0.0361
Equal6	0.7815±0.0026	0.1815±0.0065	0.2690±0.0414

續下頁

表 12（續）

方法	AUC	F1-score	Recall
V-static	0.8152±0.0040	0.2355±0.0159	0.2481±0.0233
DCS-OLA	0.7386±0.0078	0.1542±0.0078	0.2909±0.0607
DCS-LCA	0.7369±0.0087	0.1631±0.0083	0.3195±0.0354
KNORA-E	0.7613±0.0052	0.1837±0.0058	0.2714±0.0345
KNORA-U	0.7481±0.0079	0.1817±0.0081	0.2620±0.0428

資料來源：本研究實驗結果整理。

數值為十個種子的平均值與種子標準差；標準差不等同公司抽樣之標準誤。V-static 為 Calibration AP 選定的混合靜態方案；Equal6 為六模型等權平均。

各方法相對 Equal6 的 AUC 差值、公司群聚信賴區間與 Holm 校正值列於表 13。正差值代表相對基準的 AUC 增加，負差值代表降低。區間為逐項 95% 區間，顯著性則依全體比較校正後的 p_H 判斷。

表 13 實驗一各集成方法相對 Equal6 之 AUC 配對檢定

方法	ΔAUC	95% 信賴區間	p_H
Old3	-0.0681	[-0.0890, -0.0488]	0.0033*
New3	+0.0144	[-0.0019, +0.0313]	1.0000
V-static	+0.0337	[+0.0198, +0.0480]	0.0063*
DCS-OLA	-0.0430	[-0.0634, -0.0233]	0.0186*
DCS-LCA	-0.0446	[-0.0663, -0.0242]	0.0186*
KNORA-E	-0.0202	[-0.0387, -0.0029]	1.0000
KNORA-U	-0.0334	[-0.0517, -0.0161]	0.0626

資料來源：本研究實驗結果整理。

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

V-static 的 AUC 與 F1-score 相對 Equal6 分別增加 0.0337 與 0.0540，Holm 校正後 p_H 分別為 0.00632 與 0.02416。AUC 差值的逐項 95% 信賴區間為 [0.0198, 0.0480]。其靜態成員由 Calibration 決定，因此該差異屬於驗證選模程序與完整六模型等權平均之比較。相對地，Old3 的 AUC 與 F1-score 差值分別為 -0.0681 與 -0.0647，兩者 p_H 均為 0.00330。

DCS-OLA 與 DCS-LCA 的 AUC 相對 Equal6 分別降低 0.0430 與 0.0446，兩者 $p_H = 0.01860$。New3、KNORA-E 與 KNORA-U 的 AUC 比較未通過整體 Holm 校正；所有方法相對 Equal6 的 Recall 比較亦未達校正後顯著。這些結果顯示，不能預設動態選擇或

跨期間整合必然優於所有控制組。

F1-score 與 Recall 的完整檢定列於附錄 一-5。AUC 為主要報告指標，但其改善不自動代表指定門檻下的 Recall 也同時改善；三項指標須分別解讀。

4-3 實驗二：FS 集成比較

接著將八種 FS 條件，與相同種子、測試公司及集成方法的 no-FS 結果配對。兩種保留設定分別使用 9 與 14 個特徵，精簡率為 50.00% 與 22.22%。各條件都重新訓練模型，並依相同的 Calibration 規則選擇靜態成員與門檻。

表 14 實驗二各 FS 設定相對同方法 no-FS 之 AUC 差值

FS	Equal6	V-static	OLA	LCA	KNORA-E	KNORA-U
MI 50%	-0.0171	-0.0327	-0.0257	-0.0431	-0.0274	-0.0220
MI 80%	+0.0007	-0.0007	-0.0066	-0.0184	-0.0100	+0.0076
CART 50%	-0.0304	-0.0221	-0.0299	-0.0295	-0.0435*	-0.0229
CART 80%	-0.0003	-0.0013	+0.0026	+0.0003	-0.0056	+0.0013
SHAP 50%	-0.0220	-0.0182	-0.0033	-0.0109	-0.0216	-0.0141
SHAP 80%	-0.0000	-0.0036	-0.0041	-0.0090	-0.0129	-0.0013
RFE 50%	-0.0198	-0.0141	-0.0278	-0.0286	-0.0378	-0.0125
RFE 80%	+0.0022	-0.0002	+0.0115	-0.0013	-0.0014	+0.0087

資料來源：本研究實驗結果整理。

50% 與 80% 設定實際保留 9 與 14 個特徵。正值表示 AUC 增加。星號定義與表 13 相同；完整區間、F1-score、Recall 與校正值見附錄 一-5。

表 14 呈現各 FS 條件相對同方法 no-FS 的 AUC 差值。完整的 48 組 AUC 比較，以及對應的 F1-score、Recall 檢定與信賴區間，均列於附錄 一-5。差值的方向與顯著性分開判讀，未達顯著不代表已證明方法等效。

在本次整體校正下，沒有 FS 條件呈現顯著的 AUC 增加，F1-score 的全部 48 項比較亦未達顯著。CART 50% 搭配 KNORA-E 的 AUC 差值為 -0.0435，其 $p_H = 0.03900$，方向為下降；該值接近顯著門檻且受有限次 Monte Carlo 誤差影響，因此不將此單一門檻判斷視為穩健結論。

Recall 共有九項比較通過 Holm 校正，其中 V-static 在 MI 80%、SHAP 50%、SHAP 80% 及 RFE 80% 下增加，其餘五項為 DCS 方法下的下降。例如，SHAP 50% 的 V-static Recall 增加 0.1021，$p_H = 0.00632$；CART 50% 的 DCS-LCA Recall 降低 0.1847，$p_H = 0.00330$。此差異顯示 FS 的影響與集成方法有關，不能僅因部分 Recall 改善，就推論 FS 全面提升區辨能力或精確率與召回率的平衡。

對 V-static 而言，FS 後的靜態成員與門檻可依 Calibration 重新決定，其差異反映整體程序的影響。對固定方法而言，F1-score 與 Recall 仍可能受到 FS 後的模型機率與驗證門檻變化共同影響，因此不將 Recall 的變化單獨解釋為特徵數減少的直接效果。

4-4 統計推論範圍與限制

本章檢定屬於既有結果的事後探索分析，完整保留 165 項比較，避免只報告增加或達顯著者。公司群聚重抽考量同一公司的重複測試紀錄，但使用已固定的模型與驗證決策，不涵蓋重新取得訓練資料、重新選模與其他年度環境的全部不確定性。不同公司也可能受到共同產業或景氣衝擊，這些相依性並未另行建模。

本章使用公開資料中的公司層級狀態，該標籤在同一公司所有年度保持相同，且公司可能跨擬合與測試期間出現。因此，結論限於本資料與既定時間分區下的回溯性公司狀態分類。統計差異不等同模型已具備提前一年預測能力，也不能據此宣稱對全新公司或不同市場具有普遍優越性。第三章的欄位表已依實際發布版修正，但模型使用的財務欄位、數值與預測結果保持原狀。

五、 結論與未來研究

5-1 研究結論

此段尚未提供真實結論。正式稿請根據已完成的實驗證據撰寫。

5-2 研究限制與未來方向

可討論外部驗證、資料時序漂移與模型可解釋性的侷限性。

參考文獻

〔1〕 N. V. Chawla et al., “SMOTE: Synthetic Minority Over-sampling Technique”. *Journal of Artificial Intelligence Research*, 16. 2002. Pp. 321–357. DOI: 10.1613/jair.953.

〔2〕 S. M. Lundberg and S.-I. Lee, “A Unified Approach to Interpreting Model Predictions”. *Advances in Neural Information Processing Systems*. Vol. 30. 2017.

〔3〕 T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System”. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016. DOI: 10.1145/2939672.2939785.

〔4〕 G. Lombardo et al., “Machine Learning for Bankruptcy Prediction in the American Stock Market: Dataset and Benchmarks”. *Future Internet*, 14(8). 2022. P. 244. DOI: 10.3390/fi14080244.

〔5〕 DESlib, “Overall Local Accuracy (OLA)”. URL: https://deslib.readthedocs.io/en/latest/modules/dcs/ola.html 檢索日期：10/27/2026.

〔6〕 DESlib, “Local Class Accuracy (LCA)”. URL: https://deslib.readthedocs.io/en/latest/modules/dcs/lca.html 檢索日期：10/27/2026.

〔7〕 DESlib, “k-Nearest Oracle-Eliminate (KNORA-E)”. URL: https://deslib.readthedocs.io/en/latest/modules/des/knora_e.html 檢索日期：10/27/2026.

〔8〕 DESlib, “k-Nearest Oracle Union (KNORA-U)”. URL: https://deslib.readthedocs.io/en/latest/modules/des/knora_u.html 檢索日期：10/27/2026.

〔9〕 scikit-learn, “Feature selection”. URL: https://scikit-learn.org/stable/modules/feature_selection.html 檢索日期：10/27/2026.

〔10〕 LightGBM, “lightgbm.Booster”. Version 4.6.0. URL: https://lightgbm.readthedocs.io/en/v4.6.0/pythonapi/lightgbm.Booster.html 檢索日期：10/27/2026.

〔11〕 sowide research group, “Bankruptcy prediction dataset for American companies in the stock market”. URL: https://github.com/sowide/bankruptcy_dataset 檢索日期：10/27/2026.

〔12〕 sowide research group, “Public financial research supplement for the bankruptcy dataset”. URL: https://github.com/sowide/bankruptcy_dataset/blob/main/dataset_paper.zip 檢索日期：10/27/2026.

〔13〕 scikit-learn, “average_precision_score”. URL: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html 檢索日期：10/27/2026.

〔14〕 B. Efron and R. Tibshirani, “Bootstrap Methods for Standard Errors, Confidence Intervals, and Other Measures of Statistical Accuracy”. *Statistical Science*, 1(1). 1986. Pp. 54–75. DOI: 10.1214/ss/1177013815.

〔15〕 N. A. Obuchowski, “Nonparametric Analysis of Clustered ROC Curve Data”. *Biometrics*, 53(2). 1997. Pp. 567–578. DOI: 10.2307/2533958.

〔16〕 S. Holm, “A Simple Sequentially Rejective Multiple Test Procedure”. *Scandinavian Journal of Statistics*, 6(2). 1979. Pp. 65–70. URL: https://www.jstor.org/stable/4615733.

附錄一　實驗補充設定與統計檢定

一-1　兩項實驗之資料與紀錄規格

實驗一包含 Baseline 與 Old ／ New 集成比較；實驗二在集成架構中加入特徵選取。Baseline 的訓練期間敏感度比較使用 15 組年份邊界與年內驗證；兩項集成比較則採固定年份分區，並將 2014 年分為互斥的 DSEL 與 Calibration。兩種驗證制度分別解釋，不因同屬實驗一就視為完全相同的調參條件。

實驗紀錄包含資料分區與樣本識別、標籤定義、擬合期間、隨機種子、採樣前後筆數、前處理參數、所選特徵及排列順序、分類器設定、驗證候選排序、固定門檻，以及整體與逐年預測結果。紀錄另保留資料與方法版本的識別資訊，供研究重現與來源核對，不將內部儲存名稱當作方法定義。

一-2　Baseline 超參數與訓練控制

Baseline 的 XGBoost、LightGBM、Random Forest、Logistic Regression 與 TabM 均已有驗證選參的保存紀錄。不同年份邊界、訓練策略及採樣方式可選出不同參數，因此不指定單一組參數代表所有設定。正文候選表整理目前的實驗設定，不能直接回推全部歷史版本的完整搜尋範圍。

較早的 XGBoost 結果保存樹數、學習率、樹深度與最小子節點權重四項選定參數；擴充版本另納入抽樣比例及正則化等設定。搜尋候選集合、單次預算與最終選定值應分別保存，不能僅由選定值推定曾搜尋的所有組合。四種傳統分類器的預設搜尋預算為 48 組，實際執行可覆寫；Logistic Regression 的候選集合共有 30 組，預算足夠時遍歷全部候選。

表 15 Baseline 已保存之驗證 AUC 紀錄彙整

候選／版本	有效驗證筆數	Old 平均	New 平均	Retrain 平均
XGBoost（較早版本）	124	0.7689	0.8560	0.8247
XGBoost（擴充版本）	124	0.7657	0.8557	0.8139
LightGBM	124	0.7837	0.8683	0.8307
Random Forest	124	0.7344	0.8367	0.7886
Logistic Regression	124	0.5857	0.6507	0.6101
TabM	124	0.7000	0.7893	0.7607
TabICL 標記版本	0	未保存	未保存	未保存

資料來源：本研究既有 Baseline 驗證紀錄整理；未讀取 Test 指標作選型。Old ／ New 各 60 筆（15 邊界乘四採樣），Retrain 僅四筆，不複製為 15 次。不同版本搜尋預算、前處理與驗證來源未完全對齊；本表為描述性核對，不作公平演算法排名。未保存不表示指標為零。

表 15 只使用已保存的驗證 AUC，Old 與 New 分別對 15 組年份邊界及四種採樣等權彙整；Retrain 的四筆結果獨立平均。TabICL 標記版本未保存相同欄位，因此不補算或填入測試 AUC。XGBoost 的兩個版本分列，不依 Test 分數挑選其中一個。本表補足驗證紀錄的彙整方式，但因歷史搜尋預算與處理條件未完全一致，不把它用作選定最佳演算法的依據。

TabM 的 standard 與 light 訓練控制整理於表 16。最大訓練輪次與早停耐心值屬訓練控制，與網路架構及優化器候選分別設定。各次實驗的實際值依執行紀錄確認，不由設定名稱推定。

表 16 TabM 補充搜尋預算與訓練控制

參數項目	**standard**	**light**
搜尋候選數	24	8
搜尋模型 max_epochs	200	48
搜尋模型 patience	20	6
最終模型 max_epochs	200	120
最終模型 patience	20	12
batch_size	256	512
predict_batch_size	4096	8192
val_batch_size	8192	16384

資料來源：本研究訓練設定整理。

TabICL 的補充固定設定整理於表 17。該設定提供 context 抽樣與推論控制，未納入前述以驗證 AUC 進行的隨機參數搜尋。實際執行可覆寫預設值；不同後端對參數的支援亦須分別核對。本研究使用的包裝方式優先載入 TabICL，另提供 TabPFN 後端，因

此方法解讀應以實際模型後端與版本為準。

表 17 TabICL 補充固定參數預設值

參數項目	預設值	說明
n_estimators	32	內部集成成員數
max_train_samples	1024	訓練 context 筆數上限
subsample	stratified	超過上限時採分層抽樣；另提供 random 選項
norm_methods	none、power	提供給模型的正規化設定
feat_shuffle_method	latin	特徵排列設定
class_shift	True	可由 no-class-shift 關閉
outlier_threshold	4.0	離群值處理設定
softmax_temperature	0.9	輸出溫度設定
average_logits	True	可由 no-average-logits 關閉
use_hierarchical	True	可由 no-use-hierarchical 關閉
batch_size	8	推論批次大小
use_amp	True	可由 no-amp 關閉
checkpoint_version	TabICL v1.1（0506）	執行時可覆寫的模型版本字串
device	auto	可指定 cpu 或 cuda

資料來源：本研究訓練設定整理。

一-3　軟體環境與隨機性控制

依本研究採用的本機設備，CPU、記憶體、作業系統及顯示卡規格列於表 18。硬體於 2026 年 10 月 27 日由系統查核；作業系統與驅動版本列為本次查核值，不推定每次歷史執行都使用相同的更新版本。

表 18 本研究本機設備與固定年份執行設定

項目	規格／設定
CPU	Intel Core i7-10870H，2.20 GHz；8 核心、16 邏輯處理器
記憶體	32 GB（安裝容量）
作業系統	Windows 11 家用版，64 位元；版本 10.0.26200
獨立顯示卡	NVIDIA GeForce GTX 1650 Ti；4096 MiB 顯示記憶體
內建顯示晶片	Intel UHD Graphics
本機 NVIDIA 驅動	592.82（本次查核值）
固定年份 XGBoost	CPU；hist 樹建構，未設定 CUDA device
FS 執行	scikit-learn 決策樹／ MI 與 LightGBM CPU 設定；最多四執行緒
查核日期	2026 年 10 月 27 日

資料來源：依使用者指定，採本機系統查核與實驗程式設定整理。設備具有 GPU 不代表所有方法都使用 GPU；本次查得的作業系統及驅動版本不回推為每次歷史執行的原始版本。

固定年份集成實驗所保存的環境為 Python 3.14.0、NumPy 2.4.2、pandas 3.0.1、scikit-learn 1.8.0、XGBoost 3.2.0、imbalanced-learn 0.14.1、LightGBM 4.6.0 及 DESlib 0.3.7。各設定使用四個執行緒，整體最多三個工作程序平行執行。這些資訊描述產生該批結果時的環境，不以後續工作環境版本取代。

2014 年驗證分區的種子固定為 42。模型、採樣與具隨機性的特徵選取程序，使用 42、123、456、789、2024、7、21、84、168、999 共十個種子。相同種子與方法的 FS ／ no-FS 比較使用相同測試樣本；種子標準差描述程序隨機變異，不等於獨立資料抽樣的信賴區間。固定年份 XGBoost 使用 hist 樹建構且未指定 CUDA，FS 的決策樹、MI 與 LightGBM 亦使用 CPU 設定；不能由本機配有 GPU 推定上述方法採 GPU 加速。其他深度模型是否使用 GPU，依其個別執行紀錄判讀。

一-4　實驗完成範圍與比較限制

固定年份集成實驗已完成十個種子與九種特徵條件，包含一種 no-FS 與八種 FS 設定。Baseline 的驗證紀錄已依統一方式彙整，但不同來源尚未完成相同訓練與搜尋預算的重跑，因此本研究將 XGBoost 明確定位為固定的集成基底，而非由這批歷史紀錄選出的最佳分類器。兩項實驗回答的是該固定基底下的跨期間集成與 FS 問題，未主張已找出所有演算法中的最優解。

兩項集成比較使用固定的 XGBoost 基礎設定，未讀入 Baseline 各設定保存的選定參數，也未重新搜尋。若要將 Baseline 與集成的分數差歸因於模型整合，仍須對齊資料可用範圍、驗證制度、超參數與訓練預算。

Baseline 中的 Retrain 使用 Old 與 New 擬合資料合併訓練，屬獨立基準，不加入六模型池。固定年份集成實驗尚缺同協定 Retrain 對照，故不以其他驗證制度的歷史分數替代。同樣地，New 僅表示新資料模型分支；若某版本採用權重延續的 Fine-tune，須依其實際程序獨立解釋。

本研究直接採公開的公司層級狀態，同一公司的標籤在所有觀測年度相同，且公司可能跨訓練與測試年度出現。原始檔未提供可核對的破產事件日與財報公開時間，因此結果以回溯性公司狀態分類解讀，不延伸為已確認的提前一年事件預測能力。

一-5　公司群聚配對檢定完整結果

本節完整列出實驗一的 21 項檢定與實驗二的 144 項檢定。比較規則與雙尾近似檢定依第 3-5-4 節；所有表格共用 49,999 組公司重抽樣本，且 165 個 p 值共同採 Holm 校正。差值均為候選方法減對應基準，不依測試分數或顯著性排序。

信賴區間為逐項 95% 百分位區間，未作同時區間校正。p 為置中 bootstrap 的未校正值，p_H 為 Holm 校正值；附錄的 p 值顯示五位小數，指標差值與區間顯示四位小數，計算與校正使用原精度。最小可報 p 為 0.00002，並非零。有限重抽亦具有 Monte Carlo 誤差，接近顯著門檻的結論應審慎解讀；未達顯著不等同方法等效。

以 CART 50% 的 KNORA-E AUC 為例，49,999 次重抽中有 12 次置中誤差達到或超過觀察差值，因此 $p = 13/50{,}000 = 0.00026$，$p_H = 0.03900$。未校正 p 的 Monte Carlo 標準誤約為 0.000072；多重比較校正會放大此數值誤差的影響。若要將其作為關鍵顯著性結論，應增加重抽次數或以其他適切方法驗證。

實驗一：各方法與 Equal6 比較

表 19 實驗一完整配對檢定：各方法減 Equal6

方法	指標	差值	95% 信賴區間	p	p_H
Old3	AUC	-0.0681	[-0.0890, -0.0488]	0.00002	0.00330
Old3	F1	-0.0647	[-0.0937, -0.0355]	0.00002	0.00330
Old3	Recall	-0.0307	[-0.0766, +0.0144]	0.18742	1.00000
New3	AUC	+0.0144	[-0.0019, +0.0313]	0.09184	1.00000
New3	F1	+0.0192	[-0.0048, +0.0427]	0.11316	1.00000
New3	Recall	-0.0422	[-0.0710, -0.0140]	0.00416	0.58240
V-static	AUC	+0.0337	[+0.0198, +0.0480]	0.00004	0.00632
V-static	F1	+0.0540	[+0.0266, +0.0811]	0.00016	0.02416
V-static	Recall	-0.0209	[-0.0518, +0.0086]	0.17084	1.00000
DCS-OLA	AUC	-0.0430	[-0.0634, -0.0233]	0.00012	0.01860
DCS-OLA	F1	-0.0273	[-0.0572, +0.0026]	0.07438	1.00000
DCS-OLA	Recall	+0.0220	[-0.0255, +0.0692]	0.36144	1.00000
DCS-LCA	AUC	-0.0446	[-0.0663, -0.0242]	0.00012	0.01860
DCS-LCA	F1	-0.0184	[-0.0503, +0.0139]	0.26582	1.00000
DCS-LCA	Recall	+0.0505	[-0.0021, +0.1030]	0.05944	1.00000
KNORA-E	AUC	-0.0202	[-0.0387, -0.0029]	0.02702	1.00000
KNORA-E	F1	+0.0023	[-0.0198, +0.0236]	0.83454	1.00000
KNORA-E	Recall	+0.0024	[-0.0315, +0.0350]	0.88668	1.00000
KNORA-U	AUC	-0.0334	[-0.0517, -0.0161]	0.00042	0.06258

續下頁

表 19（續）

方法	指標	差值	95% 信賴區間	p	p_H
KNORA-U	F1	+0.0002	[-0.0072, +0.0071]	0.95856	1.00000
KNORA-U	Recall	-0.0070	[-0.0182, +0.0035]	0.21108	1.00000

資料來源：本研究實驗結果整理。

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

實驗二：FS 與相同方法 no-FS 比較

表 20 實驗二完整 AUC 配對檢定：FS 減同方法 no-FS

FS	方法	差值	95% 信賴區間	p	p_H
MI 50%	Equal6	-0.0171	[-0.0471, +0.0116]	0.25188	1.00000
MI 50%	V-static	-0.0327	[-0.0584, -0.0087]	0.01050	1.00000
MI 50%	DCS-OLA	-0.0257	[-0.0564, +0.0052]	0.10044	1.00000
MI 50%	DCS-LCA	-0.0431	[-0.0728, -0.0128]	0.00466	0.64308
MI 50%	KNORA-E	-0.0274	[-0.0571, +0.0018]	0.06818	1.00000
MI 50%	KNORA-U	-0.0220	[-0.0487, +0.0046]	0.10514	1.00000
MI 80%	Equal6	+0.0007	[-0.0137, +0.0151]	0.92404	1.00000
MI 80%	V-static	-0.0007	[-0.0142, +0.0125]	0.91738	1.00000
MI 80%	DCS-OLA	-0.0066	[-0.0250, +0.0117]	0.48028	1.00000
MI 80%	DCS-LCA	-0.0184	[-0.0391, +0.0022]	0.08194	1.00000
MI 80%	KNORA-E	-0.0100	[-0.0278, +0.0081]	0.27618	1.00000
MI 80%	KNORA-U	+0.0076	[-0.0094, +0.0250]	0.38194	1.00000
CART 50%	Equal6	-0.0304	[-0.0500, -0.0116]	0.00224	0.32256
CART 50%	V-static	-0.0221	[-0.0378, -0.0064]	0.00594	0.80784
CART 50%	DCS-OLA	-0.0299	[-0.0564, -0.0037]	0.02730	1.00000
CART 50%	DCS-LCA	-0.0295	[-0.0570, -0.0013]	0.03868	1.00000
CART 50%	KNORA-E	-0.0435	[-0.0666, -0.0212]	0.00026	0.03900
CART 50%	KNORA-U	-0.0229	[-0.0426, -0.0036]	0.02194	1.00000
CART 80%	Equal6	-0.0003	[-0.0117, +0.0111]	0.95828	1.00000
CART 80%	V-static	-0.0013	[-0.0130, +0.0104]	0.83052	1.00000
CART 80%	DCS-OLA	+0.0026	[-0.0188, +0.0238]	0.80822	1.00000
CART 80%	DCS-LCA	+0.0003	[-0.0203, +0.0205]	0.97564	1.00000
CART 80%	KNORA-E	-0.0056	[-0.0224, +0.0113]	0.51062	1.00000
CART 80%	KNORA-U	+0.0013	[-0.0107, +0.0134]	0.83722	1.00000
SHAP 50%	Equal6	-0.0220	[-0.0456, +0.0009]	0.06396	1.00000
SHAP 50%	V-static	-0.0182	[-0.0375, +0.0012]	0.06578	1.00000

續下頁

表 20（續）

FS	方法	差值	95% 信賴區間	p	p_H
SHAP 50%	DCS-OLA	-0.0033	[-0.0326, +0.0260]	0.82518	1.00000
SHAP 50%	DCS-LCA	-0.0109	[-0.0406, +0.0191]	0.47292	1.00000
SHAP 50%	KNORA-E	-0.0216	[-0.0487, +0.0047]	0.11142	1.00000
SHAP 50%	KNORA-U	-0.0141	[-0.0372, +0.0088]	0.22560	1.00000
SHAP 80%	Equal6	-0.0000	[-0.0106, +0.0106]	0.99394	1.00000
SHAP 80%	V-static	-0.0036	[-0.0173, +0.0106]	0.61462	1.00000
SHAP 80%	DCS-OLA	-0.0041	[-0.0268, +0.0187]	0.71830	1.00000
SHAP 80%	DCS-LCA	-0.0090	[-0.0342, +0.0163]	0.48298	1.00000
SHAP 80%	KNORA-E	-0.0129	[-0.0307, +0.0050]	0.15408	1.00000
SHAP 80%	KNORA-U	-0.0013	[-0.0139, +0.0112]	0.83592	1.00000
RFE 50%	Equal6	-0.0198	[-0.0415, +0.0016]	0.07106	1.00000
RFE 50%	V-static	-0.0141	[-0.0319, +0.0030]	0.11212	1.00000
RFE 50%	DCS-OLA	-0.0278	[-0.0560, -0.0002]	0.05066	1.00000
RFE 50%	DCS-LCA	-0.0286	[-0.0552, -0.0017]	0.03634	1.00000
RFE 50%	KNORA-E	-0.0378	[-0.0616, -0.0143]	0.00224	0.32256
RFE 50%	KNORA-U	-0.0125	[-0.0346, +0.0100]	0.26526	1.00000
RFE 80%	Equal6	+0.0022	[-0.0061, +0.0106]	0.59906	1.00000
RFE 80%	V-static	-0.0002	[-0.0091, +0.0087]	0.95992	1.00000
RFE 80%	DCS-OLA	+0.0115	[-0.0054, +0.0288]	0.18800	1.00000
RFE 80%	DCS-LCA	-0.0013	[-0.0188, +0.0167]	0.88422	1.00000
RFE 80%	KNORA-E	-0.0014	[-0.0150, +0.0128]	0.84648	1.00000
RFE 80%	KNORA-U	+0.0087	[-0.0028, +0.0202]	0.13506	1.00000

資料來源：本研究實驗結果整理。

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

表 21 實驗二完整 F1 配對檢定：FS 減同方法 no-FS

FS	方法	差值	95% 信賴區間	p	p_H
MI 50%	Equal6	-0.0168	[-0.0461, +0.0125]	0.26002	1.00000
MI 50%	V-static	-0.0395	[-0.0782, -0.0012]	0.04484	1.00000
MI 50%	DCS-OLA	-0.0020	[-0.0289, +0.0247]	0.87992	1.00000
MI 50%	DCS-LCA	-0.0277	[-0.0558, -0.0002]	0.05094	1.00000
MI 50%	KNORA-E	-0.0244	[-0.0550, +0.0047]	0.10716	1.00000
MI 50%	KNORA-U	+0.0004	[-0.0322, +0.0326]	0.97808	1.00000
MI 80%	Equal6	+0.0003	[-0.0195, +0.0204]	0.97596	1.00000
MI 80%	V-static	-0.0092	[-0.0387, +0.0205]	0.54284	1.00000
MI 80%	DCS-OLA	-0.0001	[-0.0228, +0.0229]	0.99524	1.00000
MI 80%	DCS-LCA	-0.0182	[-0.0446, +0.0083]	0.17378	1.00000
MI 80%	KNORA-E	-0.0057	[-0.0306, +0.0190]	0.65140	1.00000

續下頁

表 21（續）

FS	方法	差值	95% 信賴區間	p	p_H
MI 80%	KNORA-U	+0.0105	[-0.0094, +0.0307]	0.29838	1.00000
CART 50%	Equal6	-0.0273	[-0.0523, -0.0026]	0.03006	1.00000
CART 50%	V-static	-0.0413	[-0.0714, -0.0110]	0.00734	0.99090
CART 50%	DCS-OLA	-0.0284	[-0.0531, -0.0033]	0.02524	1.00000
CART 50%	DCS-LCA	-0.0331	[-0.0657, -0.0005]	0.04598	1.00000
CART 50%	KNORA-E	-0.0396	[-0.0648, -0.0152]	0.00160	0.23360
CART 50%	KNORA-U	-0.0196	[-0.0446, +0.0056]	0.12514	1.00000
CART 80%	Equal6	-0.0050	[-0.0234, +0.0134]	0.59386	1.00000
CART 80%	V-static	-0.0034	[-0.0230, +0.0172]	0.73982	1.00000
CART 80%	DCS-OLA	-0.0077	[-0.0311, +0.0160]	0.51782	1.00000
CART 80%	DCS-LCA	-0.0076	[-0.0300, +0.0144]	0.49750	1.00000
CART 80%	KNORA-E	+0.0019	[-0.0187, +0.0227]	0.85098	1.00000
CART 80%	KNORA-U	+0.0092	[-0.0078, +0.0266]	0.29086	1.00000
SHAP 50%	Equal6	-0.0177	[-0.0453, +0.0091]	0.20082	1.00000
SHAP 50%	V-static	-0.0488	[-0.0837, -0.0139]	0.00560	0.76720
SHAP 50%	DCS-OLA	-0.0042	[-0.0380, +0.0294]	0.80980	1.00000
SHAP 50%	DCS-LCA	-0.0270	[-0.0597, +0.0053]	0.10304	1.00000
SHAP 50%	KNORA-E	-0.0190	[-0.0511, +0.0125]	0.24466	1.00000
SHAP 50%	KNORA-U	-0.0109	[-0.0385, +0.0163]	0.43100	1.00000
SHAP 80%	Equal6	+0.0034	[-0.0173, +0.0243]	0.74344	1.00000
SHAP 80%	V-static	-0.0152	[-0.0396, +0.0099]	0.22892	1.00000
SHAP 80%	DCS-OLA	-0.0175	[-0.0401, +0.0047]	0.12432	1.00000
SHAP 80%	DCS-LCA	-0.0357	[-0.0658, -0.0052]	0.01968	1.00000
SHAP 80%	KNORA-E	-0.0119	[-0.0333, +0.0094]	0.27586	1.00000
SHAP 80%	KNORA-U	+0.0103	[-0.0087, +0.0296]	0.28914	1.00000
RFE 50%	Equal6	-0.0238	[-0.0501, +0.0020]	0.07316	1.00000
RFE 50%	V-static	-0.0236	[-0.0579, +0.0112]	0.17734	1.00000
RFE 50%	DCS-OLA	-0.0170	[-0.0414, +0.0068]	0.16816	1.00000
RFE 50%	DCS-LCA	-0.0239	[-0.0461, -0.0020]	0.03312	1.00000
RFE 50%	KNORA-E	-0.0335	[-0.0599, -0.0076]	0.01218	1.00000
RFE 50%	KNORA-U	-0.0120	[-0.0391, +0.0146]	0.38550	1.00000
RFE 80%	Equal6	+0.0058	[-0.0083, +0.0197]	0.41802	1.00000
RFE 80%	V-static	-0.0058	[-0.0254, +0.0139]	0.56196	1.00000
RFE 80%	DCS-OLA	+0.0062	[-0.0123, +0.0246]	0.51236	1.00000
RFE 80%	DCS-LCA	-0.0076	[-0.0260, +0.0107]	0.41442	1.00000
RFE 80%	KNORA-E	-0.0057	[-0.0247, +0.0125]	0.55236	1.00000
RFE 80%	KNORA-U	+0.0128	[-0.0012, +0.0270]	0.07450	1.00000

資料來源：本研究實驗結果整理。

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

表 22 實驗二完整 Recall 配對檢定：FS 減同方法 no-FS

FS	方法	差值	95% 信賴區間	p	p_H
MI 50%	Equal6	+0.0840	[+0.0358, +0.1326]	0.00098	0.14406
MI 50%	V-static	+0.0282	[-0.0175, +0.0733]	0.22176	1.00000
MI 50%	DCS-OLA	-0.0007	[-0.0528, +0.0498]	0.98046	1.00000
MI 50%	DCS-LCA	-0.0819	[-0.1343, -0.0312]	0.00218	0.31610
MI 50%	KNORA-E	+0.0181	[-0.0319, +0.0655]	0.46496	1.00000
MI 50%	KNORA-U	+0.0192	[-0.0311, +0.0682]	0.44442	1.00000
MI 80%	Equal6	-0.0181	[-0.0479, +0.0115]	0.23144	1.00000
MI 80%	V-static	+0.0819	[+0.0480, +0.1169]	0.00002	0.00330
MI 80%	DCS-OLA	-0.0376	[-0.0774, +0.0021]	0.06376	1.00000
MI 80%	DCS-LCA	-0.1098	[-0.1553, -0.0644]	0.00002	0.00330
MI 80%	KNORA-E	-0.0080	[-0.0467, +0.0305]	0.68614	1.00000
MI 80%	KNORA-U	+0.0059	[-0.0239, +0.0365]	0.69992	1.00000
CART 50%	Equal6	-0.0265	[-0.0640, +0.0103]	0.16214	1.00000
CART 50%	V-static	+0.0397	[+0.0059, +0.0740]	0.02324	1.00000
CART 50%	DCS-OLA	-0.0296	[-0.0742, +0.0155]	0.19342	1.00000
CART 50%	DCS-LCA	-0.1847	[-0.2327, -0.1369]	0.00002	0.00330
CART 50%	KNORA-E	-0.0244	[-0.0634, +0.0135]	0.21380	1.00000
CART 50%	KNORA-U	-0.0519	[-0.0865, -0.0178]	0.00312	0.44304
CART 80%	Equal6	-0.0449	[-0.0714, -0.0190]	0.00062	0.09176
CART 80%	V-static	+0.0338	[+0.0120, +0.0572]	0.00388	0.54708
CART 80%	DCS-OLA	-0.0794	[-0.1179, -0.0405]	0.00006	0.00936
CART 80%	DCS-LCA	-0.0767	[-0.1149, -0.0387]	0.00012	0.01860
CART 80%	KNORA-E	-0.0077	[-0.0390, +0.0242]	0.63158	1.00000
CART 80%	KNORA-U	-0.0042	[-0.0288, +0.0208]	0.74322	1.00000
SHAP 50%	Equal6	-0.0066	[-0.0486, +0.0348]	0.75364	1.00000
SHAP 50%	V-static	+0.1021	[+0.0630, +0.1416]	0.00004	0.00632
SHAP 50%	DCS-OLA	-0.0732	[-0.1280, -0.0187]	0.00824	1.00000
SHAP 50%	DCS-LCA	-0.0777	[-0.1308, -0.0243]	0.00420	0.58380
SHAP 50%	KNORA-E	-0.0314	[-0.0806, +0.0164]	0.20392	1.00000
SHAP 50%	KNORA-U	+0.0111	[-0.0316, +0.0538]	0.60232	1.00000
SHAP 80%	Equal6	-0.0017	[-0.0320, +0.0294]	0.91182	1.00000
SHAP 80%	V-static	+0.0690	[+0.0412, +0.0988]	0.00002	0.00330
SHAP 80%	DCS-OLA	+0.0631	[+0.0155, +0.1105]	0.00968	1.00000
SHAP 80%	DCS-LCA	-0.0916	[-0.1371, -0.0466]	0.00012	0.01860
SHAP 80%	KNORA-E	-0.0181	[-0.0509, +0.0146]	0.27960	1.00000
SHAP 80%	KNORA-U	+0.0136	[-0.0143, +0.0424]	0.34650	1.00000
RFE 50%	Equal6	+0.0042	[-0.0363, +0.0445]	0.84192	1.00000
RFE 50%	V-static	+0.0324	[-0.0097, +0.0755]	0.13518	1.00000
RFE 50%	DCS-OLA	-0.0516	[-0.0954, -0.0092]	0.02018	1.00000
RFE 50%	DCS-LCA	-0.0268	[-0.0724, +0.0185]	0.24660	1.00000
RFE 50%	KNORA-E	-0.0084	[-0.0500, +0.0323]	0.68754	1.00000

續下頁

表 22（續）

FS	方法	差值	95% 信賴區間	p	p_H
RFE 50%	KNORA-U	-0.0432	[-0.0808, -0.0068]	0.02212	1.00000
RFE 80%	Equal6	-0.0265	[-0.0473, -0.0060]	0.01218	1.00000
RFE 80%	V-static	+0.0516	[+0.0312, +0.0729]	0.00002	0.00330
RFE 80%	DCS-OLA	-0.0254	[-0.0577, +0.0067]	0.12222	1.00000
RFE 80%	DCS-LCA	-0.0366	[-0.0727, +0.0000]	0.04858	1.00000
RFE 80%	KNORA-E	-0.0118	[-0.0419, +0.0167]	0.42766	1.00000
RFE 80%	KNORA-U	-0.0056	[-0.0256, +0.0148]	0.58660	1.00000

資料來源：本研究實驗結果整理。

差值為候選方法減比較基準；信賴區間為公司群聚 bootstrap 的逐項 95% 區間，非同時區間。p_H 為兩項實驗全部 165 項比較共同採 Holm 校正之雙尾近似 p 值；星號表示 $p_H < 0.05$。所有比較使用相同公司重抽權重，模型與驗證門檻固定。

一-6　年度資料分布與特徵選取明細

表 23 依實際公開檔計算各年度紀錄數與正類比例。核對作者 2022 年與 2024 年兩次公開資料，均為 78,682 筆、8,971 個識別碼；本地檔與目前公開檔的位元組也相同。原文的 8,262 公司數無法由兩次公開檔重建，本文因此報告公開識別碼數，保留說明文字與公開內容不一致的限制。status_label 在同一公司的所有年度保持相同，表中「破產標籤紀錄數」不是該年度新增破產事件數。

2022 年與更新版的公司、年度及狀態相同，但財務欄位的排列與數值不同。本文使用更新版的欄位順序，依作者公開研究附件的欄位名稱整理表 6，不將舊版的 X 編號直接套用到新資料，也未以固定倍率把兩版財務值強制轉成相同。既有模型均使用相同的本地更新版資料，本次只修正欄位說明，沒有變更模型輸入或重算測試分數。

表 23 各年度公司財務紀錄與破產標籤分布

年度	紀錄數	破產標籤紀錄數	破產標籤比例
1999	5,308	380	7.16%
2000	5,226	404	7.73%
2001	4,897	414	8.45%
2002	4,651	414	8.90%
2003	4,417	415	9.40%
2004	4,348	404	9.29%
2005	4,205	379	9.01%
2006	4,128	366	8.87%
2007	4,009	336	8.38%
2008	3,857	284	7.36%
2009	3,743	234	6.25%
2010	3,625	218	6.01%
2011	3,513	194	5.52%
2012	3,485	182	5.22%
2013	3,484	167	4.79%
2014	3,504	142	4.05%
2015	3,354	111	3.31%
2016	3,191	83	2.60%
2017	3,014	57	1.89%
2018	2,723	36	1.32%

資料來源：本研究依實際使用資料整理。比例以公司年度紀錄計算，並非該年度新增破產事件率。

表 24 與表 25 統計每個財務特徵在十個種子中被選取的次數。每個 FS 條件的特徵數固定為 9 或 14 個，但特徵名稱可能隨種子而異。此處只描述已完成的選取結果，不把跨種子出現頻率另組成新的特徵子集。

表 24 實驗二特徵入選種子數（X1–X9）

FS 設定	X1	X2	X3	X4	X5	X6	X7	X8	X9
MI 50%	0	0	0	10	0	10	3	10	0
MI 80%	0	1	10	10	8	10	10	10	6
CART 50%	10	0	4	10	5	1	0	0	10
CART 80%	10	10	10	10	10	10	1	2	10
SHAP 50%	10	0	0	10	0	0	0	0	10
SHAP 80%	10	0	10	10	10	0	0	10	10
RFE 50%	10	0	10	10	10	2	0	0	0
RFE 80%	10	6	10	10	10	9	3	8	8

資料來源：本研究各種子特徵選取結果。數值為十個種子中入選的次數；此表僅描述已選特徵，不據此重新挑選 Test 最佳子集。

表 25 實驗二特徵入選種子數（X10–X18）

FS 設定	X10	X11	X12	X13	X14	X15	X16	X17	X18
MI 50%	0	10	10	0	9	10	0	10	8
MI 80%	0	10	10	5	10	10	10	10	10
CART 50%	10	10	10	10	0	10	0	0	0
CART 80%	10	10	10	10	0	10	7	0	10
SHAP 50%	10	10	10	10	0	10	10	0	0
SHAP 80%	10	10	10	10	10	10	10	0	10
RFE 50%	6	10	10	10	1	9	2	0	0
RFE 80%	8	10	10	10	3	10	6	2	7

資料來源：本研究各種子特徵選取結果。數值為十個種子中入選的次數；此表僅描述已選特徵，不據此重新挑選 Test 最佳子集。