

國立中央大學

資訊管理學系

碩士論文

多策略資料前處理之研究：

結合特徵選取、樣本選取與重採樣方法

A Study of Multi-Strategy Data Preprocessing:
Integrating Feature Selection, Instance Selection,
and Resampling Methods

研究生：林鈺惠

指導教授：蔡志豐 博士

中華民國 一一五 年 六 月

摘要

隨著資料規模與特徵維度持續增加，實務資料中常存在冗餘特徵、雜訊樣本與類別不平衡等問題，因此，資料前處理在資料探勘與機器學習流程中扮演重要角色。過去研究多聚焦於單一資料前處理方法，近年來，相關研究雖然已逐漸關注多重資料前處理策略之整合應用，但多數仍著重在特定領域、特定資料情境或特定方法組合，缺乏系統性的比較與分析。因此，本研究以多策略資料前處理為核心，從特徵空間、樣本空間與類別分布三個層面出發，探討特徵選取、樣本選取與重採樣方法對分類模型效能之影響。

本研究設計兩階段實驗架構。實驗一針對 20 個公開資料集，比較單一特徵選取、單一樣本選取、平行式集成方法與序列式混合方法的分類效能，以分析不同資料精簡策略及其組合方式對模型表現之影響。實驗二則聚焦於類別不平衡資料集，將實驗一中表現最佳的方法結合 SMOTE、Cluster Centroids 與 SMOTEENN 重採樣方法，探討類別平衡機制與既有前處理策略結合後的效果。兩階段實驗皆搭配 RF、XGBoost 與 SVM 三種分類器，並以 AUC 與 F1-score 作為主要評估指標。

實驗結果顯示，在整體資料集的平均表現下，特徵選取方法在分類效能上優於樣本選取與序列式混合方法。其中，CART、MI 與 GA 之多重交集特徵選取方法表現最佳，能在精簡特徵的同時提升分類表現，顯示整合不同特徵選取邏輯有助於保留具有判別力的特徵子集。另外，在類別不平衡的資料情境下，本研究以 10 個資料集進行評估。整體結果顯示，相較於 Cluster Centroids 與 SMOTEENN，SMOTE 在整體平均表現上呈現較佳的分類效能改善效果。其中，先執行 CART、MI 與 GA 之多重交集特徵選取方法，再以 SMOTE 進行重採樣處理之組合，在整體平均 AUC 與 F1-score 上皆呈現最佳結果。本研究建立多策略資料前處理的系統性比較架構，並提出不同資料情境下的策略選擇建議，可作為後續研究與實務應用在分類模型建置時之參考依據。

關鍵詞：多策略資料前處理、特徵選取、樣本選取、重採樣、類別不平衡

Abstract

As data scale and feature dimensionality continue to increase, real-world datasets often contain redundant features, noisy instances, and class imbalance. Therefore, data preprocessing plays an important role in data mining and machine learning. Although recent studies have gradually shifted from single preprocessing methods to integrated preprocessing strategies, most still focus on specific domains, data conditions, or method combinations, lacking systematic comparison and analysis. This study investigates feature selection, instance selection, and resampling methods from the perspectives of feature space, instance space, and class distribution.

This study designs a two-stage experimental framework. Experiment 1 uses 20 public datasets to compare single feature selection, single instance selection, parallel ensemble, and sequential hybrid methods, aiming to analyze the effects of different data reduction strategies on model performance. Experiment 2 focuses on class-imbalanced datasets and combines the best-performing method from Experiment 1 with SMOTE, Cluster Centroids, and SMOTEENN to examine the effect of integrating class balancing mechanisms with existing preprocessing strategies. RF, XGBoost, and SVM are used as classifiers, while AUC and F1-score serve as the main evaluation metrics.

The results show that, based on overall average performance, feature selection methods outperform instance selection and sequential hybrid methods. Among them, the multiple-intersection feature selection method based on CART, MI, and GA achieves the best performance, indicating that integrating different feature selection mechanisms helps retain discriminative feature subsets. For the 10 class-imbalanced datasets, SMOTE achieves better overall average improvement than Cluster Centroids and SMOTEENN. In particular, applying the CART, MI, and GA multiple-intersection feature selection method before SMOTE achieves the best average AUC and F1-score. This study establishes a systematic comparison framework for multi-strategy data preprocessing and provides strategy selection suggestions for future research and practical classification model development.

Keywords: Multi-Strategy Data Preprocessing, Feature Selection, Instance Selection, Resampling, Class Imbalance

目錄

摘要	i
目錄	iii
圖目錄	v
表目錄	vi
附表目錄	vii
第一章 緒論	1
1.1 研究背景	1
1.2 研究動機	2
1.3 研究目的	3
1.4 論文架構	4
第二章 文獻回顧	5
2.1 特徵選取	5
2.2 樣本選取	8
2.3 類別不平衡問題	10
2.3.1 重採樣方法	12
2.4 相關研究趨勢與分析	13
第三章 研究方法	17
3.1 實驗架構	17
3.2 實驗一	20
3.2.1 Baseline	20
3.2.2 單一特徵選取	21
3.2.3 單一樣本選取	22
3.2.4 特徵選取平行式集成	22
3.2.5 樣本選取平行式集成	24
3.2.6 序列式混合方法 (FS → IS)	25
3.2.7 序列式混合方法 (IS → FS)	25

3.3 實驗二.....	26
3.4 實驗準備.....	28
3.4.1 實驗資料集.....	28
3.4.2 實驗電腦環境.....	29
3.4.3 實驗參數設定.....	29
3.5 實驗驗證準則.....	33
3.5.1 五折交叉驗證.....	33
3.5.2 評估指標.....	34
第四章 實驗結果.....	37
4.1 實驗一結果.....	37
4.1.1 整體 43 種方法於 20 個資料集之平均分類效能比較.....	37
4.1.2 特徵選取方法 (FS) 之深入實驗結果分析與最佳方法探討.....	42
4.1.3 樣本選取方法 (IS) 之實驗結果分析.....	44
4.1.4 特徵選取與樣本選取序列式混合方法之實驗結果分析.....	47
4.1.5 高難度資料集之實驗結果與討論.....	51
4.1.6 實驗一小結.....	53
4.2 實驗二結果.....	54
4.2.1 重採樣結合資料前處理策略之整體分類效能比較.....	54
4.2.2 重採樣組合方法於不同分類器下之最佳結果分析.....	60
4.2.3 實驗二小結.....	61
第五章 結論.....	63
5.1 結論與貢獻.....	63
5.2 未來研究方向與建議.....	65
參考文獻.....	66
附錄一、實驗一詳細數據.....	71
附錄二、實驗二詳細數據.....	92

圖目錄

圖 2-1 類別不平衡資料分布示意圖	11
圖 3-1 平均頻率選取框架之整體流程示意圖	18
圖 3-2 平均頻率選取框架之特徵選取與樣本選取流程範例	19
圖 3-3 BASELINE 流程圖	20
圖 3-4 單一特徵選取流程圖	21
圖 3-5 單一樣本選取流程圖	22
圖 3-6 多種特徵選取結果之聯集與交集組合示意圖	23
圖 3-7 特徵選取平行式集成流程圖	23
圖 3-8 多種樣本選取結果之聯集與交集組合示意圖	24
圖 3-9 樣本選取平行式集成流程圖	24
圖 3-10 序列式混合方法 (FS → IS) 流程圖	25
圖 3-11 序列式混合方法 (IS → FS) 流程圖	26
圖 3-12 序列式混合方法 (實驗一最佳方法結合重採樣方法) 流程圖	27
圖 3-13 五折交叉驗證之訓練集與測試集切分示意圖	33
圖 4-1 各特徵選取方法之平均特徵精簡率	42
圖 4-2 不同樣本選取方法下三種分類器之平均 AUC	45
圖 4-3 不同樣本選取方法下三種分類器之平均 F1-SCORE	45
圖 4-4 各樣本選取方法之平均樣本精簡率比較	46
圖 4-5 樣本選取方法於 20 個資料集之可用性統計	47
圖 4-6 不同序列式混合方法 (FS → IS) 下三種分類器之平均 AUC	48
圖 4-7 不同序列式混合方法 (FS → IS) 下三種分類器之平均 F1-SCORE	49
圖 4-8 不同序列式混合方法 (IS → FS) 下三種分類器之平均 AUC	50
圖 4-9 不同序列式混合方法 (IS → FS) 下三種分類器之平均 F1-SCORE	50

表目錄

表 2-1 特徵選取方法比較	7
表 2-2 相關文獻比較.....	15
表 3-1 實驗資料集	28
表 3-2 電腦設備相關資訊	29
表 3-3 特徵選取參數設定	30
表 3-4 樣本選取參數設定	31
表 3-5 重採樣方法參數設定	32
表 3-6 分類器參數設定	33
表 4-1 實驗一所使用之資料前處理策略（共 43 種）在 20 個資料集的平均 AUC 與 F1-SCORE 表現	39
表 4-2 特徵選取方法之平均分類效能與特徵精簡率	43
表 4-3 各分類器於 AUC 指標下之 BASELINE 與最佳方法比較.....	43
表 4-4 各分類器於 F1-SCORE 指標下之 BASELINE 與最佳方法比較.....	44
表 4-5 高難度資料集之結構特性與維度分布	51
表 4-6 高難度資料集中 AUC 表現前三名方法整理.....	52
表 4-7 高難度資料集中 F1-SCORE 表現前三名方法整理	53
表 4-8 實驗二重採樣分析之最佳基礎方法篩選結果	54
表 4-9 特徵選取、樣本選取與序列式混合方法結合重採樣策略之 AUC 效能表現.....	56
表 4-10 特徵選取、樣本選取與序列式混合方法結合重採樣策略之 F1-SCORE 效能表現.....	58
表 4-11 AUC 指標下重採樣組合方法之最佳結果.....	60
表 4-12 F1-SCORE 指標下重採樣組合方法之最佳結果	61

附表目錄

附表 1 特徵選取方法之 AUC 表現 (分類器: RF)	71
附表 2 特徵選取方法之 AUC 表現 (分類器: XGBBOOST)	72
附表 3 特徵選取方法之 AUC 表現 (分類器: SVM)	73
附表 4 特徵選取方法之 F1-SCORE 表現 (分類器: RF)	74
附表 5 特徵選取方法之 F1-SCORE 表現 (分類器: XGBBOOST)	75
附表 6 特徵選取方法之 F1-SCORE 表現 (分類器: SVM)	76
附表 7 特徵選取方法之特徵精簡率	77
附表 8 樣本選取方法之 AUC 表現 (分類器: RF)	78
附表 9 樣本選取方法之 AUC 表現 (分類器: XGBBOOST)	79
附表 10 樣本選取方法之 AUC 表現 (分類器: SVM)	80
附表 11 樣本選取方法之 F1-SCORE 表現 (分類器: RF)	81
附表 12 樣本選取方法之 F1-SCORE 表現 (分類器: XGBBOOST)	82
附表 13 樣本選取方法之 F1-SCORE 表現 (分類器: SVM)	83
附表 14 樣本選取方法之樣本精簡率	84
附表 15 序列式混合方法之 AUC 表現 (分類器: RF)	85
附表 16 序列式混合方法之 AUC 表現 (分類器: XGBBOOST)	86
附表 17 序列式混合方法之 AUC 表現 (分類器: SVM)	87
附表 18 序列式混合方法之 F1-SCORE 表現 (分類器: RF)	88
附表 19 序列式混合方法之 F1-SCORE 表現 (分類器: XGBBOOST)	89
附表 20 序列式混合方法之 F1-SCORE 表現 (分類器: SVM)	90
附表 21 序列式混合方法之 第二階段 精簡率	91
附表 22 最佳特徵選取方法結合重採樣之序列式混合方法 AUC 表現	92
附表 23 最佳特徵選取方法結合重採樣之序列式混合方法 F1-SCORE 表現	93
附表 24 最佳樣本選取方法結合重採樣之序列式混合方法 AUC 表現	94
附表 25 最佳樣本選取方法結合重採樣之序列式混合方法 F1-SCORE 表現	95
附表 26 最佳序列式混合方法(FS → IS)結合重採樣之序列式混合方法 AUC 表現	96
附表 27 最佳序列式混合方法(FS → IS)結合重採樣之序列式混合方法 F1-SCORE 表現	97
附表 28 最佳序列式混合方法(IS → FS)結合重採樣之序列式混合方法 AUC 表現	98
附表 29 最佳序列式混合方法(IS → FS)結合重採樣之序列式混合方法 F1-SCORE 表現	99

第一章 緒論

1.1 研究背景

隨著資訊科技的快速發展，各領域所產生的資料量呈現爆炸性成長，加上行動裝置、感測器與各類數位系統的普及，使資料產生的速度與規模持續增加，逐漸超出傳統資料處理技術所能有效管理的範圍[1]。傳統以人工方式分析資料已難以有效處理如此龐大的資訊量。因此，資料探勘與機器學習技術逐漸被廣泛應用於醫療診斷、金融風險評估、商業決策與智慧製造等領域，以協助從大量資料中發掘隱含的知識與規則[2]。

為了有效從資料中發掘有價值的知識，資料探勘通常透過一系列系統化的流程來進行資料分析與模型建立。在資料探勘的流程中，包含資料蒐集、資料前處理、模型建立以及模型評估等步驟[3]。其中，資料前處理（Data Preprocessing）被視為資料探勘過程中極為重要的一環[4],[5]，因為實務世界中的資料往往存在各種資料品質問題，例如雜訊資料（Noise）、冗餘特徵（Redundant Features）、類別不平衡（Class Imbalance）以及遺失值（Missing Values）等[6]，若直接使用此類資料建立分類模型，可能降低模型學習能力與預測準確性。因此，在建模前透過適當的資料前處理改善資料品質，對提升模型效能具有重要影響[7]。

在眾多資料前處理技術中，特徵選取（Feature Selection, FS）、樣本選取（Instance Selection, IS）與重採樣（Resampling）方法皆被廣泛應用於改善資料品質與提升模型效能[8],[9],[10]。特徵選取主要透過篩選重要特徵以降低資料維度並移除冗餘資訊；樣本選取則透過刪除不具代表性或可能為雜訊的樣本，以提升資料品質；而重採樣方法常用於處理類別不平衡問題，透過過採樣（Over-sampling）或欠採樣（Under-sampling）的方式調整資料的類別分布。透過適當的資料前處理策略，可改善資料品質，進而提升分類模型效能[6]。因此，探討結合

多種資料前處理方法，對於提升資料探勘與機器學習模型之效能具有重要意義。

1.2 研究動機

過去研究已指出，適當的資料前處理能有效改善資料品質，並提升分類模型的預測效能。其中，特徵選取可降低資料維度並移除冗餘資訊[11]；樣本選取可刪除雜訊樣本與不具代表性的資料[12]；重採樣則能調整類別分布，改善模型在不平衡資料上的辨識能力[13]，上述方法在不同資料情境下皆具有良好的應用成效與實務價值。

然而，各類資料前處理方法著重解決的問題並不相同，亦各自具備不同優勢。例如，特徵選取著重於精簡特徵空間，樣本選取聚焦於提升訓練資料品質，而重採樣則主要用於處理類別分布失衡問題。因此，將不同資料前處理方法結合，是否能產生加乘效果，或透過彼此互補進一步提升分類效能，成為本研究欲探討的重點。

近年來已有部分研究開始採用多重資料前處理策略，例如結合特徵選取與重採樣[14], [15], [16], [17]，或整合樣本選取與重採樣[18], [19]，顯示方法整合已逐漸成為研究趨勢。然而，目前相關研究多半著重於特定組合方法或新穎演算法之提出，對於不同資料前處理策略之間的整體組合關係，仍缺乏系統性的比較與整理。尤其是不同方法應如何搭配、執行順序是否影響結果，以及方法間是否存在交互作用等問題，仍有待進一步探討。

基於上述背景，本研究不僅關注單一方法之表現，更進一步探討不同資料前處理策略之間的組合關係，並從組合方式、處理順序及交互影響三個面向進行系統性分析。研究內容將比較單一方法、集成式方法與序列式混合方法之分類效能差異，進一步探討多種前處理策略整合後是否能提升模型表現與穩定性，並作為後續實務應用中規劃與選擇資料前處理策略的參考依據。

1.3 研究目的

基於前述研究背景與動機，本研究旨在探討不同資料前處理策略對分類模型效能之影響，並分析各類方法於不同資料情境下之表現差異與適用性。首先，本研究比較特徵選取、樣本選取及其組合方法之分類表現，以了解不同資料精簡策略對模型效能之影響，並探討特徵選取與樣本選取之組合方式及執行順序是否會造成分類結果差異。

在類別不平衡資料情境下，本研究亦分析重採樣方法與既有資料前處理策略結合後的分類表現，探討加入類別平衡機制是否能改善模型效能。透過上述分析，本研究期望釐清不同資料前處理方法之適用情境與整合效益，並提供後續研究與實務應用在選擇資料前處理策略時之參考依據。綜合上述，本研究提出以下五點研究問題：

1. 在本研究之實驗範圍內，多種資料前處理策略中何者具有最佳分類效能？
2. 特徵選取方法是否能相較於未經資料前處理之原始資料模型提升分類效能？
3. 樣本選取方法是否能相較於未經資料前處理之原始資料模型提升分類效能？
4. 特徵選取與樣本選取之序列式混合策略，是否能優於單一特徵選取或單一樣本選取方法？
5. 在類別不平衡資料集中，結合重採樣方法之資料前處理策略，是否能相較於前述之特徵選取、樣本選取及序列式混合方法，進一步提升分類效能？

1.4 論文架構

本研究之論文架構共分為五章，各章內容說明如下：第一章為緒論，說明本研究之研究背景、研究動機、研究目的以及論文架構。

第二章為文獻回顧，回顧與本研究相關之研究，包括特徵選取、樣本選取以及重採樣等資料前處理方法之相關文獻，並整理近年相關研究之發展趨勢與研究成果。

第三章為研究方法，介紹本研究之實驗設計、資料前處理方法、實驗流程以及評估指標。本研究共分為兩階段實驗，實驗一主要比較不同特徵選取與樣本選取方法及其組合策略之效能，實驗二則進一步結合重採樣方法，分析不同資料前處理策略在類別不平衡資料情境下的表現。

第四章為實驗結果與分析，說明各種資料前處理策略在不同資料情境下的實驗結果，並針對分類效能進行比較與分析，以探討不同方法及其組合策略的適用情境。

第五章為結論與未來研究建議，整理本研究之主要研究發現與貢獻，並提出未來研究方向與可能的延伸研究議題。

第二章 文獻回顧

2.1 特徵選取

特徵選取是指從原始特徵集中挑選出一個最具代表性的特徵子集，屬於降維（Dimensionality Reduction）技術之一。其核心理念在於剔除對模型預測無貢獻的資訊，進而降低計算複雜度並提升模型的泛化能力，特徵選取主要用於處理以下兩類問題[11], [20]：

- **剔除「不相關特徵」(Irrelevant Features)**：這些特徵與目標變數之間缺乏關聯性，對模型而言屬於雜訊，若保留則容易誤導學習演算法，導致過擬合。
- **減少「冗餘特徵」(Redundant Features)**：這些特徵彼此高度相關（如身高與腿長），包含重複的資訊。保留過多冗餘特徵會浪費計算資源與儲存空間，選取其中一個具代表性的特徵即可。

透過特徵選取，能有效縮短訓練時間、提高模型預測精度，並增強模型結果的可解釋性[21]。特徵選取方法主要歸納為過濾式（Filter）、包裝式（Wrapper）及嵌入式（Embedded）三大類。

1. 過濾式（Filter）

Filter 方法是一種獨立於分類器的特徵選取技術，主要透過統計指標評估各特徵與目標變數之間的關聯性，並依據評分結果進行排序與篩選。由於此方法不需進行模型訓練，因此具有計算效率高的優勢[11]。此類方法特別適用於高維資料情境，如基因表現資料或文本資料，在此類情境下，Filter 方法能快速對特徵進行排序，並依據預設閾值（threshold）進行篩選，有效降低特徵維度並節省運算時間。

本研究採用相互資訊（Mutual Information, MI）作為 Filter 方法之代表。MI 透過比較特徵與目標變數「同時出現的機率」與「假設兩者相互獨立時之機率（邊

際機率乘積)」之差異，衡量特徵與目標變數之間的依賴程度。當某一特徵能有效降低目標變數的不確定性時，其 MI 值會較高，表示該特徵對分類任務具有較高的重要性[22]。相較於僅能捕捉線性關係的統計方法[23], [24]，MI 能有效反映變數之間的非線性關聯，因此在複雜資料中具有良好的適用性。

Filter 方法在特徵選取過程中多以單一變數為評估單位，忽略特徵之間的相依關係[25]，因此可能選入冗餘或對模型貢獻有限的特徵。基於此限制，相關文獻多建議將 Filter 方法與其他方法結合，以提升特徵選取品質，並進一步改善模型的泛化能力與預測效能[11], [26]。

2. 包裝式 (Wrapper)

Wrapper 方法是一種依賴分類器的特徵選取技術，其核心概念為透過學習模型的預測效能來評估不同特徵子集的優劣。與 Filter 方法不同，Wrapper 方法將特徵選取視為一個搜尋問題，透過不斷調整特徵組合並觀察模型回饋，逐步篩選出對特定模型最具貢獻的特徵集合[27]。

本研究使用基因演算法 (Genetic Algorithm, GA)，其模擬生物演化機制，透過選擇、交配與突變等操作，在龐大的搜尋空間中動態優化特徵組合，以尋求較佳甚至近似全域最佳解[28], [29], [30]。由於 Wrapper 方法能夠直接以模型效能作為評估依據，並考量特徵之間的交互關係，因此在追求高預測準確率的應用場景中，如醫療診斷或金融風險預測等任務，通常具有較高的實務價值[11]。

Wrapper 方法的主要缺點在於計算成本高，特別是在高維資料情境下，由於需反覆進行模型訓練與特徵子集評估，容易導致運算時間顯著增加[31]。此外，Wrapper 方法亦較容易產生過擬合問題[26], [28]，尤其在樣本數較少的情況下，所選取的特徵子集可能過度貼合訓練資料，進而影響模型的泛化能力。因此，相關研究多建議在高維或小樣本資料情境中，需搭配適當的資料前處理策略，或與其他特徵選取方法結合，以在分類效能與計算成本之間取得平衡[11], [32]。

3. 嵌入式 (Embedded)

Embedded 方法是一種將特徵選取整合於學習演算法訓練過程中的技術，其核心概念為在模型學習的同時自動完成特徵子集的篩選。例如，部分線性模型可藉由正則化 (regularization) 或懲罰項 (penalty terms) 降低不重要特徵的權重，而樹模型則可透過節點分裂準則與特徵重要性評估特徵對分類任務的貢獻[33]。由於 Embedded 方法同時考量模型訓練過程與特徵篩選結果，通常被視為介於 Filter 方法與 Wrapper 方法之間的折衷策略[26]。本研究採用決策樹模型 (Classification and Regression Tree, CART) 作為 Embedded 方法之代表。CART 在建模過程中，透過節點分裂機制自動選擇對分類最具貢獻的特徵，並可由樹的結構或特徵重要性指標直接反映各特徵之影響程度。

Embedded 方法在類別不平衡 (imbalanced data) 情境下，可能因目標函數偏向多數類別，而忽略對少數類別具有判別力的重要特徵，同時正則化過程亦可能將這些特徵誤判為不重要而予以移除。因此，在此類問題中，其效能可能受到限制，實務上常需搭配重採樣或其他前處理技術，以提升模型表現[11], [34]。

表 2 - 1 特徵選取方法比較

特性 / 方法	Filter	Wrapper	Embedded
核心邏輯	數據統計分析	模型效能評估	訓練過程篩選
計算效率	最高 (無需訓練)	最低 (反覆訓練)	中等 (一次訓練)
特徵關聯性	不考慮特徵間關聯	考慮子集表現	考慮權重計算
主要缺點	忽略特徵關聯	耗時、易過擬合	類別不平衡易失效

(資料來源：本研究)

為了在計算效率與模型預測效能之間取得平衡，混合式方法已成為特徵工程的重要發展方向[35]。此類方法通常採用兩階段架構：首先利用計算效率較高的 Filter 方法快速移除大量不相關或低貢獻的特徵，以縮小搜尋空間；接著再透過

Wrapper 方法進行深層篩選，以獲取最佳特徵子集。此策略結合了 Filter 的高效率與 Wrapper 的高準確性，特別適用於高維且複雜的資料環境[36], [37]。

然而，單一特徵選取方法往往難以全面捕捉資料中不同層面的資訊，因此近年研究亦逐漸引入集成式方法 (Ensemble methods)。此類方法透過平行方式整合多種特徵選取結果（如聯集、交集或排名整合），以融合不同方法的優勢，提升特徵選取結果的穩定性與模型預測效能。相較於單一方法，集成方法能保留更多具代表性且互補的特徵資訊，從而提高模型的泛化能力[38]。

不同特徵選取方法在計算成本與模型效能之間各有取捨，如何兼顧兩者已成為研究重點。因此，本研究除探討單一特徵選取方法外，亦納入混合式與集成式策略進行整合分析，藉此發揮不同方法間之互補性，進一步分析其組合方式、處理順序及交互影響，並提升特徵篩選效率與分類模型之整體預測效能。

2.2 樣本選取

樣本選取的核心目標在於從原始訓練資料中挑選出一組能有效代表資料分布的樣本子集，使分類器在維持或提升效能的同時，降低儲存需求、縮短預測時間，並提升模型的抗雜訊能力[12]。樣本選取方法可依其對樣本的處理理念與選取策略，分為三類：濃縮 (Condensation)、編輯 (Edition) 以及混合式 (Hybrid) 方法[39]。

1. 濃縮 (Condensation)

Condensation 方法的核心精神在於保留位於決策邊界 (decision boundary) 附近的關鍵樣本，並移除遠離邊界且對分類結果貢獻有限的內部樣本。透過保留接近類別邊界的關鍵樣本，此類方法通常能達到較高的資料壓縮比例，進而降低儲存需求並提升分類效率。然而，Condensation 方法對雜訊較為敏感，因為雜訊樣本往往會被誤判為邊界點而被保留，甚至可能干擾原本應被刪除之樣本，使得資料品質下降[39]。

本研究採用 Condensed Nearest Neighbor (CNN) 作為代表方法。CNN 為樣本選取領域中最早且具代表性的 Condensation 類方法之一。其核心概念為：當某筆樣本無法被當前的原型集合正確分類時，即表示該樣本蘊含決策邊界資訊，應被納入原型集合中。透過此遞增式更新機制，演算法最終可建立一組規模精簡但仍能維持分類能力的代表性樣本集合。在此過程中，CNN 能有效移除冗餘樣本、縮減資料規模，同時保留反映類別分界的重要資訊[40]。

2. 編輯 (Edition)

Edition 類方法不同於 Condensation 著重於資料壓縮，其核心目的在於移除資料中的雜訊樣本以及類別邊界的重疊區域。此類方法透過檢視樣本與其鄰近資料之間的標籤一致性，將與鄰域結構不一致的樣本視為潛在雜訊、錯誤標記，或位於高度混雜區域的資料點，並加以移除。藉由剔除這些不可靠樣本，Edition 方法能有效平滑決策邊界，提升分類模型的穩定性。雖然其資料壓縮效果通常不如 Condensation 類方法顯著，但在資料含有雜訊或品質不佳的情境下，Edition 方法往往能帶來更明顯的效能提升[39]。

本研究採用 Edited Nearest Neighbor (ENN) 作為代表方法，其核心建立在鄰域一致性 (neighborhood consistency) 的概念之上。在理想且低雜訊的資料分布中，多數樣本應與其鄰近樣本具有相同的類別標籤。反之，若某筆樣本的標記與其 k 個最近鄰的多數類別不一致，則該樣本可能為雜訊、標記錯誤，或位於複雜且不典型的決策邊界區域，因此應自資料集中移除。透過此一編輯式資料清理機制，ENN 能使資料分布更加一致且具規則性，進而降低雜訊對模型訓練過程的干擾[41]。

3. 混合式 (Hybrid)

Hybrid 方法結合 Condensation 與 Edition 兩類樣本選取策略的概念，其主要目標在於兼顧資料精簡與資料品質改善。此類方法可能透過多階段流程，先移除

錯誤標記、雜訊或類別不一致的樣本，再進一步刪除冗餘樣本。也可能透過最佳化搜尋機制，直接尋找能維持或提升分類效能的代表性樣本子集。因此，Hybrid 方法通常能在降低資料規模的同時，保留較具分類價值的樣本，特別適用於結構複雜或資料規模較大的資料集。然而，由於其可能涉及多階段處理或反覆搜尋與評估，計算成本通常較高，整體執行時間亦較單一樣本選取方法更長[39]。

本研究採用 Genetic Algorithm (GA) 作為 Hybrid 方法之代表。GA 將樣本選取問題轉換為最佳化問題，透過模擬自然演化過程中的選擇、交配與突變等機制，在龐大的解空間中搜尋較佳的樣本子集合。於此過程中，每一個染色體 (chromosome) 代表一組樣本選取方案，其基因 (gene) 對應於各樣本是否被保留，而適應度函數 (fitness function) 則依據分類模型的效能進行評估。相較於傳統 Condensation 與 Edition 方法多依賴固定規則進行篩選，GA 能透過全域搜尋機制探索不同樣本組合，並保留有助於提升分類表現的樣本子集，對於結構較複雜的資料具有較高彈性。然而，GA 需反覆進行族群演化與模型評估，因此計算成本相對較高，實務應用時需適當設定相關參數與停止條件[42]。

2.3 類別不平衡問題

類別不平衡問題是指資料集中各類別樣本數量分布存在顯著差異，其中多數樣本集中於某一類別 (majority class)，而另一類別僅包含少量樣本 (minority class)。在此情境下，傳統分類模型多以整體準確率為優化目標，容易傾向預測多數類別，導致對少數類別的辨識能力不足，進而產生效能偏差 (performance bias)。此問題廣泛存在於多種實務應用中，例如醫療診斷、金融詐欺偵測及工業故障預測等領域，而少數類別往往代表關鍵事件，若未能正確識別，可能造成嚴重後果[43], [44], [45]。




圖 2 - 1 類別不平衡資料分布示意圖

(資料來源：[43])

在類別不平衡問題中，常見的解決策略可分為資料層級 (Data-Level) 與演算法層級 (Algorithm-Level) 兩大類。資料層級方法主要透過調整資料分布，例如過採樣 (Over-sampling) 與欠採樣 (Under-sampling)，以改善類別比例失衡的問題。另一方面，演算法層級方法則透過修改模型學習機制，如成本敏感學習 (Cost-sensitive learning) 或集成方法 (Ensemble methods)，使模型在訓練過程中對少數類別給予較高權重，進而提升其辨識能力。然而，演算法層級方法通常需依賴特定分類器進行設計與調整，其效果容易受到模型選擇與參數設定影響，較缺乏通用性，且不利於跨模型之比較，此類方法亦可能增加模型複雜度，使實驗結果較難歸因於單一因素[46], [47]。相較之下，資料層級方法能在不改變分類器架構的情況下調整資料分布，使不同前處理策略的效果得以更直接地比較。因此，本研究選擇以資料層級方法為核心，並進一步聚焦於重採樣 (resampling) 技術，以系統性探討不同採樣策略對分類效能之影響。

2.3.1 重採樣方法

重採樣方法的核心概念為透過調整訓練資料中各類別樣本數量，使資料分布趨於平衡。依據操作方式不同，重採樣方法可分為過採樣（Over-sampling）、欠採樣（Under-sampling）及混合採樣（Hybrid sampling）三類。以下分別說明其原理與特性，並介紹本研究所採用之方法。

1. 過採樣

過採樣方法是透過增加少數類樣本數量，以平衡資料分布。其基本概念為對少數類樣本進行複製或生成新樣本，使其數量接近多數類。此類方法能有效保留原始資料資訊，並提升模型對少數類的學習能力，特別適用於少數類樣本具有高度重要性的情境，如醫療診斷與詐欺偵測等[48]。然而，過採樣亦可能導致過擬合（overfitting）問題，尤其在重複樣本或生成樣本品質不佳時，可能降低模型泛化能力[44], [47]。

本研究採用合成少數類過採樣技術（Synthetic Minority Over-sampling Technique, SMOTE）。SMOTE 的核心原理為：針對每一個少數類樣本，選取其鄰近的少數類樣本，並在兩者之間進行線性插值，生成新的合成樣本，此方法相較於隨機過採樣，能避免單純複製樣本所造成之過擬合問題[49], [50]。

2. 欠採樣

欠採樣方法則透過減少多數類樣本數量，使資料分布達到平衡。其基本原理為：從多數類中選取具有代表性的樣本，並移除冗餘或不重要的資料，以降低多數類對模型的主導影響。此類方法具有計算效率高與可降低訓練時間之優點，特別適用於資料量龐大的情境[13]。然而，欠採樣可能導致重要資訊遺失，進而影響模型整體表現[51]。

本研究採用 Cluster Centroids 方法作為欠採樣技術。該方法透過分群（clustering）技術，將多數類樣本劃分為多個群集，並以各群集的中心點作為代

表樣本，以取代原始資料。相較於傳統欠採樣多採隨機方式移除多數類樣本，容易破壞資料原有分布並導致模型效能不穩定，基於分群之欠採樣方法則能透過選取具代表性的樣本，有效保留資料之整體結構並提升分類效能[52]。因此，Cluster Centroids 方法能在降低資料量的同時維持多數類分布特性，兼顧資料壓縮與資訊保留之需求[53]。

3. 混合採樣

混合採樣方法結合過採樣與欠採樣技術，以同時克服兩者之限制。其基本概念為：先透過過採樣增加少數類樣本，再透過欠採樣移除多數類中之雜訊或重疊樣本，使資料分布更為平衡且具有較佳品質。此類方法能同時提升少數類辨識能力並降低資料噪音，適用於類別分布複雜或存在類別重疊的資料集。然而，混合方法通常計算成本較高，且流程較為複雜，需適當設定相關參數[44], [45]。

本研究採用 SMOTEENN 作為混合採樣方法。SMOTEENN 結合 SMOTE 與 ENN，首先利用 SMOTE 生成少數類樣本以提升其比例，接著透過 ENN 方法移除分類不一致或可能為雜訊的樣本[14], [51]。此方法不僅能改善類別不平衡問題，亦能提升資料品質與分類邊界之清晰度，因此被廣泛應用於不平衡資料處理中。

2.4 相關研究趨勢與分析

本研究彙整近五年 16 篇具代表性文獻（詳見表 2-2）後發現，資料前處理策略已逐漸由單一方法，轉向較為複雜的多重前處理結合策略。在 16 篇研究中，有 10 篇採用特徵選取與重採樣[14], [15], [16], [17], [54], [55], [56]或樣本選取與重採樣之結合策略[18], [19], [57]，顯示整合不同層級資料處理技術已成為主流趨勢。其中，Lin 等人針對序列式混合方法進行深入探討，指出樣本選取與重採樣之執行順序對模型效能具有顯著影響。透過樣本選取的篩選機制先行剔除雜訊與冗餘資訊，可為後續重採樣提供較為純淨且具代表性的資料，進而降低因放大雜訊所導致的過擬合風險，使模型表現更為穩定[19]。

然而，現有研究仍有以下幾點限制，部分研究仍侷限於單一前處理手段，未能同時考量特徵空間與樣本分布之間的交互作用[58], [59], [60], [61], [62]。此外，多數文獻僅針對特定領域或特定特徵範圍進行驗證，較少系統性探討不同資料特性下各方法之適用性。

針對上述研究趨勢與缺口，本研究將實驗設計分為兩個階段進行。實驗一聚焦在特徵與樣本層級之基礎篩選，系統性比較單一方法、集成式方法與序列式混合策略對分類效能的影響，藉此篩選出具代表性且表現穩定之方法組合。實驗二則進一步將實驗一中所得之最佳方案與重採樣技術進行整合，並著重探討不同處理順序對模型效能所產生的影響與加乘效果。

相較於既有研究多著重於提出新穎演算法，本研究更關注不同資料前處理策略之間的組合關係。此外，透過使用不同特徵維度與資料規模之資料集，本研究進一步驗證各類方法於不同資料條件下之穩定性與互補性。

表 2 - 2 相關文獻比較

No.	Year	Feature Selection			Instance Selection			Re-sampling			Preprocessing Order	Number of Features	Dataset Size	Ref
		Filt. ¹	Wrap. ²	Emb. ³	Cond. ⁴	Edit. ⁵	Hybrid	Over	Under	Hybrid				
1	2026	√	√	√	√	√	√	√	√	√	√	27 – 49,151	50 – 55,692	本研究
2	2025	√						√	√	√		20 - 95	1,000 - 10,503	[55]
3	2025	√	√	√				√	√	√	√	10 - 95	1,000 - 150,000	[56]
4	2024	√	√	√				√			√	16 - 11,340	70 – 9,298	[54]
5	2024	√								√		10	5,110	[14]
6	2024			√				√				12 - 73	1,126 - 887,380	[15]
7	2023	√										6 - 100	360 - 11,183	[59]
8	2023						√	√		√	√	4 - 20	130 – 5,500	[57]
9	2022						√	√	√	√	√	4 - 20	130 - 5,500	[19]

¹ Filt. : Filter Method

² Wrap. : Wrapper Method

³ Emb. : Embedded Method

⁴ Cond. : Condensation Method

⁵ Edit. : Editing Method

No.	Year	Feature Selection			Instance Selection			Re-sampling			Preprocessing Order	Number of Features	Dataset Size	Ref
		Filt. ¹	Wrap. ²	Emb. ³	Cond. ⁴	Edit. ⁵	Hybrid	Over	Under	Hybrid				
10	2022							√	√			2 - 30	2 - 5,000 / 3,369	[62]
11	2022					√	√					5,473 - 6,493,035	29 - 133	[61]
12	2022						√					3 - 54	58,000 - 1,000,000	[60]
13	2022	√	√	√				√	√			27	89,851	[16]
14	2021	√	√		√		√				√	10 - 101	152 - 150,000	[63]
15	2021				√	√		√	√			2 - 60	208 - 7,400	[18]
16	2021	√	√					√				30 / 44	1,000 / 267	[17]
17	2021	√	√									2,308 - 12,600	50 - 200	[58]

第三章 研究方法

3.1 實驗架構

本研究之整體實驗設計分為兩個階段進行，包含實驗一與實驗二。實驗一主要比較不同特徵選取與樣本選取方法及其組合策略對分類效能之影響，實驗二則以前述表現最佳的方法為基礎，進一步結合重採樣機制，以探討在類別不平衡情況下，不同資料前處理策略的整合效果。

在實驗一中，本研究以多種特徵選取與樣本選取方法為核心，設計包含單一方法、平行式集成方法以及序列式混合方法等架構，並與未進行任何資料前處理之 Baseline 進行比較，以分析不同資料精簡策略對分類模型效能的影響。透過此階段之實驗，可全面了解特徵選取與樣本選取方法在不同組合方式下的表現。

在實驗二中，本研究以前述實驗一各類方法中表現最佳者為基礎，包含特徵選取、樣本選取、平行式集成方法與序列式混合方法，進一步結合重採樣技術，以處理資料集中存在的類別不平衡問題。透過比較不同重採樣方法（過採樣、欠採樣與混合式方法），並分析其與資料精簡方法在不同執行順序下的組合效果，探討資料平衡處理與資料精簡策略之間的交互影響。

為確保不同方法間比較之一致性與公平性，本研究所有特徵選取、樣本選取與重採樣方法皆建構於五折交叉驗證（5-fold cross-validation）架構下執行。在每一折中，所有資料前處理與方法操作僅作用於該折的訓練資料，以避免資料洩漏問題。此外，對於特徵選取與樣本選取方法，本研究均採用「平均頻率選取框架」[64]，整合跨折之選取結果，產生最終共識子集，以提升選取結果的穩定性與一致性。其核心概念為：在交叉驗證的每一折中個別執行選取程序，彙整各折所產生的特徵（或樣本）出現次數，並計算其平均出現頻率，最後依據此平均值篩選出最終穩定的共識集合。如 圖 3-1 所示：



圖 3 - 1 平均頻率選取框架之整體流程示意圖

（資料來源：本研究）

圖 3-2 以平均頻率選取框架為基礎，分別示範特徵選取與樣本選取在五折交叉驗證下的運作流程。圖中僅呈現步驟 1 至步驟 3 作為簡化範例，用以說明跨折選取結果彙整與共識集合形成之概念，以提升對本研究框架運作方式的清晰度。




圖 3 - 2 平均頻率選取框架之特徵選取與樣本選取流程範例

(資料來源：本研究)

3.2 實驗一

實驗一旨在系統性比較多種特徵選取與樣本選取方法及其不同組合策略對分類效能的影響。本研究設計包含單一方法、平行式集成方法與序列式混合方法等多種資料精簡架構，並與未進行任何特徵或樣本選取的 Baseline 方法進行比較。最終共形成 43 組實驗比較方法。

在分類模型方面，各方法皆分別搭配隨機森林（Random Forest, RF）、支援向量機（Support Vector Machine, SVM）與 XGBoost 三種分類器進行訓練，並以 AUC 與 F1-score 作為主要效能評估指標。透過此實驗可分析不同資料精簡策略對分類模型效能的影響。

3.2.1 Baseline

Baseline 模型不進行任何資料前處理策略，直接以原始資料建立 RF、SVM 與 XGBoost 三種分類器。此設計提供後續所有特徵選取與樣本選取系列方法的比較基準，並反映資料在未經精簡時的原始分類能力。




圖 3 - 3 Baseline 流程圖

（資料來源：本研究）

3.2.2 單一特徵選取

在單一特徵選取設定中，本研究分別採用三種具代表性的特徵選取方法，包含 CART 決策樹（Embedded 類）、基因演算法 GA（Wrapper 類）與 Mutual Information（Filter 類），最終可獲得 3 組特徵子集。




圖 3 - 4 單一特徵選取流程圖

（資料來源：本研究）

3.2.3 單一樣本選取

在樣本選取方面，本研究選用三種具代表性的樣本選取方法，包括 CNN（Condensation 類）、ENN（Editing 類）與基因演算法 GA（Hybrid 類），最終產生 3 組樣本子集。此方式可評估不同樣本選取方法在剔除噪音樣本與保留代表性資料方面的能力。




圖 3 - 5 單一樣本選取流程圖

（資料來源：本研究）

3.2.4 特徵選取平行式集成

特徵選取平行式集成將 CART、GA 與 MI 的結果進行多種集合運算，以提升選取結果的穩健性。本研究考量三類組合（如圖 3-6 所示），包含：

- 兩兩聯集： $CART \cup MI$ 、 $CART \cup GA$ 、 $MI \cup GA$
- 兩兩交集： $CART \cap MI$ 、 $CART \cap GA$ 、 $MI \cap GA$
- 三者集合運算：三者聯集／三者交集／三者多重交集




圖 3 - 6 多種特徵選取結果之聯集與交集組合示意圖

(資料來源：本研究)

共形成 9 組平行式特徵子集，用以分析不同特徵選取方法的互補性與一致性。




圖 3 - 7 特徵選取平行式集成流程圖

(資料來源：本研究)

3.2.5 樣本選取平行式集成

樣本選取亦採用相同集成概念，將 CNN、ENN 與 GA 三種樣本選取結果進行集合運算（如圖 3-8 所示），包含：

- 兩兩聯集： $CNN \cup ENN$ 、 $CNN \cup GA$ 、 $ENN \cup GA$
- 兩兩交集： $CNN \cap ENN$ 、 $CNN \cap GA$ 、 $ENN \cap GA$
- 三者集合運算：三者聯集／三者交集／三者多重交集




圖 3 - 8 多種樣本選取結果之聯集與交集組合示意圖

（資料來源：本研究）

同樣可產生 9 組樣本子集，用以比較不同樣本選取方法組合的特性。




圖 3 - 9 樣本選取平行式集成流程圖

(資料來源：本研究)

3.2.6 序列式混合方法 (FS → IS)

本研究亦探討特徵選取與樣本選取方法的序列式組合策略。在先進行特徵選取，再進行樣本選取的序列式混合方法 (FS → IS) 中，資料首先經 CART、GA 或 MI 進行特徵選取，以降低資料維度並去除冗餘資訊，隨後於特徵降維後的資料上再套用 CNN、ENN 或 GA 進行樣本選取。兩階段程序共形成 9 種不同的序列式混合方法組合，用以探討先行特徵精簡是否能提升樣本選取的效果。




圖 3 - 10 序列式混合方法 (FS → IS) 流程圖

(資料來源：本研究)

3.2.7 序列式混合方法 (IS → FS)

在先進行樣本選取，再進行特徵選取的序列式混合方法 (IS → FS) 中，本研究先以 CNN、ENN 或 GA 進行樣本過濾，以提升資料品質。接著，於精簡後的資料集上套用 CART、GA 或 MI 進行特徵選取。此方向亦形成 9 種方法組合，並可檢驗樣本品質提升是否有助於改善後續特徵選取的準確性與一致性。




圖 3 - 11 序列式混合方法 (IS → FS) 流程圖

(資料來源：本研究)

3.3 實驗二

現實世界的資料常存在類別分布不平衡的情形，若直接以原始資料進行分類學習，模型容易偏向多數類別，進而造成少數類別辨識能力不足，影響整體預測效能。因此，實驗二以前述實驗一各類方法中表現最佳者作為基礎架構，包含單一與平行式特徵選取最佳方法、單一與平行式樣本選取最佳方法，以及兩種序列式混合方法 (FS → IS 與 IS → FS) 的最佳方法，進一步結合三種重採樣技術：SMOTE、Cluster Centroids 與 SMOTEENN，以形成新的混合式前處理流程。

為探討資料精簡方法與重採樣之先後順序是否影響分類效能，本研究設計兩種處理流程（如圖 3-12 所示）：

1. **先資料精簡，後重採樣**：先套用實驗一之最佳方法，再進行重採樣處理。
2. **先重採樣，後資料精簡**：先以重採樣平衡類別分布，再套用實驗一最佳方法。

透過上述雙流程設計，共形成 24 種前處理組合，可進一步分析不同前處理策略間之交互作用，以及處理順序對分類結果的影響。




圖 3 - 12 序列式混合方法（實驗一最佳方法結合重採樣方法）流程圖

（資料來源：本研究）

3.4 實驗準備

3.4.1 實驗資料集

本研究採用 20 個公開資料集，其來源包括 UCI Machine Learning Repository 與 Feature Selection @ASU 平台，涵蓋二分類與多分類任務。考量特徵選取與樣本選取方法的效能可能受到資料維度影響，為避免研究結果偏向特定維度範圍並確保評估的全面性，本研究依特徵數量將資料集劃分為四個區間： <100 、 $100-999$ 、 $1,000-9,999$ 、 $\geq 10,000$ 。每一區間各選取 5 個資料集（如表 3-1 所示），使得所提出的方法能在不同維度特性下進行比較。

在實驗設計上，實驗一以全部 20 個資料集進行分析，用以全面評估所提出方法在不同資料維度、資料型態與分類任務下的整體表現。實驗二則進一步聚焦於類別不平衡問題之處理效果，從上述 20 個資料集中篩選出不平衡比率大於或等於 2 的資料集作為實驗對象，共計 10 個資料集。透過此設計，可進一步觀察所提出方法在不平衡資料情境下的適用性與改善效果。

表 3 - 1 實驗資料集

編號	資料集	特徵數	樣本數	類別	不平衡比率
1	Body signal of smoking	27	55692	2	1.72
2	Hepatitis C Virus (HCV) for Egyptian patients	28	1385	4	1.09
3	OnlineNewsPopularity	58	39797	8	3.29
4	Connectionist Bench	60	208	2	1.14
5	Libras Movement	90	360	15	1.00
6	Hill-Valley	100	606	2	1.03
7	Drug induced Autoimmunity Prediction	196	597	2	3.03
8	darwin	451	174	2	1.05
9	madelon	500	2600	2	1.00

編號	資料集	特徵數	樣本數	類別	不平衡比率
10	pd speech features	754	756	2	2.94
11	toxicity	1203	171	2	2.05
12	colon	2000	62	2	2.00
13	GLIOMA	4434	50	4	2.14
14	DLBCL	5469	77	2	3.05
15	TOX_171	5748	171	4	1.15
16	arcene	10000	200	2	1.29
17	CLL_SUB_111	11340	111	3	5.10
18	SMK_CAN_187	19993	187	2	1.10
19	GLI_85	22283	85	2	2.46
20	GLA_BRA_180	49151	180	4	13.86

（資料來源：本研究）

3.4.2 實驗電腦環境

本研究所使用的電腦設備如表 3-2。

表 3 - 2 電腦設備相關資訊

項目	詳細資訊
處理器（CPU）	Intel（R）Core（TM）Ultra 9 185H 2.30 GHz
記憶體（RAM）	32.0 GB
作業系統（OS）	Windows 11 64 位元
Python 版本	Python 3.13.9

（資料來源：本研究）

3.4.3 實驗參數設定

3.4.3.1 特徵選取參數設定

本研究採用三類特徵選取策略，涵蓋 Filter、Wrapper 與 Embedded 方法。在 Filter 類方法中，使用 mutual_info_classif 計算互資訊（MI），並選取分數前 80%

的特徵，以在保留重要訊息的同時排除低相關特徵。在 Wrapper 類方法中，本研究以 GA 搜尋最佳特徵子集，並將 Random Forest 分類器在該特徵子集下的 AUC 作為適應度函數。GA 之演化流程以 DEAP 套件進行實作。在 Embedded 類方法中，採用 CART (DecisionTreeClassifier) 作為基底模型，並透過 SelectFromModel 依特徵重要度進行篩選，以提供兼具可解釋性與非線性處理能力的特徵評估機制。三種方法提供互補視角，能提升特徵子集的效能、穩健性與可解釋性，並為後續分類器建模奠定良好基礎。

表 3 - 3 特徵選取參數設定

類型	演算法名稱	相關參數
過濾類 (Filter)	MI	n_neighbors = 3 (預設值) random_state = 42 percentile = 80
包裝類 (Wrapper)	GA [65]	Population size = 40 Crossover rate = 0.6 Mutation rate = 0.03 Iteration = 20 Fitness Model = Random Forest (n_estimators = 100 預設值) Fitness Metric = roc_auc (或 roc_auc_ovr)
嵌入類 (Embedded)	CART	random_state = 42 Criterion = gini (預設)

(資料來源：本研究)

3.4.3.2 樣本選取參數設定

本研究採用三類樣本選取策略，包含 Condensation、Editing 與 Hybrid 架構，並透過既有套件進行實作。在 Condensation 類方法中，使用 imblearn 套件中的 CondensedNearestNeighbour 進行資料精簡。在 Editing 類方法中，本研究採用 imblearn 套件所實作之 Edited Nearest Neighbours (ENN) 方法進行樣本編輯。除預設參數外，本研究亦測試 $n_neighbors = 5$ 之設定，然而初步實驗結果顯示其效能未優於預設參數，因此最終採用 $n_neighbors = 3$ 。在 Hybrid 類方法中，使用 DEAP 套件進行遺傳演算法之樣本選取，搭配 imblearn 的 `geometric_mean_score` 與相關評估工具作為模型效能判定依據。

表 3 - 4 樣本選取參數設定

類型	演算法名稱	相關參數
Condensation	CNN	$neighbors = 1$ (預設) $n_seeds_S = 1$ (預設) $random_state = 42$
Editing	ENN	$n_neighbors = 3$ (預設)
Hybrid	GA [65]	Population size = 40 Crossover rate = 0.6 Mutation rate = 0.03 Iteration = 20 Fitness Model = Random Forest ($n_estimators = 100$ 預設值) Fitness Metric = <code>roc_auc</code> (或 <code>roc_auc_ovr</code>)

(資料來源：本研究)

三種類別的特徵選取方法從不同角度處理資料冗餘、噪音與代表性問題，使本研究能全面比較其對分類效能的影響。

3.4.3.3 重採樣方法參數設定

本研究於實驗二中所有重採樣方法皆使用 Python 的 imbalanced-learn (imblearn) 套件進行實作，包含 SMOTE (過採樣)、Cluster Centroids (欠採樣) 與 SMOTEENN (混合式重採樣)，其參數設定如表 3-5 所示。

表 3 - 5 重採樣方法參數設定

重採樣技術	參數項目	參數設定
SMOTE	k_neighbors	1 - 5
	random_state	42
Cluster Centroids	random_state	42
SMOTEENN	k_neighbors	1 - 5
	random_state	42

(資料來源：本研究)

為確保實驗結果具有可重現性，本研究將各方法中的 random_state 統一設定為 42。另外，在 SMOTE 與 SMOTEENN 方法中，考量部分資料集可能存在少數類別樣本數較少的情況，若固定使用預設鄰居數，可能導致因樣本不足而產生錯誤。因此，本研究將 k_neighbors 採動態方式設定，其取值範圍介於 1 至 5 之間，使其可依據少數類別樣本數進行調整，以避免因鄰居數量不足而無法執行重採樣。

3.4.3.4 分類器參數設定

本研究採用 RF、XGBoost 與 SVM 三種分類器，為避免單一固定參數組合可能造成偏差，本研究在上述範圍內嘗試多組超參數組合[66]，其超參數設定如表 3-6 所示。由於本研究以 AUC 作為主要效能指標，因此超參數選擇以 AUC 最佳化為準，F1-score 則作為輔助評估指標。

表 3 - 6 分類器參數設定

分類器	參數項目	超參數設定
RF	Number of trees	<u>100</u> , 150, 200
XGBoost	Number of trees	<u>100</u> , 400, 700
	Learning rate	0.1, 0.2, <u>0.3</u>
	Max depth	3, <u>6</u> , 10
	Min child weight	<u>1</u> , 5, 50
SVM	Complexity parameter C	<u>1</u> , 10, 100
	Kernel type	poly, <u>rbf</u>

註：底線標示之數值為各分類器的預設值

（資料來源：本研究）

3.5 實驗驗證準則

3.5.1 五折交叉驗證

本研究採用五折交叉驗證作為模型評估方式。其流程如圖 3-13 所示，將完整資料集平均分成五個不重疊的子集合，每一折依序輪流作為測試集，其餘四折作為訓練集。整體流程會重複五次，使每個資料子集皆被使用一次作為測試資料。最終模型效能則取五次測試結果之平均值，以降低資料切分所造成的偏差，提高模型評估的穩定性，避免單次切分可能造成的不穩定結果。




圖 3 - 13 五折交叉驗證之訓練集與測試集切分示意圖

（資料來源：本研究）

3.5.2 評估指標

本研究為全面評估各分類器與不同特徵與樣本選取方法之效能，採用 AUC (Area Under the ROC Curve) 與 F1-score 作為主要分類指標，並於跨方法比較時進一步使用 Wilcoxon 檢定進行統計顯著性分析。考量實驗二之資料集具有不同程度之類別不平衡情形，本研究以不平衡比率 (Imbalance Ratio, IR) 說明多數類別與少數類別之樣本比例差異。基於此資料特性，所選指標亦著重其適用性，其中 AUC 不受類別比例影響，能評估模型整體判別能力。F1-score 則兼顧 Precision 與 Recall，特別能反映少數類別的辨識表現[47]。此外，為衡量資料精簡程度，另計算特徵精簡率與樣本精簡率作為補充指標。

3.5.2.1 分類效能指標 (AUC 與 F1-score)

1. AUC

AUC 為 ROC 曲線下的面積，用以衡量分類器在不同分類閾值下區分正類與負類樣本的整體能力。相較於單一閾值下的 Accuracy，AUC 不依賴特定分類閾值，因此可較全面地評估模型在不同決策門檻下的分類表現。由於本研究涉及類別不平衡資料，Accuracy 可能受到多數類別影響而高估模型效能，因此本研究採用 AUC 作為主要評估指標，以觀察模型對不同類別樣本的整體區辨能力。然而，在高度類別不平衡情境下，AUC 仍可能無法完全反映少數類別的預測品質，因此本研究另以 F1-score 作為輔助指標，以補充模型在分類結果上的表現。

ROC 曲線是由真陽性率 (True Positive Rate, TPR) 與假陽性率 (False Positive Rate, FPR) 所構成，其中 TPR 表示實際為正類的樣本中，被模型正確判斷為正類的比例；FPR 則表示實際為負類的樣本中，被模型錯誤判斷為正類的比例。其計算公式如下：

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}$$

其中，TP (True Positive) 表示實際為正類且被模型正確判斷為正類的樣本；FP (False Positive) 表示實際為負類但被模型錯誤判斷為正類的樣本；FN (False Negative) 表示實際為正類但被模型錯誤判斷為負類的樣本；TN (True Negative) 則表示實際為負類且被模型正確判斷為負類的樣本。

2. F1-score

F1-score 是 Precision 與 Recall 的調和平均數，主要用於衡量模型在分類任務中的整體辨識能力。其中，Precision 表示模型預測為正類之樣本中，實際為正類的比例，Recall 則表示實際為正類之樣本中，能被模型正確辨識出的比例。F1-score 同時考量 Precision 與 Recall，當兩者皆表現良好時，F1-score 才會較高，因此可作為評估分類模型整體分類品質的重要指標。公式如下：

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

3.5.2.2 Wilcoxon 符號等級檢定 (Wilcoxon Signed-Rank Test)

為比較不同資料前處理方法於多個資料集上的表現差異，本研究採用 Wilcoxon 檢定作為後續統計方法。該檢定不需假設資料服從常態分布，適合比較成對樣本的差異，並廣泛應用於分類方法效能的檢定。

假設比較兩種方法 A 與 B，其在每個資料集上的評估值（如 AUC）形成成對數據 (A_i, B_i) 。Wilcoxon 檢定先計算差值：

$$d_i = A_i - B_i$$

剔除差值為 0 的項目後，對差值之絕對值排序，並根據其正負方向給予符號，最後計算正負符號等級和。若檢定之 p-value 小於顯著水準 (0.05)，則可認

為兩方法的效能差異達統計顯著。本研究以 Wilcoxon 檢定判別不同方法之效能是否具一致性的顯著差異，作為後續方法選擇與分析之依據。

3.5.2.3 特徵精簡率與樣本精簡率計算公式

為衡量特徵選取與樣本選取方法在資料精簡程度上的表現，本研究分別定義特徵精簡率與樣本精簡率作為輔助評估指標。

特徵精簡率是指經特徵選取後所移除之特徵數，占原始特徵總數之比例，其計算方式為：

$$\text{特徵精簡率} = 1 - \frac{\text{選取後特徵數}}{\text{原始特徵數}}$$

同樣地，樣本精簡率是指經樣本選取後所移除之樣本數，占原始樣本總數之比例，其計算方式為：

$$\text{樣本精簡率} = 1 - \frac{\text{選取後樣本數}}{\text{原始樣本數}}$$

上述兩項指標之數值介於 0 與 1 之間，數值越高代表資料精簡程度越高，表示所採用之特徵或樣本選取方法能在降低資料規模方面具有較高之縮減比例。

3.5.2.4 不平衡比率（Imbalance Ratio, IR）

不平衡比率是用來衡量資料集中多數類別與少數類別樣本數之差距，其計算方式如下：

$$IR = \frac{N_{\text{majority}}}{N_{\text{minority}}}$$

其中， N_{majority} 表示多數類別之樣本數， N_{minority} 表示少數類別之樣本數。IR 值越大，代表資料集中類別分布越不平衡，當 IR 接近 1 時，則表示各類別樣本數較為均衡。

第四章 實驗結果

4.1 實驗一結果

本實驗旨在系統性比較不同資料前處理策略在多樣資料集情境下的分類效能表現。在特徵選取方面，本研究採用「單一特徵選取方法」與「特徵選取平行式集成方法」；樣本選取方面，採用「單一樣本選取方法」與「樣本選取平行式集成方法」。此外，亦設計兩種序列式混合方法，分別為「先進行特徵選取再進行樣本選取（FS → IS）」，以及「先進行樣本選取再進行特徵選取（IS → FS）」，以探討不同處理順序對分類效能的影響。

上述各方法分別搭配 RF、XGBoost 與 SVM 三種分類器進行實驗，並以 AUC 與 F1-score 作為評估指標，另以未進行任何選取處理之 Baseline 作為比較基準，實驗一共形成 43 種方法組合。

本章首先以 20 個資料集之平均表現為基礎，比較不同策略在分類效能上的整體趨勢，藉以辨識在一般情境下較為穩定且有效之方法。接著，分別針對特徵選取方法與樣本選取方法進行深入分析，探討其效能表現與適用限制。在此基礎上，本研究進一步評估結合特徵選取與樣本選取之混合策略是否能產生互補效果，並依據資料集特性與分類難度，分析不同方法於特定資料情境下的潛在應用價值。

4.1.1 整體 43 種方法於 20 個資料集之平均分類效能比較

在實驗一所比較的 43 種方法中，CART、MI 與 GA 之多重交集特徵選取方法不論以 AUC 或 F1-score 作為評估指標，皆取得最高的平均分類效能，且其效能表現於三種分類器（XGBoost、RF 與 SVM）間呈現一致趨勢。相較於未進行任何選取前處理之 Baseline，上述方法的分類效能提升皆達統計顯著水準（Wilcoxon, $p < 0.05$ ）。

進一步觀察整體結果可以發現，在 20 個資料集的平均表現下，特徵選取相關方法在 AUC 與 F1-score 兩項指標上皆呈現較佳的分類效能。相較之下，樣本選取方法及序列式混合方法於整體平均表現中，較不易帶來明顯的分類效能提升。

表 4-1 彙整各方法在 20 個資料集上的平均 AUC 與 F1-score 表現。

表 4 - 1 實驗一所使用之資料前處理策略（共 43 種）在 20 個資料集的平均 AUC 與 F1-score 表現

	分類	方法	RF		XGBoost		SVM	
			AUC	F1-score	AUC	F1-score	AUC	F1-score
1	未進行任何資料前處理	Baseline	0.847	0.734	0.854	0.748	0.825	0.716
2	單一特徵選取	CART	0.834	0.731	0.839	0.722	0.773	0.667
3		MI	0.849	0.744	0.858	0.755	0.829	0.718
4		GA	0.855	0.745	0.863	0.755	0.847	0.719
5	特徵選取平行式集成	CART $\cup$ MI	0.853	0.745	0.861	0.758	0.844	0.718
6		CART $\cup$ GA	0.852	0.741	0.863	0.752	0.848	0.705
7		GA $\cup$ MI	0.850	0.745	0.858	0.753	0.832	0.721
8		CART $\cup$ MI $\cup$ GA	0.847	0.741	0.858	0.753	0.831	0.721
9		CART $\cap$ MI	0.832	0.725	0.840	0.718	0.822	0.671
10		CART $\cap$ GA	0.822	0.714	0.834	0.710	0.806	0.643
11		GA $\cap$ MI	0.860	0.748	0.863	0.755	0.843	0.729
12		CART $\cap$ MI $\cap$ GA	0.821	0.705	0.830	0.700	0.815	0.659
13		CART MI GA 多重交集	<u>0.864</u>	<u>0.759</u>	<u>0.868</u>	<u>0.763</u>	<u>0.848</u>	<u>0.731</u>
14	單一樣本選取	ENN	0.819	0.563	0.798	0.588	0.767	0.552
15		CNN	0.748	0.445	0.715	0.461	0.659	0.372
16		GA	0.814	0.666	0.775	0.662	0.751	0.621
17	樣本選取平行式集成	ENN $\cup$ CNN	0.831	0.675	0.841	0.711	0.817	0.664
18		ENN $\cup$ GA	0.858	0.710	0.863	0.727	0.818	0.657

	分類	方法	RF		XGBoost		SVM	
			AUC	F1-score	AUC	F1-score	AUC	F1-score
19		GA $\cup$ CNN	0.828	0.681	0.828	0.699	0.768	0.657
20		ENN $\cup$ CNN $\cup$ GA	0.854	0.748	0.862	0.754	0.812	0.711
21		ENN $\cap$ CNN	0.752	0.243	0.660	0.249	0.566	0.209
22		ENN $\cap$ GA	0.790	0.568	0.708	0.520	0.718	0.502
23		CNN $\cap$ GA	0.697	0.400	0.624	0.389	0.615	0.334
24		ENN $\cap$ CNN $\cap$ GA	0.651	0.263	0.624	0.277	0.598	0.260
25		ENN CNN GA 多重交集	0.814	0.523	0.787	0.539	0.764	0.472
26	序列式混合方法 (FS $\rightarrow$ IS)	CART $\rightarrow$ ENN	0.818	0.653	0.821	0.655	0.800	0.597
27		CART $\rightarrow$ CNN	0.711	0.527	0.730	0.544	0.682	0.378
28		CART $\rightarrow$ GA	0.828	0.722	0.777	0.669	0.782	0.630
29		MI $\rightarrow$ ENN	0.832	0.601	0.784	0.582	0.786	0.581
30		MI $\rightarrow$ CNN	0.741	0.443	0.710	0.467	0.655	0.392
31		MI $\rightarrow$ GA	0.823	0.679	0.779	0.658	0.765	0.645
32		GA $\rightarrow$ ENN	0.827	0.597	0.807	0.577	0.781	0.575
33		GA $\rightarrow$ CNN	0.741	0.442	0.667	0.460	0.685	0.423
34		GA(FS) $\rightarrow$ GA(IS)	0.822	0.691	0.794	0.671	0.754	0.640
35	序列式混合方法 (IS $\rightarrow$ FS)	ENN $\rightarrow$ CART	0.767	0.571	0.765	0.588	0.749	0.573
36		ENN $\rightarrow$ MI	0.818	0.572	0.802	0.569	0.773	0.530
37		ENN $\rightarrow$ GA	0.826	0.616	0.823	0.641	0.800	0.606

	分類	方法	RF		XGBoost		SVM	
			AUC	F1-score	AUC	F1-score	AUC	F1-score
38		CNN → CART	0.692	0.477	0.687	0.482	0.646	0.409
39		CNN → MI	0.753	0.455	0.712	0.473	0.698	0.460
40		CNN → GA	0.757	0.542	0.761	0.617	0.703	0.415
41		GA → CART	0.752	0.662	0.744	0.648	0.747	0.612
42		GA → MI	0.821	0.681	0.774	0.656	0.729	0.505
43		GA(IS)→ GA(FS)	0.812	0.680	0.779	0.675	0.771	0.672

註：**粗體字**表示該方法之平均分類效能優於 Baseline；**標示底線、紅色且粗體字**表示該指標下 43 種方法中的最佳結果（最佳結果係依未四捨五入之原始數值判定）。

（資料來源：本研究）

4.1.2 特徵選取方法 (FS) 之深入實驗結果分析與最佳方法探討

承接前一節 4.1.1 針對 43 種方法在 20 個資料集的整體平均比較結果可知，特徵選取相關方法在整體平均表現上優於樣本選取與序列式混合方法。其中，CART、MI 與 GA 之多重交集特徵選取方法在不同分類器與評估指標下整體表現最佳。基於此，本節將進一步聚焦於特徵選取方法，針對該多重交集策略之分類效能、特徵精簡特性與計算效率進行深入分析，以評估其實務應用之可行性。

4.1.2.1 特徵選取方法之平均分類效能與特徵精簡率分析

CART、MI 與 GA 之多重交集特徵選取方法在特徵精簡率與資訊保留之間取得相對平衡，其平均特徵精簡率為 67%。相較於單一特徵選取或特徵選取平行式集成方法，多重交集方法在避免過度刪減特徵的同時，仍能有效去除冗餘資訊，為後續模型訓練提供具判別力的特徵子集。各特徵選取方法之平均特徵精簡率如圖 4-1 所示。




圖 4 - 1 各特徵選取方法之平均特徵精簡率

(資料來源：本研究)

進一步觀察單獨使用特徵選取方法的情形可發現，單一 MI 與 GA 特徵選取方法在多數情況下皆能相較於 Baseline 提升平均 AUC 與 F1-score，其平均特徵精簡率分別為 43% 與 52%，顯示透過適度的特徵過濾即有助於改善分類效能。相較之下，由於 CART 平均特徵精簡率較高(89%)，特徵刪減幅度過大，而使其分類效能提升幅度受到限制(如表 4-2 所示)。

表 4 - 2 特徵選取方法之平均分類效能與特徵精簡率

方法	平均 AUC	平均 F1-score	平均特徵精簡率 (%)
Baseline	0.842	0.733	0%
CART	0.815	0.706	89%
MI	0.845	0.739	43%
GA	0.855	0.740	52%
CART MI GA 多重交集	0.860	0.751	67%

註：本表所示之平均 AUC 與 F1-score 為 RF、XGBoost 與 SVM 三種分類器結果之平均值。

（資料來源：本研究）

綜合上述結果可知，相較於單一 MI 與 GA 特徵選取方法，CART、MI 與 GA 之多重交集特徵選取方法即使在較高的特徵精簡率下，仍可以取得更好的 AUC 與 F1-score 表現，顯示其可在較大幅度的特徵刪減下保留較具分類判別力之特徵子集，並在特徵壓縮與分類效能之間取得良好的權衡。

4.1.2.2 特徵選取方法之實務應用建議

承接 4.1.1 整體實驗結果可知，CART、MI 與 GA 之多重交集特徵選取方法在 AUC 與 F1-score 兩項評估指標下，皆呈現整體最佳之分類效能表現。進一步從分類器層級觀察可發現，雖然 XGBoost 在平均 AUC 與 F1-score 上略高於 RF 與 SVM，但經過 Wilcoxon 檢定後，三種分類器之間的效能差異未達統計顯著水準，顯示其分類效能並無明顯差異。相關實驗結果之彙整如表 4-3 與表 4-4 所示。

表 4 - 3 各分類器於 AUC 指標下之 Baseline 與最佳方法比較

分類器	Baseline	CART MI GA 多重交集	相較 Baseline 提升幅度(%)
RF	0.847(2)	0.864* (2)	1.73%
XGBoost	0.854(1)	0.868* (1)	1.43%
SVM	0.825(3)	0.848 (3)	2.27%

註：「*」表示與 Baseline 相比具有顯著差異，採用 Wilcoxon 檢定， $p < 0.05$ 。

（資料來源：本研究）

表 4-4 各分類器於 F1-score 指標下之 Baseline 與最佳方法比較

分類器	Baseline	CART MI GA 多重交集	相較 Baseline 提升幅度(%)
RF	0.734(2)	0.759* (2)	2.47%
XGBoost	0.748(1)	0.763* (1)	1.45%
SVM	0.716(3)	0.731* (3)	1.56%

註：「*」表示與 Baseline 相比具有顯著差異，採用 Wilcoxon 檢定， $p < 0.05$ 。

（資料來源：本研究）

然而，在實務應用情境中，企業在模型建置時往往需同時考量分類效能、運算資源與部署成本。由於三種分類器在分類效能上未呈現顯著差異，因此除了平均分類效能外，訓練效率與模型部署成本亦可作為分類器選擇之重要依據。相較於 XGBoost，RF 由多棵彼此相對獨立的決策樹組成，較容易進行平行化運算，而 XGBoost 採用梯度提升架構，需在各輪迭代中依序更新模型，並計算殘差與梯度，因此其實務運算成本較高。因此，在分類效能差異未達統計顯著的情況下，本研究建議可優先採用 RF 結合 CART、MI 與 GA 之多重交集特徵選取方法，作為兼顧分類效能與訓練效率之策略選擇。若應用情境具備較充足的運算資源，且主要目標在於追求較高的平均分類效能，則 XGBoost 結合 CART、MI 與 GA 之多重交集特徵選取方法亦可作為具競爭力的替代選擇。

4.1.3 樣本選取方法（IS）之實驗結果分析

相較於特徵選取方法，樣本選取方法透過直接刪減訓練樣本以調整資料分布或降低資料規模，對分類效能之影響往往更為直接，亦伴隨一定的風險。本節聚焦於樣本選取方法，進一步評估整體分類效能、適用情境與相關限制。

4.1.3.1 樣本選取方法之整體分類效能表現

根據實驗結果可知，多數樣本選取方法在平均 AUC 與 F1-score 指標上皆未能優於 Baseline，顯示單獨使用樣本選取策略在本研究設定下，整體的分類效能提升效果有限。

在所有評估之樣本選取策略中，僅有 ENN、CNN 與 GA 三者聯集之樣本選取方法（ENN U CNN U GA）搭配 RF 與 XGBoost 分類器時，在平均樣本精簡率約 23% 的情況下，同時於平均 AUC 與 F1-score 上略優於 Baseline。雖然未達統計顯著水準，但該結果顯示，在避免過度刪減樣本的前提下，結合不同樣本選取方法仍具備一定潛在價值。




圖 4 - 2 不同樣本選取方法下三種分類器之平均 AUC

(資料來源：本研究)




圖 4 - 3 不同樣本選取方法下三種分類器之平均 F1-score

(資料來源：本研究)




圖 4-4 各樣本選取方法之平均樣本精簡率比較

(資料來源：本研究)

進一步將分類效能結果與樣本精簡率進行對照可發現，單獨使用樣本選取方法時，GA 的平均樣本精簡率最高，達 67%，CNN 次之，為 55%，ENN 則為 49%。而在交集型樣本選取方法中，ENN、CNN 與 GA 之三者交集樣本選取方法 ($ENN \cap CNN \cap GA$) 的平均樣本精簡率高達 87%。對應其分類效能表現可知，當樣本刪減幅度過大時，有效訓練資料數量將大幅減少，進而導致平均 AUC 與 F1-score 明顯下降（如圖 4-2、4-3 所示）。實驗結果顯示，在本研究的資料條件與實驗設定下，樣本選取方法難以在平均效能指標上帶來穩定且顯著的提升。

4.1.3.2 小樣本與高維資料集下之類別刪除問題

實驗結果顯示，進行樣本選取處理後，部分資料集中原有之類別樣本被完全移除，導致分類器無法完成後續訓練或效能評估，最終無法產出有效分類結果。此一現象說明樣本選取方法在特定資料情境下可能直接破壞資料之類別結構，使分類流程中斷，反映其在實務應用上的穩定性風險。各樣本選取方法於 20 個資料集之可用性統計結果如圖 4-5 所示。




圖 4-5 樣本選取方法於 20 個資料集之可用性統計

(資料來源：本研究)

進一步分析無法產出結果之資料集特性可知，此類情況多發生於高維度且樣本數有限之資料情境。在此條件下，樣本選取方法容易因樣本刪減比例過高而造成關鍵類別樣本不足，甚至完全消失，使模型無法建立有效之分類邊界。因此，樣本選取方法對資料結構高度敏感，在小樣本與高維資料集下，其方法適用性可能受到限制，在實際應用前需審慎評估其適用條件與潛在風險。

4.1.3.3 樣本選取方法之適用性與限制討論

綜合前述實驗結果可知，樣本選取方法在本研究之資料條件與實驗設定下，難以於整體資料集平均情境中穩定提升分類效能，且於小樣本與高維資料集下存在類別刪除之結構性風險，顯示其單獨使用於一般分類任務時，可能影響資料完整性與分類效能。

然而，在樣本精簡率控制較為保守之情況下（如 CNN U ENN U GA 方法，樣本精簡率約 23%），樣本選取方法仍可能在特定資料情境中維持分類效能，顯示其在特定資料情境下仍具應用價值。因此，樣本選取方法較適合作為輔助性前處理策略，並應用於樣本數充足、類別結構穩定且刪減比例可控之情境，而不宜單獨作為主要前處理方法。

4.1.4 特徵選取與樣本選取序列式混合方法之實驗結果分析

承接前述特徵選取與樣本選取方法之實驗結果，本節進一步以單一特徵選取或單一樣本選取方法作為比較基準，分析將另一種選取策略以序列式方式加入後，是否能在整體資料集平均情境下對原有分類效能產生額外改善效果。

4.1.4.1 先進行特徵選取再進行樣本選取 (FS → IS) 之效能分析

在整體 20 個資料集平均情境下之實驗結果顯示，單獨使用特徵選取方法時，MI 與 GA 在多數情況下皆能相較於 Baseline 提升平均 AUC 與 F1-score，顯示在不進行樣本刪減的前提下，透過適度的特徵過濾有助於改善分類效能。

然而，當於單一特徵選取後進一步加入樣本選取方法 (ENN、CNN 或 GA) 時，可觀察到無論搭配何種樣本選取策略，平均 AUC 與 F1-score 皆呈現下降趨勢，多數組合之效能甚至低於 Baseline。此結果顯示，在整體資料集平均情境下，在特徵選取後再進行樣本選取，未能進一步提升原有分類效能，反而可能因樣本刪減造成額外資訊流失，使特徵選取所帶來的效能上升反而受到抵銷。相關實驗結果如圖 4-6 與圖 4-7 所示。




圖 4-6 不同序列式混合方法 (FS → IS) 下三種分類器之平均 AUC

(資料來源：本研究)




圖 4 - 7 不同序列式混合方法 (FS → IS) 下三種分類器之平均 F1-score

(資料來源：本研究)

4.1.4.2 先進行樣本選取再進行特徵選取 (IS → FS) 之效能分析

在先進行樣本選取再進行特徵選取之流程中，由於單一樣本選取階段已刪除部分訓練樣本，分類效能於第一階段樣本選取時即出現下降趨勢。雖然後續加入特徵選取方法，部分組合之平均 AUC 與 F1-score 略有回升，但整體分類效能仍普遍低於 Baseline。

此結果顯示，樣本選取在前處理階段所造成的樣本層級資訊流失，可能對後續分類效能產生持續影響，即使透過特徵選取進行特徵層級之調整，亦難以完全彌補已被移除之關鍵訓練資訊。由實驗結果可知，在整體資料集平均情境下，IS → FS 之序列式混合方法未能帶來穩定的分類效能提升。相關實驗結果如圖 4-8 與圖 4-9 所示。




圖 4 - 8 不同序列式混合方法 (IS → FS) 下三種分類器之平均 AUC

(資料來源：本研究)




圖 4 - 9 不同序列式混合方法 (IS → FS) 下三種分類器之平均 F1-score

(資料來源：本研究)

4.1.4.3 混合方法於整體資料集平均情境下之限制討論

在序列式混合方法中，無論採用先進行特徵選取再進行樣本選取 (FS → IS)，或先進行樣本選取再進行特徵選取 (IS → FS) 之流程，在整體 20 個資料集平均情境下未能優於單一特徵選取策略。就 FS → IS 而言，在特徵選取後再引入樣本選取，可能因樣本刪減造成額外的樣本層級資訊流失，使原先由特徵選取所帶來的效能提升受到抵銷；而

在 IS → FS 流程中，因樣本選取在前處理階段即刪除大量訓練樣本，導致部分關鍵類別或樣本分布資訊在第一階段即被移除，使後續特徵選取即使進行特徵層級之調整，亦難以有效彌補樣本層級所流失之資訊。

整體而言，在整體資料集平均情境下，樣本選取方法不宜作為主要之效能提升手段，亦不適合在未充分考量資料特性之前提下，直接與特徵選取方法進行序列式結合。然而，樣本選取方法之效益可能高度依賴資料集之困難程度與基準分類效能，顯示其潛在價值仍有待於特定資料條件下進一步驗證，相關分析將在下一節中，針對高難度資料集進行情境化探討。

4.1.5 高難度資料集之實驗結果與討論

在整體 20 個資料集平均情境下，不同選取策略於分類效能上呈現出明顯差異，其中混合流程於平均情境下未展現一致優勢。然而，當分析範圍限縮至 Baseline 分類效能偏低之高難度資料集時，部分混合方法之效能表現呈現出與整體平均情境不同的趨勢。因此，本節針對高難度資料集，進一步分析不同選取策略於高難度資料集情境下之相對效能表現與適用性。

4.1.5.1 高難度資料集之選取原則與資料特性說明

本研究沿用第三章所定義之資料集特徵維度分組架構，在各維度區間中選擇 Baseline 分類效能表現最弱（即分類效果最低）之資料集，作為對應區間之高難度代表資料集。此類資料集顯示其原始資料結構對分類任務具較高挑戰性，在未進行任何資料前處理之情況下，分類效能明顯受限，因此本節將進一步觀察不同資料前處理策略於高難度資料集情境下之適用性與效能表現。

表 4 - 5 高難度資料集之結構特性與維度分布

資料集	特徵數	樣本數	類別	維度區間
Hepatitis C Virus (HCV) for Egyptian patients	28	1385	4	< 100
Hill-Valley	100	606	2	100–999
toxicity	1203	171	2	1,000–9,999
SMK_CAN_187	19993	187	2	≥10,000

（資料來源：本研究）

依上述原則，本研究自 20 個資料集中分別選取 HCV、Hill-Valley、toxicity 與 SMK_CAN_187 四個資料集，作為後續高難度資料集分析之對象。

4.1.5.2 高難度資料集中以 AUC 為導向之分類效能比較與方法建議

本節針對高難度資料集中，所有資料前處理策略搭配三種分類器之平均 AUC 表現進行整體排序比較，以辨識在困難分類情境下具代表性之高效能方法組合。結果顯示，平均 AUC 表現排名前三之方法皆搭配 SVM 分類器，依序為：

- (1) SVM 搭配 ENN(IS) $\cup$ CNN(IS) (平均 AUC：0.751)、
- (2) SVM 搭配 ENN(IS) $\rightarrow$ MI(FS) (平均 AUC：0.703)，以及
- (3) SVM 搭配 CART(FS) $\rightarrow$ ENN(IS) (平均 AUC：0.697)。

由此可見，在高難度資料集情境下，平均 AUC 表現較佳的方法多為樣本選取方法或序列式混合流程，且集中於 SVM 分類器之搭配結果。相較於 Baseline，其 AUC 提升幅度最高可達 8.4%。此一趨勢與前述整體 20 個資料集平均情境下，以特徵選取方法表現較佳之結果明顯不同，顯示在分類難度較高的情境中，樣本層級資訊調整與序列式處理策略可能更具發揮空間。

表 4-6 高難度資料集中 AUC 表現前三名方法整理

方法	平均 AUC	相較 Baseline 提升幅度(%)
SVM 的 Baseline	0.667	-
SVM + ENN(IS) $\cup$ CNN(IS)	0.751 (1)	8.4%
SVM + ENN(IS) $\rightarrow$ MI(FS)	0.703 (2)	3.5%
SVM + CART(FS) $\rightarrow$ ENN(IS)	0.697 (3)	3.0%

(資料來源：本研究)

然而，上述三種方法間的平均 AUC 差異經 Wilcoxon 檢定後未達統計顯著水準，顯示其整體效能表現可視為相近水準。因此，在高難度資料集情境下，可優先考慮採用這三種方法搭配 SVM 作為候選方案，實際應用時再依資料特性、樣本規模或實務限制進行彈性選擇。

4.1.5.3 高難度資料集中以 F1-score 為導向之分類效能比較與方法建議

本節針對高難度資料集中，所有資料前處理策略搭配三種分類器之平均 F1-score 表現進行整體排序比較，以辨識在困難分類情境下具代表性之高效能方法組合。結果顯示，

平均 F1-score 表現排名前三之方法依序為：

- (1) RF 搭配 CART(FS) → GA(IS) (平均 F1-score：0.597)、
- (2) XGBoost 搭配 ENN U CNN U GA (平均 F1-score：0.563)，以及
- (3) RF 搭配 ENN U CNN U GA (平均 F1-score：0.548)。

由結果可見，在高難度資料集情境下，平均 F1-score 表現較佳的方法多為樣本選取方法或序列式混合流程。其中，RF 搭配 CART(FS) → GA(IS) 相較於 Baseline 可提升 9.3% 之 F1-score，為所有方法中提升幅度最高。其餘以 ENN U CNN U GA 為主之方法，搭配 RF 或 XGBoost 分類器，亦可帶來約 4%~5% 的效能提升。

表 4-7 高難度資料集中 F1-score 表現前三名方法整理

方法	平均 F1-score	相較 Baseline 提升幅度(%)
RF 的 Baseline	0.504	-
RF + CART(FS) → GA(IS)	0.597 (1)	9.3%
RF + ENN U CNN U GA	0.548 (3)	4.4%
XGBoost 的 Baseline	0.518	-
XGBoost + ENN U CNN U GA	0.563 (2)	4.5%

(資料來源：本研究)

上述方法間的平均 F1-score 差異經 Wilcoxon 檢定後未達統計顯著水準，顯示其整體效能表現可視為相近水準，實務應用時可依資料規模、類別結構與運算資源等條件進行選擇。其中，RF 搭配 CART(FS) → GA(IS) 在高難度資料集中能穩定產出結果，在效能與方法穩定性之間展現較佳平衡，因而可作為較為保守且具實務可行性的優先選項。

4.1.6 實驗一小結

本實驗以 20 個多樣資料集為基礎，系統性比較不同資料前處理策略對分類效能之影響。整體平均結果顯示，特徵選取方法在 AUC 與 F1-score 兩項指標上皆優於其他前處理策略，其中以 CART、MI 與 GA 之多重交集特徵選取方法表現最為突出。相較之下，樣本選取方法及序列式混合方法在平均表現下多數未能有效提升分類效能，且存在類別刪除與可用性風險。

然而，當分析情境限縮至 Baseline 分類效能偏低的高難度資料集時，部分混合方法之表現趨勢與整體平均結果有所不同。在這樣的情境下，若以 AUC 為主要評估指標，

SVM 搭配部分樣本選取或混合方法可展現相對優勢。若以 F1-score 為主要指標，則 RF 結合 CART(FS) → GA(IS) 之流程在效能與穩定性間取得平衡。由實驗結果可知，資料前處理策略之效益會隨資料集特性與分析目標而有所差異，單一方法難以適用於所有情境。因此在實務應用中，應依據資料特性與分析需求審慎選擇合適之資料前處理策略。

4.2 實驗二結果

4.2.1 重採樣結合資料前處理策略之整體分類效能比較

重採樣方法主要用於改善類別分布不平衡所造成之分類偏誤，因此實驗二並未納入實驗一全部 20 個資料集，而是以不平衡比例作為篩選依據，選取不平衡比例大於或等於 2 之資料集作為分析對象[67]。經篩選後，本研究最終取得 10 個資料集，並以此作為實驗二之資料集（資料集詳細資訊可參考表 3-1）。

在實驗方法的選擇上，實驗二並非重新比較實驗一所有資料前處理方法，而是以實驗一在上述 10 個不平衡資料集中的分類結果作為依據，分別計算 RF、XGBoost 及 SVM 三種分類器的平均表現，並以 AUC 與 F1-score 作為評估指標，從特徵選取方法、樣本選取方法與序列式混合方法（包含 FS → IS 與 IS → FS 兩種執行順序）四大類方法中，各自挑選表現最佳者，作為實驗二導入重採樣方法前之基礎方法，如表 4-8 所示。

表 4-8 實驗二重採樣分析之最佳基礎方法篩選結果

分類	最佳方法 (平均 AUC)	最佳方法 (平均 F1-score)
特徵選取方法 (包含單一、集成)	CART MI GA 多重交集 (0.874)	CART MI GA 多重交集 (0.740)
樣本選取方法 (包含單一、集成)	ENN ∪ GA (0.846)	ENN ∪ CNN ∪ GA (0.722)
序列式混合方法 (FS → IS)	CART → ENN (0.838)	GA → GA (0.679)
序列式混合方法 (IS → FS)	GA → GA (0.816)	GA → GA (0.683)

註：本表所列之 AUC 與 F1-score 數值，均為 XGBoost、RF 及 SVM 三者分類器於該策略下之平均表現

（資料來源：本研究）

接續表 4-8 所篩選出的最佳基礎方法，本研究進一步將其分別結合 Cluster Centroids、SMOTE 與 SMOTEENN 三種重採樣方法，形成共 24 組混合式前處理策略。由實驗結果可知，在 24 組重採樣組合方法中，整體表現最佳者為：**先進行 CART、MI 與 GA 之多重交集特徵選取方法，再進行 SMOTE**。該方法不論在 AUC 或 F1-score 指標下皆取得最佳平均表現（如表 4-9、表 4-10 所示）。然而，若進一步與未加入重採樣方法之 **CART、MI 與 GA 之多重交集特徵選取方法** 相比，其提升幅度相對有限，其中 AUC 提升約 0.2%，F1-score 提升約 0.5%。此結果表示，SMOTE 雖能帶來正向改善，但在原本基礎方法已具備良好分類表現的情況下，其額外提升效果仍有限。

進一步觀察不同重採樣方法之表現可發現，SMOTE 相較於其他重採樣方法具有較穩定的改善效果。多數結合 SMOTE 的方法在 AUC 與 F1-score 上皆能維持或略微提升原有表現，顯示透過合成少數類別樣本，可在一定程度上改善模型對少數類別的辨識能力。相對而言，Cluster Centroids 與 SMOTEENN 在多數組合中的整體表現低於未進行重採樣之基礎方法。此外，從重採樣方法與資料前處理方法之執行順序觀察可發現，當 SMOTE 與 **CART、MI 與 GA 之多重交集特徵選取方法** 結合時，先進行特徵選取再導入 SMOTE 之平均表現略優於先進行 SMOTE 再進行特徵選取之組合。此結果顯示，在本研究資料集下，先透過特徵選取降低資料維度並保留較具判別力之特徵後，再進行少數類別樣本合成，可能較有助於維持分類效能。

表 4 - 9 特徵選取、樣本選取與序列式混合方法結合重採樣策略之 AUC 效能表現

分類	組合方法	RF 平均 AUC	XGBoost 平均 AUC	SVM 平均 AUC	平均
無進行資料前處理	Baseline	0.893	0.895	0.778	0.855
特徵選取方法 (包含單一、集成) + 重採樣方法	CART MI GA 多重交集	0.906 (所有組合 No.3)	0.903	0.814	0.874 (平均 No.2)
	CART MI GA 多重交集 → Cluster Centroids	0.868	0.850	0.779	0.833
	CART MI GA 多重交集 → SMOTE	0.908 (所有組合 No.2)	0.905	0.816	0.876 (平均 No.1)
	CART MI GA 多重交集 → SMOTEENN	0.863	0.866	0.774	0.834
	Cluster Centroids → CART MI GA 多重交集	0.849	0.841	0.751	0.814
	SMOTE → CART MI GA 多重交集	0.901	0.898	0.780	0.860
	SMOTEENN → CART MI GA 多重交集	0.842	0.839	0.730	0.784
樣本選取方法 (包含單一、集成) + 重採樣方法	ENN U GA	0.883	0.894	0.763	0.846
	ENN U GA → Cluster Centroids	0.852	0.843	0.737	0.810
	ENN U GA → SMOTE	0.854	0.855	0.750	0.820
	ENN U GA → SMOTEENN	0.828	0.825	0.726	0.793
	Cluster Centroids → ENN U GA	0.858	0.809	0.708	0.791
	SMOTE → ENN U GA	0.895	0.893	0.769	0.852
	SMOTEENN → ENN U GA	0.849	0.851	0.735	0.811

分類	組合方法	RF 平均 AUC	XGBoost 平均 AUC	SVM 平均 AUC	平均
序列式混合方法 (FS → IS) + 重採樣方法	CART → ENN	0.853	0.855	0.806	0.838
	CART → ENN → Cluster Centroids	0.847	0.849	0.802	0.833
	CART → ENN → SMOTE	0.848	0.854	0.808	0.837
	CART → ENN → SMOTEENN	0.796	0.830	0.779	0.802
	Cluster Centroids → CART → ENN	0.788	0.765	0.738	0.764
	SMOTE → CART → ENN	0.859	0.862	0.789	0.837
	SMOTEENN → CART → ENN	0.799	0.807	0.727	0.777
序列式混合方法 (IS → FS) + 重採樣方法	GA → GA	0.867	0.818	0.763	0.816
	GA → GA → Cluster Centroids	0.835	0.755	0.737	0.776
	GA → GA → SMOTE	0.870	0.817	0.771	0.819
	GA → GA → SMOTEENN	0.834	0.774	0.740	0.783
	Cluster Centroids → GA → GA	0.868	0.809	0.728	0.802
	SMOTE → GA → GA	0.921 (所有組合 No.1)	0.900	0.775	0.865 (平均 No.3)
	SMOTEENN → GA → GA	0.876	0.833	0.726	0.812

(資料來源：本研究)

表 4 - 10 特徵選取、樣本選取與序列式混合方法結合重採樣策略之 F1-score 效能表現

分類	組合方法	RF 平均 F1-score	XGBoost 平均 F1-score	SVM 平均 F1-score	平均
無進行資料前處理	Baseline	0.750	0.776	0.638	0.721
特徵選取方法 (包含單一、集成) + 重採樣方法	CART MI GA 多重交集	0.777	0.782	0.660	0.740 (平均 No.2)
	CART MI GA 多重交集 → Cluster Centroids	0.691	0.653	0.598	0.647
	CART MI GA 多重交集 → SMOTE	0.792 (所有組合 No.2)	0.784	0.661	0.745 (平均 No.1)
	CART MI GA 多重交集 → SMOTEENN	0.641	0.651	0.528	0.607
	Cluster Centroids → CART MI GA 多重交集	0.670	0.670	0.531	0.624
	SMOTE → CART MI GA 多重交集	0.787	0.781	0.625	0.731 (平均 No.3)
	SMOTEENN → CART MI GA 多重交集	0.640	0.651	0.529	0.607
樣本選取方法 (包含單一、集成) + 重採樣方法	ENN ∪ CNN ∪ GA	0.766	0.770	0.630	0.722
	ENN ∪ CNN ∪ GA → Cluster Centroids	0.676	0.671	0.515	0.621
	ENN ∪ CNN ∪ GA → SMOTE	0.755	0.752	0.616	0.708
	ENN ∪ CNN ∪ GA → SMOTEENN	0.612	0.647	0.525	0.595
	Cluster Centroids → ENN ∪ CNN ∪ GA	0.634	0.629	0.594	0.619
	SMOTE → ENN ∪ CNN ∪ GA	0.761	0.772	0.626	0.719
	SMOTEENN → ENN ∪ CNN ∪ GA	0.621	0.644	0.522	0.595

分類	組合方法	RF 平均 F1-score	XGBoost 平均 F1-score	SVM 平均 F1-score	平均
序列式混合方法 (FS → IS) + 重採樣方法	GA → GA	0.726	0.717	0.593	0.679
	GA → GA → Cluster Centroids	0.630	0.596	0.573	0.600
	GA → GA → SMOTE	0.742	0.710	0.639	0.697
	GA → GA → SMOTEENN	0.535	0.521	0.394	0.484
	Cluster Centroids → GA → GA	0.678	0.629	0.578	0.628
	SMOTE → GA → GA	0.799 (所有組合 No.1)	0.758	0.604	0.720
	SMOTEENN → GA → GA	0.626	0.630	0.497	0.584
序列式混合方法 (IS → FS) + 重採樣方法	GA → GA	0.713	0.706	0.629	0.683
	GA → GA → Cluster Centroids	0.659	0.603	0.548	0.603
	GA → GA → SMOTE	0.744	0.714	0.599	0.686
	GA → GA → SMOTEENN	0.624	0.587	0.541	0.584
	Cluster Centroids → GA → GA	0.657	0.625	0.540	0.607
	SMOTE → GA → GA	0.787 (所有組合 No.3)	0.764	0.621	0.724
	SMOTEENN → GA → GA	0.607	0.624	0.486	0.572

(資料來源：本研究)

4.2.2 重採樣組合方法於不同分類器下之最佳結果分析

在上一小節 4.2.1 中主要以 RF、XGBoost 及 SVM 三種分類器之平均值進行整體比較，用以觀察各重採樣組合方法之整體趨勢。然而，平均結果僅能呈現不同方法的整體表現，尚無法進一步反映各分類器搭配不同重採樣組合方法時的個別差異。因此，本節將針對 24 組混合式前處理策略分別結合 RF、XGBoost 及 SVM 後所形成之 72 組實驗結果進行分析（如表 4-11、表 4-12 所示），以進一步檢視重採樣組合方法於不同分類器下之分類效能表現，並說明其中表現最佳之方法。

在 AUC 指標方面，實驗結果中表現前三名如表 4-11 所示：

表 4 - 11 AUC 指標下重採樣組合方法之最佳結果

方法組合	AUC	排名	相較原方法之顯著性
重採樣 + 序列式混合方法 (IS → FS) RF 搭配 SMOTE → GA(IS) → GA(FS)	0.921	1	與 GA → GA 達 Wilcoxon 統計顯著
特徵選取方法 + 重採樣 RF 搭配 CART MI GA 多重交集 → SMOTE	0.908	2	與 CART、MI 與 GA 多重交集 未達 Wilcoxon 統計顯著
未結合重採樣 RF 搭配 CART、MI 與 GA 多重交集	0.906	3	-

（資料來源：本研究）

經 Wilcoxon 檢定後，前三名方法之間未達統計顯著差異，表示三者在整體分類能力上的表現相近。進一步與其原始基礎方法相比，在重採樣搭配序列式混合方法 (IS → FS) 中，**SMOTE → GA → GA** 相較於未進行重採樣之原方法達顯著差異，顯示在該序列式混合方法前加入 SMOTE 後，能提升 AUC 表現。

在 F1-score 指標方面，實驗結果中表現前三名如表 4-12 所示：

表 4 - 12 F1-score 指標下重採樣組合方法之最佳結果

方法組合	F1-score	排名	相較原方法之顯著性
重採樣 + 序列式混合方法 (FS → IS) RF 搭配 SMOTE → GA(FS) → GA(IS)	0.799	1	與 GA → GA 達 Wilcoxon 統計顯著
特徵選取方法 + 重採樣 RF 搭配 CART MI GA 多重交集 → SMOTE	0.792	2	與 CART、MI 與 GA 多重交集 達 Wilcoxon 統計顯著
重採樣 + 序列式混合方法 (IS → FS) RF 搭配 SMOTE → GA(IS) → GA(FS)	0.787	3	與 GA → GA 達 Wilcoxon 統計顯著

(資料來源：本研究)

經 Wilcoxon 檢定後，前三名方法之間並未達顯著差異，表示其 F1-score 表現相近。進一步比較各方法與其原始基礎方法後可發現，前三名方法皆較未進行重採樣之對應方法達顯著差異。顯示雖然 F1-score 前三名方法彼此之間差異有限，但加入 SMOTE 後皆能相較於各自原始基礎方法取得顯著改善。

整體而言，在 72 組不同分類器與前處理策略組合中，AUC 與 F1-score 的最佳結果皆出現在 RF 分類器搭配 SMOTE 相關方法之組合。雖然各指標前三名方法之間皆未達顯著差異，表示前三名方法間的表現相近，但與原始方法相比，SMOTE 仍能帶來顯著改善。尤其在 F1-score 指標下，前三名方法皆為 SMOTE 組合且皆顯著優於其原始方法，顯示 SMOTE 相較於 Cluster Centroids 與 SMOTEENN，更適合用於本研究之不平衡資料分類情境。

4.2.3 實驗二小結

實驗二主要針對不平衡比例大於或等於 2 之資料集，進一步探討在既有資料前處理策略下導入重採樣方法後，是否能進一步改善分類效能。整體結果顯示，SMOTE 在多數組合中較能維持或提升分類效能，相較之下，Cluster Centroids 與 SMOTEENN 在多數組合中未能有效提升分類效能，部分結果甚至低於未進行重採樣之基礎方法。

從整體平均結果來看，先進行 CART、MI 與 GA 之多重交集特徵選取方法，再進

行 SMOTE，同時在 AUC 與 F1-score 指標下取得最佳平均表現。然而，相較於未加入重採樣的 CART、MI 與 GA 之多重交集特徵選取方法，該組合僅呈現小幅提升 (AUC 由 0.874 提升至 0.876，增加 0.2%；F1-score 則由 0.740 提升至 0.745，增加 0.5%)，且未達 Wilcoxon 統計顯著，表示其額外改善效果有限。因此，若實務應用情境中需考量實作成本、流程複雜度或運算資源，亦可直接採用 **CART、MI 與 GA 之多重交集特徵選取方法**，作為兼具分類效能與實作可行性的方案。

進一步從三種分類器下之 72 組實驗結果觀察，最佳結果皆出現在 RF 分類器搭配 SMOTE 相關組合。若以 AUC 作為主要評估指標，建議優先採用 **RF 搭配 SMOTE → GA(IS) → GA(FS)**；若以 F1-score 作為主要評估指標，則建議優先採用 **RF 搭配 SMOTE → GA(FS) → GA(IS)**。兩者分別在 AUC 與 F1-score 指標下取得最佳表現，且相較於各自未進行重採樣之原始方法皆達顯著差異。

第五章 結論

5.1 結論與貢獻

本研究探討不同資料前處理策略對分類模型效能之影響，並從整體分類表現、資料精簡效果、類別不平衡處理與實務應用建議等面向進行分析。根據本研究之實驗結果，總結出以下結論與貢獻：

1. 建立多策略資料前處理之系統性比較架構

本研究建立一套多策略資料前處理之系統性實驗架構，整合特徵選取、樣本選取與重採樣方法，並納入單一方法、平行式集成方法與序列式混合方法等不同處理流程，以比較各類資料前處理策略對分類模型效能的影響。相較於僅針對單一方法或特定組合進行比較，本研究所建立之實驗架構具有較完整的比較範圍，可作為後續研究探討多策略資料前處理方法之參考基礎。

2. 特徵選取方法於整體資料情境下具有較佳分類效能

實驗結果顯示，在整體資料集平均情境下，特徵選取相關方法相較於樣本選取方法與序列式混合方法，較能穩定提升分類模型效能。其中，CART、MI 與 GA 多重交集特徵選取方法在整體資料集平均情境下，在 AUC 與 F1-score 兩項指標皆呈現較佳表現，顯示整合不同特徵選取邏輯有助於保留具分類判別力之特徵子集，不僅能作為資料精簡工具，也可作為提升分類效能之有效前處理策略。

3. 樣本選取方法於小樣本與高維資料下之應用限制

樣本選取方法雖可透過刪除冗餘或雜訊樣本改善資料品質，但本研究結果顯示，在部分小樣本與高維資料集中，可能因樣本刪減幅度過大而造成類別樣本不足，甚至使部分類別被完全移除，導致後續模型訓練與評估無法順利進行。樣本選取方法對資料結構較為敏感，若未審慎控制樣本刪減比例，可能造成重要訓練資訊流失。因此，樣本選取方法較適合作為特定資料情境下之輔助性處理策略，而不宜在未評估資料規模、類別分布與樣本刪減比例前直接套用。

4. 驗證方法整合效果具有情境差異，並非必然產生加乘效益

實驗結果顯示，特徵選取與樣本選取之序列式混合方法，在整體資料集平均情境下並未穩定優於特徵選取方法。然而，當分析範圍限縮至 Baseline 分類效能較低之高難度資料集時，部分樣本選取方法與序列式混合方法仍展現改善效果，顯示資料前處理策略之效益會受到資料難度與資料結構影響，不同前處理策略之結合不必然能帶來額外效益。因此，在評估多種前處理方法之整合效果時，除了觀察整體平均表現外，亦應依特定資料情境進行分析，以避免忽略方法在不同資料條件下的潛在適用性。

5. 建立不同資料情境下之資料前處理策略選擇依據

為提供後續研究與實務應用參考，本研究依不同資料情境整理適用之資料前處理策

略，作為方法選擇之依據。由實驗結果可知，資料前處理策略之效益會受到資料規模、特徵維度、類別不平衡程度與分析目標影響，因此不宜套用單一固定流程，而應依資料特性與研究需求進行調整。根據本研究之實驗結果，建議方法整理如下：

- **綜合表現：**建議優先採用 **CART、MI 與 GA 之多重交集特徵選取方法搭配 RF 分類器**。此組合在整體資料集平均情境下，於 AUC 與 F1-score 皆呈現較佳表現，並能在分類效能與特徵精簡率之間取得良好平衡。此外，考量 RF 具備較佳的平行化特性，在模型訓練效率與部署成本上亦具備實務優勢。因此，可作為一般資料情境下之優先前處理方案。
- **小樣本或高維資料集：**若資料集屬於樣本數較少或特徵維度較高之情境，建議以**特徵選取方法**作為主要前處理策略，避免直接使用高刪減率之樣本選取方法。由於樣本選取可能造成部分類別樣本不足，甚至使類別被完全移除，進而影響模型訓練與評估，因此，在此類資料情境下可優先採用 **CART、MI 與 GA 之多重交集特徵選取方法**。若需降低方法複雜度，亦可考慮單一 **MI 或 GA 特徵選取方法**作為替代方案。
- **高難度資料集：**若原始資料之 Baseline 分類效能較低，表示資料本身對分類模型具有較高挑戰性，此時部分樣本選取或序列式混合方法亦可能具有應用價值。若以 AUC 為主要指標，可考慮 **SVM 搭配 ENN (IS) U CNN (IS)、ENN (IS) → MI (FS)** 或 **CART (FS) → ENN (IS)**。若以 F1-score 為主要指標，則可考慮 **RF 搭配 CART (FS) → GA (IS)** 或 **ENN U CNN U GA**。然而，本研究之高難度資料集係依各維度區間中 Baseline 分類效能最低者進行篩選，並非以固定門檻劃分，因此實務應用時應先觀察原始資料之 Baseline 表現，再判斷是否需採用樣本選取或序列式混合方法。
- **類別不平衡資料集：**本研究以不平衡比例大於或等於 2 作為類別不平衡資料集之篩選依據，因此當資料集符合此條件時，建議優先評估 SMOTE 相關組合。若以整體平均表現為主要考量，可採用 **CART、MI 與 GA 多重交集特徵選取方法 → SMOTE**；若以 AUC 為主要指標時，可優先考慮 **RF 搭配 SMOTE → GA (IS) → GA (FS)**；以 F1-score 為主要指標時，則可優先考慮 **RF 搭配 SMOTE → GA (FS) → GA (IS)**。

5.2 未來研究方向與建議

本研究以特徵選取、樣本選取與重採樣方法為核心，探討不同資料前處理策略及其組合方式對分類模型效能之影響。雖然本研究已針對不同資料情境進行系統性比較，並提出相關實務建議，然而受限於研究範圍與實驗設計，仍有可延伸之方向。後續研究可從以下幾個面向進行探討：

1. 納入更多資料特性以強化情境化分析

本研究已依據特徵維度、資料難度與類別不平衡比例等資料特性進行分析，初步觀察不同資料情境下各類前處理方法之表現差異。然而，資料前處理策略之效益仍可能受到其他資料特性影響，例如資料雜訊程度、特徵冗餘程度、類別重疊程度及樣本分布複雜度等。因此，後續研究可在既有分析基礎上，進一步納入更多資料特性指標，以更完整地探討不同前處理方法之適用條件。透過更細緻的資料情境分析，有助於掌握各類方法在不同資料條件下的表現差異，並作為實務應用中選擇前處理策略之參考。

2. 納入更多資料前處理方法進行比較

本研究為保持原始資料結構與特徵意義，主要採用特徵選取方法進行資料維度精簡，並於實驗結果中顯示其在多數資料情境下具有良好的分類表現。未來研究可進一步納入特徵萃取方法進行比較，特徵萃取同樣具有降低資料維度之效果，但若是透過轉換原始特徵形成新的特徵空間，與特徵選取保留原始特徵之方式有所不同。因此，後續研究可比較特徵選取與特徵萃取在分類效能、資料壓縮程度與模型可解釋性上的差異。

在樣本選取方面，本研究結果顯示，部分樣本選取方法在小樣本或高維資料集中可能發生類別樣本被過度刪除的情形，進而影響模型訓練與分類效能。因此，後續可探討更具保守性或可控制刪減比例之樣本選取方法，以降低關鍵樣本流失與類別結構被破壞的風險，並提升樣本選取方法於不同資料情境下之穩定性。

3. 使用深度學習之分類演算法

本研究採用 RF、XGBoost 與 SVM 三種傳統機器學習分類器進行比較，以分析資料前處理策略於不同分類模型下之效能表現。未來研究可進一步納入深度學習分類演算法，探討多策略資料前處理方法在不同模型架構下之適用性。由於深度學習模型具備自動學習資料表徵的能力，對於高維度、非線性或結構複雜資料可能呈現不同於傳統模型的表現。因此，後續可比較傳統機器學習與深度學習模型在搭配各類前處理策略後的效能差異，以釐清資料前處理方法在不同模型架構下的應用價值。

參考文獻

- [1] M. Shahnawaz and M. Kumar, “A Comprehensive Survey on Big Data Analytics: Characteristics, Tools and Techniques,” *ACM Comput. Surv.*, vol. 57, no. 8, pp. 1 – 33, Aug. 2025, doi: 10.1145/3718364.
- [2] A. Badshah, A. Daud, R. Alharbey, A. Banjar, A. Bukhari, and B. Alshemaimri, “Big data applications: overview, challenges and future,” *Artif Intell Rev*, vol. 57, no. 11, p. 290, Sep. 2024, doi: 10.1007/s10462-024-10938-5.
- [3] U. Fayyad, “From Data Mining to Knowledge Discovery in Databases” .
- [4] S. García, J. Luengo, and F. Herrera, *Data Preprocessing in Data Mining*, vol. 72. in Intelligent Systems Reference Library, vol. 72. Cham: Springer International Publishing, 2015. doi: 10.1007/978-3-319-10247-4.
- [5] J. Li *et al.*, “Feature Selection: A Data Perspective,” *ACM Comput. Surv.*, vol. 50, no. 6, pp. 1 – 45, Nov. 2018, doi: 10.1145/3136625.
- [6] S. B. Kotsiantis, D. Kanellopoulos, and P. E. Pintelas, “Data Preprocessing for Supervised Learning,” vol. 1, no. 1, 2006.
- [7] J. Hariharakrishnan, S. Mohanavalli, Srividya, and K. B. Sundhara Kumar, “Survey of pre-processing techniques for mining big data,” in *2017 International Conference on Computer, Communication and Signal Processing (ICCCSP)*, Chennai: IEEE, Jan. 2017, pp. 1 – 5. doi: 10.1109/ICCCSP.2017.7944072.
- [8] H. Kaur, H. S. Pannu, and A. K. Malhi, “A Systematic Review on Imbalanced Data Challenges in Machine Learning: Applications and Solutions,” *ACM Comput. Surv.*, vol. 52, no. 4, pp. 1 – 36, Jul. 2020, doi: 10.1145/3343440.
- [9] L. C. Molina, L. Belanche, and A. Nebot, “Feature selection algorithms: a survey and experimental evaluation,” in *2002 IEEE International Conference on Data Mining, 2002. Proceedings.*, Maebashi City, Japan: IEEE Comput. Soc, 2002, pp. 306 – 313. doi: 10.1109/ICDM.2002.1183917.
- [10] H. Liu and H. Motoda, “On Issues of Instance Selection” .
- [11] M. R. Islam, A. A. Lima, S. C. Das, M. F. Mridha, A. R. Prodeep, and Y. Watanobe, “A Comprehensive Survey on the Process, Methods, Evaluation, and Challenges of Feature Selection,” *IEEE Access*, vol. 10, pp. 99595 – 99632, 2022, doi: 10.1109/ACCESS.2022.3205618.
- [12] J. A. Olvera-López, J. A. Carrasco-Ochoa, J. F. Martínez-Trinidad, and J. Kittler, “A review of instance selection methods,” *Artif Intell Rev*, vol. 34, no. 2, pp. 133 – 143, Aug. 2010, doi: 10.1007/s10462-010-9165-y.
- [13] M. Carvalho, A. J. Pinho, and S. Brás, “Resampling approaches to handle class imbalance: a review from a data perspective,” *J Big Data*, vol. 12, no. 1, p. 71, Mar. 2025, doi: 10.1186/s40537-025-01119-4.
- [14] H. Hairani, T. Widiyaningtyas, and D. D. Prasetya, “Feature Selection and Hybrid Sampling with Machine Learning Methods for Health Data Classification,” *RIA*, vol. 38, no. 4, pp. 1255 – 1261, Aug. 2024, doi: 10.18280/ria.380419.
- [15] V. Amarnadh and N. R. Moparthi, “Range control-based class imbalance and optimized granular elastic net regression feature selection for credit risk assessment,” *Knowl Inf Syst*,

- vol. 66, no. 9, pp. 5281 – 5310, Sep. 2024, doi: 10.1007/s10115-024-02103-9.
- [16] L. Papíková and M. Papík, “Effects of classification, feature selection, and resampling methods on bankruptcy prediction of small and medium-sized enterprises,” *Intelligent Sys in Account*, vol. 29, no. 4, pp. 254 – 281, Oct. 2022, doi: 10.1002/isaf.1521.
 - [17] S. Matharaarachchi, M. Domaratzki, and S. Muthukumarana, “Assessing feature selection method performance with class imbalance data,” *Machine Learning with Applications*, vol. 6, p. 100170, Dec. 2021, doi: 10.1016/j.mlwa.2021.100170.
 - [18] I. Czarnowski, “Learning from Imbalanced Data Streams Based on Over-Sampling and Instance Selection,” in *Computational Science – ICCS 2021*, vol. 12744, M. Paszynski, D. Kranzlmüller, V. V. Krzhizhanovskaya, J. J. Dongarra, and P. M. A. Sloot, Eds., in Lecture Notes in Computer Science, vol. 12744, Cham: Springer International Publishing, 2021, pp. 378 – 391. doi: 10.1007/978-3-030-77967-2_32.
 - [19] C. Lin, C.-F. Tsai, and W.-C. Lin, “Towards hybrid over- and under-sampling combination methods for class imbalanced datasets: an experimental study,” *Artif Intell Rev*, vol. 56, no. 2, pp. 845 – 863, Feb. 2023, doi: 10.1007/s10462-022-10186-5.
 - [20] A. J. Ferreira and M. A. T. Figueiredo, “An unsupervised approach to feature discretization and selection,” *Pattern Recognition*, vol. 45, no. 9, pp. 3048 – 3060, Sep. 2012, doi: 10.1016/j.patcog.2011.12.008.
 - [21] M. Dash and H. Liu, “Feature Selection for Classification” .
 - [22] A. Kraskov, H. Stögbauer, and P. Grassberger, “Estimating mutual information,” *Phys. Rev. E*, vol. 69, no. 6, p. 066138, Jun. 2004, doi: 10.1103/PhysRevE.69.066138.
 - [23] J. Benesty, J. Chen, Y. Huang, and I. Cohen, “Pearson Correlation Coefficient,” in *Noise Reduction in Speech Processing*, vol. 2, in Springer Topics in Signal Processing, vol. 2, Berlin, Heidelberg: Springer Berlin Heidelberg, 2009, pp. 1 – 4. doi: 10.1007/978-3-642-00296-0_5.
 - [24] S. Dahiya, S. S. Handa, and N. P. Singh, “A Rank Aggregation Algorithm for Ensemble of Multiple Feature Selection Techniques in Credit Risk Evaluation,” *ijarai*, vol. 5, no. 9, 2016, doi: 10.14569/IJARAI.2016.050901.
 - [25] Hanchuan Peng, Fuhui Long, and C. Ding, “Feature selection based on mutual information criteria of max-dependency, max-relevance, and min-redundancy,” *IEEE Trans. Pattern Anal. Machine Intell.*, vol. 27, no. 8, pp. 1226 – 1238, Aug. 2005, doi: 10.1109/TPAMI.2005.159.
 - [26] Y. Saeys, I. Inza, and P. Larrañaga, “A review of feature selection techniques in bioinformatics,” *Bioinformatics*, vol. 23, no. 19, pp. 2507 – 2517, Oct. 2007, doi: 10.1093/bioinformatics/btm344.
 - [27] A. G. Karegowda, A. S. Manjunath, and M. A. Jayaram, “Feature Subset Selection Problem using Wrapper Approach in Supervised Learning,” *IJCA*, vol. 1, no. 7, pp. 13 – 17, Feb. 2010, doi: 10.5120/169-295.
 - [28] R. Kohavi and G. H. John, “Wrappers for feature subset selection,” *Artificial Intelligence*, vol. 97, no. 1 – 2, pp. 273 – 324, Dec. 1997, doi: 10.1016/S0004-3702(97)00043-X.
 - [29] C.-F. Tsai, W. Eberle, and C.-Y. Chu, “Genetic algorithms in feature and instance selection,” *Knowledge-Based Systems*, vol. 39, pp. 240 – 247, Feb. 2013, doi: 10.1016/j.knosys.2012.11.005.
 - [30] K. De Jong, “Learning with genetic algorithms: An overview,” *Mach Learn*, vol. 3, no.

- 2 – 3, pp. 121 – 138, Oct. 1988, doi: 10.1007/BF00113894.
- [31] P. Bermejo, J. A. Gámez, and J. M. Puerta, “Speeding up incremental wrapper feature subset selection with Naive Bayes classifier,” *Knowledge-Based Systems*, vol. 55, pp. 140 – 147, Jan. 2014, doi: 10.1016/j.knosys.2013.10.016.
 - [32] R. Ruiz, J. C. Riquelme, and J. S. Aguilar-Ruiz, “Incremental wrapper-based gene selection from microarray data for cancer classification,” *Pattern Recognition*, vol. 39, no. 12, pp. 2383 – 2392, Dec. 2006, doi: 10.1016/j.patcog.2005.11.001.
 - [33] Y. Saeys, T. Abeel, and Y. Van De Peer, “Robust Feature Selection Using Ensemble Feature Selection Techniques,” in *Machine Learning and Knowledge Discovery in Databases*, vol. 5212, W. Daelemans, B. Goethals, and K. Morik, Eds., in Lecture Notes in Computer Science, vol. 5212., Berlin, Heidelberg: Springer Berlin Heidelberg, 2008, pp. 313 – 325. doi: 10.1007/978-3-540-87481-2_21.
 - [34] S. Maldonado and J. López, “Dealing with high-dimensional class-imbalanced datasets: Embedded feature selection for SVM classification,” *Applied Soft Computing*, vol. 67, pp. 94 – 105, Jun. 2018, doi: 10.1016/j.asoc.2018.02.051.
 - [35] A.-C. Haury, P. Gestraud, and J.-P. Vert, “The Influence of Feature Selection Methods on Accuracy, Stability and Interpretability of Molecular Signatures,” *PLoS ONE*, vol. 6, no. 12, p. e28210, Dec. 2011, doi: 10.1371/journal.pone.0028210.
 - [36] M. Kang, Md. R. Islam, J. Kim, J.-M. Kim, and M. Pecht, “A Hybrid Feature Selection Scheme for Reducing Diagnostic Performance Deterioration Caused by Outliers in Data-Driven Diagnostics,” *IEEE Trans. Ind. Electron.*, vol. 63, no. 5, pp. 3299 – 3310, May 2016, doi: 10.1109/TIE.2016.2527623.
 - [37] R. Islam, S. A. Khan, and J. Kim, “Discriminant Feature Distribution Analysis-Based Hybrid Feature Selection for Online Bearing Fault Diagnosis in Induction Motors,” *Journal of Sensors*, vol. 2016, pp. 1 – 16, 2016, doi: 10.1155/2016/7145715.
 - [38] N. Pudjihartono, T. Fadason, A. W. Kempa-Liehr, and J. M. O’ Sullivan, “A Review of Feature Selection Methods for Machine Learning-Based Disease Risk Prediction,” *Front. Bioinform.*, vol. 2, p. 927312, Jun. 2022, doi: 10.3389/fbinf.2022.927312.
 - [39] S. Garcia, J. Derrac, J. R. Cano, and F. Herrera, “Prototype Selection for Nearest Neighbor Classification: Taxonomy and Empirical Study,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 34, no. 3, pp. 417 – 435, Mar. 2012, doi: 10.1109/TPAMI.2011.142.
 - [40] P. Hart, “The condensed nearest neighbor rule (Corresp.),” *IEEE Trans. Inform. Theory*, vol. 14, no. 3, pp. 515 – 516, May 1968, doi: 10.1109/TIT.1968.1054155.
 - [41] D. L. Wilson, “Asymptotic Properties of Nearest Neighbor Rules Using Edited Data,” *IEEE Trans. Syst., Man, Cybern.*, vol. SMC-2, no. 3, pp. 408 – 421, Jul. 1972, doi: 10.1109/TSMC.1972.4309137.
 - [42] L. I. Kuncheva, “Editing for the k-nearest neighbors rule by a genetic algorithm,” *Pattern Recognition Letters*, vol. 16, no. 8, pp. 809 – 814, Aug. 1995, doi: 10.1016/0167-8655(95)00047-K.
 - [43] H. Kaur, H. S. Pannu, and A. K. Malhi, “A Systematic Review on Imbalanced Data Challenges in Machine Learning: Applications and Solutions,” *ACM Comput. Surv.*, vol. 52, no. 4, pp. 1 – 36, Jul. 2020, doi: 10.1145/3343440.
 - [44] J. L. Leevy, T. M. Khoshgoftaar, R. A. Bauder, and N. Seliya, “A survey on addressing high-class imbalance in big data,” *J Big Data*, vol. 5, no. 1, p. 42, Dec. 2018, doi:

10.1186/s40537-018-0151-6.

- [45] B. Krawczyk, “Learning from imbalanced data: open challenges and future directions,” *Prog Artif Intell*, vol. 5, no. 4, pp. 221 – 232, Nov. 2016, doi: 10.1007/s13748-016-0094-0.
- [46] E. Troullinou, G. Tsagkatakis, A. Losonczy, P. Poirazi, and P. Tsakalides, “A Generative Neighborhood-Based Deep Autoencoder for Robust Imbalanced Classification,” *IEEE Trans. Artif. Intell.*, vol. 5, no. 1, pp. 80 – 91, Jan. 2024, doi: 10.1109/TAI.2023.3249685.
- [47] M. Altalhan, A. Algarni, and M. Turki-Hadj Alouane, “Imbalanced Data Problem in Machine Learning: A Review,” *IEEE Access*, vol. 13, pp. 13686 – 13699, 2025, doi: 10.1109/ACCESS.2025.3531662.
- [48] E. Battistella, D. Ghiassian, and A.-L. Barabási, “Improving the performance and interpretability on medical datasets using graphical ensemble feature selection,” *Bioinformatics*, vol. 40, no. 6, p. btac341, Jun. 2024, doi: 10.1093/bioinformatics/btac341.
- [49] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic Minority Over-sampling Technique,” *jair*, vol. 16, pp. 321 – 357, Jun. 2002, doi: 10.1613/jair.953.
- [50] A. D. Pozzolo, O. Caelen, R. A. Johnson, and G. Bontempi, “Calibrating Probability with Undersampling for Unbalanced Classification,” in *2015 IEEE Symposium Series on Computational Intelligence*, Cape Town, South Africa: IEEE, Dec. 2015, pp. 159 – 166. doi: 10.1109/SSCI.2015.33.
- [51] V. Kumar *et al.*, “Addressing Binary Classification over Class Imbalanced Clinical Datasets Using Computationally Intelligent Techniques,” *Healthcare*, vol. 10, no. 7, p. 1293, Jul. 2022, doi: 10.3390/healthcare10071293.
- [52] S.-J. Yen and Y.-S. Lee, “Cluster-based under-sampling approaches for imbalanced data distributions,” *Expert Systems with Applications*, vol. 36, no. 3, pp. 5718 – 5727, Apr. 2009, doi: 10.1016/j.eswa.2008.06.108.
- [53] Q. Zhou and B. Sun, “Adaptive K-means clustering based under-sampling methods to solve the class imbalance problem,” *Data and Information Management*, vol. 8, no. 3, p. 100064, Sep. 2024, doi: 10.1016/j.dim.2023.100064.
- [54] C.-F. Tsai, K.-C. Chen, and W.-C. Lin, “Feature selection and its combination with data over-sampling for multi-class imbalanced datasets,” *Applied Soft Computing*, vol. 153, p. 111267, Mar. 2024, doi: 10.1016/j.asoc.2024.111267.
- [55] Y.-H. Hu, C.-F. Tsai, and P.-T. Wang, “Combining multiple data resampling methods and classifier ensembles for better financial distress prediction: homogeneous and heterogeneous approaches,” *Ann Oper Res*, vol. 353, no. 2, pp. 793 – 814, Oct. 2025, doi: 10.1007/s10479-025-06706-5.
- [56] C. Tsai, W. Lin, and Y. Chen, “Data Quality Improvement for Financial Distress Prediction: Feature Selection, Data Re-Sampling, and Their Combinations in Different Orders,” *Journal of Forecasting*, vol. 44, no. 7, pp. 2205 – 2229, Nov. 2025, doi: 10.1002/for.70002.
- [57] C. Lin, C.-F. Tsai, and W.-C. Lin, “Towards hybrid over- and under-sampling combination methods for class imbalanced datasets: an experimental study,” *Artif Intell Rev*, vol. 56, no. 2, pp. 845 – 863, Feb. 2023, doi: 10.1007/s10462-022-10186-5.
- [58] W. Ma, X. Zhou, H. Zhu, L. Li, and L. Jiao, “A two-stage hybrid ant colony optimization for high-dimensional feature selection,” *Pattern Recognition*, vol. 116, p. 107933, Aug. 2021, doi: 10.1016/j.patcog.2021.107933.

- [59] F. Kamalov, F. Thabtah, and H. H. Leung, "Feature Selection in Imbalanced Data," *Ann. Data. Sci.*, vol. 10, no. 6, pp. 1527 – 1541, Dec. 2023, doi: 10.1007/s40745-021-00366-5.
- [60] J. Zhai and D. Song, "Optimal instance subset selection from big data using genetic algorithm and open source framework," *J Big Data*, vol. 9, no. 1, p. 87, Dec. 2022, doi: 10.1186/s40537-022-00640-0.
- [61] G. E. Melo-Acosta, F. Duitama-Muñoz, and J. D. Arias-Londoño, "An Instance Selection Algorithm for Big Data in High imbalanced datasets based on LSH" .
- [62] R. Van Den Goorbergh, M. Van Smeden, D. Timmerman, and B. Van Calster, "The harm of class imbalance corrections for risk prediction models: illustration and simulation using logistic regression," *Journal of the American Medical Informatics Association*, vol. 29, no. 9, pp. 1525 – 1534, Aug. 2022, doi: 10.1093/jamia/ocac093.
- [63] C.-F. Tsai, K.-L. Sue, Y.-H. Hu, and A. Chiu, "Combining feature selection, instance selection, and ensemble classification techniques for improved financial distress prediction," *Journal of Business Research*, vol. 130, pp. 200 – 209, Jun. 2021, doi: 10.1016/j.jbusres.2021.03.018.
- [64] C.-F. Tsai and Y.-T. Sung, "Ensemble feature selection in high dimension, low sample size datasets: Parallel and serial combination approaches," *Knowledge-Based Systems*, vol. 203, p. 106097, Sep. 2020, doi: 10.1016/j.knosys.2020.106097.
- [65] J. Grefenstette, "Optimization of Control Parameters for Genetic Algorithms," *IEEE Trans. Syst., Man, Cybern.*, vol. 16, no. 1, pp. 122 – 128, Jan. 1986, doi: 10.1109/TSMC.1986.289288.
- [66] Y.-H. Hu, C.-F. Tsai, and P.-T. Wang, "Combining multiple data resampling methods and classifier ensembles for better financial distress prediction: homogeneous and heterogeneous approaches," *Ann Oper Res*, vol. 353, no. 2, pp. 793 – 814, Oct. 2025, doi: 10.1007/s10479-025-06706-5.
- [67] "CoGBUS- Center of Gravity based under Sampling Method for Imbalanced Data Classification," *ijrte*, vol. 8, no. 2, pp. 2463 – 2468, Jul. 2019, doi: 10.35940/ijrte.B2077.078219.

附錄一、實驗一詳細數據

附表 1 特徵選取方法之 AUC 表現 (分類器: RF)

Dataset	Baseline	單一特徵選取方法			特徵選取平行式集成方法								
		CART	MI	GA	CART $\cup$ MI	CART $\cup$ GA	GA $\cup$ MI	CART $\cup$ MI $\cup$ GA	CART $\cap$ MI	CART $\cap$ GA	GA $\cap$ MI	CART $\cap$ MI $\cap$ GA	CART MI GA 多重交集
Connectionist Bench	0.927	0.886	0.925	0.940	0.933	0.943	0.936	0.924	0.874	0.883	0.930	0.845	0.938
Libras Movement	0.986	0.985	0.985	0.986	0.985	0.985	0.985	0.986	0.980	0.982	0.982	0.972	0.984
Hepatitis C Virus for Egyptian patients	0.507	0.504	0.507	0.516	0.490	0.495	0.505	0.501	0.502	0.503	0.512	0.503	0.512
OnlineNewsPopularity	0.942	0.941	0.943	0.951	0.943	0.951	0.944	0.944	0.941	0.941	0.950	0.941	0.950
Body signal of smoking	0.916	0.911	0.918	0.918	0.919	0.919	0.918	0.919	0.909	0.906	0.918	0.906	0.918
darwin	0.966	0.932	0.964	0.974	0.964	0.968	0.964	0.964	0.932	0.877	0.972	0.877	0.976
Drug induced Autoimmunity Prediction	0.876	0.873	0.867	0.888	0.880	0.885	0.882	0.876	0.871	0.865	0.889	0.864	0.877
Hill-Valley	0.507	0.553	0.496	0.563	0.506	0.542	0.520	0.506	0.539	0.569	0.532	0.563	0.551
pd speech features	0.948	0.945	0.953	0.949	0.951	0.954	0.949	0.950	0.937	0.916	0.959	0.917	0.959
madelon	0.793	0.907	0.773	0.838	0.832	0.832	0.817	0.813	0.870	0.930	0.813	0.898	0.880
colon	0.924	0.848	0.925	0.941	0.925	0.929	0.911	0.911	0.848	0.719	0.948	0.719	0.934
GLIOMA	0.956	0.926	0.951	0.958	0.951	0.958	0.952	0.952	0.926	0.926	0.960	0.926	0.960
DLBCL	0.966	0.903	0.970	0.969	0.970	0.969	0.966	0.966	0.903	0.903	0.979	0.903	0.979
toxicity	0.454	0.515	0.464	0.445	0.478	0.456	0.478	0.454	0.538	0.427	0.497	0.486	0.503
TOX_171	0.952	0.895	0.960	0.953	0.958	0.956	0.954	0.955	0.905	0.905	0.960	0.905	0.960
GLI_85	0.949	0.887	0.947	0.942	0.947	0.936	0.952	0.952	0.887	-	0.935	-	0.887
CLL SUB_111	0.835	0.851	0.872	0.863	0.872	0.832	0.836	0.836	0.851	0.825	0.882	0.825	0.851
GLA BRA_180	0.896	0.858	0.905	0.892	0.905	0.892	0.887	0.887	0.858	0.824	0.902	0.824	0.858
SMK CAN_187	0.747	0.700	0.750	0.727	0.750	0.743	0.748	0.748	0.700	-	0.767	-	0.700
arcene	0.889	0.868	0.898	0.892	0.898	0.892	0.899	0.899	0.868	0.868	0.909	0.868	0.868
平均	0.847	0.834	0.849	0.855	0.853	0.852	0.850	0.847	0.832	0.822	0.860	0.821	0.864

註:「-」表示進行特徵選取或樣本選取後,該資料集中未保留任何可供後續模型訓練之特徵或樣本。

附表 2 特徵選取方法之 AUC 表現 (分類器: XGBoost)

Dataset	Baseline	單一特徵選取方法			特徵選取平行式集成方法								
		CART	MI	GA	CART $\cup$ MI	CART $\cup$ GA	GA $\cup$ MI	CART $\cup$ MI $\cup$ GA	CART $\cap$ MI	CART $\cap$ GA	GA $\cap$ MI	CART $\cap$ MI $\cap$ GA	CART MI GA 多重交集
Connectionist Bench	0.942	0.881	0.937	0.966	0.939	0.956	0.951	0.944	0.871	0.877	0.950	0.849	0.962
Libras Movement	0.973	0.975	0.974	0.971	0.972	0.972	0.971	0.972	0.971	0.969	0.974	0.961	0.973
Hepatitis C Virus for Egyptian patients	0.517	0.499	0.513	0.528	0.509	0.515	0.516	0.510	0.511	0.510	0.519	0.510	0.523
OnlineNewsPopularity	0.962	0.943	0.961	0.962	0.961	0.962	0.962	0.962	0.943	0.943	0.961	0.943	0.961
Body signal of smoking	0.904	0.896	0.906	0.902	0.908	0.906	0.907	0.909	0.892	0.883	0.902	0.883	0.905
darwin	0.948	0.940	0.951	0.959	0.951	0.962	0.949	0.949	0.940	0.854	0.961	0.854	0.963
Drug induced Autoimmunity Prediction	0.867	0.867	0.877	0.883	0.877	0.881	0.871	0.872	0.878	0.871	0.886	0.875	0.885
Hill-Valley	0.549	0.591	0.548	0.605	0.559	0.594	0.558	0.553	0.565	0.628	0.605	0.596	0.611
pd_speech_features	0.952	0.951	0.956	0.950	0.957	0.955	0.954	0.955	0.951	0.918	0.955	0.917	0.958
madelon	0.907	0.921	0.864	0.911	0.910	0.911	0.907	0.906	0.896	0.930	0.881	0.910	0.920
colon	0.884	0.848	0.909	0.890	0.909	0.915	0.903	0.903	0.848	0.719	0.896	0.719	0.915
GLIOMA	0.938	0.928	0.941	0.946	0.941	0.946	0.938	0.938	0.928	0.928	0.950	0.928	0.950
DLBCL	0.979	0.939	0.977	0.978	0.977	0.978	0.983	0.983	0.939	0.939	0.988	0.939	0.988
toxicity	0.500	0.533	0.529	0.531	0.539	0.532	0.504	0.501	0.591	0.500	0.525	0.500	0.541
TOX_171	0.935	0.892	0.934	0.956	0.934	0.956	0.936	0.936	0.892	0.892	0.958	0.892	0.958
GLI_85	0.911	0.851	0.911	0.906	0.911	0.913	0.911	0.911	0.867	-	0.906	-	0.908
CLL_SUB_111	0.853	0.867	0.864	0.853	0.864	0.853	0.857	0.857	0.851	0.825	0.854	0.825	0.852
GLA_BRA_180	0.886	0.857	0.893	0.873	0.893	0.878	0.889	0.889	0.857	0.885	0.877	0.885	0.878
SMK_CAN_187	0.794	0.720	0.810	0.778	0.810	0.775	0.811	0.811	0.720	-	0.799	-	0.800
arcene	0.880	0.885	0.903	0.906	0.903	0.906	0.893	0.893	0.885	0.885	0.918	0.885	0.918
平均	0.854	0.839	0.858	0.863	0.861	0.863	0.858	0.858	0.840	0.834	0.863	0.830	0.868

附表 3 特徵選取方法之 AUC 表現 (分類器: SVM)

Dataset	Baseline	單一特徵選取方法			特徵選取平行式集成方法								
		CART	MI	GA	CART $\cup$ MI	CART $\cup$ GA	GA $\cup$ MI	CART $\cup$ MI $\cup$ GA	CART $\cap$ MI	CART $\cap$ GA	GA $\cap$ MI	CART $\cap$ MI $\cap$ GA	CART MI GA 多重交集
Connectionist Bench	0.921	0.882	0.916	0.934	0.911	0.930	0.919	0.915	0.872	0.869	0.912	0.855	0.936
Libras Movement	0.990	0.988	0.989	0.989	0.989	0.988	0.990	0.990	0.983	0.988	0.988	0.982	0.987
Hepatitis C Virus for Egyptian patients	0.509	0.510	0.509	0.506	0.509	0.513	0.509	0.509	0.511	0.514	0.507	0.514	0.508
OnlineNewsPopularity	0.773	0.762	0.770	0.769	0.770	0.769	0.773	0.773	0.764	0.764	0.771	0.764	0.771
Body signal of smoking	0.759	0.815	0.827	0.826	0.838	0.849	0.837	0.838	0.823	0.823	0.835	0.822	0.837
darwin	0.894	0.238	0.913	0.922	0.913	0.922	0.905	0.905	0.890	0.871	0.900	0.871	0.907
Drug induced Autoimmunity Prediction	0.495	0.764	0.503	0.815	0.503	0.808	0.502	0.502	0.798	0.820	0.817	0.789	0.813
Hill-Valley	0.833	0.862	0.806	0.851	0.830	0.849	0.821	0.819	0.791	0.714	0.817	0.613	0.843
pd_speech_features	0.679	0.765	0.680	0.680	0.923	0.680	0.680	0.680	0.780	0.774	0.680	0.950	0.680
madelon	0.749	0.860	0.770	0.808	0.793	0.794	0.780	0.772	0.871	0.752	0.814	0.904	0.832
colon	0.909	0.891	0.921	0.934	0.921	0.934	0.928	0.928	0.891	0.834	0.929	0.834	0.929
GLIOMA	0.956	0.599	0.979	0.961	0.979	0.961	0.971	0.971	0.933	0.933	0.988	0.933	0.988
DLBCL	1.000	0.978	0.996	1.000	0.996	1.000	0.995	0.995	0.978	0.978	1.000	0.978	1.000
toxicity	0.592	0.543	0.585	0.528	0.584	0.533	0.588	0.588	0.557	0.557	0.506	0.557	0.508
TOX_171	0.996	0.851	0.997	0.991	0.997	0.991	0.995	0.995	0.851	0.851	0.979	0.851	0.994
GLI_85	0.952	0.895	0.956	0.956	0.956	0.956	0.956	0.956	0.895	-	0.959	-	0.952
CLL_SUB_111	0.832	0.837	0.802	0.832	0.802	0.832	0.838	0.838	0.837	0.774	0.799	0.774	0.832
GLA_BRA_180	0.883	0.838	0.881	0.880	0.881	0.880	0.882	0.882	0.838	0.823	0.884	0.823	0.883
SMK_CAN_187	0.818	0.721	0.825	0.810	0.825	0.809	0.814	0.814	0.721	-	0.826	-	0.818
arcene	0.962	0.851	0.958	0.957	0.958	0.957	0.957	0.957	0.851	0.851	0.960	0.851	0.962
平均	0.825	0.773	0.829	0.847	0.844	0.848	0.832	0.831	0.822	0.806	0.843	0.815	0.848

附表 4 特徵選取方法之 F1-score 表現 (分類器: RF)

Dataset	Baseline	單一特徵選取方法			特徵選取平行式集成方法								
		CART	MI	GA	CART $\cup$ MI	CART $\cup$ GA	GA $\cup$ MI	CART $\cup$ MI $\cup$ GA	CART $\cap$ MI	CART $\cap$ GA	GA $\cap$ MI	CART $\cap$ MI $\cap$ GA	CART MI GA 多重交集
Connectionist Bench	0.815	0.802	0.817	0.831	0.820	0.839	0.845	0.830	0.762	0.803	0.836	0.763	0.855
Libras Movement	0.808	0.794	0.806	0.809	0.809	0.806	0.813	0.812	0.751	0.779	0.769	0.686	0.802
Hepatitis C Virus for Egyptian patients	0.265	0.243	0.261	0.248	0.241	0.233	0.248	0.255	0.247	0.261	0.243	0.261	0.266
OnlineNewsPopularity	0.668	0.665	0.670	0.693	0.670	0.693	0.671	0.671	0.665	0.665	0.693	0.665	0.693
Body signal of smoking	0.835	0.824	0.835	0.833	0.835	0.836	0.834	0.835	0.823	0.817	0.833	0.817	0.834
darwin	0.896	0.878	0.902	0.908	0.902	0.913	0.879	0.879	0.878	0.775	0.907	0.775	0.919
Drug induced Autoimmunity Prediction	0.820	0.803	0.824	0.832	0.820	0.816	0.829	0.806	0.830	0.826	0.835	0.817	0.827
Hill-Valley	0.511	0.534	0.513	0.565	0.518	0.537	0.540	0.511	0.535	0.556	0.535	0.552	0.531
pd_speech_features	0.869	0.870	0.887	0.862	0.873	0.872	0.873	0.875	0.881	0.849	0.887	0.851	0.893
madelon	0.718	0.829	0.703	0.750	0.745	0.750	0.738	0.735	0.786	0.858	0.734	0.819	0.795
colon	0.785	0.883	0.802	0.833	0.802	0.831	0.833	0.833	0.883	0.826	0.817	0.826	0.786
GLIOMA	0.789	0.751	0.761	0.785	0.761	0.785	0.785	0.785	0.751	0.751	0.805	0.751	0.805
DLBCL	0.842	0.836	0.906	0.858	0.906	0.858	0.884	0.884	0.836	0.836	0.903	0.836	0.903
toxicity	0.554	0.588	0.542	0.545	0.540	0.535	0.546	0.537	0.561	0.552	0.530	0.559	0.569
TOX_171	0.801	0.742	0.804	0.803	0.812	0.812	0.824	0.815	0.736	0.736	0.812	0.736	0.812
GLI_85	0.871	0.831	0.871	0.844	0.871	0.820	0.871	0.871	0.831	-	0.860	-	0.886
CLL_SUB_111	0.720	0.763	0.791	0.802	0.791	0.771	0.747	0.747	0.763	0.737	0.773	0.737	0.802
GLA_BRA_180	0.652	0.588	0.679	0.630	0.679	0.658	0.658	0.658	0.588	0.564	0.664	0.564	0.683
SMK_CAN_187	0.684	0.658	0.680	0.668	0.680	0.661	0.671	0.671	0.658	-	0.691	-	0.693
arcene	0.784	0.731	0.829	0.798	0.829	0.798	0.814	0.814	0.731	0.731	0.823	0.731	0.823
平均	0.734	0.731	0.744	0.745	0.745	0.741	0.745	0.741	0.725	0.714	0.748	0.705	0.759

附表 5 特徵選取方法之 F1-score 表現 (分類器 XGBoost)

Dataset	Baseline	單一特徵選取方法			特徵選取平行式集成方法								
		CART	MI	GA	CART $\cup$ MI	CART $\cup$ GA	GA $\cup$ MI	CART $\cup$ MI $\cup$ GA	CART $\cap$ MI	CART $\cap$ GA	GA $\cap$ MI	CART $\cap$ MI $\cap$ GA	CART MI GA 多重交集
Connectionist Bench	0.870	0.789	0.836	0.870	0.890	0.885	0.879	0.889	0.768	0.802	0.885	0.734	0.899
Libras Movement	0.748	0.761	0.753	0.759	0.754	0.759	0.761	0.746	0.730	0.746	0.790	0.684	0.766
Hepatitis C Virus for Egyptian patients	0.272	0.242	0.269	0.269	0.256	0.254	0.264	0.258	0.267	0.274	0.256	0.274	0.267
OnlineNewsPopularity	0.734	0.668	0.730	0.735	0.730	0.735	0.733	0.733	0.668	0.668	0.730	0.668	0.730
Body signal of smoking	0.829	0.812	0.824	0.823	0.829	0.827	0.828	0.827	0.810	0.805	0.822	0.805	0.826
darwin	0.873	0.856	0.891	0.891	0.891	0.879	0.879	0.879	0.856	0.809	0.879	0.809	0.885
Drug induced Autoimmunity Prediction	0.849	0.824	0.846	0.845	0.840	0.834	0.841	0.855	0.842	0.853	0.850	0.827	0.842
Hill-Valley	0.554	0.569	0.554	0.577	0.530	0.570	0.543	0.539	0.542	0.574	0.567	0.563	0.580
pd_speech_features	0.890	0.881	0.904	0.900	0.905	0.907	0.894	0.895	0.892	0.853	0.903	0.849	0.901
madelon	0.842	0.850	0.791	0.843	0.836	0.844	0.843	0.838	0.826	0.862	0.809	0.832	0.858
colon	0.753	0.846	0.768	0.728	0.768	0.722	0.750	0.750	0.846	0.826	0.744	0.826	0.782
GLIOMA	0.734	0.679	0.757	0.726	0.757	0.726	0.746	0.746	0.679	0.679	0.758	0.679	0.758
DLBCL	0.917	0.824	0.915	0.883	0.915	0.883	0.930	0.930	0.824	0.824	0.934	0.824	0.934
toxicity	0.541	0.597	0.562	0.607	0.571	0.582	0.585	0.591	0.591	0.541	0.596	0.541	0.584
TOX_171	0.750	0.672	0.784	0.833	0.784	0.833	0.759	0.759	0.655	0.655	0.799	0.655	0.799
GLI_85	0.823	0.744	0.839	0.835	0.839	0.879	0.823	0.823	0.838	-	0.835	-	0.876
CLL_SUB_111	0.762	0.838	0.763	0.744	0.763	0.744	0.773	0.773	0.744	0.710	0.735	0.710	0.744
GLA_BRA_180	0.715	0.576	0.739	0.696	0.739	0.685	0.718	0.718	0.576	0.583	0.663	0.583	0.666
SMK_CAN_187	0.705	0.642	0.725	0.702	0.725	0.660	0.704	0.704	0.642	-	0.700	-	0.711
arcene	0.809	0.762	0.844	0.828	0.844	0.828	0.803	0.803	0.762	0.762	0.849	0.762	0.849
平均	0.748	0.722	0.755	0.755	0.758	0.752	0.753	0.753	0.718	0.710	0.755	0.700	0.763

附表 6 特徵選取方法之 F1-score 表現 (分類器 : SVM)

Dataset	Baseline	單一特徵選取方法			特徵選取平行式集成方法								
		CART	MI	GA	CART $\cup$ MI	CART $\cup$ GA	GA $\cup$ MI	CART $\cup$ MI $\cup$ GA	CART $\cap$ MI	CART $\cap$ GA	GA $\cap$ MI	CART $\cap$ MI $\cap$ GA	CART MI GA 多重交集
Connectionist Bench	0.846	0.793	0.855	0.870	0.827	0.865	0.841	0.841	0.793	0.771	0.836	0.732	0.870
Libras Movement	0.902	0.859	0.893	0.893	0.896	0.893	0.893	0.896	0.820	0.862	0.858	0.801	0.864
Hepatitis C Virus for Egyptian patients	0.236	0.196	0.239	0.255	0.234	0.231	0.240	0.235	0.181	0.243	0.253	0.243	0.221
OnlineNewsPopularity	0.352	0.326	0.346	0.337	0.346	0.337	0.354	0.354	0.328	0.328	0.342	0.328	0.342
Body signal of smoking	0.623	0.731	0.746	0.746	0.759	0.476	0.758	0.759	0.747	0.747	0.758	0.745	0.759
darwin	0.833	0.786	0.821	0.850	0.821	0.850	0.850	0.850	0.822	0.769	0.826	0.769	0.826
Drug induced Autoimmunity Prediction	0.645	0.769	0.645	0.783	0.645	0.791	0.644	0.645	0.791	0.799	0.805	0.799	0.802
Hill-Valley	0.469	0.478	0.427	0.455	0.399	0.476	0.411	0.409	0.404	0.388	0.454	0.560	0.435
pd_speech_features	0.645	0.638	0.645	0.645	0.661	0.645	0.645	0.645	0.751	0.752	0.645	0.718	0.645
madelon	0.682	0.773	0.700	0.731	0.723	0.724	0.707	0.704	0.791	0.541	0.730	0.826	0.750
colon	0.766	0.883	0.766	0.766	0.766	0.766	0.766	0.766	0.883	0.826	0.823	0.826	0.840
GLIOMA	0.821	0.599	0.840	0.821	0.840	0.821	0.799	0.799	0.599	0.599	0.840	0.599	0.840
DLBCL	0.958	0.864	0.917	0.840	0.917	0.840	0.962	0.962	0.864	0.864	0.962	0.864	0.962
toxicity	0.532	0.526	0.535	0.541	0.535	0.541	0.535	0.535	0.541	0.541	0.551	0.541	0.551
TOX_171	0.969	0.607	0.958	0.906	0.958	0.906	0.964	0.964	0.597	0.597	0.912	0.597	0.923
GLI_85	0.891	0.814	0.904	0.892	0.904	0.892	0.904	0.904	0.814	-	0.917	-	0.917
CLL_SUB_111	0.765	0.723	0.710	0.667	0.710	0.667	0.756	0.756	0.723	0.666	0.689	0.666	0.689
GLA_BRA_180	0.695	0.524	0.723	0.714	0.723	0.714	0.720	0.720	0.524	0.512	0.725	0.512	0.725
SMK_CAN_187	0.772	0.683	0.783	0.777	0.783	0.777	0.777	0.777	0.683	-	0.756	-	0.756
arcene	0.910	0.763	0.905	0.895	0.905	0.895	0.890	0.890	0.763	0.763	0.905	0.763	0.905
平均	0.716	0.667	0.718	0.719	0.718	0.705	0.721	0.721	0.671	0.643	0.729	0.659	0.731

附表 7 特徵選取方法之特徵精簡率

Dataset	Baseline	單一特徵選取方法			特徵選取平行式集成方法								
		CART	MI	GA	CART $\cup$ MI	CART $\cup$ GA	GA $\cup$ MI	CART $\cup$ MI $\cup$ GA	CART $\cap$ MI	CART $\cap$ GA	GA $\cap$ MI	CART $\cap$ MI $\cap$ GA	CART MI GA 多重交集
Connectionist Bench	0.000	0.700	0.517	0.450	0.333	0.367	0.250	0.200	0.883	0.783	0.717	0.917	0.550
Libras Movement	0.000	0.744	0.278	0.500	0.211	0.411	0.144	0.122	0.811	0.833	0.633	0.878	0.522
Hepatitis C Virus for Egyptian patients	0.000	0.643	0.393	0.714	0.321	0.464	0.321	0.250	0.714	0.893	0.786	0.893	0.607
OnlineNewsPopularity	0.000	0.898	0.237	0.542	0.224	0.535	0.121	0.121	0.897	0.897	0.638	0.897	0.638
Body signal of smoking	0.000	0.615	0.346	0.462	0.333	0.370	0.333	0.296	0.667	0.741	0.519	0.741	0.444
darwin	0.000	0.991	0.391	0.504	0.393	0.499	0.220	0.220	0.991	0.998	0.679	0.998	0.672
Drug induced Autoimmunity Prediction	0.000	0.821	0.531	0.510	0.480	0.434	0.281	0.250	0.872	0.898	0.760	0.918	0.694
Hill-Valley	0.000	0.650	0.370	0.630	0.260	0.450	0.260	0.200	0.760	0.830	0.740	0.880	0.570
pd_speech_features	0.000	0.967	0.382	0.503	0.373	0.488	0.174	0.170	0.976	0.981	0.711	0.987	0.695
madelon	0.000	0.786	0.524	0.494	0.418	0.396	0.244	0.194	0.892	0.884	0.774	0.940	0.670
colon	0.000	0.999	0.500	0.516	0.500	0.515	0.255	0.255	0.999	1.000	0.761	1.000	0.760
GLIOMA	0.000	1.000	0.380	0.492	0.380	0.492	0.189	0.189	1.000	1.000	0.684	1.000	0.684
DLBCL	0.000	1.000	0.456	0.494	0.456	0.494	0.228	0.228	1.000	1.000	0.723	1.000	0.723
toxicity	0.000	0.997	0.457	0.505	0.456	0.504	0.230	0.229	0.998	0.998	0.732	0.999	0.731
TOX_171	0.000	0.999	0.454	0.505	0.453	0.505	0.231	0.231	0.999	0.999	0.727	0.999	0.727
GLI_85	0.000	1.000	0.464	0.504	0.464	0.504	0.234	0.234	1.000	-	0.733	-	0.733
CLL_SUB_111	0.000	1.000	0.475	0.497	0.475	0.496	0.236	0.236	1.000	1.000	0.735	1.000	0.735
GLA_BRA_180	0.000	1.000	0.408	0.497	0.408	0.497	0.201	0.201	1.000	1.000	0.703	1.000	0.703
SMK_CAN_187	0.000	1.000	0.491	0.502	0.491	0.502	0.246	0.246	1.000	-	0.747	-	0.747
arcene	0.000	1.000	0.495	0.503	0.495	0.503	0.253	0.253	1.000	1.000	0.745	1.000	0.745
平均	0.000	0.890	0.427	0.516	0.396	0.471	0.232	0.216	0.923	0.937	0.712	0.952	0.668

附表 8 樣本選取方法之 AUC 表現 (分類器: RF)

Dataset	Baseline	單一樣本選取方法			樣本選取平行式集成方法								
		ENN	CNN	GA	ENN $\cup$ CNN	ENN $\cup$ GA	GA $\cup$ CNN	ENN $\cup$ CNN $\cup$ GA	ENN $\cap$ CNN	ENN $\cap$ GA	GA $\cap$ CNN	ENN $\cap$ CNN $\cap$ GA	ENN CNN GA 多重交集
Connectionist Bench	0.927	0.910	0.839	0.884	0.919	0.927	0.883	0.922	0.717	0.889	0.671	0.592	0.866
Libras Movement	0.986	0.891	0.784	0.947	0.935	0.963	0.960	0.969	-	-	-	-	-
Hepatitis C Virus for Egyptian patients	0.507	-	0.475	0.507	-	-	0.492	-	-	-	0.514	-	-
OnlineNewsPopularity	0.942	0.854	0.650	0.929	0.859	0.929	0.928	0.929	-	0.829	-	-	0.826
Body signal of smoking	0.916	0.847	0.888	0.865	0.894	0.886	0.901	0.901	0.814	0.825	0.848	0.792	0.867
darwin	0.966	0.958	0.955	0.967	0.963	0.975	0.966	0.963	-	0.926	0.921	-	0.941
Drug induced Autoimmunity Prediction	0.876	0.834	0.831	0.742	0.869	0.870	0.861	0.878	0.653	0.708	0.651	0.562	0.821
Hill-Valley	0.507	0.504	0.458	0.554	0.450	0.546	0.530	0.523	0.505	0.498	0.511	-	0.522
pd_speech_features	0.948	0.847	0.907	0.910	0.931	0.924	0.935	0.942	0.796	0.824	0.856	0.738	0.901
madelon	0.793	0.694	0.540	0.702	0.720	0.749	0.740	0.758	0.535	0.657	0.522	0.531	0.656
colon	0.924	0.856	0.781	0.806	0.863	0.918	0.839	0.854	-	0.820	0.684	-	0.894
GLIOMA	0.956	0.897	-	-	-	-	-	-	-	-	-	-	-
DLBCL	0.966	0.940	0.950	0.973	0.975	0.964	0.978	0.977	0.974	0.939	0.828	-	0.975
toxicity	0.454	0.597	0.455	0.593	0.479	0.616	0.530	0.522	-	0.614	0.608	-	0.592
TOX_171	0.952	0.807	0.903	0.889	0.934	0.918	0.927	0.927	0.748	-	0.853	-	0.879
GLI_85	0.949	0.903	0.865	0.941	0.914	0.931	0.945	0.940	0.844	0.915	0.686	-	0.919
CLL_SUB_111	0.835	0.776	0.711	0.712	0.792	0.815	0.802	0.838	-	0.668	0.694	-	0.738
GLA_BRA_180	0.896	-	0.696	0.890	-	-	0.892	-	-	-	-	-	-
SMK_CAN_187	0.747	0.749	0.747	0.759	0.747	0.746	0.752	0.752	0.728	-	0.730	-	0.719
arcene	0.889	0.828	0.759	0.886	0.843	0.863	0.881	0.881	0.701	0.814	0.593	-	0.825
平均	0.847	0.819	0.748	0.814	0.831	0.858	0.828	0.854	0.752	0.790	0.697	0.651	0.814

註：粉紅色底色表示進行樣本選取後，五折交叉驗證中部分折次因某一類別樣本被完全刪除，導致無法進行後續模型訓練或效能評估。

附表 9 樣本選取方法之 AUC 表現 (分類器: XGBoost)

Dataset	Baseline	單一樣本選取方法			樣本選取平行式集成方法								
		ENN	CNN	GA	ENN $\cup$ CNN	ENN $\cup$ GA	GA $\cup$ CNN	ENN $\cup$ CNN $\cup$ GA	ENN $\cap$ CNN	ENN $\cap$ GA	GA $\cap$ CNN	ENN $\cap$ CNN $\cap$ GA	ENN CNN GA 多重交集
Connectionist Bench	0.942	0.916	0.861	0.875	0.936	0.920	0.914	0.934	0.666	0.859	0.657	0.500	0.866
Libras Movement	0.973	0.805	0.738	0.883	0.870	0.925	0.922	0.939	-	-	-	-	-
Hepatitis C Virus for Egyptian patients	0.517	-	0.496	0.521	-	-	0.493	-	-	-	0.509	-	-
OnlineNewsPopularity	0.962	0.881	0.615	0.947	0.882	0.947	0.947	0.946	-	0.851	-	-	0.857
Body signal of smoking	0.904	0.841	0.872	0.855	0.882	0.877	0.888	0.889	0.823	0.828	0.842	0.808	0.854
darwin	0.948	0.900	0.927	0.933	0.941	0.953	0.943	0.948	-	0.825	0.666	-	0.887
Drug induced Autoimmunity Prediction	0.867	0.841	0.822	0.707	0.865	0.865	0.852	0.865	0.644	0.678	0.641	0.506	0.787
Hill-Valley	0.549	0.531	0.533	0.587	0.513	0.568	0.562	0.560	0.500	0.500	0.548	-	0.537
pd speech features	0.952	0.876	0.922	0.888	0.940	0.943	0.943	0.948	0.788	0.836	0.821	0.668	0.907
madelon	0.907	0.756	0.633	0.810	0.845	0.872	0.866	0.882	0.570	0.704	0.553	0.608	0.755
colon	0.884	0.861	0.691	0.714	0.851	0.886	0.803	0.824	-	0.500	0.500	-	0.793
GLIOMA	0.938	0.705	-	-	-	-	-	-	-	-	-	-	-
DLBCL	0.979	0.862	0.866	0.790	0.970	0.965	0.970	0.979	0.500	0.670	0.739	-	0.903
toxicity	0.500	0.618	0.500	0.585	0.500	0.618	0.521	0.500	-	0.612	0.500	-	0.591
TOX_171	0.935	0.729	0.865	0.836	0.892	0.880	0.914	0.915	0.977	-	0.731	-	0.792
GLI_85	0.911	0.907	0.757	0.760	0.950	0.942	0.927	0.927	0.500	0.704	0.500	-	0.830
CLL_SUB_111	0.853	0.734	0.558	0.730	0.797	0.859	0.785	0.880	-	0.535	0.549	-	0.636
GLA_BRA_180	0.886	-	0.652	0.845	-	-	0.860	-	-	-	-	-	-
SMK_CAN_187	0.794	0.716	0.760	0.718	0.787	0.731	0.764	0.792	0.600	-	0.699	-	0.692
arcene	0.880	0.827	0.504	0.784	0.856	0.891	0.890	0.904	0.500	0.809	0.500	-	0.825
平均	0.854	0.798	0.715	0.775	0.841	0.863	0.828	0.862	0.660	0.708	0.624	0.624	0.787

附表 10 樣本選取方法之 AUC 表現 (分類器：SVM)

Dataset	Baseline	單一樣本選取方法			樣本選取平行式集成方法								
		ENN	CNN	GA	ENN $\cup$ CNN	ENN $\cup$ GA	GA $\cup$ CNN	ENN $\cup$ CNN $\cup$ GA	ENN $\cap$ CNN	ENN $\cap$ GA	GA $\cap$ CNN	ENN $\cap$ CNN $\cap$ GA	ENN CNN GA 多重交集
Connectionist Bench	0.921	0.909	0.819	0.897	0.921	0.918	0.891	0.914	0.421	0.871	0.560	0.493	0.866
Libras Movement	0.990	0.862	0.444	0.956	0.934	0.969	0.971	0.975	-	-	-	-	-
Hepatitis C Virus for Egyptian patients	0.509	-	0.539	0.507	-	-	0.514	-	-	-	0.498	-	-
OnlineNewsPopularity	0.773	0.761	0.594	0.770	0.762	0.771	0.770	0.771	-	0.754	-	-	0.743
Body signal of smoking	0.759	0.739	0.783	0.744	0.751	0.749	0.753	0.753	0.721	0.738	0.782	0.700	0.786
darwin	0.894	0.815	0.848	0.861	0.939	0.890	0.871	0.876	-	0.808	0.769	-	0.811
Drug induced Autoimmunity Prediction	0.495	0.516	0.499	0.525	0.589	0.504	0.502	0.510	0.499	0.517	0.516	0.512	0.500
Hill-Valley	0.833	0.598	0.740	0.606	0.589	0.764	0.768	0.768	0.552	0.552	0.475	-	0.656
pd speech features	0.679	0.704	0.644	0.680	0.772	0.696	0.685	0.681	0.680	0.695	0.557	0.688	0.693
madelon	0.749	0.719	0.653	0.696	0.914	0.737	0.723	0.736	0.631	0.681	0.602	0.597	0.705
colon	0.909	0.894	0.378	0.600	0.854	0.913	0.830	0.859	-	0.489	0.420	-	0.873
GLIOMA	0.956	0.652	-	-	-	-	-	-	-	-	-	-	-
DLBCL	1.000	0.984	0.995	0.986	1.000	1.000	1.000	1.000	0.498	0.961	0.996	-	1.000
toxicity	0.592	0.559	0.330	0.514	0.566	0.545	0.573	0.546	-	0.538	0.530	-	0.532
TOX_171	0.996	0.715	0.926	0.838	0.930	0.897	0.948	0.947	0.661	-	0.788	-	0.877
GLI_85	0.952	0.929	0.675	0.911	0.939	0.943	0.477	0.939	0.480	0.880	0.492	-	0.905
CLL_SUB_111	0.832	0.675	0.623	0.632	0.683	0.783	0.653	0.705	-	0.560	0.618	-	0.635
GLA_BRA_180	0.883	-	0.589	0.868	-	-	0.863	-	-	-	-	-	-
SMK_CAN_187	0.818	0.787	0.755	0.778	0.772	0.775	0.770	0.778	0.395	-	0.720	-	0.627
arcene	0.962	0.893	0.692	0.924	0.914	0.952	0.949	0.957	0.688	0.878	0.493	-	0.892
平均	0.825	0.767	0.659	0.751	0.817	0.818	0.768	0.812	0.566	0.718	0.615	0.598	0.764

附表 11 樣本選取方法之 F1-score 表現（分類器：RF）

Dataset	Baseline	單一樣本選取方法			樣本選取平行式集成方法								
		ENN	CNN	GA	ENN $\cup$ CNN	ENN $\cup$ GA	GA $\cup$ CNN	ENN $\cup$ CNN $\cup$ GA	ENN $\cap$ CNN	ENN $\cap$ GA	GA $\cap$ CNN	ENN $\cap$ CNN $\cap$ GA	ENN CNN GA 多重交集
Connectionist Bench	0.815	0.791	0.484	0.791	0.836	0.820	0.751	0.807	0.297	0.753	0.307	0.297	0.565
Libras Movement	0.808	0.511	0.250	0.680	0.558	0.726	0.708	0.807	-	-	-	-	-
Hepatitis C Virus for Egyptian patients	0.265	-	0.097	0.257	-	-	0.141	-	-	-	0.102	-	-
OnlineNewsPopularity	0.668	0.381	0.033	0.627	0.391	0.623	0.622	0.627	-	0.304	-	-	0.297
Body signal of smoking	0.835	0.699	0.747	0.782	0.777	0.765	0.790	0.805	0.378	0.688	0.722	0.328	0.716
darwin	0.896	0.456	0.798	0.879	0.866	0.802	0.896	0.879	-	0.455	0.514	-	0.524
Drug induced Autoimmunity Prediction	0.820	0.759	0.672	0.739	0.835	0.851	0.846	0.845	0.151	0.603	0.453	0.165	0.567
Hill-Valley	0.511	0.329	0.329	0.524	0.333	0.442	0.458	0.464	0.505	0.326	0.369	-	0.329
pd_speech_features	0.869	0.773	0.790	0.833	0.857	0.848	0.879	0.864	0.234	0.726	0.724	0.140	0.782
madelon	0.718	0.417	0.333	0.641	0.447	0.523	0.387	0.560	0.333	0.347	0.333	0.333	0.338
colon	0.785	0.653	0.450	0.639	0.754	0.759	0.719	0.835	-	0.726	0.500	-	0.507
GLIOMA	0.789	0.433	-	-	-	-	-	-	-	-	-	-	-
DLBCL	0.842	0.864	0.757	0.762	0.884	0.881	0.933	0.916	0.098	0.815	0.348	-	0.891
toxicity	0.554	0.312	0.508	0.614	0.546	0.522	0.535	0.540	-	0.224	0.409	-	0.316
TOX_171	0.801	0.206	0.420	0.580	0.644	0.605	0.709	0.686	0.085	-	0.453	-	0.299
GLI_85	0.871	0.814	0.271	0.827	0.823	0.854	0.871	0.889	0.137	0.803	0.137	-	0.694
CLL_SUB_111	0.720	0.584	0.333	0.457	0.575	0.709	0.631	0.751	-	0.319	0.354	-	0.484
GLA_BRA_180	0.652	-	0.247	0.640	-	-	0.691	-	-	-	-	-	-
SMK_CAN_187	0.684	0.330	0.573	0.647	0.603	0.551	0.616	0.640	0.310	-	0.515	-	0.381
arcene	0.784	0.737	0.274	0.749	0.740	0.770	0.709	0.775	0.266	0.706	0.269	-	0.661
平均	0.734	0.563	0.445	0.666	0.675	0.710	0.681	0.748	0.243	0.568	0.400	0.263	0.563

附表 12 樣本選取方法之 F1-score 表現 (分類器: XGBoost)

Dataset	Baseline	單一樣本選取方法			樣本選取平行式集成方法								
		ENN	CNN	GA	ENN $\cup$ CNN	ENN $\cup$ GA	GA $\cup$ CNN	ENN $\cup$ CNN $\cup$ GA	ENN $\cap$ CNN	ENN $\cap$ GA	GA $\cap$ CNN	ENN $\cap$ CNN $\cap$ GA	ENN CNN GA 多重交集
Connectionist Bench	0.870	0.785	0.670	0.767	0.880	0.811	0.816	0.850	0.346	0.732	0.327	0.297	0.696
Libras Movement	0.748	0.397	0.189	0.538	0.487	0.628	0.577	0.624	-	-	-	-	-
Hepatitis C Virus for Egyptian patients	0.272	-	0.177	0.270	-	-	0.221	-	-	-	0.201	-	-
OnlineNewsPopularity	0.734	0.523	0.105	0.679	0.528	0.682	0.681	0.678	-	0.453	-	-	0.446
Body signal of smoking	0.829	0.702	0.765	0.772	0.789	0.777	0.799	0.808	0.408	0.692	0.715	0.404	0.715
darwin	0.873	0.494	0.815	0.838	0.844	0.770	0.862	0.879	-	0.543	0.570	-	0.523
Drug induced Autoimmunity Prediction	0.849	0.746	0.706	0.741	0.835	0.836	0.817	0.841	0.203	0.618	0.505	0.122	0.620
Hill-Valley	0.554	0.326	0.372	0.557	0.375	0.477	0.505	0.492	0.327	0.326	0.375	-	0.335
pd_speech_features	0.890	0.778	0.811	0.825	0.886	0.890	0.880	0.898	0.248	0.713	0.716	0.153	0.788
madelon	0.842	0.594	0.335	0.748	0.657	0.720	0.685	0.763	0.333	0.478	0.336	0.333	0.427
colon	0.753	0.716	0.597	0.669	0.754	0.841	0.686	0.705	-	0.379	0.185	-	0.716
GLIOMA	0.734	0.233	-	-	-	-	-	-	-	-	-	-	0.233
DLBCL	0.917	0.819	0.730	0.713	0.899	0.882	0.876	0.920	0.098	0.612	0.544	-	0.819
toxicity	0.541	0.327	0.317	0.584	0.541	0.489	0.559	0.541	-	0.182	0.162	-	0.327
TOX_171	0.750	0.729	0.560	0.618	0.673	0.646	0.752	0.759	0.109	-	0.477	-	0.729
GLI_85	0.823	0.824	0.386	0.767	0.880	0.808	0.824	0.831	0.137	0.623	0.137	-	0.824
CLL_SUB_111	0.762	0.473	0.342	0.504	0.674	0.739	0.695	0.789	-	0.242	0.286	-	0.473
GLA_BRA_180	0.715	-	0.230	0.611	-	-	0.651	-	-	-	-	-	-
SMK_CAN_187	0.705	0.352	0.279	0.684	0.667	0.577	0.660	0.656	0.311	-	0.500	-	0.352
arcene	0.809	0.735	0.279	0.710	0.722	0.800	0.721	0.800	0.266	0.720	0.269	-	0.735
平均	0.748	0.588	0.461	0.662	0.711	0.727	0.699	0.754	0.249	0.520	0.389	0.277	0.539

附表 13 樣本選取方法之 F1-score 表現 (分類器：SVM)

Dataset	Baseline	單一樣本選取方法			樣本選取平行式集成方法								
		ENN	CNN	GA	ENN $\cup$ CNN	ENN $\cup$ GA	GA $\cup$ CNN	ENN $\cup$ CNN $\cup$ GA	ENN $\cap$ CNN	ENN $\cap$ GA	GA $\cap$ CNN	ENN $\cap$ CNN $\cap$ GA	ENN CNN GA 多重交集
Connectionist Bench	0.846	0.831	0.632	0.820	0.851	0.871	0.831	0.851	0.376	0.787	0.424	0.485	0.392
Libras Movement	0.902	0.583	0.432	0.730	0.616	0.778	0.762	0.785	-	-	-	-	-
Hepatitis C Virus for Egyptian patients	0.236	-	0.093	0.235	-	-	0.093	-	-	-	0.093	-	-
OnlineNewsPopularity	0.352	0.281	0.107	0.332	0.307	0.331	0.329	0.338	-	0.241	-	-	0.274
Body signal of smoking	0.623	0.418	0.197	0.557	0.692	0.682	0.695	0.685	0.197	0.197	0.197	0.197	0.197
darwin	0.833	0.318	0.797	0.786	0.860	0.321	0.743	0.821	-	0.547	0.321	-	0.612
Drug induced Autoimmunity Prediction	0.645	0.652	0.098	0.646	0.589	0.642	0.644	0.645	0.102	0.274	0.099	0.099	0.101
Hill-Valley	0.469	0.325	0.403	0.435	0.047	0.428	0.428	0.428	0.327	0.326	0.326	-	0.370
pd speech features	0.645	0.714	0.103	0.647	0.590	0.733	0.730	0.725	0.103	0.707	0.103	0.103	0.691
madelon	0.682	0.514	0.333	0.637	0.802	0.614	0.590	0.644	0.333	0.445	0.333	0.333	0.393
colon	0.766	0.518	0.185	0.508	0.772	0.737	0.757	0.836	-	0.682	0.219	-	0.400
GLIOMA	0.821	0.612	-	-	-	-	-	-	-	-	-	-	-
DLBCL	0.958	0.925	0.950	0.703	0.962	0.949	0.946	0.946	0.098	0.656	0.758	-	0.917
toxicity	0.532	0.162	0.330	0.538	0.535	0.162	0.532	0.532	-	0.162	0.200	-	0.162
TOX 171	0.969	0.347	0.743	0.686	0.778	0.800	0.858	0.865	0.085		0.603	-	0.641
GLI 85	0.891	0.830	0.373	0.806	0.860	0.858	0.821	0.844	0.137	0.753	0.256	-	0.768
CLL SUB 111	0.765	0.603	0.430	0.502	0.540	0.640	0.491	0.610	-	0.371	0.519	-	0.530
GLA BRA 180	0.695	-	0.047	0.682	-	-	0.666	-	-	-	-	-	-
SMK CAN 187	0.772	0.407	0.310	0.714	0.590	0.659	0.600	0.627	0.311		0.626	-	0.500
arcene	0.910	0.809	0.328	0.844	0.802	0.854	0.845	0.855	0.280	0.792	0.269	-	0.743
平均	0.716	0.552	0.372	0.621	0.664	0.657	0.657	0.711	0.209	0.502	0.334	0.260	0.472

附表 14 樣本選取方法之樣本精簡率

Dataset	Baseline	單一樣本選取方法			樣本選取平行式集成方法								
		ENN	CNN	GA	ENN $\cup$ CNN	ENN $\cup$ GA	GA $\cup$ CNN	ENN $\cup$ CNN $\cup$ GA	ENN $\cap$ CNN	ENN $\cap$ GA	GA $\cap$ CNN	ENN $\cap$ CNN $\cap$ GA	ENN CNN GA 多重交集
Connectionist Bench	0.000	0.192	0.414	0.692	0.101	0.144	0.279	0.063	0.505	0.740	0.827	0.837	0.399
Libras Movement	0.000	0.615	0.826	0.631	0.494	0.375	0.522	0.300	-	-	-	-	-
Hepatitis C Virus for Egyptian patients	0.000	-	0.558	0.702	-	-	0.395	-	-	-	0.865	-	-
OnlineNewsPopularity	0.000	0.864	0.943	0.684	0.856	0.592	0.647	0.586	-	0.958	-	-	0.922
Body signal of smoking	0.000	0.481	0.432	0.686	0.291	0.329	0.297	0.200	0.623	0.838	0.822	0.883	0.518
darwin	0.000	0.454	0.259	0.690	0.201	0.328	0.144	0.121	-	0.816	0.805	-	0.431
Drug induced Autoimmunity Prediction	0.000	0.456	0.570	0.672	0.293	0.310	0.387	0.193	0.732	0.817	0.854	0.900	0.605
Hill-Valley	0.000	0.500	0.437	0.698	0.432	0.343	0.295	0.292	0.505	0.855	0.840	-	0.487
pd_speech_features	0.000	0.441	0.541	0.644	0.258	0.291	0.357	0.169	0.724	0.794	0.828	0.889	0.568
madelon	0.000	0.401	0.434	0.673	0.340	0.272	0.297	0.233	0.495	0.803	0.810	0.833	0.443
colon	0.000	0.420	0.484	0.710	0.258	0.290	0.323	0.177	-	0.839	0.871	-	0.516
GLIOMA	0.000	0.633	-	-	-	-	-	-	-	-	-	-	-
DLBCL	0.000	0.325	0.572	0.623	0.156	0.195	0.377	0.104	0.740	0.753	0.818	-	0.520
toxicity	0.000	0.614	0.357	0.702	0.298	0.450	0.234	0.199	0.673	0.866	0.825	-	0.585
TOX_171	0.000	0.670	0.526	0.632	0.450	0.409	0.333	0.292	0.749	0.895	0.825	-	0.608
GLI_85	0.000	0.298	0.631	0.667	0.247	0.212	0.435	0.177	0.694	0.765	0.871	-	0.298
CLL_SUB_111	0.000	0.775	0.838	0.649	0.712	0.487	0.541	0.460	-	0.937	0.946	-	0.775
GLA_BRA_180	0.000	-	0.805	0.704	-	-	0.583	-	-	-	-	-	-
SMK_CAN_187	0.000	0.462	0.290	0.667	0.257	0.305	0.219	0.182	0.503	-	0.743	-	0.462
arcene	0.000	0.250	0.520	0.650	0.215	0.160	0.330	0.135	0.555	0.740	0.840	-	0.250
平均	0.000	0.492	0.546	0.672	0.347	0.324	0.366	0.230	0.621	0.829	0.837	0.867	0.557

附表 15 序列式混合方法之 AUC 表現 (分類器: RF)

Dataset	序列式混合方法：先進行特徵選取，再進行樣本選取 (FS → IS)									序列式混合方法：先進行樣本選取，再進行特徵選取 (IS → FS)								
	CART→ ENN	CART→ CNN	CART→ GA	MI→ ENN	MI→ CNN	MI→ GA	GA→ ENN	GA→ CNN	GA→ GA	ENN→ CART	ENN→ MI	ENN→ GA	CNN→ CART	CNN→ MI	CNN→ GA	GA→ CART	GA→ MI	GA→ GA
Connectionist Bench	0.874	0.812	0.889	0.902	0.869	0.892	0.926	0.850	0.899	0.921	0.904	0.911	0.779	0.835	0.844	0.819	0.875	0.878
Libras Movement	-	-	0.950	0.937	-	0.937	0.916	-	0.956	0.868	0.884	-	0.733	0.787	-	0.950	0.947	-
Hepatitis C Virus for Egyptian patients	-	0.507	0.514	-	0.492	0.502	-	0.512	0.526	--	-	-	0.491	0.486	0.507	0.489	0.503	0.510
OnlineNewsPopularity	0.883	0.627	0.931	0.857	0.614	0.931	0.863	0.627	0.938	0.867	0.860	0.778	0.656	0.626	-	0.937	0.933	0.938
Body signal of smoking	0.854	0.860	0.854	0.859	0.879	0.865	0.861	0.878	0.864	0.800	0.846	0.850	0.871	0.889	0.892	0.839	0.865	0.867
darwin	0.901	0.902	0.942	0.961	0.971	0.965	0.940	0.968	0.967	0.788	0.952	0.948	0.885	0.962	0.964	0.765	0.969	0.973
Drug induced Autoimmunity Prediction	0.860	0.800	0.792	0.830	0.819	0.794	0.873	0.820	0.792	0.821	0.828	0.836	0.833	0.851	0.850	0.688	0.739	0.758
Hill-Valley	0.513	0.457	0.557	0.509	0.444	0.572	0.511	0.446	0.542	0.501	0.499	-	0.447	0.444	0.464	0.565	0.553	0.550
pd speech features	0.905	0.883	0.908	0.848	0.920	0.920	0.846	0.909	0.910	0.860	0.845	0.844	0.909	0.914	0.921	0.866	0.919	0.908
madelon	0.821	0.636	0.836	0.695	0.567	0.723	0.727	0.584	0.765	0.744	0.711	0.714	0.569	0.554	0.553	0.856	0.668	0.734
colon	-	-	0.883	0.897	0.843	0.923	0.890	0.763	0.841	0.699	0.844	0.871	0.703	0.821	0.819	0.713	0.835	-
GLIOMA	-	-	-	0.930	-	-	0.920	-	-	0.692	0.909	-	-	-	-	-	-	-
DLBCL	0.908	0.765	0.964	0.950	0.906	0.938	0.931	0.914	0.977	0.931	0.925	0.929	0.685	0.962	0.942	0.704	0.979	0.975
toxicity	0.639	0.483	0.617	0.607	0.435	0.590	0.585	0.402	0.615	0.574	0.598	0.598	0.527	0.433	0.480	0.605	0.616	0.614
TOX 171	-	0.857	0.874	0.859	0.907	0.894	0.821	0.901	0.923	0.718	0.825	-	0.822	0.923	0.926	0.770	0.907	0.898
GLI 85	0.877	0.816	0.893	0.922	0.907	0.892	0.905	0.877	0.880	0.919	0.891	0.913	0.776	0.903	-	0.842	0.901	0.912
CLL SUB 111	0.867	0.779	0.846	0.772	0.670	0.817	0.767	0.685	0.875	0.655	0.766	-	0.566	0.692	-	0.754	0.810	-
GLA BRA 180	-	0.750	0.843	-	0.635	0.894	-	0.674	0.877	-	-	-	0.519	0.669	-	0.736	0.897	0.892
SMK CAN 187	0.715	0.620	0.760	0.756	0.757	0.760	0.733	0.741	0.723	0.588	0.751	0.719	0.740	0.766	0.738	0.666	0.772	0.746
arcene	0.850	0.564	0.867	0.835	0.703	0.823	0.825	0.799	0.719	0.794	0.840	0.837	-	0.760	-	0.770	0.898	0.797
平均	0.818	0.711	0.828	0.832	0.741	0.823	0.827	0.741	0.822	0.767	0.818	0.826	0.692	0.753	0.757	0.752	0.821	0.812

附表 16 序列式混合方法之 AUC 表現 (分類器: XGBoost)

Dataset	序列式混合方法：先進行特徵選取，再進行樣本選取 (FS → IS)									序列式混合方法：先進行樣本選取，再進行特徵選取 (IS → FS)								
	CART→ ENN	CART→ CNN	CART→ GA	MI→ ENN	MI→ CNN	MI→ GA	GA→ ENN	GA→ CNN	GA→ GA	ENN→ CART	ENN→ MI	ENN→ GA	CNN→ CART	CNN→ MI	CNN→ GA	GA→ CART	GA→ MI	GA→ GA
Connectionist Bench	0.877	0.853	0.872	0.900	0.872	0.891	0.942	0.913	0.902	0.910	0.913	0.907	0.753	0.834	0.834	0.818	0.865	0.838
Libras Movement	-	-	0.886	0.816	-	0.873	0.814	-	0.898	0.792	0.780	-	0.744	0.757	-	0.889	0.891	-
Hepatitis C Virus for Egyptian patients	-	0.494	0.515	-	0.493	0.517	-	0.513	0.536	-	-	-	0.499	0.492	0.518	0.493	0.507	0.510
OnlineNewsPopularity	0.892	0.618	0.591	0.881	0.620	0.946	0.882	0.616	0.947	0.886	0.881	0.812	0.615	0.621	-	0.941	0.947	0.946
Body signal of smoking	0.839	0.823	0.841	0.851	0.842	0.855	0.848	0.836	0.852	0.812	0.839	0.830	0.849	0.864	0.872	0.827	0.853	0.855
darwin	0.886	0.889	0.916	0.917	0.954	0.898	0.868	0.946	0.949	0.807	0.907	0.880	0.905	0.932	0.941	0.753	0.936	0.946
Drug induced Autoimmunity Prediction	0.860	0.795	0.783	0.833	0.831	0.783	0.882	0.824	0.769	0.828	0.830	0.820	0.795	0.844	0.836	0.695	0.691	0.696
Hill-Valley	0.546	0.534	0.591	0.534	0.500	0.561	0.547	0.522	0.581	0.531	0.533	-	0.500	0.500	0.522	0.578	0.576	0.555
pd speech features	0.906	0.895	0.879	0.879	0.925	0.889	0.878	0.923	0.880	0.855	0.880	0.882	0.908	0.929	0.924	0.849	0.888	0.902
madelon	0.858	0.637	0.859	0.753	0.561	0.775	0.782	0.641	0.838	0.786	0.765	0.772	0.560	0.611	0.619	0.859	0.704	0.823
colon	-	-	0.677	0.805	0.723	0.818	0.849	0.781	0.833	0.699	0.884	0.904	0.701	0.668	0.670	0.603	0.705	-
GLIOMA	-	-	-	0.695	-	-	0.759	-	-	0.693	0.732	-	-	-	-	-	-	-
DLBCL	0.927	0.914	0.818	0.915	0.836	0.704	0.914	0.701	0.775	0.863	0.862	0.902	0.664	0.870	1.000	0.760	0.799	0.829
toxicity	0.635	0.503	0.600	0.559	0.500	0.589	0.593	0.500	0.540	0.605	0.606	0.573	0.556	0.500	0.500	0.619	0.612	0.584
TOX 171	-	0.835	0.865	0.779	0.849	0.844	0.722	0.213	0.863	0.704	0.729	-	0.799	0.878	0.874	0.779	0.841	0.841
GLI 85	0.869	0.893	0.853	0.921	0.776	0.722	0.900	0.650	0.855	0.873	0.917	0.903	0.736	0.749	-	0.797	0.787	0.787
CLL SUB 111	0.857	0.788	0.846	0.496	0.554	0.763	0.722	0.575	0.852	0.673	0.734	-	0.553	0.564	-	0.737	0.750	-
GLA BRA 180	-	0.731	0.832	-	0.678	0.865	-	0.648	0.815	-	-	-	0.532	0.638	-	0.772	0.846	0.855
SMK CAN 187	0.724	0.655	0.720	0.697	0.747	0.805	0.731	0.710	0.709	0.584	0.756	0.708	0.748	0.755	0.774	0.676	0.730	0.726
arcene	0.840	0.539	0.853	0.847	0.500	0.753	0.837	0.550	0.730	0.819	0.835	0.822	-	0.500	-	0.743	0.813	0.797
平均	0.821	0.730	0.777	0.784	0.710	0.779	0.807	0.667	0.794	0.765	0.802	0.823	0.687	0.712	0.761	0.744	0.774	0.779

附表 17 序列式混合方法之 AUC 表現 (分類器：SVM)

Dataset	序列式混合方法：先進行特徵選取，再進行樣本選取 (FS → IS)									序列式混合方法：先進行樣本選取，再進行特徵選取 (IS → FS)								
	CART→ ENN	CART→ CNN	CART→ GA	MI→ ENN	MI→ CNN	MI→ GA	GA→ ENN	GA→ CNN	GA→ GA	ENN→ CART	ENN→ MI	ENN→ GA	CNN→ CART	CNN→ MI	CNN→ GA	GA→ CART	GA→ MI	GA→ GA
Connectionist Bench	0.872	0.818	0.887	0.863	0.831	0.882	0.919	0.869	0.886	0.901	0.884	0.895	0.661	0.846	0.662	0.959	0.883	0.857
Libras Movement	-	-	0.944	0.875	-	0.927	0.847	-	0.960	0.852	0.861	-	0.441	0.453	-	0.959	0.957	-
Hepatitis C Virus for Egyptian patients	-	0.506	0.515	-	0.530	0.498	-	0.515	0.491	-	-	-	0.528	0.527	0.520	0.510	0.507	0.501
OnlineNewsPopularity	0.759	0.565	0.761	0.761	0.505	0.771	0.753	0.544	0.767	0.756	0.762	0.760	0.346	0.593	-	0.764	0.770	0.768
Body signal of smoking	0.804	0.788	0.819	0.823	0.802	0.829	0.824	0.796	0.829	0.804	0.741	0.812	0.793	0.808	0.811	0.714	0.828	0.830
darwin	0.879	0.863	0.853	0.921	0.890	0.882	0.699	0.914	0.864	0.781	0.898	0.857	0.882	0.894	0.879	0.785	0.894	0.892
Drug induced Autoimmunity Prediction	0.798	0.720	0.715	0.517	0.492	0.496	0.806	0.731	0.744	0.518	0.519	0.517	0.643	0.711	0.503	0.587	0.711	0.638
Hill-Valley	0.601	0.793	0.725	0.585	0.702	0.647	0.626	0.384	0.490	0.540	0.579	-	0.762	0.694	0.734	0.638	0.615	0.607
pd speech features	0.782	0.575	0.642	0.695	0.673	0.543	0.695	0.612	0.612	0.665	0.695	0.695	0.711	0.661	0.657	0.603	0.661	0.680
madelon	0.833	0.761	0.804	0.731	0.656	0.718	0.758	0.704	0.753	0.785	0.743	0.746	0.575	0.629	0.651	0.833	0.629	0.730
colon	-	-	0.699	0.913	0.418	0.744	0.890	0.451	0.473	0.724	0.909	0.883	0.771	0.499	0.344	0.754	0.499	-
GLIOMA	-	-	-	0.807	-	-	0.648	-	-	0.703	0.679	-	-	-	-	-	-	-
DLBCL	0.978	0.764	0.978	1.000	0.938	1.000	1.000	1.000	1.000	0.931	0.979	0.983	0.548	0.995	1.000	0.793	0.995	0.986
toxicity	0.624	0.477	0.617	0.525	0.198	0.552	0.572	0.566	0.451	0.660	0.609	0.591	0.467	0.561	0.562	0.657	0.561	0.493
TOX 171		0.787	0.791	0.804	0.690	0.888	0.696	0.910	0.903	0.696	0.707	-	0.828	0.930	0.923	0.804	0.930	0.832
GLI 85	0.909	0.836	0.913	0.945	0.884	0.903	0.927	0.714	0.912	0.905	0.935	0.912	0.788	0.689	-	0.854	0.689	0.908
CLL SUB 111	0.841	0.604	0.818	0.662	0.642	0.664	0.667	0.616	0.782	0.687	0.675	-	0.564	0.662	-	0.724	0.662	-
GLA BRA 180	-	0.603	0.834	-	0.616	0.880	-	0.593	0.877	-	-	-	0.553	0.601	-	0.768	0.587	0.866
SMK CAN 187	0.636	0.597	0.729	0.752	0.762	0.815	0.739	0.746	0.773	0.618	0.755	0.752	0.742	0.763	0.756	0.714	0.763	0.777
arcene	0.852	0.553	0.835	0.896	0.642	0.867	0.900	0.619	0.813	0.852	0.896	0.900	-	0.692	-	0.770	0.692	0.915
平均	0.800	0.682	0.782	0.786	0.655	0.765	0.781	0.685	0.754	0.749	0.773	0.800	0.646	0.698	0.703	0.747	0.729	0.771

附表 18 序列式混合方法之 F1-score 表現 (分類器: RF)

Dataset	序列式混合方法：先進行特徵選取，再進行樣本選取 (FS → IS)									序列式混合方法：先進行樣本選取，再進行特徵選取 (IS → FS)								
	CART→ ENN	CART→ CNN	CART→ GA	MI→ ENN	MI→ CNN	MI→ GA	GA→ ENN	GA→ CNN	GA→ GA	ENN→ CART	ENN→ MI	ENN→ GA	CNN→ CART	CNN→ MI	CNN→ GA	GA→ CART	GA→ MI	GA→ GA
Connectionist Bench	0.727	0.608	0.786	0.761	0.539	0.765	0.810	0.525	0.784	0.785	0.777	0.785	0.484	0.465	0.469	0.723	0.782	0.787
Libras Movement	-	-	0.620	0.756	-	0.562	0.775	-	0.622	0.532	0.499	-	0.206	0.195	-	0.669	0.622	-
Hepatitis C Virus for Egyptian patients	-	0.095	0.507	-	0.102	0.245	-	0.117	0.263	-	-	-	0.100	0.104	0.128	0.244	0.232	0.249
OnlineNewsPopularity	0.526	0.157	0.634	0.393	0.033	0.637	0.415	0.041	0.656	0.522	0.406	0.292	0.036	0.035	-	0.652	0.637	0.651
Body signal of smoking	0.767	0.704	0.767	0.725	0.673	0.781	0.727	0.654	0.779	0.522	0.697	0.697	0.737	0.752	0.754	0.759	0.779	0.782
darwin	0.750	0.731	0.836	0.695	0.855	0.837	0.321	0.848	0.879	0.538	0.506	0.484	0.778	0.842	0.854	0.680	0.890	0.890
Drug induced Autoimmunity Prediction	0.772	0.641	0.783	0.755	0.686	0.758	0.763	0.671	0.767	0.735	0.749	0.758	0.671	0.700	0.704	0.763	0.762	0.745
Hill-Valley	0.326	0.349	0.548	0.328	0.343	0.545	0.329	0.327	0.516	0.332	0.328	-	0.340	0.334	0.334	0.538	0.525	0.536
pd speech features	0.817	0.616	0.807	0.772	0.797	0.828	0.780	0.794	0.823	0.770	0.767	0.767	0.790	0.807	0.794	0.817	0.835	0.827
madelon	0.675	0.333	0.757	0.473	0.334	0.668	0.510	0.333	0.765	0.566	0.467	0.482	0.333	0.333	0.333	0.778	0.625	0.663
colon	-	-	0.777	0.654	0.398	0.760	0.761	0.444	0.757	0.574	0.652	0.694	0.696	0.481	0.450	0.737	0.715	-
GLIOMA	-	-	-	0.566	-	-	0.542	-	-	0.447	0.464	-	-	-	-	-	-	-
DLBCL	0.803	0.718	0.866	0.890	0.468	0.833	0.864	0.712	0.826	0.843	0.880	0.867	0.489	0.758	0.755	0.760	0.828	0.795
toxicity	0.371	0.464	0.632	0.333	0.471	0.615	0.344	0.410	0.623	0.428	0.352	0.311	0.492	0.456	0.478	0.605	0.615	0.593
TOX 171	-	0.857	0.673	0.268	0.496	0.636	0.225	0.413	0.682	0.302	0.213	-	0.521	0.540	0.485	0.541	0.633	0.591
GLI 85	0.742	0.596	0.845	0.825	0.423	0.737	0.801	0.307	0.746	0.801	0.789	0.787	0.647	0.266	-	0.841	0.824	0.779
CLL SUB 111	0.732	0.655	0.780	0.495	0.355	0.638	0.612	0.306	0.725	0.540	0.597	-	0.274	0.333	-	0.611	0.460	-
GLA BRA 180	-	0.462	0.634	-	0.201	0.645		0.255	0.677	--	-	-	0.191	0.258	-	0.505	0.669	0.661
SMK CAN 187	0.562	0.490	0.702	0.330	0.576	0.691	0.332	0.576	0.517	0.407	0.344	0.333	0.740	0.591	0.574	0.661	0.721	0.688
arcene	0.702	0.320	0.749	0.747	0.307	0.686	0.726	0.277	0.692	0.732	0.742	0.757		0.283		0.698	0.760	0.709
平均	0.653	0.527	0.722	0.601	0.443	0.679	0.597	0.442	0.691	0.571	0.572	0.616	0.477	0.455	0.542	0.662	0.681	0.680

附表 19 序列式混合方法之 F1-score 表現 (分類器: XGBoost)

Dataset	序列式混合方法：先進行特徵選取，再進行樣本選取 (FS → IS)									序列式混合方法：先進行樣本選取，再進行特徵選取 (IS → FS)								
	CART→ ENN	CART→ CNN	CART→ GA	MI→ ENN	MI→ CNN	MI→ GA	GA→ ENN	GA→ CNN	GA→ GA	ENN→ CART	ENN→ MI	ENN→ GA	CNN→ CART	CNN→ MI	CNN→ GA	GA→ CART	GA→ MI	GA→ GA
Connectionist Bench	0.729	0.677	0.872	0.775	0.717	0.754	0.831	0.708	0.806	0.800	0.797	0.786	0.568	0.669	0.654	0.713	0.768	0.778
Libras Movement	-	-	0.519	0.416	-	0.446	0.415	-	0.516	0.365	0.389	-	0.139	0.167	-	0.567	0.529	
Hepatitis C Virus for Egyptian patients	-	0.108	0.271	-	0.169	0.277	-	0.178	0.279	-	-	-	0.094	0.147	0.202	0.246	0.260	0.256
OnlineNewsPopularity	0.535	0.181	0.556	0.525	0.120	0.678	0.527	0.122	0.683	0.518	0.524	0.448	0.123	0.133	-	0.662	0.682	0.677
Body signal of smoking	0.716	0.681	0.757	0.728	0.650	0.771	0.730	0.625	0.771	0.812	0.700	0.699	0.745	0.758	0.763	0.747	0.768	0.771
darwin	0.727	0.685	0.837	0.692	0.844	0.795	0.333	0.796	0.867	0.511	0.506	0.502	0.803	0.809	0.808	0.684	0.844	0.862
Drug induced Autoimmunity Prediction	0.758	0.684	0.783	0.725	0.720	0.789	0.774	0.697	0.776	0.735	0.728	0.721	0.663	0.713	0.700	0.738	0.737	0.744
Hill-Valley	0.326	0.353	0.556	0.328	0.326	0.537	0.326	0.368	0.543	0.331	0.331	-	0.326	0.326	0.359	0.552	0.550	0.530
pd speech features	0.820	0.895	0.813	0.779	0.817	0.832	0.784	0.828	0.831	0.764	0.784	0.777	0.792	0.826	0.812	0.812	0.836	0.842
madelon	0.736	0.340	0.784	0.605	0.336	0.722	0.645	0.337	0.764	0.626	0.596	0.600	0.346	0.337	0.333	0.789	0.642	0.751
colon	-	-	0.552	0.674	0.489	0.782	0.705	0.544	0.672	0.633	0.738	0.754	0.696	0.590	0.580	0.621	0.669	-
GLIOMA	-	-	-	0.288	-	-	0.444	-	-	0.384	0.303	-	-	-	-	-	-	-
DLBCL	0.820	0.860	0.715	0.842	0.551	0.696	0.824	0.701	0.772	0.806	0.819	0.854	0.567	0.718	0.724	0.800	0.713	0.744
toxicity	0.377	0.407	0.605	0.359	0.162	0.550	0.328	0.162	0.559	0.459	0.322	0.278	0.520	0.317	0.317	0.595	0.595	0.580
TOX 171	-	0.579	0.578	0.263	0.539	0.604	0.242	0.497	0.595	0.287	0.232	-	0.464	0.580	0.581	0.518	0.637	0.625
GLI 85	0.808	0.904	0.889	0.824	0.539	0.640	0.825	0.510	0.768	0.802	0.836	0.814	0.676	0.409	-	0.837	0.767	0.770
CLL SUB 111	0.707	0.633	0.718	0.496	0.314	0.632	0.475	0.229	0.758	0.557	0.473	-	0.294	0.334	-	0.604	0.500	-
GLA BRA 180	-	0.467	0.559	-	0.276	0.651	-	0.167	0.620	-	-	-	0.192	0.203	-	0.495	0.598	0.611
SMK CAN 187	0.528	0.438	0.666	0.349	0.652	0.715	0.351	0.574	0.552	0.409	0.376	0.359	0.623	0.611	0.774	0.637	0.646	0.653
arcene	0.711	0.340	0.731	0.756	0.269	0.627	0.758	0.267	0.637	0.717	0.725	0.746	-	0.269	-	0.706	0.725	0.709
平均	0.655	0.544	0.669	0.582	0.467	0.658	0.577	0.460	0.671	0.588	0.569	0.641	0.482	0.473	0.617	0.648	0.656	0.675

附表 20 序列式混合方法之 F1-score 表現 (分類器：SVM)

Dataset	序列式混合方法：先進行特徵選取，再進行樣本選取 (FS → IS)									序列式混合方法：先進行樣本選取，再進行特徵選取 (IS → FS)								
	CART→ ENN	CART→ CNN	CART→ GA	MI→ ENN	MI→ CNN	MI→ GA	GA→ ENN	GA→ CNN	GA→ GA	ENN→ CART	ENN→ MI	ENN→ GA	CNN→ CART	CNN→ MI	CNN→ GA	GA→ CART	GA→ MI	GA→ GA
Connectionist Bench	0.797	0.711	0.807	0.815	0.670	0.804	0.811	0.693	0.807	0.810	0.763	0.801	0.610	0.721	0.590	0.748	0.845	0.802
Libras Movement	-	-	0.677	0.526	-	0.669	0.571	-	0.700	0.549	0.569	-	0.405	0.466	-	0.741	0.680	
Hepatitis C Virus for Egyptian patients	-	0.093	0.111	-	0.093	0.239	-	0.093	0.203	-	-	-	0.093	0.093	0.093	0.233	0.246	0.238
OnlineNewsPopularity	0.293	0.027	0.317	0.297	0.004	0.351	0.323	0.004	0.338	0.314	0.282	0.329	0.113	0.107	-	0.308	0.332	0.317
Body signal of smoking	0.655	0.696	0.741	0.699	0.688	0.749	0.701	0.197	0.751	0.675	0.197	0.685	0.197	0.700	0.700	0.532	0.751	0.753
darwin	0.534	0.391	0.775	0.321	0.771	0.755	0.321	0.808	0.775	0.502	0.321	0.468	0.779	0.820	0.798	0.641	0.820	0.806
Drug induced Autoimmunity Prediction	0.722	0.672	0.741	0.649	0.097	0.644	0.698	0.650	0.779	0.650	0.649	0.649	0.560	0.630	0.098	0.668	0.630	0.705
Hill-Valley	0.326	0.336	0.432	0.326	0.364	0.380	0.326	0.384	0.393	0.326	0.326	-	0.390	0.362	0.408	0.440	0.322	0.402
pd speech features	0.654	0.207	0.660	0.711	0.103	0.638	0.711	0.462	0.652	0.711	0.711	0.711	0.663	0.649	0.103	0.638	0.649	0.647
madelon	0.702	0.333	0.729	0.568	0.333	0.655	0.590	0.333	0.679	0.628	0.556	0.565	0.333	0.333	0.333	0.755	0.333	0.670
colon	-	-	0.660	0.614	0.215	0.553	0.570	0.185	0.552	0.633	0.726	0.499	0.696	0.185	0.185	0.737	0.185	-
GLIOMA	-	-	-	0.697	-	-	0.618	-	-	0.468	0.363	-	-	-	-	-	-	-
DLBCL	0.864	0.366	0.711	0.952	0.938	0.789	0.963	0.964	0.648	0.806	0.869	0.940	0.146	0.804	0.939	0.692	0.950	0.962
toxicity	0.162	0.456	0.622	0.174	0.198	0.552	0.162	0.189	0.549	0.426	0.162	0.162	0.502	0.337	0.336	0.602	0.337	0.538
TOX 171	-	0.170	0.507	0.434	0.690	0.888	0.360	0.709	0.723	0.256	0.346		0.292	0.742	0.711	0.564	0.742	0.701
GLI 85	0.877	0.395	0.805	0.860	0.137	0.811	0.778	0.487	0.826	0.803	0.827	0.825	0.661	0.338	-	0.770	0.338	0.843
CLL SUB 111	0.693	0.526	0.722	0.502	0.421	0.553	0.420	0.554	0.692	0.550	0.579	-	0.253	0.527	-	0.652	0.527	-
GLA BRA 180	-	0.497	0.579	-	0.319	0.666	-	0.045	0.684	-	-	-	0.027	0.052	-	0.503	0.027	0.706
SMK CAN 187	0.532	0.359	0.657	0.439	0.646	0.738	0.435	0.519	0.696	0.395	0.420	0.411	0.645	0.559	0.310	0.647	0.559	0.721
arcene	0.727	0.286	0.718	0.803	0.269	0.779	0.900	0.422	0.744	0.742	0.822	0.822	-	0.269	-	0.715	0.269	0.859
平均	0.597	0.378	0.630	0.581	0.392	0.645	0.575	0.423	0.640	0.573	0.530	0.606	0.409	0.460	0.415	0.612	0.505	0.672

附表 21 序列式混合方法之第二階段精簡率

Dataset	序列式混合方法：先進行特徵選取，再進行樣本選取 (FS → IS)									序列式混合方法：先進行樣本選取，再進行特徵選取 (IS → FS)								
	第二階段樣本精簡率									第二階段特徵精簡率								
	CART→ ENN	CART→ CNN	CART→ GA	MI→ ENN	MI→ CNN	MI→ GA	GA→ ENN	GA→ CNN	GA→ GA	ENN→ CART	ENN→ MI	ENN→ GA	CNN→ CART	CNN→ MI	CNN→ GA	GA→ CART	GA→ MI	GA→ GA
Connectionist Bench	0.236	0.404	0.649	0.212	0.414	0.683	0.183	0.404	0.639	0.767	0.450	0.500	0.833	0.433	0.483	0.917	0.842	0.667
Libras Movement	-	-	0.683	0.575	-	0.675	0.603	-	0.667	0.722	0.378	-	0.822	0.200	-	0.578	0.300	-
Hepatitis C Virus for Egyptian patients		0.569	0.693	-	0.560	0.695	-	0.581	0.694	-	-	-	0.607	0.464	0.643	0.607	0.393	0.679
OnlineNewsPopularity	0.853	0.944	0.683	0.864	0.943	0.683	0.183	0.943	0.639	0.932	0.322	0.492	0.763	0.407	-	0.917	0.417	0.667
Body signal of smoking	0.615	0.545	0.687	0.351	0.547	0.685	0.343	0.548	0.682	0.885	0.269	0.577	0.538	0.539	0.346	0.692	0.423	0.423
darwin	0.310	0.351	0.672	0.391	0.276	0.661	0.483	0.253	0.655	0.993	0.467	0.453	0.991	0.440	0.496	0.996	0.469	0.487
Drug induced Autoimmunity Prediction	0.429	0.571	0.682	0.459	0.571	0.663	0.427	0.571	0.688	0.827	0.505	0.546	0.821	0.469	0.542	0.888	0.424	0.485
Hill-Valley	0.498	0.434	0.713	0.495	0.424	0.693	0.497	0.429	0.711	0.970	0.500	-	0.700	0.250	0.556	0.690	0.580	0.590
pd speech features	0.370	0.650	0.691	0.495	0.542	0.673	0.451	0.545	0.694	0.987	0.399	0.488	0.979	0.447	0.475	0.991	0.464	0.481
madelon	0.303	0.444	0.669	0.385	0.438	0.672	0.379	0.441	0.675	0.880	0.512	0.534	0.802	0.482	0.470	0.890	0.808	0.518
colon	-	-	0.678	0.387	0.532	0.661	0.387	0.516	0.800	1.000	0.496	0.485	1.000	0.457	0.495	1.000	0.435	-
GLIOMA	-	-	-	0.592	-	-	0.633	-	-	1.000	0.422	-	-	-	-	-	-	-
DLBCL	0.195	0.662	0.636	0.234	0.636	0.675	0.312	0.585	0.688	0.999	0.439	0.501	1.000	0.450	0.498	1.000	0.474	0.503
toxicity	0.579	0.415	0.702	0.597	0.392	0.713	0.585	0.404	0.702	0.999	0.438	0.493	0.996	0.369	0.487	0.998	0.492	0.516
TOX 171	-	0.573	0.637	0.649	0.532	0.684	0.686	0.520	0.579	0.999	0.420	-	0.999	0.473	0.496	1.000	0.471	0.495
GLI 85	0.214	0.607	0.643	0.298	0.619	0.703	0.298	0.619	0.655	1.000	0.463	0.502	1.000	0.452	-	1.000	0.486	0.500
CLL SUB 111	0.649	0.694	0.685	0.784	0.838	0.649	0.784	0.847	0.658	1.000	0.455	-	1.000	0.441	-	1.000	0.473	-
GLA BRA 180	-	0.687	0.620	-	0.805	0.698	-	0.805	0.643	-	-	-	1.000	0.412	-	1.000	0.449	0.502
SMK CAN 187	0.387	0.280	0.710	0.452	0.290	0.393	0.452	0.285	0.694	1.000	0.480	0.500	1.000	0.492	0.501	1.000	0.452	0.498
arcene	0.165	0.405	0.675	0.240	0.510	0.680	0.250	0.515	0.660	1.000	0.444	0.502	-	0.512	-	1.000	0.490	0.512
平均	0.423	0.547	0.674	0.470	0.550	0.666	0.435	0.547	0.676	0.939	0.434	0.505	0.892	0.431	0.498	0.908	0.490	0.532

附錄二、實驗二詳細數據

附表 22 最佳特徵選取方法結合重採樣之序列式混合方法 AUC 表現

Dataset	分類器	先進行 CART、MI 與 GA 的多重交集方法，再進行重採樣			先進行重採樣方法，再進行 CART、MI 與 GA 的多重交集		
		Cluster Centroids	SMOTE	SMOTEENN	Cluster Centroids	SMOTE	SMOTEENN
OnlineNewsPopularity	RF	0.916	0.949	0.899	0.921	0.949	0.899
	XGBoost	0.930	0.960	0.911	0.935	0.961	0.909
	SVM	0.767	0.771	0.748	0.763	0.774	0.745
Drug_induced_Autoimmunity_Prediction	RF	0.772	0.883	0.860	0.652	0.888	0.823
	XGBoost	0.794	0.898	0.873	0.666	0.889	0.819
	SVM	0.767	0.815	0.775	0.498	0.528	0.508
pd_speech_features	RF	0.880	0.956	0.872	0.870	0.958	0.881
	XGBoost	0.892	0.965	0.891	0.886	0.968	0.893
	SVM	0.677	0.699	0.679	0.674	0.700	0.676
colon	RF	0.894	0.930	0.926	0.894	0.910	0.885
	XGBoost	0.854	0.896	0.906	0.835	0.854	0.845
	SVM	0.923	0.918	0.904	0.901	0.923	0.866
GLIOMA	RF	0.956	0.949	0.914	0.930	0.944	-
	XGBoost	0.767	0.938	0.816	0.800	0.890	-
	SVM	0.948	0.985	0.899	0.945	0.980	-
DLBCL	RF	0.975	0.979	0.979	0.977	0.988	0.988
	XGBoost	0.881	0.988	0.988	0.875	0.979	0.979
	SVM	1.000	1.000	1.000	0.982	0.995	1.000
toxicity	RF	0.523	0.543	0.512	0.528	0.546	0.468
	XGBoost	0.594	0.554	0.538	0.615	0.547	0.500
	SVM	0.527	0.542	0.517	0.531	0.511	0.487
GLI_85	RF	0.936	0.958	0.928	0.933	0.947	0.922
	XGBoost	0.892	0.907	0.927	0.900	0.890	0.868
	SVM	0.949	0.962	0.931	0.963	0.955	0.918
CLL_S_UB_111	RF	0.864	0.891	0.793	0.825	0.821	0.732
	XGBoost	0.859	0.870	0.800	0.859	0.869	0.754
	SVM	0.608	0.782	0.594	0.618	0.812	0.617
GLA_BRA_180	RF	0.877	0.890	0.845	0.885	0.892	0.856
	XGBoost	0.811	0.878	0.846	0.860	0.890	0.823
	SVM	0.863	0.885	0.853	0.859	0.878	0.861

附表 23 最佳特徵選取方法結合重採樣之序列式混合方法 F1-score 表現

Dataset	分類器	先進行 CART、MI 與 GA 的多重交集方法，再進行重採樣			先進行重採樣方法，再進行 CART、MI 與 GA 的多重交集		
		Cluster Centroids	SMOTE	SMOTEENN	Cluster Centroids	SMOTE	SMOTEENN
OnlineNewsPopularity	RF	0.580	0.689	0.406	0.601	0.692	0.408
	XGBoost	0.614	0.726	0.463	0.638	0.731	0.455
	SVM	0.311	0.323	0.231	0.337	0.332	0.232
Drug_induced_Autoimmunity_Prediction	RF	0.581	0.857	0.830	0.480	0.853	0.759
	XGBoost	0.580	0.860	0.829	0.469	0.856	0.770
	SVM	0.692	0.803	0.773	0.117	0.531	0.644
pd_speech_features	RF	0.708	0.900	0.721	0.711	0.913	0.721
	XGBoost	0.730	0.915	0.764	0.764	0.920	0.763
	SVM	0.712	0.718	0.346	0.696	0.718	0.341
colon	RF	0.820	0.833	0.776	0.787	0.850	0.779
	XGBoost	0.754	0.782	0.767	0.772	0.739	0.814
	SVM	0.834	0.833	0.808	0.804	0.818	0.808
GLIOMA	RF	0.813	0.821	0.532	0.787	0.802	-
	XGBoost	0.440	0.707	0.490	0.577	0.703	-
	SVM	0.816	0.840	0.731	0.840	0.822	-
DLBCL	RF	0.856	0.932	0.932	0.880	0.948	0.934
	XGBoost	0.818	0.909	0.909	0.766	0.919	0.921
	SVM	0.940	0.952	0.952	0.914	0.962	0.962
toxicity	RF	0.511	0.555	0.559	0.513	0.590	0.526
	XGBoost	0.548	0.591	0.556	0.561	0.588	0.541
	SVM	0.209	0.556	0.541	0.229	0.556	0.538
GLI_85	RF	0.872	0.914	0.785	0.847	0.865	0.774
	XGBoost	0.765	0.880	0.804	0.827	0.795	0.766
	SVM	0.884	0.918	0.758	0.917	0.879	0.800
CLL_S UB_111	RF	0.808	0.829	0.616	0.715	0.740	0.586
	XGBoost	0.729	0.769	0.555	0.775	0.789	0.544
	SVM	0.480	0.671	0.430	0.459	0.685	0.491
GLA_BRA_180	RF	0.688	0.698	0.639	0.665	0.725	0.641
	XGBoost	0.616	0.677	0.635	0.665	0.720	0.564
	SVM	0.668	0.704	0.503	0.679	0.704	0.578

附表 24 最佳樣本選取方法結合重採樣之序列式混合方法 AUC 表現

Dataset	分類器	先進行 ENN U GA 樣本選取方法，再進行重採樣			先進行重採樣方法，再進行 ENN U GA 樣本選取方法		
		Cluster Centroids	SMOTE	SMOTEENN	Cluster Centroids	SMOTE	SMOTEENN
OnlineNewsPopularity	RF	0.917	0.818	0.901	0.895	0.934	0.890
	XGBoost	0.939	0.824	0.918	0.924	0.955	0.909
	SVM	0.768	0.739	0.767	0.767	0.771	0.751
Drug_induced_Autoimmunity_Prediction	RF	0.709	0.869	0.812	0.629	0.869	0.827
	XGBoost	0.730	0.871	0.795	0.667	0.854	0.816
	SVM	0.509	0.526	0.507	0.504	0.511	0.503
pd_speech_features	RF	0.923	0.924	0.848	0.883	0.945	0.863
	XGBoost	0.924	0.936	0.880	0.887	0.955	0.888
	SVM	0.697	0.696	0.693	0.497	0.686	0.677
colon	RF	0.891	0.885	0.838	0.868	0.918	0.889
	XGBoost	0.885	0.886	0.774	0.825	0.891	0.878
	SVM	0.898	0.898	0.853	0.844	0.903	0.884
GLIOMA	RF	-	-	-	1.000	0.958	0.940
	XGBoost	-	-	-	0.756	0.910	0.937
	SVM	-	-	-	0.650	0.965	0.893
DLBCL	RF	0.951	0.979	0.979	0.967	0.983	0.983
	XGBoost	0.868	0.979	0.979	0.784	0.969	0.975
	SVM	1.000	1.000	1.000	1.000	1.000	1.000
toxicity	RF	0.649	0.596	0.577	0.582	0.542	0.480
	XGBoost	0.590	0.595	0.593	0.605	0.534	0.500
	SVM	0.511	0.482	0.504	0.546	0.513	0.464
GLI_85	RF	0.915	0.936	0.915	0.943	0.924	0.939
	XGBoost	0.913	0.898	0.847	0.892	0.911	0.888
	SVM	0.936	0.943	0.925	0.963	0.946	0.922
CLL_S UB_111	RF	0.771	0.825	0.647	0.924	0.854	0.721
	XGBoost	0.734	0.847	0.678	0.670	0.859	0.760
	SVM	0.612	0.774	0.578	0.582	0.760	0.583
GLA_BRA_180	RF	-	-	-	0.910	0.895	0.854
	XGBoost	-	-	-	0.810	0.886	0.813
	SVM	-	-	-	0.862	0.878	0.857

附表 25 最佳樣本選取方法結合重採樣之序列式混合方法 F1-score 表現

Dataset	分類器	先進行 ENN U CNN U GA 樣本選取方法，再進行重採樣			先進行重採樣方法，再進行 ENN U CNN U GA 樣本選取方法		
		Cluster Centroids	SMOTE	SMOTEENN	Cluster Centroids	SMOTE	SMOTEENN
OnlineNewsPopularity	RF	0.591	0.614	0.439	0.531	0.619	0.386
	XGBoost	0.646	0.660	0.550	0.605	0.699	0.459
	SVM	0.327	0.331	0.294	0.311	0.296	0.245
Drug_induced_Autoimmunity_Prediction	RF	0.553	0.854	0.741	0.488	0.845	0.758
	XGBoost	0.528	0.856	0.747	0.497	0.838	0.770
	SVM	0.211	0.531	0.644	0.644	0.643	0.644
pd_speech_features	RF	0.739	0.885	0.697	0.697	0.885	0.722
	XGBoost	0.768	0.893	0.739	0.721	0.902	0.758
	SVM	0.720	0.722	0.596	0.679	0.666	0.453
colon	RF	0.782	0.836	0.748	0.806	0.831	0.770
	XGBoost	0.691	0.725	0.677	0.748	0.785	0.732
	SVM	0.757	0.821	0.660	0.806	0.864	0.689
GLIOMA	RF	-	-	-	0.624	0.735	0.526
	XGBoost	-	-	-	0.444	0.717	0.776
	SVM	-	-	-	0.824	0.840	0.532
DLBCL	RF	0.867	0.934	0.945	0.878	0.918	0.918
	XGBoost	0.817	0.870	0.857	0.744	0.890	0.851
	SVM	0.929	0.934	0.934	0.922	0.946	0.946
toxicity	RF	0.498	0.554	0.526	0.525	0.564	0.544
	XGBoost	0.552	0.517	0.556	0.572	0.573	0.541
	SVM	0.209	0.464	0.541	0.483	0.578	0.535
GLI_85	RF	0.859	0.835	0.778	0.847	0.879	0.732
	XGBoost	0.746	0.845	0.813	0.836	0.843	0.742
	SVM	0.858	0.844	0.812	0.881	0.891	0.800
CLL_S_UB_111	RF	0.640	0.687	0.323	0.637	0.801	0.633
	XGBoost	0.657	0.696	0.385	0.600	0.809	0.560
	SVM	0.416	0.691	0.133	0.448	0.691	0.524
GLA_BRA_180	RF	-	-	-	0.625	0.709	0.634
	XGBoost	-	-	-	0.591	0.676	0.574
	SVM	-	-	-	0.609	0.656	0.528

附表 26 最佳序列式混合方法(FS → IS)結合重採樣之序列式混合方法 AUC 表現

Dataset	分類器	先進行 CART、MI 與 GA 的多重交集方法，再進行重採樣			先進行重採樣方法，再進行 CART、MI 與 GA 的多重交集		
		Cluster Centroids	SMOTE	SMOTEENN	Cluster Centroids	SMOTE	SMOTEENN
OnlineNewsPopularity	RF	0.879	0.870	0.865	0.798	0.872	0.819
	XGBoost	0.877	0.882	0.882	0.797	0.902	0.869
	SVM	0.745	0.755	0.754	0.726	0.743	0.735
Drug_induced_Autoimmunity_Prediction	RF	0.851	0.861	0.817	0.555	0.842	0.806
	XGBoost	0.853	0.849	0.817	0.587	0.839	0.778
	SVM	0.799	0.804	0.764	0.506	0.688	0.512
pd_speech_features	RF	0.889	0.905	0.882	0.842	0.921	0.873
	XGBoost	0.897	0.911	0.878	0.815	0.930	0.849
	SVM	0.773	0.776	0.769	0.657	0.662	0.738
colon	RF	-	-	-	0.966	-	0.823
	XGBoost	-	-	-	0.930	-	0.823
	SVM	-	-	-	0.950	-	0.823
GLIOMA	RF	-	-	-	-	0.893	-
	XGBoost	-	-	-	-	0.871	-
	SVM	-	-	-	-	0.923	-
DLBCL	RF	0.898	0.908	0.911	0.952	0.992	0.992
	XGBoost	0.927	0.927	0.891	0.843	0.952	0.952
	SVM	0.978	0.978	0.978	0.930	0.978	0.978
toxicity	RF	0.627	0.636	0.627	0.589	0.540	0.451
	XGBoost	0.662	0.643	0.666	0.563	0.563	0.530
	SVM	0.613	0.630	0.635	0.500	0.657	0.451
GLI_85	RF	0.887	0.875	0.627	0.847	0.877	0.868
	XGBoost	0.864	0.877	0.867	0.822	0.852	0.854
	SVM	0.912	0.916	0.916	0.906	0.922	0.884
CLL_S UB_111	RF	0.866	0.859	0.778	0.792	0.848	-
	XGBoost	0.835	0.862	0.757	0.742	0.844	-
	SVM	0.849	0.853	0.659	0.799	0.854	-
GLA_BRA_180	RF	-	-	-	-	0.901	0.694
	XGBoost	-	-	-	-	0.904	0.702
	SVM	-	-	-	-	0.877	0.709

附表 27 最佳序列式混合方法(FS → IS)結合重採樣之序列式混合方法 F1-score 表現

Dataset	分類器	先進行 CART、MI 與 GA 的多重交集方法，再進行重採樣			先進行重採樣方法，再進行 CART、MI 與 GA 的多重交集		
		Cluster Centroids	SMOTE	SMOTEENN	Cluster Centroids	SMOTE	SMOTEENN
OnlineNewsPopularity	RF	0.539	0.649	0.376	0.588	0.663	0.389
	XGBoost	0.575	0.677	0.400	0.612	0.705	0.433
	SVM	0.309	0.319	0.232	0.328	0.329	0.232
Drug_induced_Autoimmunity_Prediction	RF	0.458	0.796	0.780	0.503	0.849	0.750
	XGBoost	0.534	0.777	0.796	0.477	0.833	0.774
	SVM	0.638	0.748	0.768	0.475	0.330	0.644
pd_speech_features	RF	0.685	0.845	0.614	0.716	0.900	0.653
	XGBoost	0.695	0.836	0.608	0.723	0.884	0.696
	SVM	0.679	0.719	0.103	0.700	0.723	0.103
colon	RF	0.678	0.760	0.578	0.714	0.873	0.826
	XGBoost	0.587	0.632	0.592	0.751	0.741	0.852
	SVM	0.579	0.736	0.585	0.807	0.849	0.663
GLIOMA	RF	-	-	-	0.583	0.791	-
	XGBoost	-	-	-	0.499	0.655	-
	SVM	-	-	-	0.711	0.845	-
DLBCL	RF	0.831	0.846	0.846	0.938	0.944	1.000
	XGBoost	0.643	0.772	0.772	0.866	0.913	0.901
	SVM	0.892	0.983	0.983	0.934	1.000	0.961
toxicity	RF	0.606	0.653	0.543	0.670	0.746	0.561
	XGBoost	0.549	0.580	0.541	0.585	0.648	0.580
	SVM	0.561	0.557	0.555	0.400	0.516	0.570
GLI_85	RF	0.800	0.791	0.364	0.900	0.890	0.692
	XGBoost	0.775	0.762	0.288	0.731	0.797	0.755
	SVM	0.756	0.836	0.137	0.926	0.858	0.800
CLL_S UB_111	RF	0.708	0.761	0.402	0.754	0.832	0.539
	XGBoost	0.571	0.750	0.388	0.586	0.710	0.408
	SVM	0.517	0.702	0.181	0.502	0.707	0.531
GLA_BRA_180	RF	0.610	0.691	0.471	0.709	0.733	0.623
	XGBoost	0.453	0.577	0.370	0.569	0.679	0.566
	SVM	0.667	0.694	0.292	0.618	0.704	0.619

附表 28 最佳序列式混合方法(IS → FS)結合重採樣之序列式混合方法 AUC 表現

Dataset	分類器	先進行 CART、MI 與 GA 的多重交集方法，再進行重採樣			先進行重採樣方法，再進行 CART、MI 與 GA 的多重交集		
		Cluster Centroids	SMOTE	SMOTEENN	Cluster Centroids	SMOTE	SMOTEENN
OnlineNewsPopularity	RF	0.898	0.935	0.878	0.908	0.938	0.892
	XGBoost	0.910	0.944	0.885	0.922	0.952	0.903
	SVM	0.763	0.768	0.740	0.763	0.769	0.743
Drug_induced_Autoimmunity_Prediction	RF	0.693	0.752	0.718	0.671	0.884	0.844
	XGBoost	0.643	0.705	0.686	0.672	0.847	0.803
	SVM	0.599	0.622	0.612	0.543	0.571	0.527
pd_speech_features	RF	0.820	0.922	0.881	0.878	0.946	0.896
	XGBoost	0.815	0.907	0.863	0.873	0.938	0.897
	SVM	0.494	0.701	0.654	0.673	0.701	0.667
colon	RF	-	-	-	0.955	0.951	0.961
	XGBoost	-	-	-	0.853	0.930	0.839
	SVM	-	-	-	0.801	0.926	0.863
GLIOMA	RF	-	-	-	0.965	0.984	0.938
	XGBoost	-	-	-	0.706	0.867	0.709
	SVM	-	-	-	0.649	0.895	0.669
DLBCL	RF	0.985	0.975	0.975	0.988	1.000	1.000
	XGBoost	0.702	0.831	0.831	0.781	0.969	0.982
	SVM	1.000	0.982	0.982	0.996	0.996	0.991
toxicity	RF	0.614	0.627	0.598	0.755	0.717	0.676
	XGBoost	0.570	0.606	0.538	0.709	0.728	0.634
	SVM	0.521	0.545	0.472	0.536	0.532	0.520
GLI_85	RF	0.902	0.936	0.901	0.936	0.977	0.924
	XGBoost	0.733	0.747	0.719	0.763	0.887	0.823
	SVM	0.905	0.908	0.874	0.946	0.943	0.938
CLL_S UB_111	RF	-	-	-	0.811	0.878	0.762
	XGBoost	-	-	-	0.739	0.874	0.716
	SVM	-	-	-	0.575	0.741	0.606
GLA_BRA_180	RF	0.870	0.882	0.842	0.873	0.902	0.864
	XGBoost	0.755	0.852	0.783	0.835	0.890	0.826
	SVM	0.849	0.873	0.850	0.864	0.887	0.861

附表 29 最佳序列式混合方法(IS → FS)結合重採樣之序列式混合方法 F1-score 表現

Dataset	分類器	先進行 CART、MI 與 GA 的多重交集方法，再進行重採樣			先進行重採樣方法，再進行 CART、MI 與 GA 的多重交集		
		Cluster Centroids	SMOTE	SMOTEENN	Cluster Centroids	SMOTE	SMOTEENN
OnlineNewsPopularity	RF	0.529	0.645	0.381	0.558	0.653	0.388
	XGBoost	0.543	0.671	0.401	0.590	0.697	0.436
	SVM	0.310	0.317	0.245	0.311	0.337	0.244
Drug_induced_Autoimmunity_Prediction	RF	0.548	0.768	0.749	0.439	0.833	0.746
	XGBoost	0.550	0.735	0.756	0.414	0.803	0.798
	SVM	0.587	0.658	0.695	0.362	0.569	0.645
pd_speech_features	RF	0.711	0.853	0.691	0.725	0.881	0.645
	XGBoost	0.715	0.855	0.716	0.759	0.886	0.724
	SVM	0.526	0.711	0.146	0.698	0.721	0.133
colon	RF	-	-	-	0.813	0.866	0.846
	XGBoost	-	-	-	0.762	0.768	0.793
	SVM	-	-	-	0.816	0.826	0.681
GLIOMA	RF	-	-	-	0.744	0.798	0.473
	XGBoost	-	-	-	0.576	0.634	0.376
	SVM	-	-	-	0.824	0.908	0.601
DLBCL	RF	0.854	0.848	0.848	0.806	0.963	0.925
	XGBoost	0.684	0.762	0.762	0.793	0.936	0.944
	SVM	0.964	0.950	0.950	0.818	0.902	0.958
toxicity	RF	0.588	0.619	0.567	0.637	0.700	0.676
	XGBoost	0.533	0.611	0.556	0.614	0.663	0.581
	SVM	0.216	0.295	0.541	0.264	0.449	0.538
GLI_85	RF	0.834	0.878	0.701	0.843	0.902	0.719
	XGBoost	0.737	0.770	0.628	0.791	0.799	0.776
	SVM	0.789	0.854	0.753	0.893	0.861	0.763
CLL_S UB_111	RF	-	-	-	0.711	0.800	0.524
	XGBoost	-	-	-	0.580	0.796	0.486
	SVM	-	-	-	0.412	0.625	0.476
GLA_BRA_180	RF	0.678	0.699	0.678	0.661	0.722	0.596
	XGBoost	0.523	0.638	0.475	0.538	0.696	0.619
	SVM	0.680	0.694	0.753	0.615	0.711	0.611